ВСТУПНІ МАТЕРІАЛИ

Відомості для титульного аркуша

Затверджена тема українською мовою: «Системний аналіз та інтелектуальні технології консистентного моделювання процесів ієрархічної генерації відеоданих».

Назва англійською мовою: *Systems Analysis and Intelligent Technologies for Consistent Modelling of Hierarchical Video-Data Generation Processes*.

Здобувач: Леонід Русланович Кулик.

Галузь знань: 12 Інформаційні технології.

Спеціальність: 124 Системний аналіз.

Науковий керівник: Олександр Борисович Мокін, доктор технічних наук, професор.

Установа: Вінницький національний технічний університет, м. Вінниця, 2026.

УДК: 004.054:[004.032.26+004.85] **[ДАНІ ВІД АВТОРА: перевірити класифікацію та всі поля титульного аркуша за затвердженими документами установи.]**

Українська анотація

Кулик Л. Р. *Системний аналіз та інтелектуальні технології консистентного моделювання процесів ієрархічної генерації відеоданих*. Кваліфікаційна наукова праця на правах рукопису, подана на здобуття ступеня доктора філософії за спеціальністю 124 «Системний аналіз» галузі знань 12 «Інформаційні технології». Вінницький національний технічний університет, Вінниця, 2026.

Дисертацію присвячено довгогоризонтному прогнозуванню відео як системній задачі з обмеженими ресурсами. Її центральна проблема полягає у збереженні релевантного стану та об’єктної траєкторії тоді, коли безпосереднє спостереження вже залишило поле огляду або коротке контекстне вікно. Зі збільшенням горизонту модель повинна не лише формувати правдоподібні наступні кадри, а й зберігати інформацію про об’єкти, їхню ідентичність,

траєкторії та ділянки сцени, які тимчасово зникають із поля спостереження. Цьому заважають три пов’язані обмеження: місткість збереженого контексту, пам’ять активацій довгого навчального ланцюга та рівномірний розподіл просторової ємності між ділянками різної інформаційної складності. Ці витрати часто узагальнюють терміном «пам’ять», хоча вони виникають у різних частинах системи, масштабуються за різними змінними й потребують різних втручань.

Мета дисертаційної роботи полягає у підвищенні значущої для задачі консистентності та ресурсної ефективності довгогоризонтного ієрархічного прогнозування відео шляхом системного аналізу й перевірки механізмів збереження віддаленої історії, часового навчання, просторового представлення та оцінювання результатів. Основним архітектурним предметом є ієрархічний контекст; інші механізми розглянуто як засоби усунення обмежень його масштабування.

Центральною архітектурною задачею роботи є збереження релевантної історії, коли щільне вікно детальних кадрів обмежене. Ієрархічне пакетування досліджено як спосіб збільшити часову досяжність контексту без пропорційного зростання кількості детальних токенів. TempVerseFormer і V-BLT розв’язують суміжні обмеження: перший метод зменшує потребу в збереженні активацій під час навчання, другий реалізує локально–глобальну ієрархію та надає сигнал локальної прогнозної складності. Опубліковані результати цих методів і центральне порівняння пакетів отримано окремо, щоб не змішувати причинні ефекти. Після завершення основної програми додатково виконано обмежену інтеграційну перевірку, у якій стан зі сталими грубими й детальними областями, однопрохідний часовий перехід і реверсивне розгортання працюють в одному прототипі.

Зміст роботи. У вступі обґрунтовано актуальність теми, сформульовано мету й шість завдань дослідження, визначено об’єкт, предмет і методи, подано наукову новизну, практичне значення, відомості про достовірність результатів та особистий внесок здобувача. Довгогоризонтне прогнозування розглянуто як частково спостережуваний динамічний процес, у якому просторове

представлення, контекст застосування й пам’ять навчальних активацій утворюють різні ресурсні контури.

У першому розділі виконано системний аналіз консистентного прогнозування відео. Критерії зовнішнього вигляду, ідентичності, геометрії, семантичного змісту, часової неперервності, правильності траєкторії та міжрівневої консистентності розглянуто як взаємопов’язані, але не взаємозамінні. Проаналізовано дифузійні, авторегресійні, енергетичні й трансформерні підходи, способи керування консистентністю та методи довготривалого доступу до історії. Часткова спостережуваність приводить до дефіциту досяжності; ієрархічний контекст збільшує доступний проміжок, але створює ціну втраченої деталізації. Для перевірки цього причинного ланцюга сформульовано вимоги до явного обліку бюджету, геометрії часових прив’язок, доступної інформації, експериментальної популяції та показника, який відповідає заявленому механізму.

У другому розділі досліджено два окремо перевірені засоби усунення обмежень масштабування ієрархічної системи. Перший стосується реверсивного часового обчислення в TempVerseFormer. Точне відновлення заявляється для збережуваного подвоєного стану трансформера, тоді як кодування, проєкції, злиття, декодування та функція втрат залишаються поза межею реверсивності. У задачі контрольованого обертання пам’ять часової моделі становить близько 0,89 ГБ для одного, чотирьох і шістнадцяти кроків; зіставлені нереверсивні варіанти на шістнадцяти кроках потребують близько 2,60–2,61 ГБ. Опублікований профіль для довших горизонтів залишається близьким до 1 ГБ до 1024 кроків, але реверсивне відтворення має обчислювальну ціну й не гарантує кращої якості прогнозу.

Другий метод реалізовано у Vision Byte Latent Transformer. V-BLT виконує локально–глобально–локальну обробку байтів каналів растрових пікселів, використовує N-вимірне ротаційне позиційне кодування для збереження часових і просторових координат після лінеаризації та прогнозує категоріальний розподіл за 256 значеннями кожного байта. Така локально–глобальна побудова

обґрунтовує ієрархічне стиснення одиниць, що надходять до глобальної моделі. Перевірка концепції з фіксованими просторово-часовими блоками розміром 4 × 4 × 4 продемонструвала нижчу обчислювальну складність у GFLOPs, ніж наведені конфігурації ViViT і UNet-3D, а також сприятливі, хоча не завжди найкращі, показники на процедурних відео обертових двовимірних фігур і тривимірних полікубів. Прогнозна ентропія формує просторову карту складності й мотивує нерівномірний розподіл детальної ємності. Динамічна зміна розміру ділянок або розподілу обчислень за цією картою в завершених експериментах V-BLT не перевірялася.

У третьому розділі розроблено дворівневу модель ієрархічного контексту для довгогоризонтного прогнозування відео. Заморожений кодек прихованого простору утворює грубий і детальний просторові потоки, які обробляє один дифузійний предиктор зі спільною увагою. Пакет контексту формалізовано через рівень представлення, часовий крок, кількість кадрів і геометрію прив’язки. Окремо враховано токени контексту, цілі, корисного навантаження та повної послідовності. Для авторегресивного застосування визначено оновлення грубого й детального кільцевих буферів. У центральному порівнянні пакетів TempVerseFormer, V-BLT і RoPE-ND навмисно не змінюють цей предиктор, щоб ефект контексту залишався інтерпретованим. Наприкінці розділу предиктор зі сталими ділянками відокремлено від OpenSTL-сумісної архітектури з адаптивним пакуванням з фізичним грубо-детальним пакуванням, сталою квотою, координатним кодуванням, маршрутизацією та реверсивністю лише всередині Transformer-ядра.

У четвертому розділі наведено експериментальну перевірку розроблених методів і меж їх застосовності. Тороїдальний тест повторного входу (Toroidal Re-entry Benchmark, TRB; внутрішня назва LoopMom) забезпечує точне аналітичне визначення моментів, коли потрібна ділянка сцени була видимою та чи входить вона до досяжності конкретного пакета. Оцінювання охоплює показники кадру й переднього плану, пропущений і зайвий передній план, зіставлення об’єктів зі збереженою ідентичністю, покриття, неперервність

траєкторії, парні ефекти на рівні кліпів і одночасні інтервали для сімейств порівнянь. Під час статистичного оцінювання залежність між кадрами одного кліпу зберігається, а повторні навчання розглянуто як окреме джерело невизначеності. Дані розроблення відокремлено від відкладеної підтверджувальної вибірки, вибірок із заздалегідь визначеним призначенням і захищених контрольних вибірок. Негативні результати також включено до підсумкового доказового запису. Для розширеної TRB-матриці окремо встановлено спільну тривалість навчання 30 000 кроків; попередню перевірку технічної здійсненності сумісної архітектури наведено без зміни замороженої межі «досяжність–точність відтворення».

У загальних висновках результати зіставлено із шістьма завданнями дослідження та сформульовано правило вибору методу за обмежувальним ресурсом. Ієрархічне пакування доцільне, коли бракує досяжності минулого; щільний детальний контекст потрібний, коли визначальною є точність відтворення; реверсивне відтворення або контрольні точки активацій застосовують, коли навчання обмежує пам’ять. Основні причинні ефекти цих втручань виміряно окремо. Додатковий прототип показує їхню часткову технічну сумісність, але не перетворює економію різних складників пам’яті на автоматично мультиплікативний виграш.

Основні наукові та практичні результати полягають у такому:

Центральний емпіричний результат стосується не загальної переваги ієрархічної архітектури, а визначеної області її доцільності. Коли зіставлене за бюджетом щільне вікно не охоплює релевантного минулого, грубий довгий потік забезпечує доступ до давнішньої історії. Після насичення часової досяжності перевага може перейти до детального плоского контексту.

1. Запропоновано системну декомпозицію довгогоризонтного відеопредиктора за трьома ресурсами: просторовою ємністю представлення, доступним під час застосування контекстом та пам’яттю активацій під час навчання. Для кожного ресурсу визначено окремий інтерфейс втручання й межу відповідного твердження.

2. Уточнено критерії консистентності для самоподаваного прогнозування відео та пов’язано їх з окремими спостережуваними відмовами: втратою об’єкта, появою зайвого переднього плану, підміною ідентичності, помилкою траєкторії та суперечністю між рівнями представлення.
3. Розроблено й перевірено реверсивний часовий блок із явним контрактом відновлюваного стану. Вимірювання підтвердили його доцільність у режимі, де пам’ять активацій є обмежувальним ресурсом, і водночас показали необхідність враховувати додаткові обчислення.
4. Розроблено ієрархічне байтове представлення V-BLT з RoPE-ND та прогнозною ентропією як внутрішнім показником просторової складності. Експериментально підтверджено працездатність фіксованого пакетування; адаптивне керування регіонами залишено поза межами доведених результатів.
5. Розроблено модель і протокол зіставлення ієрархічних і плоских пакетів контексту за явного токенного бюджету. На відкладеній множині випадків, у яких пакети відрізняються за часовою досяжністю, ієрархічний контекст покращив зареєстрований показник на 0,0980 і 0,0914 для двох незалежних навчань, коли зіставлене плоске вікно не містило потрібної історії.
6. На одночасно проаналізованій межі компромісу перевагу ієрархії підтверджено за 896 і 1152 токенів контексту; результат за 1792 токенів залишився невирішеним; перевагу детального плоского контексту підтверджено за 2432 і 3072 токенів. Пакети з 48 грубих кадрів і шести або двох детальних кадрів забезпечують номінально ту саму 48-кадрову досяжність за 1152 або 896 токенів, що у 2,67 та 3,43 раза менше, ніж 48 детальних кадрів.
7. Дослідження робастності зберегли основні напрями ефектів за альтернативного розподілу обчислень алгоритму вибірки й незалежно навченого кодека. Пізня інверсія із самоподаваного дослідження не відтворилася, тому її не включено до підтверджених висновків. На захищеному довгому Moving-MNIST напрям ефектів просторового

покриття й неперервності сприяв ієрархії для всіх трьох ініціалізацій, але одночасні інтервали не перетинали нуль лише для ініціалізацій 0 і 2. Перевагу плоского детального контексту за ідентичністю підтверджено для всіх трьох ініціалізацій.

8. У додатковій перевірці технічної здійсненності реалізовано стан сталої ширини з 24 токенами та 384 скалярними значеннями на кадр, що у 10,67 раза менше за необроблений кадр 64×64 за однакової точності зберігання. На повних 10 000 кліпах Moving-MNIST модель отримала MSE 28,7175: краще за наведені ConvLSTM-S та E3D-LSTM, але гірше за вихідний SimVP-gSTA і TAU. На горизонті 40 прогнозованих кадрів другопорядкова реверсивна оболонка використала 550,86 МБ проти 1418,79 МБ у BPTT-профілі. Після першого переходу режими мали різну зовнішню динаміку, тому це інженерне відношення піків, а не причинний ефект реверсивності за тотожної прямої функції. Результат підтверджує технічну сумісність компонентів, але не загальне лідерство за якістю.

Наукова новизна дисертаційної роботи полягає в такому:

1. Удосконалено системне подання консистентності прогнозованого відео шляхом переходу від одного агрегованого показника до сукупності критеріїв, що охоплюють часову неперервність, правильність траєкторії, повторну появу об’єкта, хибний передній план та міжрівневу відповідність.
2. Набув подальшого розвитку метод реверсивного часового обчислення завдяки явному відокремленню відновлюваного стану від нереверсивних інтерфейсів та спільному аналізу алгебричного відновлення, пам’яті активацій і обчислювальної ціни.
3. Удосконалено ієрархічне представлення візуальних даних на рівні байтів каналів растрових пікселів шляхом використання локально–глобально–локальної обробки, RoPE-ND і прогнозної ентропії для оцінювання просторової складності без окремої голови невизначеності.

4. Вперше для розглянутих конфігурацій виконано контрольоване зіставлення ієрархічного та плоского відеоконтексту за бюджетом і досяжністю та встановлено умовну межу компромісу «досяжність–точність відтворення» з нижньою областю переваги ієрархії, невирішеною проміжною точкою і верхньою областю переваги детального плоского контексту.
5. Удосконалено методику оцінювання прогнозування, залежного від збереженої історії, через точну геометричну спостережуваність, окремі для кожної пари множини випадків із різницею досяжності, повні показники переднього плану, зіставлення об’єктів зі збереженою ідентичністю та статистичне оцінювання з повторною вибіркою на рівні кліпів.

Новизна має методологічний та емпіричний характер. У роботі не заявляється пріоритет щодо ієрархічних відеомоделей, реверсивних мереж або адаптивної токенізації як широких класів архітектур.

Перевірка зі сталими ділянками не виділяється як самостійний пункт центральної наукової новизни, оскільки виконана в режимі розроблення для однієї ініціалізації. Її роль полягає в демонстрації здійсненності системного синтезу та в установленні межі композиційного виграшу. Остаточну фізично упаковану архітектуру до завершення зіставних експериментів подано як реалізований і програмно перевірений метод, а не як доведену перевагу за якістю або пам’яттю GPU.

Окреслена межа новизни визначає й коло коректного застосування результатів. **Отримані результати є корисними для:** дослідників, які проєктують моделі прогнозування відео за обмеженого контексту або пам’яті; розробників експериментальних систем, яким потрібні відтворювані порівняння пакетів контексту; фахівців із процедурного синтезу даних для перевірки часової динаміки, просторової складності та пам’яті; навчальних курсів із системного аналізу, машинного навчання й генеративного моделювання; подальших робіт із довгими природними відео після окремої зовнішньої валідації. Застосування результатів у критичних для безпеки системах не перевірялося.

Практичне значення отриманих результатів полягає у створенні комплексу програмних засобів для відтворюваного дослідження відеопрогнозування. До нього належать репозиторій TempVerseFormer для реверсивного часового навчання; репозиторій visionBLT з V-BLT і RoPE-ND; набір інструментів simple-shape-dataset-toolbox для процедурного генерування відео двовимірних фігур і тривимірних полікубів; генератори TRB (LoopMom) і довгого Moving-MNIST з метаданими об’єктів, що зберігаються в часі; модулі підготовки конфігурацій, навчання, застосування, оцінювання, зіставлення експериментів та побудови таблиць і рисунків із заморожених артефактів. Інтеграційне розширення додає фізичне пакування стану, координатне кодування, маршрутизацію сталої квоти, внутрішньо реверсивне Transformer-ядро, конфігурації Moving MNIST/TaxiBJ та відновлюваний контролер OpenSTL-запусків. Реалізовано перевірку сумісності конфігурацій, авторизацію експериментів із забороною за замовчуванням, контентно-адресовані специфікації запусків і повний набір кадрових та об’єктних показників. Разом ці засоби реалізують повний цикл від контрольованого синтезу даних до перевірки твердження за замороженим артефактом, підтримуючи повторення експериментів, розроблення нових контрольованих наборів даних і навчальне використання.

Структуру ієрархії розглянуто через місткість, розподіл між рівнями, часову підтримку, просторову деталізацію та перекриття. Для адаптивного предиктора окремо визначено перевірки числової коректності, ресурсів і якості; комірки без вимірювань не входять до підтверджених висновків.

Ключові слова: системний аналіз; довгогоризонтне прогнозування відео; ієрархічний контекст; консистентність; межа досяжність–точність відтворення; реверсивні обчислення; пам’ять активацій; моделювання растрових байтів; прогнозна ентропія; дифузія у прихованому просторі; точна спостережуваність; статистичне оцінювання на рівні кліпів.

Англійський реферат

Kulyk L. R. *Systems Analysis and Intelligent Technologies for Consistent Modelling of Hierarchical Video-Data Generation Processes*. Qualifying scientific work submitted as a manuscript for the degree of Doctor of Philosophy in specialty 124 System Analysis, field 12 Information Technologies. Vinnytsia National Technical University, Vinnytsia, 2026.

The dissertation treats long-horizon video prediction as a resource-constrained systems problem. Its central problem is preserving task-relevant state and object trajectories after direct evidence has left the current observation or a short context window. Three related constraints limit this ability: retained-context capacity, activation storage along a long training chain, and uniform allocation of spatial capacity to regions with unequal predictive complexity. They arise at different system interfaces rather than forming one undifferentiated type of memory.

Aim. The dissertation aims to improve task-relevant consistency and resource efficiency in long-horizon hierarchical video prediction through systems analysis and validated interventions for retained history, temporal training, spatial representation, and evaluation. Hierarchical retained context is the main architectural subject; the other mechanisms address constraints that arise when it is scaled.

Structure and content. The Introduction justifies the topic, states the aim and six research tasks, and defines the object, subject, methods, novelty, practical significance, reliability, and the candidate's contribution. Chapter 1 models long-horizon prediction as a partially observed dynamic system. It separates appearance, identity, geometry, semantic content, temporal continuity, trajectory correctness, and cross-level agreement, and derives requirements for causal, resource-accounted comparison.

Chapter 2 studies two separately validated methods that address constraints on scaling a hierarchy-centred system. TempVerseFormer applies reversible computation to a persistent doubled transformer state while keeping non-invertible encoding, projection, fusion, decoding, and loss interfaces outside the exact claim. On the reported controlled-rotation task, temporal-model memory remains about 0.89 GB at

one, four, and sixteen steps, compared with about 2.60–2.61 GB for matched non-reversible variants at sixteen steps. Vision Byte Latent Transformer applies local–global–local processing to raster pixel-channel bytes, uses RoPE-ND to preserve temporal and spatial coordinates, and estimates spatial predictive complexity through categorical entropy. The evaluated method uses fixed 4 × 4 × 4 packages; dynamic entropy-driven allocation was not tested.

Chapter 3 develops a two-level hierarchical retained-context model. A frozen latent codec supplies coarse and fine streams to one joint-attention diffusion predictor. Packages are defined by spatial level, temporal stride, frame count, and anchor geometry, with context, target, payload, and total-token costs accounted separately. TempVerseFormer, V-BLT, and RoPE-ND are intentionally absent from the central package comparison so that its causal interpretation remains intact. A separate method section distinguishes the earlier fixed-region prototype from the final OpenSTL-compatible design, which performs physical coarse/fine packing under a fixed quota, encodes centre, time, scale, and level, and applies reversibility only inside the Transformer core.

Chapter 4 validates the methods and their applicability boundaries. The purpose-built Toroidal Re-entry Benchmark (TRB; internal name LoopMom) provides exact geometric observability for memory-dependent events. Evaluation includes frame and foreground endpoints, missing and extra foreground, persistent-object assignment, identity, coverage, trajectory continuity, paired clip-level effects, and simultaneous maximum-statistic intervals. Statistical inference accounts for clustering by clips, while training seeds form a separate uncertainty level. Development, untouched, purpose-locked, and protected populations are kept distinct, and negative results remain in the final evidence record. A completed schedule calibration selects 30,000 steps for the expanded TRB matrix. The earlier feasibility study remains separate from the frozen reach–fidelity evidence.

The General Conclusions map the findings back to the six research tasks and state a binding-resource selection rule. Hierarchical packaging is appropriate when distant reach is missing; dense fine context is preferable when fidelity is limiting; and

reversible replay or activation checkpointing is relevant when training memory is the bottleneck. Their main causal effects were measured separately. A later prototype demonstrates partial technical composability without treating savings in different memory components as automatically multiplicative.

Main scientific and practical results. The dissertation establishes a three-constraint decomposition of one long-horizon problem; an explicit reversible-state contract; a raster-byte representation with RoPE-ND and entropy-based complexity estimation; and a matched-budget protocol for hierarchical versus flat context.

On the untouched reach-differential population, hierarchy improves the registered endpoint by 0.0980 and 0.0914 for two training seeds when the matched flat window cannot include the needed past. Across the simultaneous frontier, hierarchy is confirmed at 896 and 1,152 context tokens, 1,792 tokens remain unresolved, and fine-resolution flat context is confirmed at 2,432 and 3,072 tokens. Forty-eight coarse frames with six or two fine frames use 1,152 or 896 tokens, respectively, which is 2.67 and 3.43 times fewer than 48 fine frames. Robustness tests preserve the main effect directions; the late self-fed inversion does not replicate. On protected long Moving-MNIST, support and trajectory effects favour hierarchy for all three seeds but are simultaneously resolved only for seeds 0 and 2; flat context preserves digit identity better for all three seeds.

In a separate one-seed feasibility study, a fixed-region state stores 384 scalar values per frame and obtains MSE 28.7175 on 10,000 canonical Moving-MNIST clips. At a 40-frame horizon, the second-order reversible wrapper uses 550.86 MB versus 1,418.79 MB in the BPTT profile; because the external dynamics diverge after the first transition, this is an engineering peak ratio rather than a causal same-forward estimate. The prototype demonstrates compatibility, not general quality leadership.

Scientific novelty. The work develops trajectory-level consistency criteria linked to observable failures; delimits reversible temporal computation by an explicit state boundary and a measured memory–computation frontier; develops a hierarchical raster-byte representation with multidimensional positional structure and entropy-based complexity estimation; establishes a matched-budget reach–fidelity frontier for

the tested hierarchical and flat context packages; and combines exact observability, pair-specific reach populations, persistent-object endpoints, and clip-cluster-aware inference. The novelty is methodological and empirical. Priority over hierarchical video models, reversible networks, or adaptive tokenization as broad architectural classes is not claimed. The later integration prototype is reported as feasibility evidence rather than a separate central novelty claim.

Potential use. The results are useful for research on memory-limited video prediction, controlled evaluation of long-range dependence, procedural data generation, reproducible experiment management, and teaching in system analysis and machine learning. Application to safety-critical systems or unrestricted natural video requires separate external validation.

Practical significance. The software outputs include the TempVerseFormer and visionBLT repositories; the simple-shape-dataset-toolbox for procedural 2-D shape and 3-D polycube video generation; TRB (LoopMom) and persistent long Moving-MNIST generators with object metadata; and modules for configuration validation, training, inference, endpoint calculation, experiment comparison, physical state packing, positional encoding, fixed-quota routing, an internally reversible Transformer core, resumable OpenSTL execution, and evidence-derived figure and table generation. Fail-closed authorization, content-addressed run specifications, immutable artifacts, and stable research interfaces support reproducibility. A direct design rule follows: compress retained state when distant reach is missing, preserve dense detail when fidelity is limiting, and reconstruct activations when the training activation tape is the dominant cost.

Hierarchy is examined through capacity, allocation across scales, temporal support, spatial detail and overlap. Numerical correctness, resource use and predictive quality have separate validation protocols; unmeasured results do not support empirical conclusions.

Keywords: systems analysis; long-horizon video prediction; hierarchical context; consistency; reach–fidelity frontier; reversible computation; activation

memory; raster-byte modelling; predictive entropy; latent diffusion; exact observability; clip-cluster-aware inference.

Публікації здобувача

- **[A1]** Кулик Л. Р., Мокін О. Б. «Масштабування прогнозування відео за допомогою просторово-часових патчів». *Вісник Вінницького політехнічного інституту*, 2025, № 5, с. 129–139. DOI: 10.31649/1997-9266-2025-182-5-129-139.
- **[A2]** Кулик Л. «Часове моделювання за допомогою реверсивних трансформерів». *Neural Computing and Applications*, 2026, т. 38, стаття 30. DOI: 10.1007/s00521-025-11707-3. Одноосібний автор; видання індексується у Scopus.
- **[A3]** Кулик Л. Р., Мокін О. Б. «Методи забезпечення консистентності генерації в дифузійних моделях». *Вісник Вінницького політехнічного інституту*, 2024, № 4, с. 75–85. DOI: 10.31649/1997-9266-2024-175-4-75-85.
- **[A4]** Кулик Л. Р. «Коли ієрархічна відеопам’ять виправдовує себе? Межа досяжність–точність відтворення та інтегрований ресурсоефективний предиктор». Рукопис у підготовці. **[ДАНІ ВІД АВТОРА: затвердити остаточну назву, склад авторів, цільовий журнал та статус публікації.]**
- **Публікації у збірниках конференцій: [ВВЕСТИ АВТОРОМ: вказати шість перевірених бібліографічних записів та підтвердити, чи належить DSMSI-2023 до цього списку.]**

Символи та скорочення

Символ або скорочення	Значення
AR	авторегресійний
BPTT	зворотне поширення через час
CI	довірчий інтервал
CRN	спільні випадкові числа
DDIM	неявна дифузійна модель знешумлення
DDPM	імовірнісна дифузійна модель знешумлення

Символ або скорочення	**Значення**
DiT	дифузійний трансформер
EBM / EBT	енергетична модель / енергетичний трансформер
EMA	експоненційне ковзаюче середнє
FID / FVD	відстань Фреше / відстань Фреше для відео
fg-MSE	середньоквадратична похибка переднього плану
LPIPS	навчена перцептивна подібність фрагментів зображення
MSE	середньоквадратична похибка
NFE	кількість обчислень функції
RoPE-ND	N-вимірне ротаційне позиційне вбудовування
SSIM	індекс структурної подібності
TRB	тороїдальний тест повторного входу (Toroidal Re-entry Benchmark; внутрішня назва LoopMom)
V-BLT	Vision Byte Latent Transformer
VAE	варіаційний автоенкодер

У тексті **випадкова ініціалізація** означає початкове значення генератора випадкових чисел. Для кожного результату окремо зазначено, чи йдеться про ініціалізацію навчання, формування даних або алгоритму вибірки.

ЗМІСТ

ВСТУПНІ МАТЕРІАЛИ 1
Відомості для титульного аркуша 1
Українська анотація 1
Англійський реферат 10
Публікації здобувача 14
Символи та скорочення 14
ВСТУП 23
Актуальність та обґрунтування теми дослідження 23
Зв’язок із дослідницькими програмами, планами та темами 25
Мета та дослідницькі завдання 26
Об’єкт і предмет дослідження 28
Методи дослідження 29
Наукова новизна 30
Практичне значення 33
Надійність та валідність результатів 34
Особистий внесок здобувача 35
Апробація та публікації 36
Структура та обсяг дисертації 37
РОЗДІЛ 1 – СИСТЕМНИЙ АНАЛІЗ І ВИМОГИ ДО КОНСИСТЕНТНОСТІ ДОВГОГОРИЗОНТНОГО ПРОГНОЗУВАННЯ ВІДЕО 38
1.1 Прогнозування відео як частково спостережувана динамічна система 38
1.1.1 Межі системи, стан, спостереження та керування 38
1.1.2 Проблематика зростання невизначеності при авторегресивній генерації 41
1.1.3 Формулювання передбачення як багатокритеріальної задачі з обмеженими ресурсами 43
1.2 Консистентність як багатокритеріальна властивість 46
1.2.1 Чому одного показника якості недостатньо 46

1.2.2 Зовнішній вигляд, об’єкт та концептуальна консистентність..... 48
1.2.3 Часова та траєкторна консистентність..... 51
1.2.4 Ієрархічна та міжрівнева консистентність 54
1.2.5 Від статичних критеріїв контролю до вимог до відео 56
1.3 Вузькі місця довгогоризонтної неконсистентності..... 64
1.3.1 Зростання пам’яті під час навчання часових моделей..... 64
1.3.2 Просторовий розподіл токенів у кадрі..... 66
1.3.3 Обмежена досяжність збереженого контексту 67
1.3.4 Системна карта вузьких місць і втручань 69
1.3.5 Просторова, часова та обчислювальна форми ієрархії 70
1.4 Аналіз існуючих методів..... 71
1.4.1 Моделювання в часі з довгим горизонтом та навчання з ефективним використанням ресурсів..... 72
1.4.2 Адаптивне та ієрархічне візуальне представлення..... 73
1.4.3 Довгий контекст і багатошвидкісна пам’ять..... 74
1.5 Декомпозиція проблеми та вимоги до розроблених методів 77
1.5.1 Виведені вимоги до проєктування 77
1.5.2 Дослідницькі гіпотези..... 78
1.5.3 Висновки до розділу 81
РОЗДІЛ 2 – МЕТОДИ УСУНЕННЯ ОБМЕЖЕНЬ МАСШТАБУВАННЯ ІЄРАРХІЧНОГО ПРОГНОЗУВАННЯ..... 83
2.1 Контрольована експериментальна основа..... 83
2.1.1 Процедурна генерація відеоданих..... 83
2.1.2 Обертання двовимірних фігур 85
2.1.3 Обертові тривимірні полікуби..... 85
2.1.4 Набори даних у дисертації 86
2.2 Моделювання реверсивних часових процесів 89
2.2.1 Активаційна пам’ять у довгих часових ланцюгах..... 89
2.2.2 Блок реверсивного перетворення 90

2.2.3 Часове ланцюгове з’єднання 94
2.2.4 Зворотне поширення незалежне від часового горизонту 97
2.2.5 Результати контрольованого аналізу часових закономірностей 100
2.2.6 Зовнішня валідація OpenSTL 102
2.2.7 Межа активаційної пам’яті та обчислювальної потужності 104
2.2.8 Розширення стохастичного відтворення та окремі перевірки рекурентного ядра 107
2.2.9 Застосовність щодо BPTT та системи контрольних точок 110
2.3 Ієрархічне просторове представлення та оцінка ентропії 112
2.3.1 Проблема розподілу фіксованих патчів 112
2.3.2 Архітектура V-BLT 113
2.3.3 Причинна увага та категоріальна байтова ціль 116
2.3.4 Багатовимірне ротаційне позиційне кодування 118
2.3.5 Прогностична ентропія як сигнал просторової складності 120
2.3.6 Експериментальні результати для двовимірних та тривимірних обертань 123
2.3.7 Порівняння виміряного методу з пропонованим динамічним поділом на регіони 124
2.4 Наслідки для проєктування ієрархічно-контекстної моделі 126
2.4.1 Результати, що мають концептуальне значення 126
2.4.2 Висновки до розділу 127
РОЗДІЛ 3 – ІЄРАРХІЧНА КОНТЕКСТНА МОДЕЛЬ ДОВГОГОРИЗОНТНОГО ПРОГНОЗУВАННЯ ВІДЕО 130
3.1 Збережений контекст як проблема кінцевої моделі 131
3.1.1 Консистентність як вимога до досяжності пам’яті 131
3.1.2 Простір проєктування контекстного пакета 132
3.1.3 Гіпотеза «досяжність–точність відтворення» 135
3.2 Ієрархічний прихований стан 137
3.2.1 Дворівневий заморожений автоенкодер 137
3.2.2 Побудова потоку та векторів вбудовування 140

3.2.3 Передавання контексту за допомогою спільної уваги 143
3.2.4 Межі градієнта та інформаційна асиметрія..... 144
3.3 Ядро генеративного прогнозування 146
3.3.1 Цільова функція дифузії у прихованому просторі 146
3.3.2 Базова мережа Transformer..... 148
3.3.3 Формування вибірки за допомогою DDIM 150
3.3.4 Регресійний контрольний модуль прогнозування..... 152
3.4 Авторегресивне розгортання та оновлення пам’яті 153
3.4.1 Рекурентність кільцевого буфера..... 153
3.4.2 Геометрія прив’язки та причинно-наслідкова семантика..... 155
3.4.3 Контекст, ціль та загальна вартість..... 156
3.5 Інструменти оцінювання та оцінювані ефекти 158
3.5.1 Чому короткі тести не можуть виявити механізм досяжності .. 158
3.5.2 Генератор TRB та геометрія повторного входу..... 159
3.5.3 Аналітична видимість і популяції різниці досяжності 161
3.5.4 Повні метрики кадру та об’єкта 163
3.5.5 Межі оцінювання об’єктів зі сталою ідентичністю та стандартних наборів..... 165
3.5.6 Статистичний протокол..... 167
3.6 Методика дослідження структури ієрархічного контексту..... 169
3.6.1 Дослідницькі питання та контрольовані чинники..... 169
3.6.2 Спільні умови навчання та оцінювання..... 171
3.6.3 Загальний бюджет і розподіл між рівнями..... 172
3.6.4 Часова підтримка та просторово-часова деталізація..... 174
3.6.5 Глибина ієрархії та перекриття представлень..... 176
3.6.6 Незалежна перевірка та діагностика механізму 179
3.7 Ієрархічний предиктор з адаптивним пакуванням і реверсивним ядром..... 181
3.7.1 Мета інтеграції та межа архітектури 181

3.7.2 Предиктор зі сталими просторовими областями 183
3.7.3 Ієрархічна піраміда та фізично упакований стан 186
3.7.4 Динамічна маршрутизація деталей 188
3.7.5 Фізичне позиційне кодування 190
3.7.6 Внутрішньо реверсивне ядро й декодер майбутнього 190
3.7.7 Протокол перевірки коректності, ресурсів і якості 191
3.8 Висновки до розділу 194
РОЗДІЛ 4 – ЕКСПЕРИМЕНТАЛЬНА ВАЛІДАЦІЯ ТА ВИЗНАЧЕННЯ РОБОЧОЇ ОБЛАСТІ 197
4.1 Експериментальна карта та правила порівняння 197
4.1.1 Дослідницькі питання, набори даних та рівні доказовості 197
4.1.2 Словник бюджету та правила порівняння 199
4.1.3 Обґрунтування спільного зрізу 30 000 кроків 200
4.2 Вибір механізму генерації 202
4.2.1 Регресія та дифузія за контрольованої ємності 202
4.2.2 Перевірка енергетичного спуску як альтернативного механізму 204
4.2.3 Вибір механізму 205
4.3 Ієрархічна досяжність за фіксованого бюджету контексту 206
4.3.1 Відкладене підтвердження різниці досяжності 206
4.3.2 Підтвердження на повній вибірці та за всіма показниками 208
4.3.3 Інтерпретація досяжності 209
4.4 Межа «досяжність–точність відтворення» та ефективність пам’яті 209
4.4.1 Одночасно перевірена межа 210
4.4.2 Точна арифметика токенів та корисного навантаження 211
4.4.3 Досяжність і точність відтворення як область доцільності 212
4.5 Форма контекстного пакета та взаємодія з моделлю 213
4.5.1 Просторова ієрархія проти часового піддискретизування 213
4.5.2 Взаємодія з вихідним модулем прогнозування 215

4.6 Робастність основних напрямів 216
4.6.1 Бюджет алгоритму вибірки та випадковість 216
4.6.2 Незалежно навчений кодек 217
4.7 Межа та негативні докази 218
4.7.1 Невдала реплікація пізньої межі за самоподачі 218
4.7.2 Еталон із прямим доступом до необробленої історії 219
4.7.3 Межа просторового покриття та ідентичності об’єктів, що зберігаються в часі 220
4.7.4 Межі працездатності на короткому горизонті та реальних даних 222
4.8 Вплив структури ієрархії на якість і ресурси 223
4.8.1 Загальний бюджет і розподіл між рівнями 223
4.8.2 Часова підтримка та просторово-часова деталізація 226
4.8.3 Глибина ієрархії та перекриття представлень 228
4.8.4 Незалежна перевірка та діагностика механізму 229
4.9 Якість і ресурсні властивості ієрархічного предиктора 231
4.9.1 Фізичне пакування та працездатність просторового подання 232
4.9.2 Часова рекурентність і вимірювання пам’яті 233
4.9.3 Рівень доказовості та межі композиційного виграшу 235
4.9.4 Числова коректність і ресурсна вартість 236
4.9.5 Працездатність навчання та якість прогнозу 237
4.10 Правило вибору методу на системному рівні 240
4.10.1 Діагностика обмежувальних умов 241
4.10.2 Узагальнене правило застосовності 243
4.10.3 Взаємозв’язок між розробленими методами 244
4.11 Набір програмних засобів та практичне застосування 245
4.11.1 Архітектура програмного забезпечення 245
4.11.2 Впровадження та використання в освітніх цілях 247
4.12 Обмеження та загрози валідності 247

4.12.1 Внутрішня валідність та валідність конструкту 247
4.12.2 Статистична та зовнішня валідність 248
4.12.3 Висновки розділу 250
ЗАГАЛЬНІ ВИСНОВКИ 252
Практичне значення 258
Обмеження та напрямки подальших досліджень 259
СПИСОК ВИКОРИСТАНИХ ДЖЕРЕЛ 260
ДОДАТКИ 274
Додаток А – Публікації, результати дисертації та особистий внесок 274
Додаток Б – Адміністративні записи та акти про впровадження 276
Додаток В – Реєстр конфігурацій та правил інтерпретації 277
Додаток Г – Індекс доказів та походження 289
Додаток Д – Договір про статистичну звітність 291
Додаток Е – Додатковий метод та матеріал щодо негативних результатів 295
Додаток Ж – Програмне забезпечення та карта відтворення 298
Додаток И – Походження та дозволи щодо рисунків 301
Додаток И – Покриття експериментальних питань 301

ВСТУП

Дослідження розглядає ієрархію через місткість контексту, розподіл між рівнями, часову підтримку, просторову деталізацію та перекриття. Окремо перевіряються адаптивне пакування й пам’ять активацій. Ці аспекти утворюють спільне питання збереження корисної інформації за обмежених ресурсів: методика §3.6 визначає контрольовані порівняння, §3.7 — обчислювальні контракти предиктора, а §§4.8–4.9 — відповідні результати та межі висновків.

Актуальність та обґрунтування теми дослідження

Відеопредиктор часто оцінюють покадрово, хоча багато суттєвих помилок стають помітними лише після накопичення похибок упродовж кількох кроків прогнозування. Рух камери може знову відкрити ділянку, яка вже була видимою, а модель заповнить її правдоподібною, проте не підтвердженою минулим текстурою. Це не просто зменшення різкості зображення. Такий випадок означає, що процес генерації не зберіг інформацію, яку задача вважає інваріантною.

На довгому горизонті ця проблема посилюється з двох причин. По-перше, відео є лише спостереженням за динамічним світом: частина стану може бути закрита, залишити поле огляду або зникнути з короткого контекстного вікна. По-друге, під час авторегресивного розгортання модель отримує власні попередні прогнози як нові входи. Помилка змінює не один кадр, а подальшу траєкторію обчислення. Тому близькість окремого прогнозу до еталона ще не доводить, що система збереже потрібний об’єкт, відновить його після повторної появи або не створить непідтверджений передній план.

Зміст консистентності залежить від задачі. Для спостереження за рухом вирішальною може бути неперервність траєкторії; для повторного розпізнавання – збереження ідентичності; для моделювання огляду сцени – правильна просторова підтримка після повернення камери. Один агрегований показник якості не розрізняє ці відмови. Отже, вимоги до пам’яті моделі треба пов’язувати з тим, яку властивість процесу необхідно зберегти й за якою спостережуваною помилкою це буде перевірено. Доступ до віддаленого стану є передумовою

довгогоризонтної траєкторної та об’єктної консистентності, тоді як деталізація представлення визначає, які властивості цього стану збережуться.

Слово «пам’ять» тут позначає кілька різних витрат. Під час навчання зберігаються активації для зворотного проходу. Під час формування прогнозу модель утримує контекст або стан, з якого дістає минулу інформацію. Просторове представлення, своєю чергою, визначає, скільки обчислювальної ємності отримують ділянки різної складності. Зменшення однієї витрати не гарантує зменшення інших. Водночас скорочення просторової надлишковості збереженого стану може за того самого бюджету звільнити ємність для більшої часової досяжності; такий обмін не є автоматичним покращенням якості й потребує окремого вимірювання. Це не три незалежні теми, а три обмеження одного довгогоризонтного процесу, які потрібно вимірювати на відповідних інтерфейсах.

Попередні дослідження пропонують сильні компоненти, але рідко ізолюють механізм їхньої переваги за сумісних бюджетів. Збереження контрольних точок активацій і реверсивні мережі обмінюють пам’ять на повторні обчислення [30–32, 92, 108–113]. Ієрархічні моделі прихованого простору, рекурентний стан, стиснена пам’ять, пошук, розріджена увага та моделі простору станів розширюють часовий доступ різними способами [14–24, 33–37, 79–83]. Візуальні трансформери на основі патчів і моделі з байтовими представленнями у прихованому просторі змінюють саму одиницю обчислення [69–78]. Сам факт наявності кількох рівнів ще не доводить користі ієрархії. Під час порівняння нерідко одночасно змінюються архітектура, кількість токенів, цільова функція, інтерфейс цілі або оцінювана множина випадків. Тоді кращий показник характеризує всю конфігурацію, а не причину її переваги. Для відокремлення ефекту потрібні зіставлене за бюджетом втручання та точна геометрія доступної історії.

Звідси випливає методологія контрольованого системного дослідження. Консистентність у ній задається критеріями конкретної задачі, ресурси навчання та формування прогнозу обліковуються окремо, пакети контексту залишаються

порівнянними, а оцінювані випадки добираються так, щоб досліджуваний механізм можна було ідентифікувати. Окремо враховується статистична залежність кадрів одного авторегресивного розгортання: багато кадрів із того самого кліпу не є багатьма незалежними спостереженнями.

Центральною архітектурною задачею дисертації є збереження релевантної історії за обмеженого контексту. Ієрархічне пакетування досліджується як спосіб збільшити часову досяжність без пропорційного зростання кількості детальних токенів. TempVerseFormer стосується активацій під час довгого навчання, а V-BLT – ієрархічного просторового представлення та оцінки локальної складності. У центральному порівнянні пакетів ці компоненти навмисно не змінюють предиктор, тому спостережуваний ефект можна пов’язати з контекстом. Матриця структурних порівнянь окремо варіює загальний бюджет, розподіл токенів між рівнями, кількість рівнів, часову досяжність, перекриття й просторово-часове розміщення детальної квоти. Для перевірки взаємодії ресурсних механізмів інтегрований предиктор поєднує фізично упакований грубо-детальний стан, маршрутизацію деталей за сталої квоти, позиційне кодування за фізичними координатами та внутрішньо реверсивне ядро. Предиктор зі сталими ділянками залишається перевіркою технічної здійсненності; твердження про адаптивну композицію визначається окремим зіставним протоколом і не приписується дослідам за іншими протоколами.

Зв’язок із дослідницькими програмами, планами та темами

Дисертаційну роботу виконано у Вінницькому національному технічному університеті в межах наукового напряму «Системний аналіз та інтелектуальні інформаційні технології». **[ДАНІ ВІД АВТОРА: зазначити офіційну назву, номер, строки виконання та роль здобувача для держбюджетної теми 1.] [ДАНІ ВІД АВТОРА: додати відповідні перевірені відомості для держбюджетної теми 2.]** Остаточне формулювання має відповідати підписаним документам установи; назви тем і відповідальність виконавців не виводяться з історії програмного забезпечення.

Мета та дослідницькі завдання

Метою дисертації є підвищення значущої для задачі консистентності та ресурсної ефективності довгогоризонтного ієрархічного прогнозування відео шляхом системного аналізу й дослідження часового навчання, просторового представлення, збереженого контексту та оцінювання, з основним фокусом на ієрархічному збереженні віддаленої історії.

Під значущою для задачі консистентністю розуміється збереження саме тих властивостей процесу, які мають залишатися незмінними або розвиватися за визначеним правилом: ідентичності, просторової підтримки, траєкторії, часової неперервності чи відповідності між рівнями. Ресурсна ефективність означає не мінімізацію одного абстрактного показника «пам’яті», а зменшення конкретної витрати за збереження потрібної властивості та за явно визначеної ціни в обчисленнях або деталізації.

Досягнення цієї мети передбачає більше, ніж просте об’єднання наявних модулів. Кожен метод має бути пов’язаний з ресурсом, який він безпосередньо змінює, а докази повинні давати змогу відрізнити дію механізму від супутньої архітектурної відмінності. Тому робота починається з формальних критеріїв, переходить до двох засобів усунення обмежень масштабування, а далі зосереджується на центральному дослідженні контексту зі зіставленими бюджетами. Завдання 2 і 3 стосуються здійсненності довшого навчання та ієрархічного просторового представлення; завдання 4–6 утворюють основну лінію побудови й перевірки ієрархічної контекстної моделі. Завершальна перевірка технічної здійсненності встановлює сумісність принципів, не перетворюючи її на сьоме незалежне завдання. Цей порядок є концептуальним, а не хронологічним.

Для досягнення поставленої мети сформульовано шість дослідницьких завдань:

1. Проаналізувати довгогоризонтне прогнозування відео як частково спостережувану динамічну систему; класифікувати релевантну

невизначеність і порушення консистентності; сформувати вимоги до причинного порівняння з явним обліком ресурсів.

2. Розробити й окреслити межі реверсивних часових обчислень для довгогоризонтного навчання, перевірити реконструкцію стану й процедуру зворотного проходу та охарактеризувати компроміс між пам’яттю активацій і обчисленнями.
3. Створити ієрархічне представлення растрових байтів, багатовимірне ротаційне позиційне кодування й оцінювання просторової прогнозної складності на основі ентропії, відокремивши перевірений метод фіксованих блоків від запропонованого динамічного розподілу.
4. Побудувати ієрархічний відеопредиктор із довгим контекстом, у якому явно визначено грубий і детальний потоки, прив’язки, вартість токенів, інтерфейс цілі та авторегресивне оновлення; дослідити вплив загального бюджету, розподілу між рівнями, кількості рівнів, перекриття, грубої досяжності та просторово-часового розміщення детальної квоти.
5. Сформувати інструменти точної спостережуваності, повний набір кадрових і об’єктних показників та парне статистичне виведення з урахуванням кластеризації за кліпами для порівнянь, ефект яких залежить від досяжності збереженої історії.
6. Оцінити методи, їхню робастність, негативні випадки та зовнішні межі; визначити робочі області, у яких доцільні ієрархічний контекст, щільний контекст, збереження контрольних точок активацій або реверсивність; перевірити композицію фізичного позиційного кодування, динамічної маршрутизації та внутрішньо реверсивного ядра у спільній OpenSTL-сумісній архітектурі.

Завдання перевіряють три наскрізні системні гіпотези. Вони не замінюють зареєстровані експериментальні H1–H5 у §3.6, а пов’язують їх із загальною структурою дисертації.

Системна гіпотеза	Перевірюване очікування	Умова спростування або обмеження
ГС1: пам’ять активацій	Відтворення станів реверсивного часового ядра зменшує залежну від горизонту складову пам’яті активацій ціною додаткових обчислень	реконструкція або градієнти не проходять задані допуски; загальна пам’ять не зменшується у виміряному режимі
ГС2: досяжність контексту	За однакового токенного бюджету ієрархічний пакет допомагає у специфічній для пари популяції, де релевантне спостереження недоступне плоскому пакету	ефект відсутній у зареєстрованій смузі або не зберігається на незалежних перевірках
ГС3: точність відтворення	Після насичення часової досяжності детальний плоский контекст може відновити перевагу за показниками зовнішнього вигляду та ідентичності	напрям не відтворюється за бюджетами, ініціалізаціями або цільовими показниками

Разом ці завдання відповідають на одне системне питання: як довгогоризонтний предиктор має зберігати потрібну історію, а потім розподіляти просторову деталізацію та пам’ять навчання, щоб підтримувати релевантний для задачі критерій консистентності за обмежених ресурсів? Ієрархія є основним архітектурним рішенням для контексту, а два інші механізми визначають умови її практичного масштабування. Йдеться про умовне правило проєктування, а не про архітектуру, яка перемагає в кожному тесті.

Об’єкт і предмет дослідження

Об’єктом дослідження є процес нейронного прогнозування відео на довгих горизонтах із самоподачею за обмежених обчислювальних ресурсів і пам’яті. Він охоплює формування, збереження та повторне використання візуальної інформації під час навчання й авторегресивного застосування, коли згенеровані кадри надходять до наступних входів моделі, а релевантний вміст сцени може залишити поточне поле огляду або вікно контексту.

Предметом дослідження є ієрархічні контекстні представлення як основний об’єкт емпіричного зіставлення, а також системні моделі, реверсивні часові перетворення, просторові представлення, позиційні кодування, засоби оцінювання та статистичні процедури, призначені для збереження релевантної до задачі консистентності й визначення робочих областей досяжності та точності відтворення. Предмет охоплює зв’язки між втручанням, ресурсом, який воно

безпосередньо змінює, та показниками консистентності, за якими його оцінюють. Загальні твердження про всі генеративні відеосистеми та ефективність застосування в неперевірених сферах до предмета дослідження не належать.

Методи дослідження

Системну декомпозицію використано для визначення стану, спостереження, керування, збурення, зворотного зв'язку прогнозування та місць виникнення основних ресурсних витрат [5–11, 41]. Багатокритеріальний аналіз розділяє консистентність зовнішнього вигляду, ідентичність, геометрію, траєкторію, хибний передній план і міжрівневу консистентність замість зведення їх до одного показника. Відповідно, методи згруповано не за назвами моделей, а за ресурсним інтерфейсом, який вони змінюють. Для аналізу контексту застосовано явну геометрію часових прив'язок і токенний облік; для часових обчислень – алгебраїчну реконструкцію стану й вимірювання пам'яті; для просторового представлення – локально-глобальну обробку, багатовимірне позиційне кодування та категоріальну ентропію [9]. Якщо калібрування не вимірюється, ентропія трактується лише як діагностичний показник розкиду прогнозу [44, 45].

Контрольоване процедурне моделювання ізолює часову динаміку та потребу в пам'яті. Тороїдальний тест повторного входу (TRB; внутрішня назва LoopMom) має аналітично відому геометрію світу й поля огляду та є єдиним набором структурної матриці контекстних експериментів. Довгий Moving-MNIST з об'єктами, ідентичність яких зберігається в метаданих, залишається завершеною другорядною перевіркою робастності без нових запусків. Стандартний Moving MNIST 10→10 і TaxiBJ 4→4 використовуються через спільний інтерфейс OpenSTL для окремої синтетичної та реальної перевірки інтегрованої архітектури [1, 124, 126].

Після визначення експериментальної популяції результат оцінюють на кадровому й об'єктному рівнях. Відповідність між об'єктами встановлюється угорським алгоритмом [125]. Ефекти обчислюються на парних кліпах, а

повторна вибірка виконується на рівні кліпів, а не окремих кадрів розгортання. Для заздалегідь визначених сімейств порівнянь будуються одночасні інтервали [120–123]. Контентно-адресовані конфігурації, відкладені й захищені контрольні вибірки та звітування безпосередньо з артефактів зменшують можливості для післяекспериментального переосмислення. Попередня реєстрація й аналіз варіативності стандартних наборів оцінювання так само відокремлюють заплановані твердження від спостереженої мінливості [168, 170]. Структурна матриця контексту використовує дві незалежні ініціалізації для кожної унікальної конфігурації; значення обох запусків подаються окремо, без побудови удаваного надійного інтервалу за двома точками. Для інтегрованої архітектури окремо вимірюються кількість токенів вхідної послідовності Transformer, повний живий упакований стан, параметри й стан оптимізатора, інкрементальний пік ядра, повний пік навчального кроку та пік під час виведення. Такий розклад не дає змоги підмінити скорочення одного складника твердженням про тотожний наскрізний виграш.

Наукова новизна

Наукова новизна роботи має методологічний та емпіричний характер. Центральний внесок полягає у контрольованому, зіставленому за бюджетом визначенні області, де ієрархічний контекст дає перевагу завдяки більшій часовій досяжності, та області, де детальний плоский контекст відновлює перевагу. Розширення цього внеску полягає у факторному дослідженні бюджету, розподілу між рівнями, кількості рівнів, перекриття та просторово-часової детальної квоти за незмінного предиктора й наперед визначеного протоколу вибору. Результати на інших ресурсних інтерфейсах пояснюють умови масштабування цієї системи. Предиктор зі сталими ділянками підтверджує лише технічну сумісність фіксованого пакування й реверсивного розгортання; OpenSTL-сумісна архітектура з адаптивним пакуванням має окрему межу доказу й не є підставою для ретроспективної заяви про одну спільно підтверджену модель. Новизна не ґрунтується на пріоритеті над широкими класами ієрархічних відеомоделей, реверсивних мереж або адаптивної токенізації.

1. Розроблено багатокритеріальне формулювання консистентності для довгого прогнозування відео із самоподачею. Вимоги до зовнішнього вигляду, ідентичності, геометрії та концептуального змісту доповнено часовою неперервністю, правильністю траєкторії, відновленням після повторного входження, чутливим до галюцинацій покриттям переднього плану й консистентністю між явними рівнями представлення. Кожен критерій пов’язано зі спостережуваною помилкою та відповідним показником, тому низька середня кадрова похибка не ототожнюється з консистентністю всього процесу.

На відміну від попередньої таксономії статичних зображень і традиційного агрегування кадрових оцінок, запропонований підхід перетворює вимоги до траєкторії на вимірювані критерії. Затримки подій, помилки зіставлення, хибний передній план і міжрівневі суперечності стають окремо спостережуваними.

2. Реверсивні часові обчислення обмежено явним контрактом стану. Адитивне зв’язування застосовується до збережуваного подвоєного стану трансформера, а нереверсивні інтерфейси кодування, проєкції, злиття, декодування та втрати залишаються поза точним твердженням. Алгебраїчну реконструкцію поєднано з числовим відтворенням, порівнянням градієнтів, вимірюванням пам’яті активацій і обліком обчислень. Це дає змогу визначити, коли реверсивне відтворення корисне, а коли доцільніші контрольні точки активацій або звичайне зворотне поширення.

Відмінністю від загальної конструкції реверсивної мережі є перевірена межа застосовності: реконструкція, збережений стан, метадані відтворення й обчислювальна надбавка оцінюються разом. Наявність одного реверсивного блока не вважається достатнім доказом наскрізної реверсивності. Нове профілювання реверсивного розгортання упакованого стану є допоміжною перевіркою цього принципу, а не заміною опублікованого результату TempVerseFormer.

3. Розроблено ієрархічне візуальне представлення на основі нестиснених байтів каналів растрових пікселів із локально–глобально–локальною обробкою, каузальним прогнозуванням і N-вимірним ротаційним позиційним кодуванням. Категоріальна прогнозна ентропія надає внутрішній для моделі сигнал просторової складності без окремого навченого модуля невизначеності. Перевірений метод використовує фіксовані просторово-часові блоки з публікації. Застосування ентропії для динамічної зміни розмірів ділянок або обчислень визначено як майбутній контролер і не зараховано до експериментальних результатів. Пізніше агрегування за сталими областями використовує споріднений принцип інформаційного зважування, але не є реалізацією динамічного розподільника V-BLT.
4. Розроблено дворівневу ієрархічну модель контексту для довгогоризонтного прогнозування за зіставлених бюджетів. Специфікація пакета окремо задає просторовий рівень, часовий крок, кількість кадрів, геометрію прив’язок, токени контексту й цілі та корисне навантаження. Грубі й детальні токени обробляє один спільний предиктор, однак наукова новизна полягає не в першому використанні кількох масштабів, а в контрольованому втручанні у форму пакета. Завдяки цьому експериментально визначено межу досяжності й точності відтворення: ієрархія оцінюється там, де груба історія виходить за межі щільного детального вікна, а плоский контекст також перевіряється після насичення досяжності, коли можуть домінувати деталі ідентичності.

Ієрархічні архітектури прихованого простору вже існують [20, 35–37]. Новим елементом є контрольоване втручання «пакет за фіксованого бюджету» та виміряні нижня й верхня інверсії, а не саме використання кількох масштабів.

5. Розроблено методологію оцінювання прогнозування відео, залежного від пам’яті. Точна геометрична спостережуваність визначає специфічні для пар популяції з різницею досяжності замість опори лише на агреговані кліпи. Повні показники переднього плану штрафують і пропущений, і

зайвий вміст; зіставлення об’єктів, що зберігаються в часі, розділяє просторове покриття, неперервність, ідентичність та траєкторію. Парне передискретизування кліпів та одночасне статистичне виведення з урахуванням кластеризації за кліпами зберігають залежність усередині розгортання й враховують множинність. У результаті твердження про збережену досяжність допускає емпіричне спростування саме в популяції, де відрізняються порівнювані пакети.

Практичне значення

Практичним результатом роботи є інструментарій для відтворюваних досліджень, а не готовий до промислового впровадження продукт. До нього входять репозиторій TempVerseFormer для дослідження реверсивного часового навчання; репозиторій visionBLT з реалізаціями V-BLT і RoPE-ND; комплекс simple-shape-dataset-toolbox для процедурного генерування відео двовимірних фігур і тривимірних полікубів; генератори TRB (LoopMom) і довгого Moving-MNIST з метаданими об’єктів зі сталою ідентичністю; модулі підготовки конфігурацій, навчання, застосування, оцінювання та побудови артефактів. Додатково реалізовано маніфестно кероване фізичне пакування стану, конфігурації розподілу контексту, маршрутизацію деталей, фізичне позиційне кодування, внутрішньо реверсивне ядро й інтеграцію з OpenSTL. Стабільний публічний інтерфейс командного рядка повідомляє версію та перевіряє шлюз авторизації; навчання, оцінювання, аналіз і валідація виконуються окремими відтворюваними дослідницькими процесами. Така організація відповідає принципу відтворюваності: твердження мають бути простежуваними до даних, коду, конфігурацій та оголошеної процедури оцінювання [166].

Комплекси процедурного синтезу дають змогу створювати контрольовані послідовності з відомими параметрами руху, геометрією сцени, моментами зникнення й повторної появи та, де це передбачено, ідентифікаторами об’єктів. Це корисно для перевірки механізмів, які важко ізолювати на природному відео. Інструменти керування експериментами реалізують перевірку сумісності конфігурацій, авторизацію запусків із забороною за замовчуванням, контентно-

адресовані специфікації та незмінні доказові артефакти. Вони зменшують ризик випадкового порівняння несумісних інтерфейсів і підтримують повторне формування таблиць та рисунків із зафіксованих результатів.

Методи також задають процедуру вибору для майбутніх систем. Якщо потрібне минуле лежить поза щільним вікном, довший потік нижчої роздільної здатності може забезпечити досяжність. Коли релевантна історія вже доступна, але губляться деталі ідентичності, доцільнішим є щільний детальний контекст. Якщо під час навчання домінує стрічка активацій зворотного проходу, контрольні точки або перевірене реверсивне ядро можуть обміняти додаткові обчислення на пам’ять. Прогнозна ентропія здатна обґрунтувати політику просторового розподілу, проте її наскрізну користь ще потрібно перевірити безпосередньо.

Відомості про впровадження та освітнє використання подаються лише в обсязі, підтвердженому підписаними документами. **[ДАНІ ВІД АВТОРА: зазначити перевірені установи, дати, охоплені програмні компоненти та літери додатків для актів упровадження.]**

Надійність та валідність результатів

Надійність підтримується на кількох рівнях. Алгебраїчні властивості перевіряються з урахуванням меж реалізації; числове відтворення та напрями градієнтів порівнюються там, де заявлено реверсивність. Контрольовані генератори відкривають прихований механізм замість опори лише на природні сцени з невідомою історією. У центральному контекстному дослідженні дані розроблення відокремлено від відкладеної підтверджувальної вибірки, вибірок із заздалегідь визначеним призначенням і захищених контрольних вибірок, закріплених хешами. Це відповідає логіці захисту відкладених даних під час адаптивного аналізу [167]. Коли цього потребує дослідницьке питання, порівнювані моделі мають зіставлену ємність; результати, де одночасно змінюється кілька інтерфейсів, позначаються окремо як порівняння повних конфігурацій.

Перевірки відтворюваності доповнюють ці засоби захисту висновків. Конфігурації й контрольні точки є контентно-адресованими, основні артефакти повторно генеруються із заморожених таблиць доказів, а перевірки сумісності відхиляють порівняння з різними інтерфейсами. Опубліковані точкові оцінки без записів на рівні ініціалізацій залишаються позначеними саме як точкові; невизначеність до них ретроспективно не додається. Перевірене походження даних та оцінена варіативність вибірки зберігаються окремо, оскільки підтверджують різні види надійності. Інтеграційний прототип має статус перевірки технічної здійсненності для однієї ініціалізації навчання і не об’єднується з відкладеними або захищеними результатами центральної програми.

Особистий внесок здобувача

У межах програми здобувач сформулював системну декомпозицію, розробив програмне забезпечення та контрольовані генератори, реалізував віднесені до дисертації компоненти моделей і оцінювання, провів експерименти, упорядкував артефакти доказів та підготував науковий аналіз. Внесок у спільні публікації відокремлено від розширень, виконаних лише для дисертації.

Здобувач також виконав синтез на рівні дисертації: уніфікував термінологію окремих досліджень, зіставив межі реалізацій з опублікованими описами та звузив твердження там, де експерименти підтверджують лише фіксовану конфігурацію або умовну робочу область. Адміністративні формулювання ролей співавторів мають бути погоджені з відповідними авторами та установою.

- Для **[A1]** здобувач розробив і реалізував V-BLT, інтеграцію RoPE-ND, процедурні експерименти та аналіз; співавтор забезпечив наукове керівництво, системне формулювання та рецензування рукопису. У дисертації адаптивне формулювання звужено до фактично наведених доказів для фіксованих блоків.
- **[A2]** є одноосібною працею. Здобувач розробив TempVerseFormer і реверсивну процедуру зворотного проходу в часі, провів експерименти з

контрольованим рухом та зовнішні порівняння, оцінив пам’ять і час. Перевірений контракт реверсивного стану та пізніший аналіз стохастичного відтворення викладено окремо як розширення статті.

- Для **[A3]** здобувач виконав технічний огляд і запропонував категорію концептуальної консистентності; співавтор здійснював наукове керівництво та редакційний перегляд. Дисертація розвиває обговорення статичних зображень до операційних критеріїв відео, не приписуючи статті часових доказів.
- Для **[A4]** здобувач розробив дослідження ієрархічного контексту, інструмент точної спостережуваності, набір показників, статистичний протокол, програму перевірки робастності, фізично упаковану інтегровану архітектуру, її OpenSTL-інтерфейс, рисунки та відтворюваний ланцюг артефактів. **[ДАНІ ВІД АВТОРА: перевірити остаточний список авторів і формулювання внеску перед поданням.]**

Інтеграційне розширення виконано як дисертаційний синтез після формування первинної програми [A4]. Програму підготовлюваного рукопису [A4] сформовано як поєднання контрольованого дослідження ієрархічного контексту та окремо обмеженої інтегрованої OpenSTL-перевірки в межах однієї статті. Предиктор зі сталими ділянками з однією випадковою ініціалізацією зберігає статус перевірки технічної здійсненності; сильніші твердження допускаються лише для архітектури з адаптивним пакуванням після двох ініціалізацій, зіставних базових моделей і вимірювання пам’яті за спільним протоколом.

Апробація та публікації

Основні результати опубліковано у трьох журнальних статтях [A1]–[A3]. Один рукопис [A4], що поєднує розширене дослідження ієрархічного контексту й окремо обмежену інтегровану OpenSTL-перевірку, перебуває в підготовці. **[ДАНІ ВІД АВТОРА: додати повні записи шести матеріалів конференцій, назви заходів, місця проведення або онлайн-статус, дати, сторінки та остаточне зведення публікацій; підтвердити включення DSMSI-2023.]**

Структура та обсяг дисертації

Дисертація містить анотації, вступ, чотири розділи, загальні висновки, список використаних джерел і додатки. У розділі 2 подано два засоби усунення обмежень масштабування: реверсивні часові обчислення для навчання, обмеженого пам’яттю активацій, та ієрархічне представлення растрових байтів для неоднорідної просторової складності. Розділ 3 містить центральну архітектурну розробку – ієрархічну модель збереженого контексту, повну матрицю її контрольованих конфігурацій та контракти сталого та адаптивного пакування в OpenSTL-сумісних предикторах. Експериментальні дані розділу 4 дають змогу вибрати генеративний механізм, перевірити досяжність і точність відтворення за різних бюджетів, дослідити вплив розподілу між рівнями, грубої досяжності, кількості рівнів, перекриття та просторово-часової квоти, оцінити робастність і граничні випадки, а також відокремлено перевірити коректність, якість і пам’ять інтегрованої архітектури.

Загальні висновки повертаються до шести завдань і формулюють отримані методи, робочі області та обмеження для визначених задач і протоколів. Список джерел пов’язує технічні й емпіричні твердження, на яких побудовано аргументацію. До додатків винесено матеріали для аудиту або відтворення: повні конфігурації, таблиці за ініціалізаціями й показниками, додаткові виведення, підтвердження негативних результатів, записи походження, програмні команди, відомості про використання рисунків, адміністративні документи та відповідність між публікаціями й результатами. **[ДАНІ ВІД АВТОРА: після інституційного верстання зазначити загальну кількість сторінок і сторінок основного тексту, кількість рисунків, таблиць, джерел і додатків та остаточні літери додатків.]**

РОЗДІЛ 1 – СИСТЕМНИЙ АНАЛІЗ І ВИМОГИ ДО КОНСИСТЕНТНОСТІ ДОВГОГОРИЗОНТНОГО ПРОГНОЗУВАННЯ ВІДЕО

У вступі центральну проблему сформульовано як збереження довгогоризонтної консистентності ієрархічного прогнозу за обмеженої пам’яті. Щоб перейти від цього формулювання до архітектури, потрібно уточнити, який стан система має пам’ятати, яку саме консистентність треба зберігати і чому одного ресурсу «пам’ять» для опису задачі недостатньо. Тому прогнозування відео спочатку розглядається як частково спостережувана динамічна система, далі консистентність розкладається на спостережувані критерії, а три ресурсні обмеження виводяться як наслідки однієї задачі, а не як три незалежні теми.

Для системної постановки важливо відрізняти доступність інформації від вартості її оброблення. Місткість, частка рівнів, часова підтримка й деталізація визначають, що може знати предиктор; пам’ять активацій визначає, як його можна навчати. Ці відмінності переходять у методику контрольованих порівнянь §3.6 та обчислювальні контракти §3.7.

1.1 Прогнозування відео як частково спостережувана динамічна система

Цей підрозділ задає межі досліджуваної системи: відокремлює прихований стан сцени від кадру, який спостерігає модель, пояснює рекурсивне використання власних прогнозів і вводить ресурси, що обмежують таке розгортання. Послідовність потрібна для того, щоб надалі не ототожнювати фізичну динаміку, стан предиктора, його контекст і пам’ять навчального графа.

1.1.1 Межі системи, стан, спостереження та керування

Розглянемо сцену, що розвивається, повний фізичний і семантичний стан якої у дискретний момент часу t позначено через x_t. До нього можуть належати геометрія та ідентичність об’єктів, їхні пози, швидкості, освітлення, положення камери й інші змінні, які не спостерігаються безпосередньо, але впливають на наступний кадр. Керувальний сигнал u_t представляє дію камери, агента або інший вимірюваний вплив. Збурення w_t охоплює стохастичну динаміку й невраховані чинники. За такої постановки перехід стану має вигляд

$$x_{t+1} = f(x_t, u_t, w_t). \tag{1.1}$$

Кадр y_t є не повним станом світу, а його спостереженням: $y_t = h(x_t, v_t)$, де h є оператором спостереження, а v_t — шумом датчика або синтетичного рендерингу. Розмежування стану та спостереження потрібне не лише для синтетичних відео. У дистанційному зондуванні або фізично обґрунтованому прогнозуванні поширення лісових пожеж датчик охоплює лише частину процесу, тоді як істотні просторові зміни залишаються прихованими. Тому візуально правдоподібний кадр ще не є достатнім: прогноз має відповідати стану й динаміці системи [47–49].



Рисунок 1.1 – Межі системи довгогоризонтного прогнозування відео. *Джерело: авторська схема системи.*

На рис. 1.1 прогнозувач розміщено всередині контуру спостереження. Оператор побудови контексту C_t відбирає або стискає минулі спостереження у стан моделі $m_t = C_t(y_{\le t}, u_{\le t})$. Прогнозувач із параметрами θ генерує розподіл для майбутнього вікна,

$$p_\theta\left(\hat{y}_{t+1:t+K} \mid m_t, u_{t:t+K-1}\right). \tag{1.2}$$

Параметри моделі та правило побудови контексту обираються так, щоб зменшити очікувані втрати $\mathcal{L}$ не на одному кадрі, а в усьому прогнозованому вікні:

$$min_{\theta,C} \mathbb{E}\left[\sum_{k=1}^{K} \lambda_k \mathcal{L}\left(\hat{y}_{t+k}, y_{t+k}; x_{t+k}\right)\right], \tag{1.3}$$

де крапка з комою підкреслює, що показник може залежати від прихованих властивостей задачі, наприклад ідентичності або істинної області просторового покриття, хоча предиктор приймає на вхід лише серію зображень. Ваги λ_k не

обов’язково мають бути рівномірними. Для короткогоризонтного контролера найбільшу вагу може мати безпосередня похибка; у дослідженні пам’яті навмисно сильніше зважуються події, докази яких містяться у віддаленому минулому.

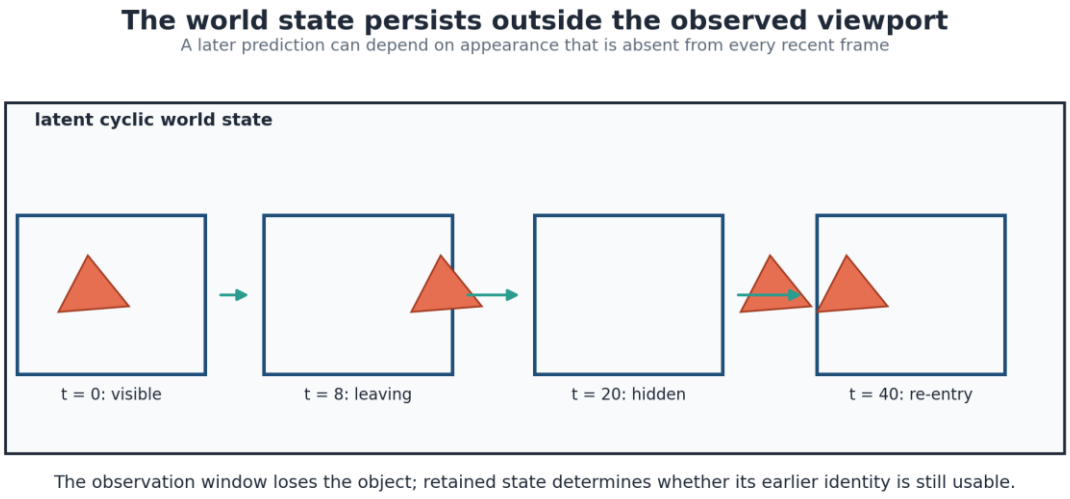


Рисунок 1.2 – Прихований стан проти спостереження у вікні перегляду. *Джерело: концептуальний сторіборд, створений для дисертації.*

Рисунок 1.2 пояснює, чому поняття «попередні кадри» і «стан системи» не є взаємозамінними. Камера спостерігає лише прямокутний фрагмент більшого циклічного світу. Коли об’єкт залишає поле зору, його положення та зовнішній вигляд продовжують існувати в прихованому стані, хоча в поточних кадрах їх уже немає. Коротке детальне вікно поступово втрачає прямі свідчення про такий об’єкт; довший потік нижчої роздільної здатності може зберегти відомості про його траєкторію, але втратити частину ознак ідентичності. У розділах 3 і 4 ця різниця стане основою контрольованої перевірки досяжності контексту.

Якщо релевантне спостереження вже вилучене з плоского контекстного вікна і не закодоване в іншому стані, збільшення глибини або обчислювальної потужності предиктора не може відновити недоступне пряме свідчення. Воно здатне лише точніше апроксимувати майбутнє за інформацією, яка залишилася, або покладатися на вивчені апріорні закономірності. Тому місткість предиктора і досяжність його фактичного контексту є різними змінними. Експериментальне порівняння має спочатку встановити, які часові прив’язки доступні кожній конфігурації, і лише після цього пов’язувати відмінність якості з ієрархічним зберіганням історії.

1.1.2 Проблематика зростання невизначеності при авторегресивній генерації

Під час навчання модель часто отримує еталонну послідовність, тоді як під час авторегресивного застосування її власний прогноз повертається на вхід. Після кожного кроку контекстне вікно зсувається: найдавніші елементи вилучаються, а новий прогноз займає їхнє місце [25–29]. Отже, починаючи з другого прогнозованого кадру, вхід уже залежить від попередніх виходів самої моделі. Цю самоподачу можна записати як рекурсію:

$$\hat{y}_{t+k} \sim p_\theta\left(\hat{y}_{t+k} \mid C_{t+k-1}(y_{\le t}, \hat{y}_{t+1:t+k-1}), u_{\le t+k-1}\right). \quad (1.4)$$

У цьому процесі потрібно розділяти рішення, які впливають на різні ланки причинного ланцюга:

1. Учительська подача визначає, які кадри надходять до моделі під час навчання.
2. Цільова функція та обчислювальний граф визначають, через скільки кроків передається градієнт і скільки активацій потрібно зберігати або відтворювати.
3. Політика контексту визначає, які давні спостереження залишаються доступними під час прогнозування і з якою деталізацією вони представлені.

Зміна режиму подачі може послабити розбіжність між навчанням і застосуванням, але не повертає подію, яку вже вилучено з пам’яті. Реверсивний часовий перехід змінює вартість передавання градієнта, але так само не збільшує досяжність збереженого стану. Саме політика контексту є центральною для ієрархічного пакета в розділі 3; просторова одиниця представлення визначає, якою ціною деталізації цю досяжність отримано.

Накопичення помилки в самоподаваному процесі не зводиться до додавання незалежних числових відхилень. Планове підмішування прогнозів під час навчання (*scheduled sampling*) і самокондиціювання зменшують розбіжність між еталонними та згенерованими входами [25–29], проте не відновлюють інформацію, якої вже немає у збереженому контексті. Якщо рекурентний перехід

подано як $\hat{s}_{t+1} = F_\theta(\hat{s}_t)$, то мале збурення на ранньому кроці переноситься наступними переходами. У лінійному наближенні його масштаб визначається послідовним добутком матриць похідних, тобто якобіанів, уздовж згенерованої траєкторії [93]. Через це середня залежність похибки від горизонту може поєднувати якісно різні фази. У подальшому аналізі ранній інтервал авторегресії відокремлюється від можливої пізньої межі.

Похибка може виглядати оманливо стабільною. Якщо модель поступово усуває невизначені деталі переднього плану, її вихід здатний збігтися до простого фонового стану. Після цього середня піксельна похибка майже не зростає, хоча об'єкт уже втрачено. Стохастична модель створює іншу складність: вона може представляти кілька допустимих майбутніх станів, але отримати несприятливу оцінку точковою метрикою навіть тоді, коли один зі зразків є коректним. Для розмежування таких випадків потрібні явні показники та правила врахування кандидатів [130, 131, 155].

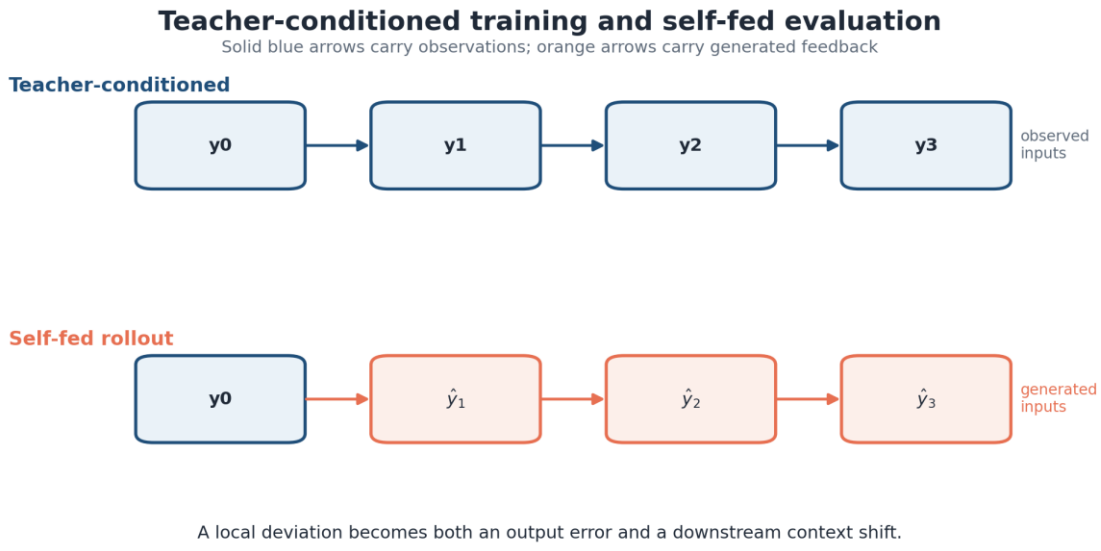


Рисунок 1.3 – Умовна рекурсія з учительською подачею та із самоподачею. За учительської подачі кожний перехід отримує еталонний попередній кадр; під час самоподачі прогноз повертається на вхід, тому його похибка впливає на всі наступні кроки. Схема пояснює різницю режимів, але не є кількісним результатом. *Джерело: концептуальна схема дисертації.*

1.1.3 Формулювання передбачення як багатокритеріальної задачі з обмеженими ресурсами

Модель машинного навчання працює за скінченних обчислювальних і апаратних ресурсів. Обчислювальний бюджет визначає тривалість навчання й застосування, тоді як доступна пам’ять додатково обмежує розмір моделі, пакет паралельного навчання, довжину диференційованого графа та обсяг історії, доступної моделі прогнозування. Ці обмеження взаємодіють, але не є взаємозамінними. Для подальшого аналізу загальне використання пам’яті розкладається на п’ять складників:

$$M_{\text{total}} = M_{\text{parameters}} + M_{\text{optimizer}} + M_{\text{activations}} + M_{\text{context/state}} + M_{\text{transient}}. \quad (1.5)$$

Пам’ять параметрів і станів оптимізатора визначається переважно розміром моделі, точністю обчислень та алгоритмом навчання. Пам’ять активацій зберігає або відтворює проміжні значення, потрібні для градієнтів. Контекстна пам’ять чи пам’ять стану утримує історичну інформацію для прогнозування, а тимчасова пам’ять охоплює робочі області уваги, буфери алгоритму вибірки, декодовані кандидати та резервування фреймворку. Сума цих складників показує, чи достатньо апаратного ресурсу, але вони не є однією змінною проєктування [108].

На рисунку 1.4 показано, де саме виникають три обмеження центральної задачі. Ієрархічне пакування безпосередньо змінює збережений стан і часову досяжність історії. Реверсивне відтворення діє на активаціях диференційованого ланцюга, а V-BLT змінює просторову одиницю локальної та глобальної обробки. Опубліковані ефекти цих втручань виміряно окремо, що зберігає їхню причинну інтерпретацію. Пізніший інтеграційний прототип перевіряє технічну сумісність принципів у спільному тракті; однак його результат не дає підстав автоматично перемножувати окремі коефіцієнти економії.



Рисунок 1.4 – Розташування витрат системної пам'яті. *Джерело: авторська схема, створена для дисертації.*

Оскільки кожне ресурсне втручання може змінювати інший прояв консистентності, результат описується не одним балом, а вектором втрат. Для прогнозованого відео $\hat{Y}$ та еталонного відео Y він має вигляд:

$$\ell(\hat{Y}, Y) = (\ell_{\text{frame}}, \ell_{\text{support}}, \ell_{\text{identity}}, \ell_{\text{trajectory}}, \ell_{\text{extra}}, \ell_{\text{cross}}). \quad (1.6)$$

Компоненти ℓ_{frame}, ℓ_{support}, ℓ_{identity}, $\ell_{\text{trajectory}}$, ℓ_{extra} та ℓ_{cross} відповідають відповідно за кадрову якість, просторове покриття, ідентичність, траєкторію, зайвий передній план і міжрівневу відповідність. Вектор ваг $\boldsymbol{\alpha}$ задає важливість цих критеріїв для конкретної задачі. Позначимо через $\mathcal{F}(B_{\text{ctx}}, B_{\text{act}}, B_{\text{work}})$ множину конфігурацій (θ, C, a), які не перевищують заданих бюджетів контекстної пам'яті, пам'яті активацій та обчислювальної роботи. Тоді спільна задача оптимізації має вигляд

$$min_{(\theta,C,a)\in\mathcal{F}(B_{\text{ctx}},B_{\text{act}},B_{\text{work}})} \mathbb{E}\left[\boldsymbol{\alpha}^{\top}\ell(\hat{Y}, Y)\right]. \quad (1.7)$$

У формулі (1.7) θ позначає параметри моделі, C – політику формування контексту, а a – спосіб організації обчислень, зокрема збереження або відтворення активацій. Множина $\mathcal{F}$ містить лише конфігурації, для яких $M_{\text{context/state}}(C) \leq B_{\text{ctx}}$, $M_{\text{activations}}(\theta, a, K) \leq B_{\text{act}}$ та $Work(\theta, C, a, K) \leq B_{\text{work}}$. У розділах 2–4 втручання оцінюються окремо та в композиції (§3.7 і §4.9), зі збереженням різних одиниць вартості й протоколів.

Ресурсні складники мають різні змінні масштабування. Пам’ять параметрів зростає разом із розміром моделі, пам’ять активацій – разом із диференційованим графом, а пам’ять контексту – разом з обсягом збереженої історії. Обчислювальна робота уваги залежить від довжини послідовності, що надходить до блока. Алгоритми уваги, оптимізовані з урахуванням обміну даними між рівнями пам’яті, зокрема FlashAttention [13], зменшують тимчасові витрати точної уваги, але не змінюють того, яку історію зберігає модель. Політика контексту може впливати і на збережений стан, і на навантаження уваги, тому коректне порівняння додатково фіксує представлення токенів, точність обчислень, розмір пакета та довжину цілі.

Токенний бюджет описує довжину інтерфейсу моделі, тоді як байтовий бюджет – фізичний обсяг збереженого стану. Авторське розрізнення цих величин потрібне тому, що в ієрархічних підходах грубий токен і детальний вектор прихованого простору можуть мати різну розмірність і нести різний корисний обсяг даних. Тому в розділі 3 окремо фіксуються кількість токенів і корисний обсяг у байтах.

Інтерпретація за принципом Парето також має залишатися дискретною. Перевірені пакети охоплюють лише скінченний набір бюджетів, тому за ними не можна відновити повну неперервну криву без додаткових припущень.

Таблиця 1.1 – Терміни, пов’язані з ресурсами, та їхні інтерфейси керування. У таблиці розрізняються величини, які змінюються внаслідок втручання, та супутні витрати, що можуть залишатися незмінними.

Термін ресурсу	**Збережений об’єкт**	**Домінуюча фаза**	**Втручання, що досліджується тут**	**Поширений фактор змішування**
Параметри	навчені ваги	навчання та застосування	ємність залишається фіксованою у межах зіставлених порівнянь	архітектура змінюється залежно від бюджету
Оптимізатор	моменти та градієнти	навчання	враховуються, але не оптимізуються безпосередньо	числова точність і розподілене зберігання стану
Активації	проміжні диференційовані стани	навчання	створення контрольних точок або реверсивне відтворення	додаткові перерахунки опущені

Термін ресурсу	**Збережений об’єкт**	**Домінуюча фаза**	**Втручання, що досліджується тут**	**Поширений фактор змішування**
Контекст/стан	збережені спостереження або стан у прихованому просторі	навчання та застосування	плоскі, ієрархічні або піддискретизовані пакети	спільна зміна досяжності й точності відтворення
Тимчасова пам’ять	робочі буфери уваги та формування вибірки	обидві фази	вимірюється через загальну обчислювальну роботу/NFE, де це доречно	пікове виділення пам’яті, помилково прийняте за збережений стан

Облік ресурсів відповідає на питання, скільки історичної інформації система здатна утримати, але ще не визначає, яку властивість прогнозу потрібно зберегти. Тому наступний крок аналізу пов’язує кожен ресурсний дефіцит із конкретною спостережуваною відмовою консистентності.

1.2 Консистентність як багатокритеріальна властивість

Після визначення системи потрібно встановити, що саме означає коректний довгогоризонтний прогноз. У цьому підрозділі консистентність розкладається на кадрову якість, просторове покриття, ідентичність, траєкторію та відповідність між рівнями представлення; для кожної властивості окремо визначається спостережуваний тип помилки.

1.2.1 Чому одного показника якості недостатньо

Консистентність не можна зводити до загальної візуальної якості. Об’єкт може рухатися правильною траєкторією й водночас втрачати ознаки ідентичності через розмиття або злиття з фоном. Можлива й протилежна ситуація: зовнішній вигляд залишається впізнаваним, але положення чи напрям руху стають помилковими. У сцені з домінантним фоном низька середня похибка здатна приховати навіть повне зникнення об’єкта переднього плану. Отже, показник має відповідати визначеному типу відмови, а не встановлювати саму її семантику.

Обмеження єдиного показника видно на прикладі поширених метрик. MSE вимірює поточкове відхилення, SSIM – локальну структуру [127], LPIPS – відстань у просторі глибоких ознак [128], а FID і FVD – статистичну відмінність

розподілів [94, 129]. Кожне агрегування відкидає іншу частину інформації. Жоден із цих показників самостійно не встановлює, чи досі присутній конкретний об’єкт, чи виник зайвий передній план і чи відновлено вигляд, спостережений у віддаленому минулому.



Рисунок 1.5 – Паралельна перевірка прогнозу за кількома критеріями консистентності. Стовпці є умовними прикладами, а позначки показують, які незалежні вимоги виконує кожний прогноз. Схема не задає порядку оптимізації, скалярної оцінки чи емпіричної шкали. *Джерело: концептуальний рисунок із дисертації.*

Рисунок 1.5 не описує рух кандидата до деякої «нижчої» чи «кращої» області. Він показує логічну умову прийнятності: прогноз може зберігати просторове покриття, але втрачати ідентичність, або відтворювати зовнішній вигляд, але порушувати траєкторію. Тому поліпшення одного критерію не гарантує поліпшення решти. У подальшому емпіричному аналізі контексти не називаються загалом «більш консистентними»; натомість установлюється, яку властивість кожний із них зберігає краще.

Найвиразніше обмеження агрегованого показника проявляється в розріджених сценах. Якщо більшість пікселів належить до однорідного фону, прогноз порожнього простору може мати прийнятне значення MSE для всього кадру, хоча рухомий об’єкт втрачено повністю. MSE, обчислена лише на еталонному передньому плані, підвищує вагу об’єкта, але може ігнорувати галюциновані області поза еталонною маскою [46, 51]. Помилка на об’єднаній масці охоплює обидві області, проте її знаменник уже залежить від прогнозу. Тому кадрові метрики надалі доповнюються прецизійністю, повнотою, частками пропущеного й зайвого переднього плану та кількістю зв’язних компонентів. Випадки з порожньою маскою визначаються до оцінювання.

Для кліпу i та кандидата прогнозу k незалежні аспекти подано вектором показників:

$$\mathbf{q}_{ik} = \left(q_{ik}^{\text{frame}}, q_{ik}^{\text{support}}, q_{ik}^{\text{identity}}, q_{ik}^{\text{trajectory}}, q_{ik}^{\text{extra}}\right) \quad (1.8)$$

Тут q_{ik}^{frame} характеризує кадрову якість, q_{ik}^{support} – просторове покриття, q_{ik}^{identity} – збереження ідентичності, $q_{ik}^{\text{trajectory}}$ – правильність руху, а q_{ik}^{extra} – появу зайвого переднього плану. Склад вектора залежить від задачі, але його принцип залишається незмінним: різні типи помилок не згортаються в один бал до того, як буде встановлено їхній зміст. Далі ці критерії вводяться від статичного зображення до часової послідовності.

1.2.2 Зовнішній вигляд, об’єкт та концептуальна консистентність

Сучасні дифузійні моделі здатні створювати окремі зображення високої візуальної якості, однак правдоподібність одного результату ще не показує, чи збережено потрібний об’єкт, стиль або геометричну умову між кількома генераціями. Рисунок 1.6 зіставляє ці два рівні задачі. Статична панель демонструє різноманіття окремих результатів, а умовна відеопослідовність показує додаткову вимогу: властивості мають залишатися простежуваними між кадрами, зокрема після виходу об’єкта з поля зору.

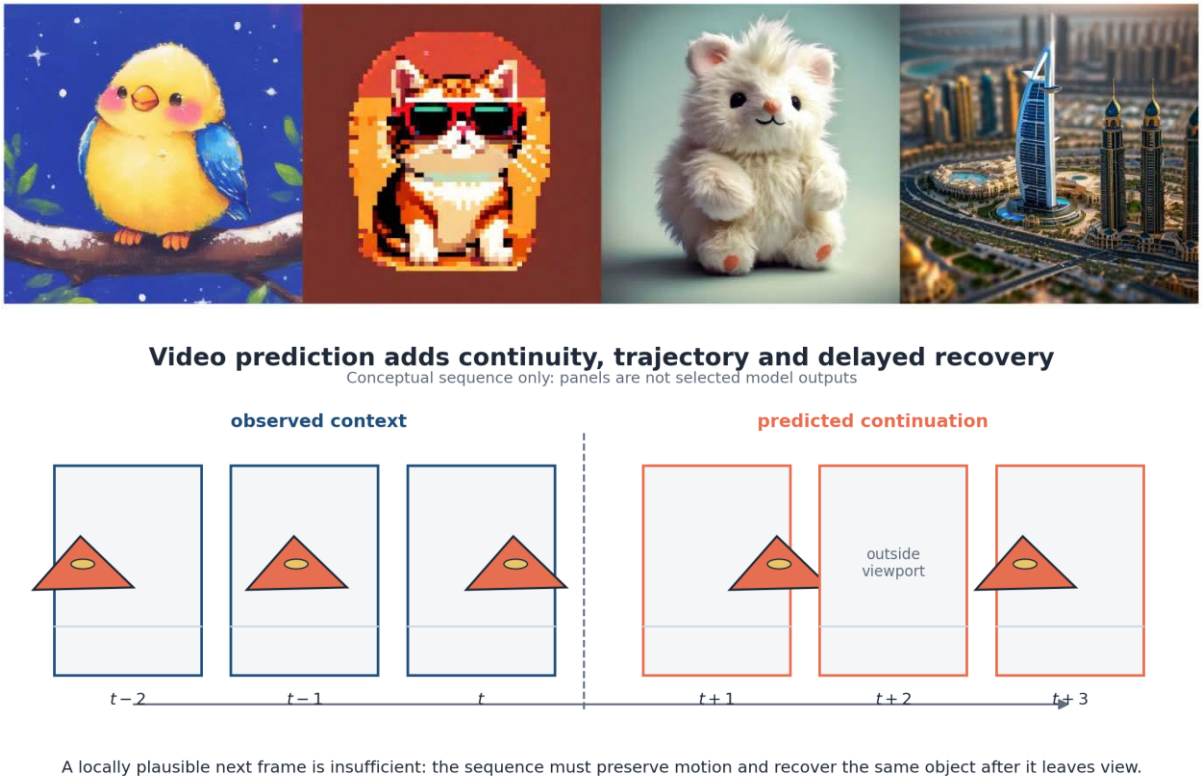


Рисунок 1.6 – Від якості окремого зображення до консистентності відеопослідовності: а – ілюстративні результати SDXL; б – концептуальний приклад прогнозування руху, зникнення та повторної появи об’єкта. Панель а відтворено з Kulyk та Mokin [133], оригінальний рисунок 1, створений Л. Куликом із локально згенерованих результатів SDXL і використаний за ліцензією CC BY 4.0; панель б створено для дисертації. Обидві панелі мають пояснювальне, а не доказове значення.

Попередній аналіз генерації зображень на основі дифузії відокремлював стиль або зовнішній вигляд, ідентичність об’єкта, форму або геометрію та запропоновану категорію концептуальної консистентності [133]. Геометрія стосується контуру, просторового розташування й структурних відношень. Концептуальна консистентність у значенні, запропонованому в [133], описує збереження семантичної ідеї вищого рівня між результатами, поверхневий вигляд яких може змінюватися. Класичні дослідження візуального представлення та пізніші оцінки моделей зору й мови показують, чому семантичну консистентність не можна встановити лише з пікселів [100–104]. Критерії перетинаються: ідентичність обличчя частково залежить від геометрії та текстури, а стилізована послідовність може зберігати концепцію попри зміну обох ознак.

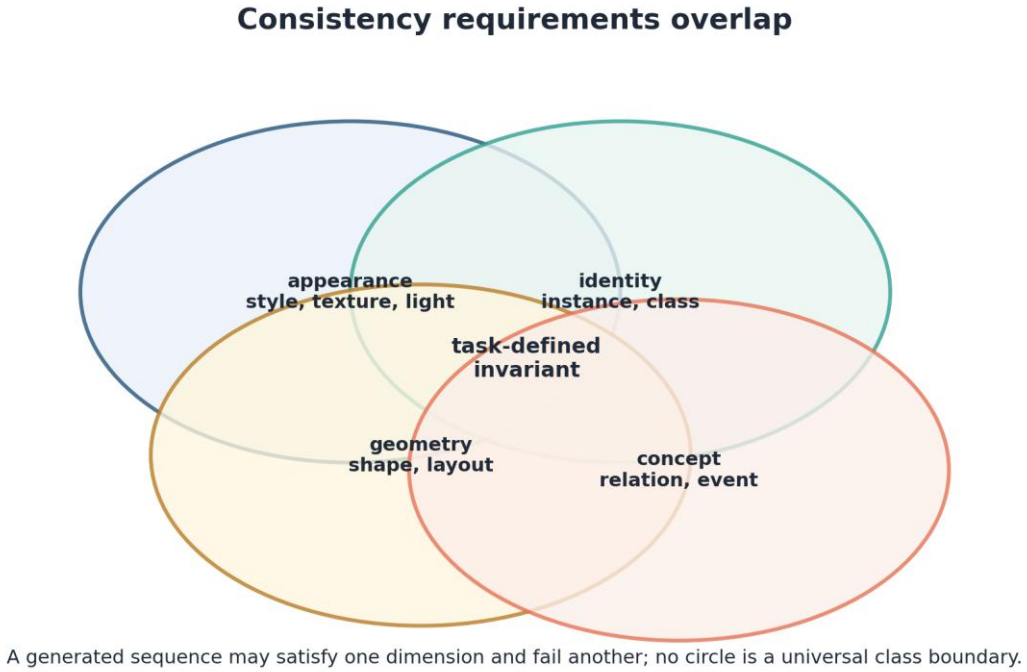


Рисунок 1.7 – Критерії консистентності, що перекриваються. *Джерело: синтез, розроблений на основі дисертації з урахуванням [133].*

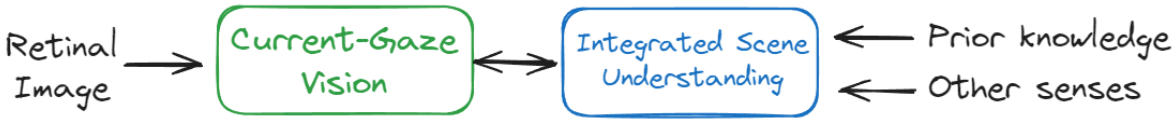


Рисунок 1.8 – Локальний візуальний вхід та інтегроване розуміння сцени. *Джерело: Кулик та Мокін [133], оригінальний рисунок 5; ілюстрація виконана Л. Куликом, концептуально заснована на роботі Герцмана [174]; використано за ліцензією CC BY 4.0. Евристична ілюстрація.*

Таблиця 1.2 – Критерії консистентності, спостережувані помилки та «сліпі зони» метрик. Жоден показник не розглядається як повна заміна інших.

Критерій	**Типова помилка у згенерованому відео**	**Типовий показник**	**Що може пропустити показник**
Зовнішній вигляд/стиль	відхилення кольору, текстури або освітлення	схожість ознак або стилю	правильний результат з неправильною ідентифікацією об’єкта
Ідентичність	об’єкт змінює клас або екземпляр після оклюзії	точність ідентифікації на основі зіставлення	просторове покриття може залишатися неправильним
Геометрія/просторове покриття	контур руйнується, об’єкт зникає або з’являється зайвий передній план	перекриття, покриття, прецизійність/повнота, частки пропусків і зайвого переднього плану	дрібні атрибути всередині області об’єкта
Поняття/семантика	послідовність суперечить передбачуваному відношенню або події	класифікатор завдань, структуроване відношення або протокол людини	часова безперервність та локалізація
Траєкторія	рух плавний, але проходить неправильним шляхом	похибка центроїда або пози з часом	зовнішній вигляд та внутрішня структура

Критерій	Типова помилка у згенерованому відео	Типовий показник	Що може пропустити показник
Міжрівнева консистентність	грубий стан і детальний прогноз описують різні події	декодована міжрівнева розбіжність	обидва рівні можуть бути помилковими одночасно

Інтерфейси керування відрізняються моментом і способом внесення зовнішньої інформації: через вхід, внутрішній стан або адаптацію параметрів. У режимі «зображення-до-зображення» еталон подається під час кожної генерації [95]. DreamBooth і LoRA натомість кодують об’єкт або стиль шляхом прямої адаптації параметрів моделі [96, 97]. Повторювану ідентичність тоді можна генерувати без передавання повного еталону, але потрібні додаткові дані й ресурси для оптимізації. ControlNet вносить керувальний сигнал у вигляді країв, глибини, пози або сегментації [98]. Методи інверсії відновлюють представлення наявного зображення у прихованому або шумовому просторі й використовують його як початкову точку керування [114, 115]. StyleAligned та споріднені методи пов’язують ознаки уваги між зразками і допускають поєднання з іншими керувальними сигналами [99]. Для довгогоризонтного прогнозування визначальним є не загальний рейтинг цих підходів, а те, чи залишається їхнє свідчення доступним після виходу відповідного кадру з поточного вікна.

1.2.3 Часова та траєкторна консистентність

Розглянуті вище критерії сформовано переважно для статичних зображень. У відео до них додаються дві часові вимоги. По-перше, зміни між сусідніми кадрами мають бути неперервними. По-друге, вся послідовність повинна відтворювати очікувану динаміку: напрям і швидкість руху, збереження стану під час оклюзії та правильну повторну появу на довгому горизонті.

Локальна плавність не гарантує правильності довгої траєкторії. Невелике зміщення на кожному кадрі може не створювати помітного стрибка, але поступово відвести об’єкт від еталонного шляху. Так само об’єкт може зникнути й плавно з’явитися знову, проте вже з іншими ознаками ідентичності. Отже,

часова неперервність є необхідною, але недостатньою умовою консистентного прогнозу.

Щоб відокремити правильність руху від плавності зображення, для кожного об’єкта i розглядається множина моментів $\mathcal{T}_i$, у яких еталонний і прогнозований об’єкти можна зіставити. Нехай c_{it} і $\hat{c}_{it}$ позначають їхні еталонний та прогнозований центроїди в момент t. Середня похибка траєкторії визначається як:

$$L_{\text{traj}}^{(i)} = \frac{1}{|\mathcal{T}_i|} \sum_{t \in \mathcal{T}_i} \left\| \hat{c}_{it} - c_{it} \right\|_2. \tag{1.9}$$

Формула (1.9) враховує просторове зміщення між зіставленими об’єктами, але сама не виявляє підміни їхніх ідентичностей. Тому правило зіставлення має бути стабільним у часі або явно враховувати ідентичність. Класифікатор ідентичності розв’язує іншу частину задачі: він може правильно розпізнати цифру, навіть якщо її положення суттєво помилкове. Лише спільне використання показників покриття, зіставлення, ідентичності та траєкторії дає змогу інтерпретувати поведінку об’єкта, що зберігається в часі.

Окреме правило потрібне для зниклого або незіставленого об’єкта. Якщо такі випадки просто вилучати з підрахунку, модель може отримати сприятливу оцінку ідентичності саме тоді, коли вона втратила об’єкт. У подальшому протоколі для них наперед задаються штрафи, а метадані генератора зберігають справжню ідентичність упродовж кліпу. Контекст до моменту зникнення містить прямі свідчення зовнішнього вигляду; тому повторна поява перевіряє, чи зберегла й використала їх модель. Парні порівняння та кілька початкових значень генератора випадкових чисел оцінюють стійкість результату, а еталон із прямим доступом до необробленої історії задає верхню межу доступності інформації [125].

Рисунок 1.9 узагальнює п’ять типових відмов: зміну зовнішнього вигляду, підміну ідентичності, втрату просторового покриття, відхилення траєкторії та появу зайвого переднього плану. Кожна з них може виникнути за поверхнево плавної послідовності, тому потребує окремого показника.

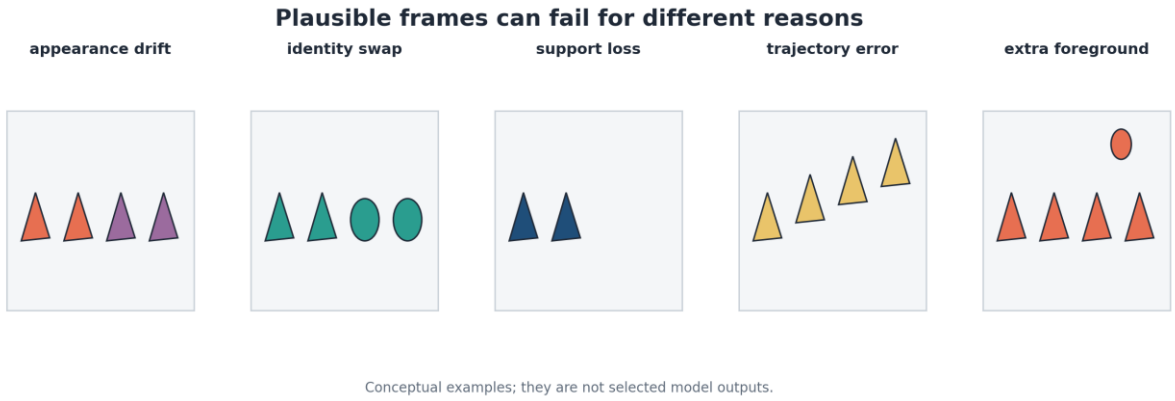


Рисунок 1.9 – Різні типи відмов із поверхнево правдоподібними кадрами.

Для бінарної еталонної маски переднього плану G_t та прогнозованої маски P_t одного показника перекриття недостатньо. Зокрема, порожні маски потребують окремого правила, а зайвий прогноз поза еталонною областю має штрафуватися так само явно, як пропущений об’єкт. Для непорожньої еталонної маски використовуються нормовані відносно її площі частки пропущеного й зайвого переднього плану:

$$r_{\text{miss}}(t) = \frac{|G_t \setminus P_t|}{|G_t|}. \tag{1.10}$$

У формулі (1.10) множина $G_t \setminus P_t$ містить еталонні пікселі, які модель пропустила. Частка зайвого переднього плану визначається окремо як $r_{\text{extra}}(t) = |P_t \setminus G_t|/|G_t|$ і враховує передбачені пікселі без еталонного відповідника. Обидві частки дорівнюють нулю лише тоді, коли відповідної помилки немає; r_{extra} може перевищувати одиницю, якщо зайва область більша за еталонний об’єкт. Рисунок 1.10 показує, як ці просторові показники доповнюють, але не замінюють оцінювання траєкторії та ідентичності.

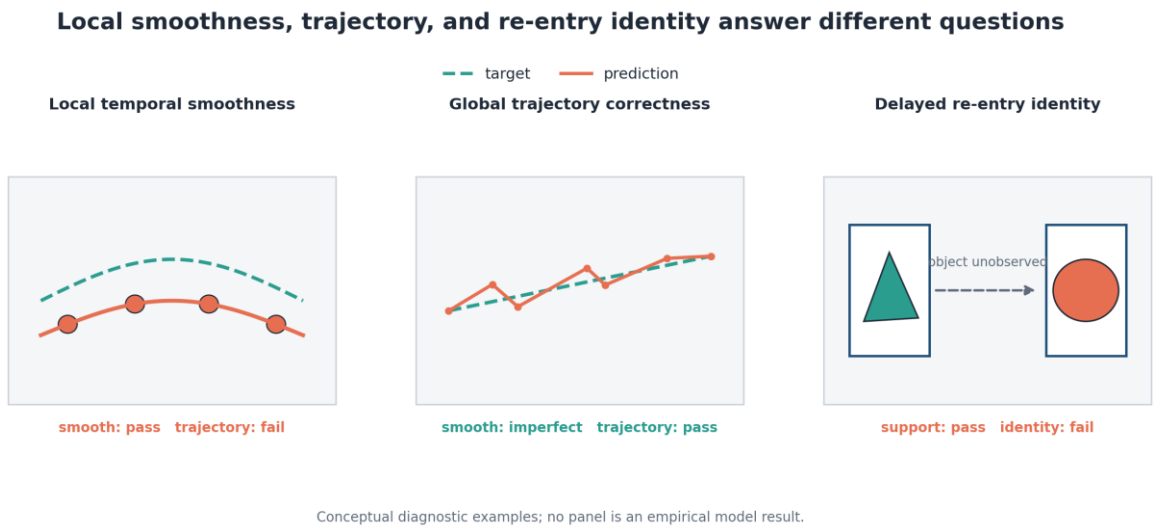


Рисунок 1.10 – Операціональне розмежування часової плавності, правильності траєкторії та ідентичності повторного входу. *Джерело: концептуальний рисунок з дисертації.*

Отже, довга часова консистентність потребує не лише плавного декодування кадрів, а й доступу до свідчень, які могли зникнути з недавнього вікна. Ієрархічний контекст може розширити такий доступ за обмеженого бюджету, зберігаючи давні кадри у грубішому представленні. Водночас поява кількох рівнів породжує нову вимогу: грубий стан і детальний прогноз мають описувати ту саму подію.

1.2.4 Ієрархічна та міжрівнева консистентність

Ієрархія додає до оцінювання ще один вимір, але лише тоді, коли система має чітко визначені рівні та відоме відображення між ними. Потрібно встановити, які рівні представляють ту саму подію, як співвідносяться їхні часові й просторові координати та яку інформацію зберігає проєкція для порівняння. Багатомасштабні архітектури демонструють користь повільних і швидких або грубих і детальних представлень [20, 35–37, 150], проте сама наявність цих рівнів не гарантує їхньої взаємної консистентності.

Нехай z_t^c і z_t^f є станами грубого та детального рівнів у момент t, а D_c і D_f – відповідними декодерами. Оскільки їхні просторові розміри можуть відрізнятися, оператор $\mathcal{S}$ приводить детальний результат до масштабу грубого рівня. Тоді міжрівневу розбіжність можна записати через функцію відстані d:

$$L_{\text{cross}}(t) = d\Big(D_c(z_t^c), \mathcal{S}(D_f(z_t^f))\Big) \tag{1.11}$$

Найпростіша ієрархія має два рівні: грубий рівень зберігає структуру сцени або давнішу історію, а детальний уточнює локальні ознаки. Трирівнева схема додає проміжне представлення, яке може пом’якшити різкий перехід між масштабами, але водночас збільшує кількість інтерфейсів, на яких можлива суперечність. Формула (1.11) безпосередньо описує дві шкали; для трьох і більше рівнів аналогічні розбіжності обчислюються між сусідніми або наперед визначеними парами.

Для ієрархічної моделі в роботі визначено три перевірки. Спочатку кожен рівень оцінюється за властивістю, яку він має зберігати: грубу карту заповнення, наприклад, не можна штрафувати за відсутність дрібної текстури. Далі перевіряється інформація, спільна для рівнів. Нарешті, детальний вихід порівнюється з еталонними даними, адже внутрішньо консистентна ієрархія все одно може описувати неправильне майбутнє. У завершених експериментах основний висновок спирається на декодовані показники та ефекти для конкретних пар пакетів. Формула (1.11) задає можливий міжрівневий критерій, але без окремого зареєстрованого тесту він не подається як емпіричний результат.

Рівні ієрархії виконують неоднакові інформаційні функції, тому мають оцінюватися різними групами показників. Для грубого рівня першочерговими є збереження просторового покриття, положення та напряму траєкторії; для детального рівня — ідентичність, форма, контур і локальна текстура. Агрегований показник похибки кадру може бути корисним для загальної перевірки якості, але не доводить одночасного збереження обох груп властивостей. Через це результати розділу 4 подаються як профіль взаємодоповнювальних метрик, а не як один універсальний рейтинг конфігурацій.

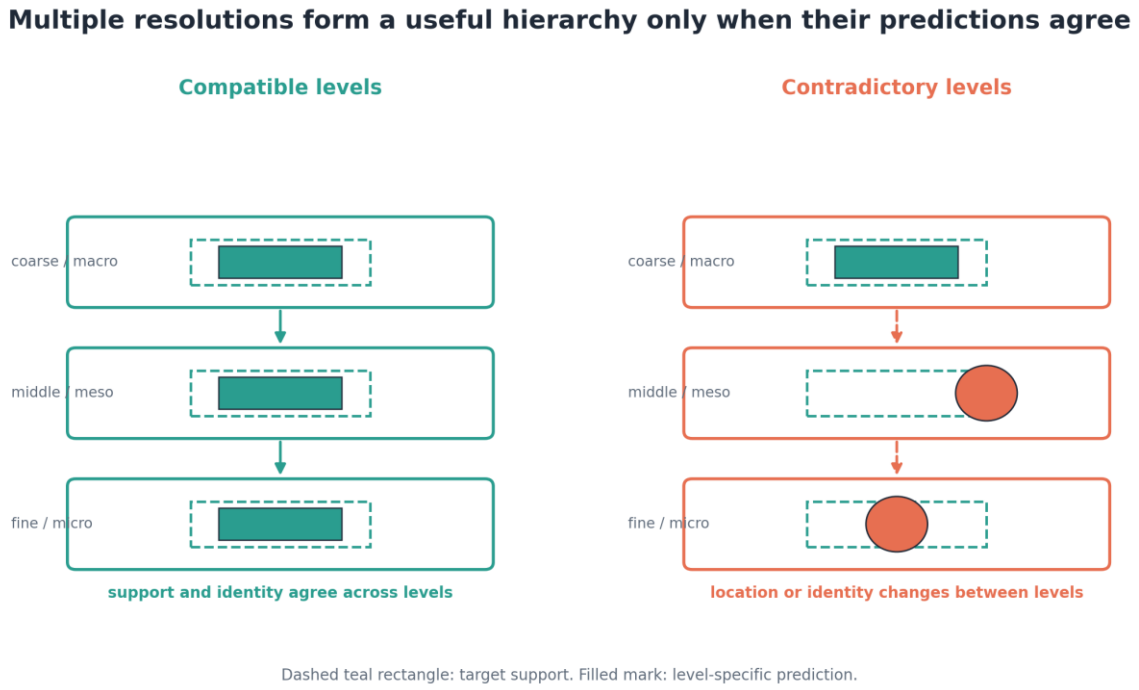


Рисунок 1.11 – Консистентні та суперечливі прогнози на різних рівнях представлення. Наявність кількох рівнів деталізації створює проблему відповідності; вона не гарантує, що грубі й детальні результати описують ту саму подію. *Джерело: концептуальний рисунок із дисертації.*

У дисертації досліджено дві різні реалізації ієрархічного принципу. V-BLT у розділі 2 розподіляє обробку одного растрово-байтового представлення між локальним і глобальним рівнями. Модель розділу 3 натомість зберігає грубу й детальну часові історії для розширення досяжності контексту. Їх поєднує залежність розподілу ємності від масштабу, але вони не мають спільного тензорного шляху й не перевірялися як одна наскрізна архітектура.

1.2.5 Від статичних критеріїв контролю до вимог до відео

Критерії статичного зображення зберігають значення у відео, але змінюється спосіб їх перевірки. Зовнішній вигляд та ідентичність оцінюються в часі, зокрема після оклюзії або повторної появи. Геометричний критерій поширюється на просторове покриття, контур і рух. Семантична ідея вже не обмежується одним кадром, а набуває форми події чи відношення, що розгортається в послідовності. Модель автономного прогнозування не отримує структуру майбутнього наперед і має вивести її з динаміки та збереженого стану.

На рисунку 1.12 показано, як критерії статичних зображень розширюються на відео. Еталонний кадр визначає зовнішній вигляд або ідентичність у певний момент, але перевірка може відбутися значно пізніше, після авторегресивного

розгортання. Упродовж цього інтервалу модель отримує власні виходи, а доступні свідчення послідовно входять до контексту й залишають його. Тому траєкторія та повторна поява є часовими конструкціями. Міжрівнева консистентність додається лише для моделей із кількома явно визначеними рівнями представлення.

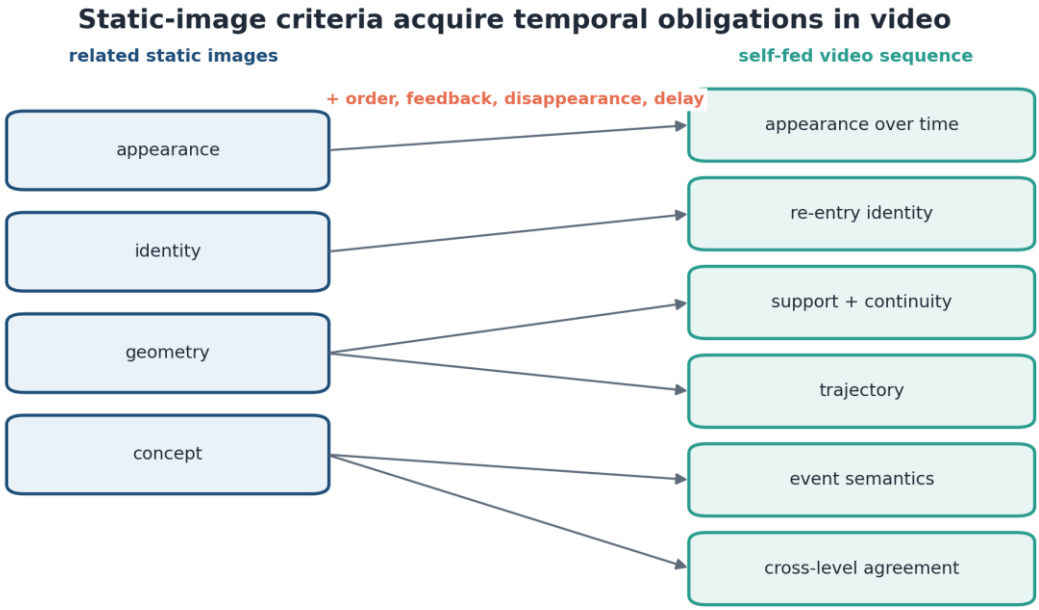


Рисунок 1.12 – Від інваріантів статичних зображень до вимог до відео. *Джерело: синтез на основі дисертації.*

У дифузійній моделі виникає ще одна координата, яку не можна ототожнювати з фізичним часом відео. Рисунки 1.13–1.15 послідовно показують зашумлення навчального зразка, ітеративне усунення шуму та загальну схему генерації у прихованому просторі [2, 3]. На рисунку 1.15 текст задає умову, процес дифузії уточнює один стан прихованого простору, а декодер перетворює його на статичне зображення.

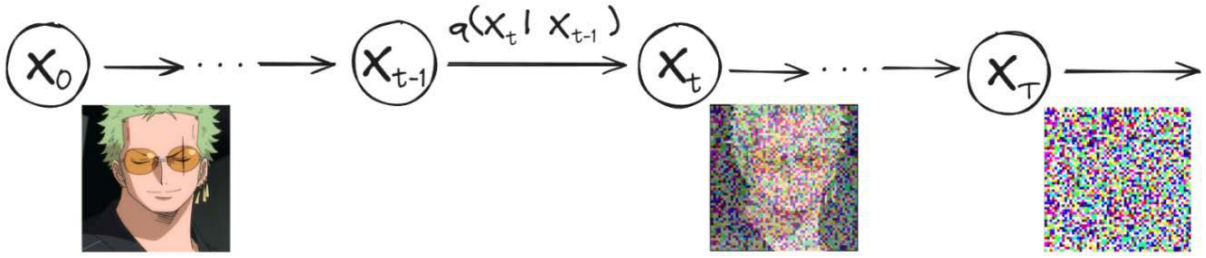


Рисунок 1.13 – Пряма дифузія як прогресивне спотворення. *Джерело: Кулик та Мокін [133], оригінальний рисунок 2; відтворено без змін.*

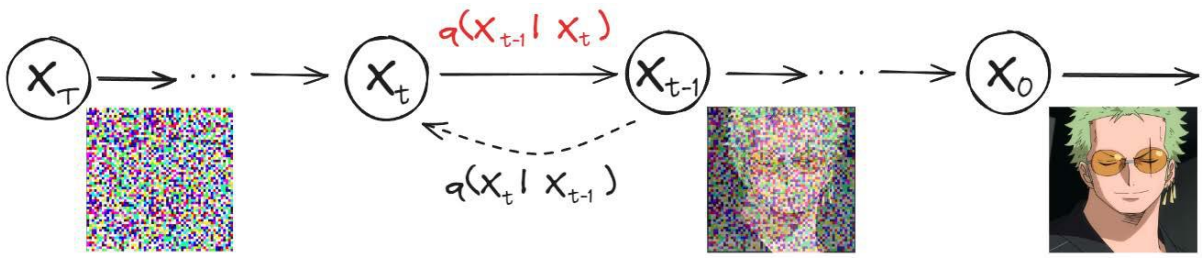


Рисунок 1.14 – Зворотна дифузія як ітеративне усунення шуму. *Джерело: Кулик та Мокін [133], оригінальний рисунок 3; відтворено без змін.*

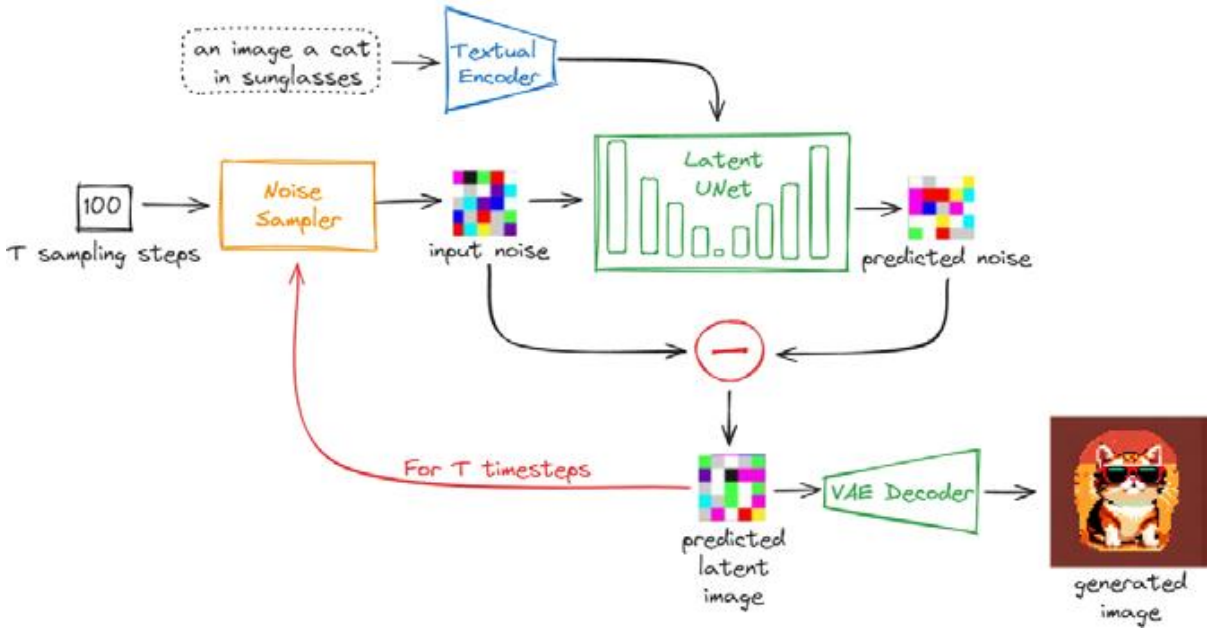


Рисунок 1.15 – Загальний обчислювальний тракт генерації на основі дифузії у прихованому просторі. *Джерело: Кулик та Мокін [133], оригінальний рисунок 4; відтворено без змін.*

Отже, крок дифузії та момент фізичного часу відео є різними сутностями. Перший індексує рівень шуму під час уточнення одного зразка, а другий – послідовні стани сцени. Модель відеодифузії містить обидві координати, тому збіжність циклу усунення шуму сама по собі не забезпечує часової консистентності між кадрами.

У статичній керованій генерації потрібне свідчення часто залишається доступним під час кожного запуску: це може бути еталонне зображення, текст, поза, контур або відновлений стан у прихованому просторі. В автономному відеопрогнозуванні майбутній кадр такої умови не надає. Тому статичні методи корисні тут не як готові розв’язки часової пам’яті, а як класифікація місць, де система може зберігати інформацію про бажаний результат: на вході, у параметрах, у структурній умові, у траєкторії прихованого простору або в механізмі уваги.

Рисунки 1.16–1.20 показують ці інтерфейси не як послідовні етапи одного методу, а як альтернативні способи передавання різних типів свідчень.

У підході «зображення-до-зображення» на рисунку 1.16 еталон безпосередньо задає вихідну структуру. Менше зашумлення сильніше прив’язує результат до джерела, тоді як більше допускає ширші зміни; жоден режим сам по собі не створює довготривалої пам’яті.

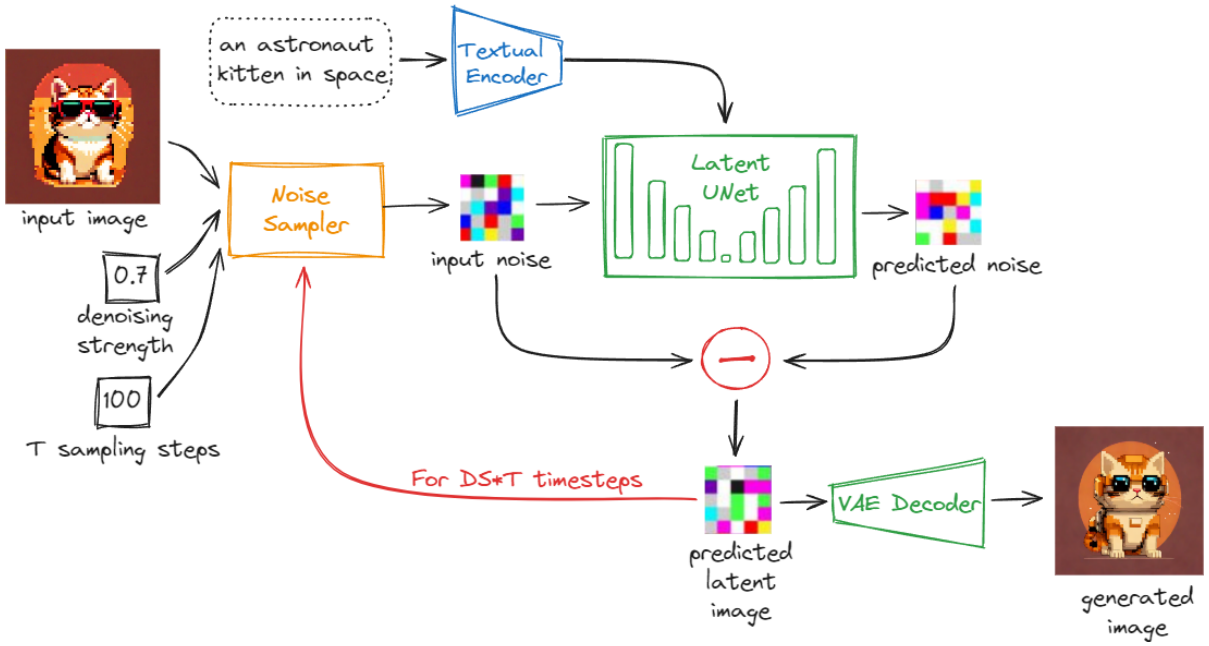


Рисунок 1.16 – Генерація «зображення-до-зображення» на основі еталону та рівня шуму. *Джерело: Кулик та Мокін [133], оригінальний рисунок 6; відтворено без змін.*

ControlNet переносить керувальний сигнал в окрему структурну гілку. Контур, карта глибини або поза безпосередньо обмежують геометрію результату, але не визначають усі ознаки конкретного об’єкта. Ця різниця між відповіддю на питання «де і якої форми?» та «що саме?» згодом використовується для тлумачення межі між просторовим покриттям та ідентичністю.

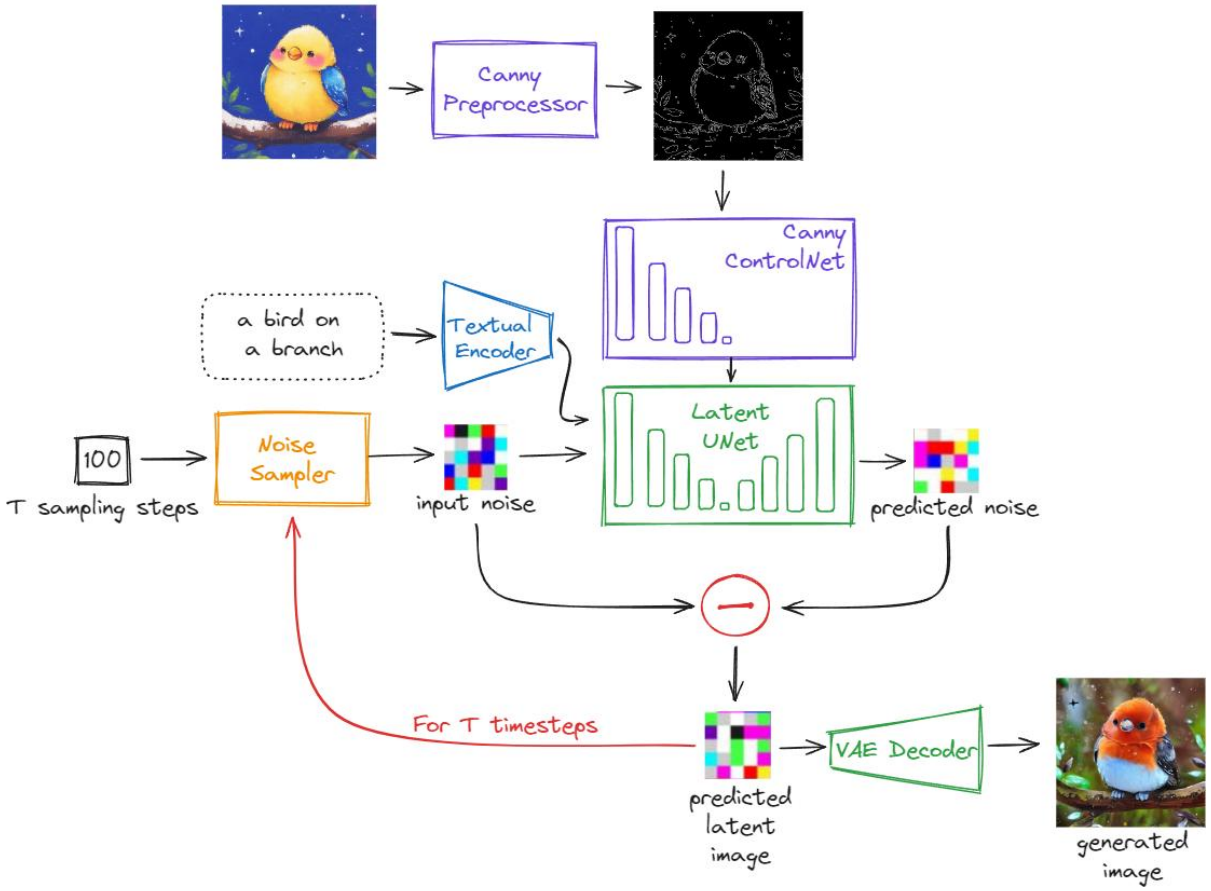


Рисунок 1.17 – Структурне обумовлення контролює геометрію більш безпосередньо, ніж ідентичність. *Джерело: Кулик та Мокін [133], оригінальний рисунок 7; відтворено без змін.*

Метод інверсії, зображений на рисунку 1.18, прив’язує редагування до конкретного джерела сильніше, ніж вільне генерування. За це доводиться сплачувати похибкою реконструкції та додатковою роботою з оптимізації або відновлення шумового стану [114, 115].

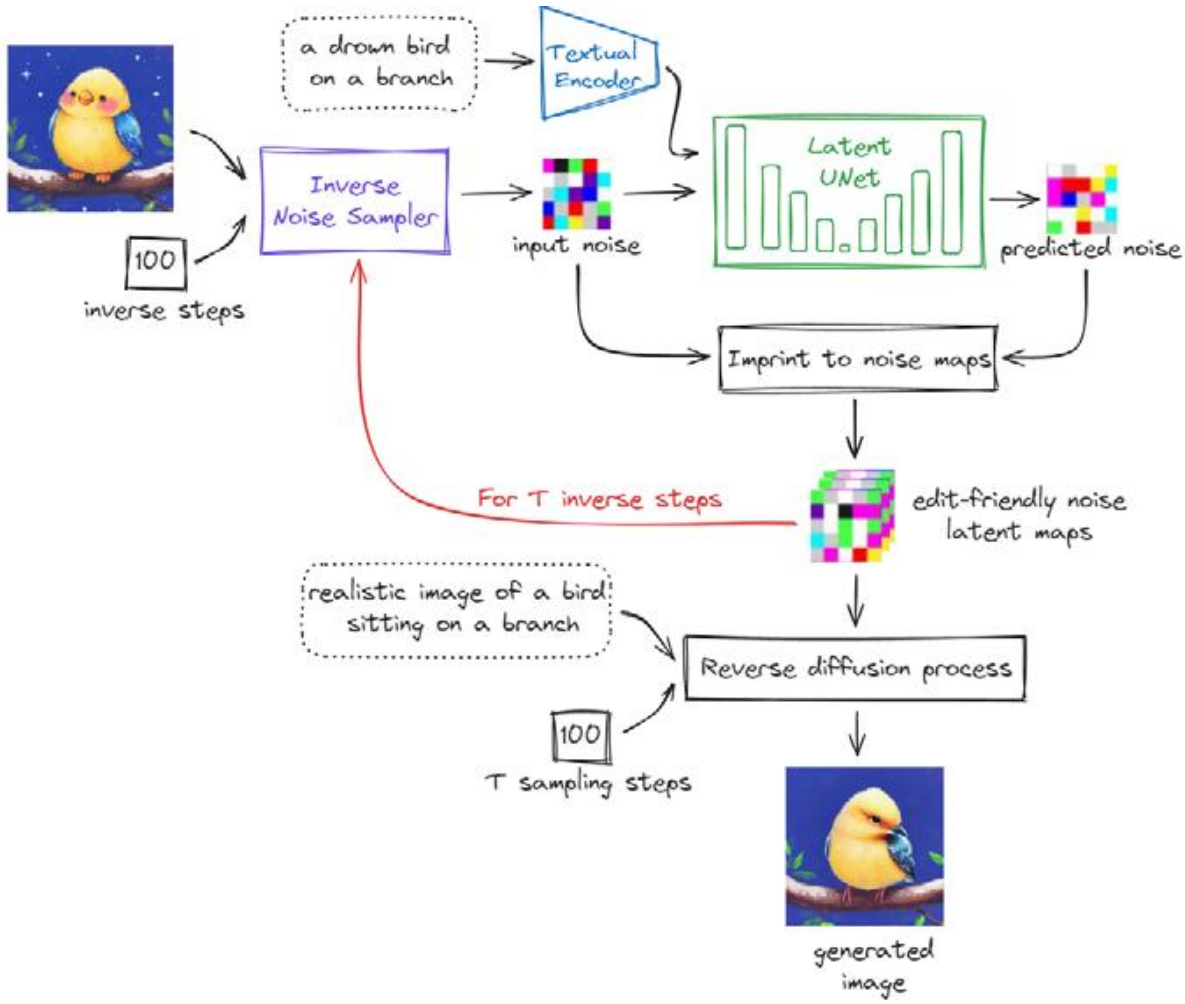


Рисунок 1.18 – Управління на основі інверсії через відновлену траєкторію у прихованому просторі. *Джерело: Кулик та Мокін [133], оригінальний рисунок 8; відтворено без змін.*

Інший інтерфейс керування не фіксує геометрію конкретного зразка, а пов’язує ознаки між кількома генераціями. У StyleAligned спільна увага підтримує подібність стилю для різних об’єктів, що показано на рисунку 1.19. Такий механізм зберігає вибрану інваріантну властивість, але не гарантує тотожності змісту або траєкторії.



Рисунок 1.19 – Спільний стиль для різних суб’єктів. *Джерело: Кулик та Мокін [133], оригінальний рисунок 9; відтворено без змін.*

Порівняння цих прикладів виявляє принципову межу. Контур або поза можуть бути задані точно, тоді як ідентичність усередині заданої області може

змінитись. І навпаки, адаптовані параметри можуть зберігати зовнішній вигляд об’єкта, не визначаючи його майбутнього положення.

Для відеопрогнозування ця відмінність переходить у пару «просторове покриття – точність ідентичності», яку надалі оцінено окремими показниками. Еталонний вхід, адаптація параметрів, структурна умова, інверсія та спільна увага зберігають різну інформацію й потребують різних витрат під час налаштування або застосування.

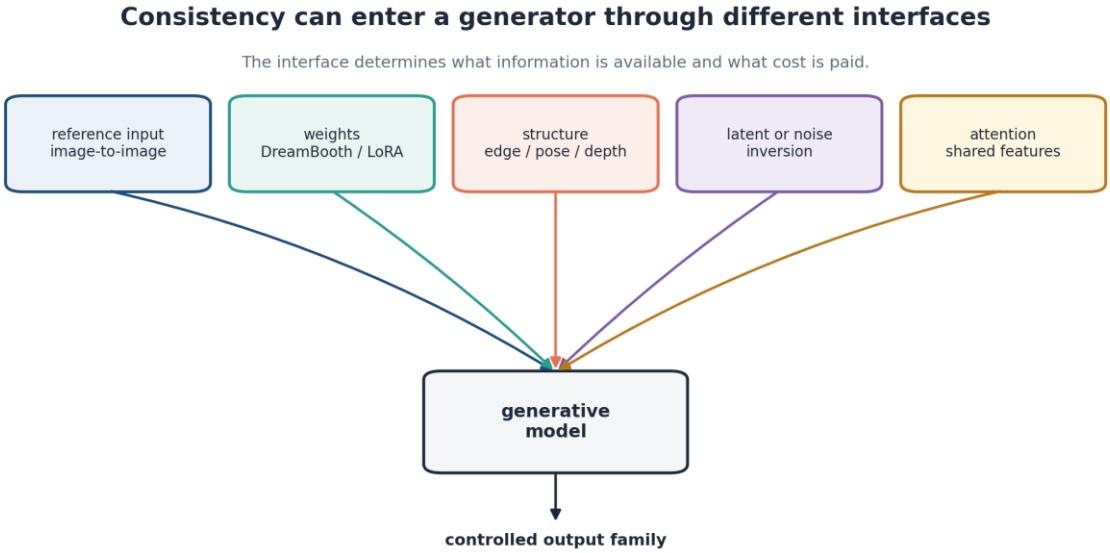


Рисунок 1.20 – П’ять інтерфейсів для контролю пов’язаних генерацій.

Схема на рисунку 1.20 узагальнює не назви моделей, а п’ять місць внесення керувальної інформації. Вона дає змогу поставити однакове запитання до кожного методу: яке свідчення доступне під час генерації, де воно зберігається і яку властивість може підтримати? Відповідь не завжди охоплює весь об’єкт. Правильне розташування може співіснувати з неправильною ідентичністю, тоді як ідентичність може зберігатися попри порушену просторову неперервність. Це розрізнення мотивує показники для об’єктів, що зберігаються в часі, не приписуючи статичним і часовим методам спільного причинного механізму.

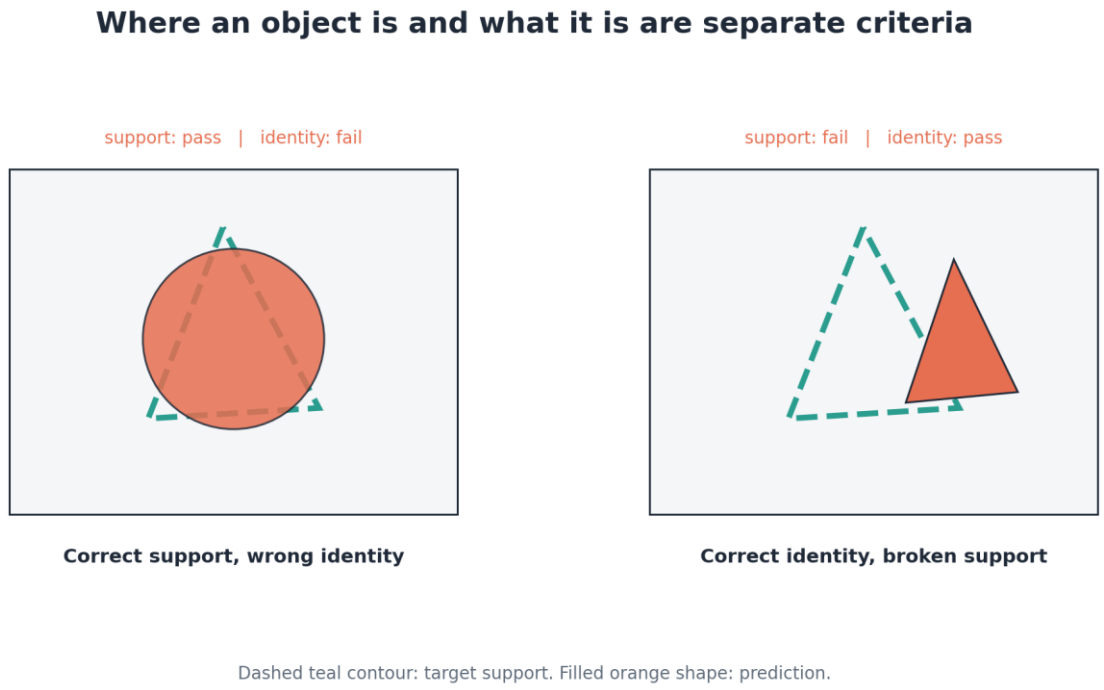


Рисунок 1.21 – Просторове покриття та ідентичність як незалежні осі.

Порівняння методів має враховувати не лише збережену властивість, а й доступну інформацію. Якщо генератор отримує майбутню позу або контур, він використовує привілейоване свідчення, якого немає в автономному прогнозі. Адаптація параметрів та інверсія також зберігають відомості в різних частинах системи й потребують різних обчислень. Тому висновок про пам’ять є коректним лише тоді, коли явно зафіксовано, що модель знала на момент прогнозування.

Оцінювання починається з перевірки доступності потрібного свідчення; лише після цього помилку можна пов’язувати з пам’яттю пакета. Просторове покриття та зайвий передній план показують, чи збережено область об’єкта, а зіставлена ідентичність і траєкторія – чи збережено саме той об’єкт і його рух. Кадрові та перцептивні показники залишаються доповнювальними. Такий порядок не дозволяє високому агрегованому балу наперед визначити інтерпретацію результату. Подібна вимога діє й для пояснюваності: пояснення має цінність лише тоді, коли його структура та роль у рішенні задані явно [39, 40].

1.3 Вузькі місця довгогоризонтної неконсистентності

Попередній підрозділ визначив типи помилок, а цей пов’язує їх із трьома різними ресурсними причинами. Спочатку розглядається пам’ять активацій довгого диференційованого процесу, потім нерівномірний розподіл просторової інформації та, нарешті, обмежена досяжність збереженої історії. Завершальна карта показує, яке втручання й який доказ належать кожному вузькому місцю.

1.3.1 Зростання пам’яті під час навчання часових моделей

Часову модель можна навчати щонайменше у двох режимах. Трансформер здатний одночасно опрацювати все навчальне вікно з каузальною маскою; тоді часові позиції утворюють широку послідовність у межах одного прямого проходу. Інший режим відтворює сам процес застосування: вихід одного кроку переходить на вхід наступного, а повторне використання модуля створює довгий рекурентний граф. TempVerseFormer використовує трансформерні блоки всередині часової моделі, але його реверсивне відтворення стосується саме повторюваного стану, через який передається градієнт.

Зворотне поширення в часі (BPTT, *backpropagation through time*) розгортає рекурентний процес у спрямований ациклічний граф [28, 29, 105]. Нехай один часовий крок створює набір активацій обсягом A, потрібний для локального обчислення градієнта, а K позначає кількість диференційованих кроків. Якщо всі такі набори зберігаються до зворотного проходу, їхня пам’ять зростає у першому наближенні як:

$$M_{\text{act}}^{\text{BPTT}}(K) = \Theta(KA), \tag{1.12}$$

Формула (1.12) описує лише часову стрічку активацій: параметри, градієнти, стан оптимізатора та робочі буфери залишаються окремими складниками. Рисунок 1.22 показує, як кожен новий крок додає до стрічки ще один набір проміжних значень, якщо їх не відтворювати повторно.

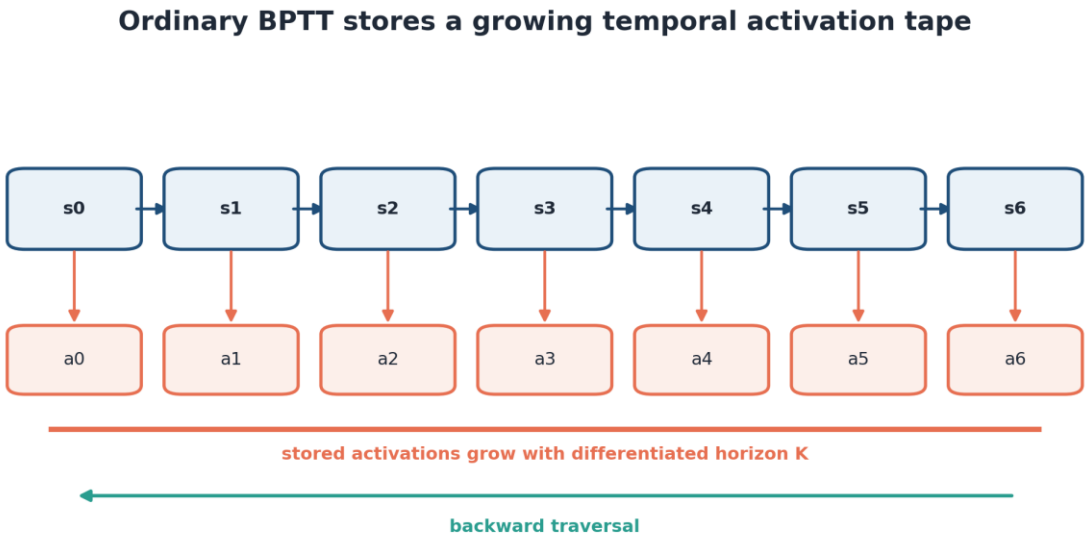


Рисунок 1.22 – Зростання стрічки активацій під час часового зворотного поширення.

Найпростіший спосіб обмежити пам’ять полягає в усіченні BPTT: стан між сегментами передається вперед, але градієнт зупиняється на їхніх межах. Це зменшує довжину графа, проте віддалені залежності вже не впливають на ранні кроки оптимізації. Збереження контрольних точок має інший компроміс. У пам’яті залишаються лише вибрані граничні стани, а внутрішні ділянки графа повторно обчислюються під час зворотного проходу [30, 31, 108, 109]. За незмінного графа та детермінованого відтворення цільова функція не змінюється, але зростає обчислювальна робота.

Реверсивне з’єднання використовує структуру самого блока. Якщо його вхід можна відновити з виходу, проміжні активації не потрібно зберігати впродовж усього прямого проходу [32, 92]. Під час зворотного поширення вони реконструюються безпосередньо перед обчисленням локального градієнта, а потім звільняються. Такий механізм не робить увесь обчислювальний тракт оберненим: нереверсивні проєкції, кодер, декодер і межі функції втрат усе одно потребують окремого обліку. У розділі 2 цей компроміс досліджено на прикладі TempVerseFormer.

Контрольною змінною в такому порівнянні є диференційований горизонт, а не лише кількість згенерованих кадрів. Усічення змінює шлях градієнта, контрольні точки змінюють правило зберігання й повторного обчислення, а

реверсивне ядро відновлює лише стани в межах заявленого оборотного інтерфейсу. Тому практичне порівняння має вимірювати пікову пам’ять і час за однакових горизонту, розміру пакета, числової точності та інтерфейсу моделі. Інакше скорочення часової стрічки може бути приховане сталими витратами, які не залежать від досліджуваного механізму.

1.3.2 Просторовий розподіл токенів у кадрі

Більшість візуальних трансформерів перетворює кадр на регулярну сітку прямокутних, часто квадратних, фрагментів. Вони можуть не перекриватися або частково перекриватися; у відео до просторових розмірів іноді додається часовий розмір. Фіксована сітка проста, придатна до паралельної обробки й забезпечує передбачувану довжину послідовності [69–71]. Для T кадрів розміру $H \times W$ і неперекривних просторових патчів $p_h \times p_w$ кількість токенів становить:

$$N_{\text{fixed}} = T \left\lceil \frac{H}{p_h} \right\rceil \left\lceil \frac{W}{p_w} \right\rceil. \tag{1.13}$$

Округлення вгору враховує крайові області, розмір яких не кратний розміру патча. Формула (1.13) також показує обмеження фіксованої сітки: кількість токенів визначається геометрією кадру, а не інформаційною складністю окремих областей.

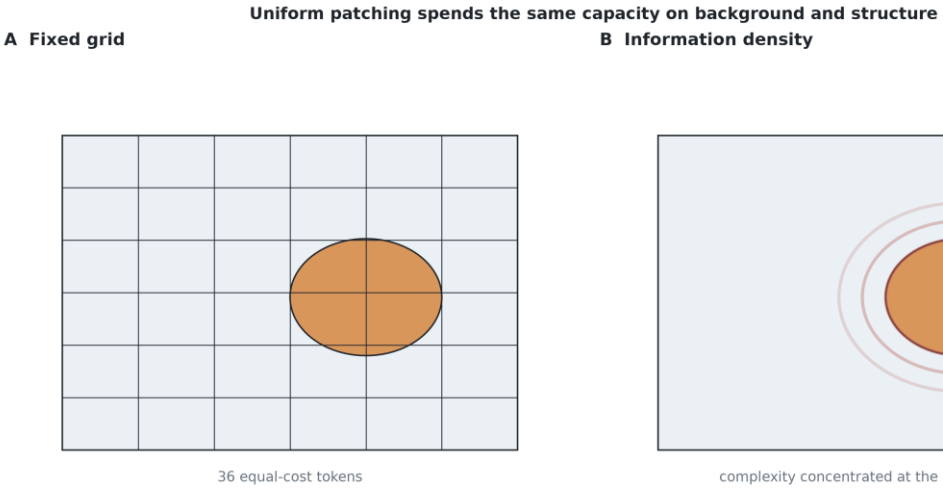


Рисунок 1.23 – Рівномірний просторовий розподіл на нерівномірній сцені.

Рисунок 1.23 ілюструє цю невідповідність. Однорідний фон може займати більшу частину кадру й отримувати більшість токенів, хоча складна межа рухомого об’єкта потребує детальнішої обробки. Отже, просторова щільність інформації потенційно може керувати розподілом як пам’яті, так і обчислень. У цій роботі як сигнал локальної складності розглянуто прогнозну ентропію V-BLT; вона може керувати вибором розміру регіонів або частоти їх обробки, але динамічний розподіл не належить до підтверджених результатів опублікованого методу.

У категоріальній моделі таким сигналом може бути прогностична ентропія. Для сталої й добре передбачуваної області розподіл вихідного байта концентрується, тоді як біля рухомої межі або за кількох можливих майбутніх станів він стає ширшим. Проте висока ентропія може виникати також через недостатню модель, обмежений контекст або мультимодальність. Тому вона не є автоматично каліброваною невизначеністю і сама по собі не доводить, що адаптивна сітка поліпшить співвідношення між якістю та вартістю.

Динамічний розподільник додатково потребує правил причинного агрегування, фіксованого обчислювального бюджету, операцій маршрутизації та об'єднання, а також наскрізного порівняння з тією самою моделлю на фіксованій сітці. У V-BLT цей етап не реалізовано. Перевірено фіксовані пакети растрових байтів, багатовимірне позиційне кодування та відтворювані карти ентропії. Ці карти мотивують майбутню адаптацію, але поки що залишаються виміряним сигналом, а не доведеною політикою розподілу.

У локально–глобальній ієрархії V-BLT є й другий розподіл: локальні модулі обробляють детальні байти, а глобальний модуль працює зі стислим набором представлень патчів. Це скорочує глобальну послідовність, але реальна економія залежить також від локальної роботи, переміщення даних, використання апаратних ресурсів і форми пакета, а не лише від заявлених GFLOPs. Опубліковані точкові оцінки підтверджують працездатність архітектури, але не встановлюють універсального закону масштабування [44, 45].

1.3.3 Обмежена досяжність збереженого контексту

Просторова ієрархія визначає, скільки деталей обробляється всередині кадру. Для довгогоризонтного прогнозування постає інше питання: наскільки давню подію взагалі може адресувати збережений контекст. Нехай у момент прогнозування t пакет C_t містить кадри або рівні, прив'язані до множини початкових моментів $\mathcal{A}_t$. Номінальна досяжність пакета визначається віком найдавнішої з цих прив'язок:

$$R(C_t) = t - min_{\tau \in \mathcal{A}_t} \tau. \tag{1.14}$$

Формула (1.14) описує геометричну можливість доступу, а не якість збережених даних. Якщо подія відбулася раніше за $t - R(C_t)$, пакет не містить прямої прив'язки до неї. Якщо вона входить у цей інтервал, модель усе одно може втратити потрібні деталі під час стискання або не використати доступне свідчення. Рисунок 1.24 показує перший, найпростіший випадок: релевантний кадр уже залишив коротке щільне вікно.

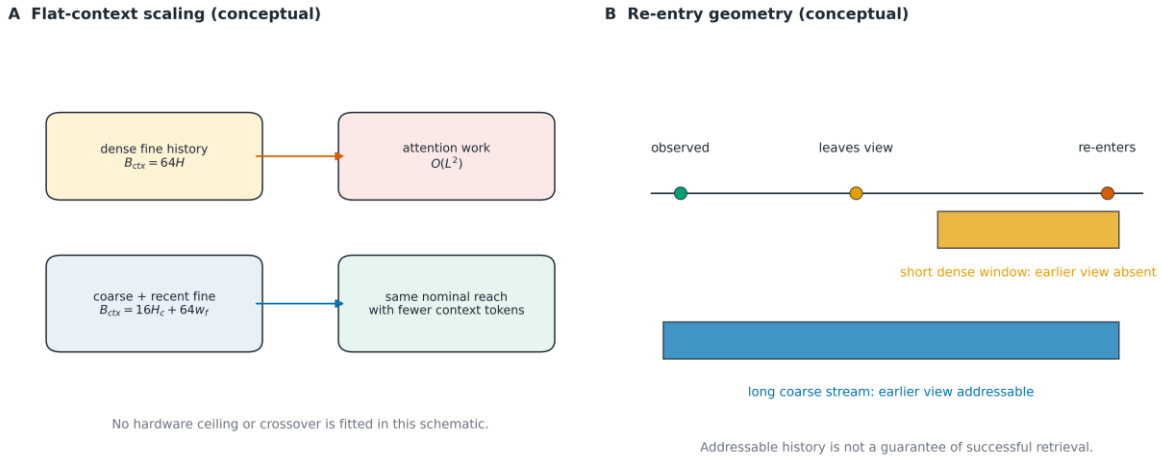


Рисунок 1.24 – Релевантне спостереження поза щільним вікном детального контексту.

За фіксованої кількості токенів досяжність і деталізація конкурують. Пакет може зберігати більше давніх кадрів у грубому масштабі або менше недавніх кадрів у детальному масштабі; часовий відбір також може бути рідшим. Тому два пакети однакового розміру здатні адресувати різні події через різну геометрію прив'язок. Якщо об'єкт залишається в межах недавнього вікна, довший контекст може не давати користі. Якщо релевантна подія передує досяжності обох пакетів, жоден із них не має інформаційної переваги. Саме тому агрегована якість є допоміжним доказом, а причинний тест потребує популяції, де досяжність пакетів справді відрізняється.

Сам факт зберігання даних ще не означає, що модель здатна їх використати. У межах авторської методики твердження про довготривалу пам'ять розкладається на три умови. Перша – **досяжність**: релевантне спостереження входить до фактичних прив'язок пакета. Друга – **точність відтворення**: грубий або розріджений рівень зберіг потрібну інформацію. Третя – **повторне використання**: модель застосувала доступне свідчення в прогнозі.

Геометрія встановлює лише першу можливість і не доводить безвтратного кодування чи успішного вилучення.

Звідси випливає умовний характер переваги ієрархії. Коли щільне вікно не досягає потрібної події, довгий грубий потік може зберегти її положення або загальний рух. Якщо обидва пакети вже охоплюють подію, визначальним стає обсяг збережених деталей. Тому дослідження не шукає універсальну архітектуру-переможця, а перевіряє окремі точки межі «досяжність–точність відтворення».

1.3.4 Системна карта вузьких місць і втручань

Попередні підрозділи виявили одну проблему та три обмеження її масштабування. Головним є дефіцит досяжності збереженого контексту: без доступу до віддаленої події неможливо підтримати її стан і траєкторію. Довше навчальне розгортання додатково збільшує стрічку активацій, а рівномірна просторова сітка витрачає детальну ємність без урахування локальної складності. Рисунок 1.25 зводить цей причинний порядок в одну карту.



Рисунок 1.25 – Карта причинно-наслідкових зв'язків дисертації.

Центральна гілка рисунка показує, які грубі та детальні фрагменти історії доступні під час прогнозування. Дві допоміжні гілки відображають спосіб передавання градієнта через часовий стан і локально–глобальне представлення растрових байтів із просторово-часовими координатами. У кожному випадку

ланцюг проходить від діагностованого обмеження через відповідне втручання до вимірюваного результату.

Основна доказова програма навмисно перевіряє втручання окремо: так перевагу форми контексту не можна сплутати зі зміною часового блока або просторового кодування. Сумісність інтерфейсів досліджується в інтеграційній перевірці, описаній у §3.7 і §4.9. Вона показує, що ієрархічний стан сталої ширини, просторове агрегування та реверсивне розгортання можуть працювати в одному прототипі, але не перетворює окремі оцінки витрат на автоматично мультиплікативну загальну економію.

Карта є причинною в методичному сенсі ланцюга «діагностика – втручання – вимірювання». Зростання пам’яті активацій перевіряється зі збільшенням диференційованого горизонту й вимірюється через пам’ять та час відтворення. Просторовий розподіл досліджується через фіксовану локально-глобальну обробку і структуру прогностичної ентропії. Досяжність контексту визначається геометрією прив’язок пакетів та популяціями повторної появи. Результат однієї гілки не підтверджує іншу, бо відрізняються змінна втручання, облік ресурсу й показник. Після незалежного аналізу перших двох гілок розділи 3 і 4 ізольовано перевіряють центральне питання: коли ієрархічне пакування контексту виправдовує втрату деталізації.

1.3.5 Просторова, часова та обчислювальна форми ієрархії

Ієрархічність у цій роботі не ототожнюється з одним типом блока. У просторовому вимірі повне грубе покриття кадру може доповнюватися вибірковим детальним представленням лише тих областей, для яких локальна інформаційна щільність є найбільшою. Така організація змінює розподіл токенів усередині кадру, але не обов’язково збільшує часову досяжність. Якщо загальний бюджет є фіксованим, зменшення просторової вартості окремого часового зрізу може вивільнити ємність для давніших спостережень, однак користь такого обміну має бути встановлена окремим експериментом.

У часовому вимірі роздільна здатність представлення розподіляється залежно від віку спостереження: недавні позиції можуть зберігатися детально, а

віддалені — грубіше або з більшим кроком. За однакової кількості токенів це безпосередньо змінює множину часових прив’язок у формулі (1.14). Для одного моменту часу грубий і детальний рівні можуть бути вкладеними, взаємовиключними або пов’язаними залишковим представленням. Вкладена схема дублює частину інформації на двох масштабах, взаємовиключна усуває таке дублювання, а залишкова зберігає грубу основу та кодує лише уточнення; їхня придатність залежить від того, чи компенсує точність уточнення витіснення інших часових позицій.

Обчислювальна ієрархія стосується не складу контексту, а способу виконання прямого та зворотного проходів. Реверсивне відтворення зменшує потребу у збереженні проміжних активацій усередині визначеного ядра, проте не розширює множину спостережень, доступних предиктору. Динамічний розподіл, навпаки, може змінювати те, які просторові області або часові позиції отримують детальне представлення за фіксованої квоти. За сталої кількості вибраних токенів він перевіряє якість розміщення обмеженої ємності, а не автоматичне зменшення загальної пам’яті.

Отже, втручання на карті рисунка 1.25 змінюють різні складники ресурсного балансу. Просторове агрегування впливає на кількість токенів у кадрі; часове пакування — на досяжність і точність відтворення історії; реверсивне ядро — на збережені активації під час навчання; динамічна маршрутизація — на розташування сталої квоти деталізації. Їхні ефекти не можна перемножувати без наскрізного вимірювання, оскільки сталі витрати кодера, декодера, оптимізатора й робочих буферів залишаються спільними для інтегрованої системи.

1.4 Аналіз існуючих методів

Огляд організовано не за назвами архітектур, а за тим, яким ресурсом або конструктом вони керують. Такий порядок дає змогу відокремити методи довгого часового моделювання від методів економії активацій, просторового перерозподілу токенів і збереження давньої історії, а наприкінці сформулювати прогалину, яку перевіряють наступні розділи.

1.4.1 Моделювання в часі з довгим горизонтом та навчання з ефективним використанням ресурсів

Методи прогнозування відео відрізняються не лише типом блока, а й способом організації часу. Рекурентні моделі послідовно оновлюють прихований стан, моделі з прямим просторово-часовим перетворенням обробляють навчальне вікно як один тензор, а трансформери представляють кадри або їхні фрагменти як послідовність з каузальними обмеженнями. Для довгого горизонту важливо розділяти два питання: яку історію зберігає модель під час прогнозування і через яку частину часового процесу проходить градієнт під час навчання.

Рекурентні відеопредиктори стискають попередні спостереження у прихований стан. ConvLSTM переніс операції LSTM у згортковий простір і дав змогу зберігати просторову структуру в часовому переході [137]. PredRNN і PredRNN++ розвинули окремі шляхи просторової та часової пам’яті, E3D-LSTM використав тривимірну рекурентну обробку, а PhyDNet розділив фізично інтерпретовану й залишкову динаміку [138–140, 152]. Спільною перевагою цього сімейства є компактний стан; спільним ризиком – поступова втрата конкретної давньої події всередині такого стискання.

Нерекурентні моделі показали, що сильний прогноз усередині фіксованого вікна не обов’язково потребує покрокового оновлення прихованого стану. SimVP використовує схему «кодер–часовий транслятор–декодер» [141], TAU поєднує просторову увагу з моделюванням часових змін [153], а Earthformer організовує взаємодії за допомогою кубоїдної уваги [142]. Трансформер відрізняється від класичної рекурентної моделі можливістю паралельно зіставляти позиції в навчальному вікні. Водночас той самий трансформерний модуль можна застосовувати рекурентно між послідовними станами або вікнами; саме така межа між трансформерним блоком і часовим ланцюгом мотивує TempVerseFormer у розділі 2.

Моделі світу розширюють це завдання від прогнозування кадрів до навчання внутрішньої динаміки, придатної для уявного розгортання й керування.

Частина таких моделей підтримує компактний рекурентний стан [64–67, 132], тоді як генеративні відеомоделі використовують варіаційні приховані змінні, авторегресію, дифузію або маскування [38, 42, 43, 50, 53–63, 74, 151, 156–158]. Їх зазвичай порівнюють за якістю прогнозу або керування. Пам’ять активацій і точна досяжність конкретної давньої події часто залишаються супутніми, а не центральними показниками.

Коротковіконне навчання обмежує диференційований граф, але не оптимізує повну багатокрокову втрату. Навчання за винагородою або її диференційованим наближенням змінює цільову функцію, проте саме по собі не визначає, як зберігати часові активації чи контекст [117, 118]. Якщо градієнт має проходити через довший ланцюг, виникає окремий системний вибір між збереженням, повторним обчисленням і реверсивним відтворенням станів. Отже, дослідницька прогалина полягає не у відсутності ще одного часового блока, а у вимірюванні того, який ресурс обмежує обраний режим і якою є ціна його зменшення.

1.4.2 Адаптивне та ієрархічне візуальне представлення

Токенізація фрагментів перетворює регулярні області зображення на послідовність, придатну для трансформера [69]; у відео патч додатково може охоплювати часовий інтервал [70, 71]. Фіксована сітка передбачувана за вартістю, але однаково обробляє інформативні й однорідні області. Тому адаптивні методи змінюють різні частини цього процесу. Динамічне обрізання вилучає токени після оцінювання їхньої важливості, TokenLearner формує компактний набір навчених токенів, адаптивна глибина припиняє обробку окремих прикладів або токенів, а об’єднання зливає подібні представлення [143–146]. NaViT підтримує різні співвідношення сторін у спільній послідовності, тоді як FlexiViT навчає модель працювати з кількома розмірами патчів [147, 148]. Ці підходи демонструють різні способи перерозподілу обчислень, але не дають автоматичного причинного правила для поділу конкретного відеокадру.

У мовних моделях дискретні одиниці зазвичай визначає словник токенізатора. Для зображень і відео аналогічну роль часто виконує кодова книга

векторного квантування: кодер відображає локальну область у найближчий дискретний код, а трансформер прогнозує послідовність таких кодів [73]. Перевагою є коротша послідовність; обмеженням – залежність від навченої кодової книги та її похибки реконструкції. Байтова модель обирає іншу крайність і прогнозує елементарні дискретні значення без окремого семантичного словника.

У BLT текстові байти спочатку групуються локальним модулем у патчі зі змінним інформаційним навантаженням. Глобальний трансформер працює з коротшою послідовністю представлень патчів, після чого локальний декодер повертає передбачення на рівень байтів [72]. V-BLT переносить схему «локальний–глобальний–локальний» на байти каналів растрових пікселів і додає багатовимірні координати простору та часу [134]. Категоріальний розподіл для кожного вихідного байта дає змогу безпосередньо обчислювати прогностичну ентропію. Багатовимірне ротаційне кодування зберігає відносні фазові відношення вздовж кожної осі [106, 107], проте саме по собі не визначає оптимального поділу на регіони.

Отже, V-BLT мотивується двома окремими питаннями. Перше стосується того, чи може локально-глобальна байтова ієрархія прогнозувати відео без навченої візуальної кодової книги. Друге – чи містить вихідний категоріальний розподіл просторово структурований сигнал складності, придатний для майбутнього адаптивного поділу. Архітектуру та межі цих тверджень докладно розглянуто в §2.3; у цьому розділі вони потрібні лише для постановки просторової ресурсної задачі.

1.4.3 Довгий контекст і багатошвидкісна пам’ять

Довгий контекст можна підтримувати чотирма базовими способами: розширювати щільне вікно, стискати давні стани, знаходити вибрані спогади за запитом або оновлювати частину пам’яті повільніше. Transformer-XL реалізує перший крок до явної пам’яті, кешуючи приховані стани попередніх сегментів [14]. Compressive Transformer додає до недавнього кешу стиснену давню пам’ять [15]. Memorizing Transformers змінює не форму зберігання, а правило доступу:

потрібні ключі й значення знаходяться за наближеною близькістю [16]. Ці механізми збільшують доступний горизонт різними шляхами, тому однакова назва «довгий контекст» не означає однакової інформації чи вартості.

Багатошвидкісні моделі заздалегідь розподіляють стан між часовими масштабами. Clockwork RNN оновлює групи прихованих одиниць із різними періодами [33], Variational Temporal Abstraction навчає приховані сегменти змінної тривалості [34], а Clockwork VAE представляє відео на вкладених часових рівнях [20]. MSPred також використовує явні просторово-часові масштаби в рекурентному прогнозуванні [150]. Спільна ідея полягає в тому, що не вся інформація потребує однакової частоти оновлення.

У сучасних моделях відеосвіту пам’ять дедалі частіше стає окремою підсистемою. Одні підходи подовжують послідовну модель простором станів [22], інші стискають просторову пам’ять світу [23] або додають вилучення, опорні стани, навчувані запити й геометрично організований доступ [24, 79–81]. Memory Maze, MBench і MemoBench оцінюють різні прояви пам’яті [68, 82, 83], але їхні задачі не завжди дають точну відповідь, чи входила конкретна давня подія до контексту конкретної моделі.

Найближчим архітектурним аналогом до грубо-детального принципу є MilliVid, де ієрархічні представлення у прихованому просторі підтримують довгогоризонтну консистентність [37]. Водночас WorldPack переважно стискає просторову пам’ять [23], а методи з вилученням або опорними станами змінюють правило доступу [24, 79–81]. Отже, архітектурна новизна не може формулюватися як сам факт існування ієрархії. Невирішеним залишається контрольоване зіставлення пакетів за бюджетом і точна перевірка режиму, у якому додаткова досяжність справді визначає результат.

Звичайна оцінка якості не показує, чи перевага довгого контексту виникла саме через доступ до давнішої події. Для причинного зіставлення потрібні сцена з відомою історією, точні часові прив’язки та пара пакетів, один із яких бачить подію, а інший – ні. Протокол розділів 3–4 будується навколо цієї умови й

додатково перевіряє зворотну межу: що відбувається після того, як обидва пакети вже мають достатню досяжність.

Огляд виявляє п’ять різних ліній контролю. Усічення графа, контрольні точки та реверсивні блоки керують збереженими диференційованими активаціями; їх потрібно оцінювати за піковою пам’яттю, додатковою роботою та відповідністю градієнтів [28–32, 92]. Багатомасштабні кодери, обрізання, навчені токени, об’єднання й змінні патчі перерозподіляють просторову або глобальну роботу; для них потрібне зіставлення якості з фактичною кількістю токенів чи FLOP [71, 72, 143–148]. У цій лінії дисертація додатково відокремлює виміряний ентропійний сигнал V-BLT від ще не перевіреної адаптивної політики поділу.

Кешована, стиснута, вибірково отримана, рекурентна та ієрархічна пам’ять керує тим, яку історію можна адресувати і з якою деталізацією вона зберігається [14–24, 33–37, 79–83]. Звичайного показника якості тут недостатньо: потрібна популяція, у якій відомо, що релевантна подія доступна одному пакету й недоступна іншому за зіставленого бюджету. Саме так у розділах 3–4 перевіряється різниця досяжності та зворотна інверсія після того, як детальний плоский пакет уже охоплює потрібне минуле.

Планове підмішування прогнозів, самокондиціювання й цілі на розгортанні керують розбіжністю між навчанням і самоподачею, але не визначають самі по собі ні обсяг збереженої історії, ні пам’ять активацій [25–29]. Окремо покадрові, перцептивні, розподільчі та об’єктні метрики керують лише конструктом оцінювання [94, 120–131]. Тому протокол має бути чутливим до конкретної відмови, ураховувати хибнопозитивні результати й виконувати статистичне виведення на рівні незалежних кліпів.

Отже, література не утворює єдиного рейтингу «методів пам’яті». Кожна група змінює іншу величину й потребує іншого доказу. Це розмежування визначає структуру наступних розділів і не дозволяє підмінити результат однієї ресурсної гілки результатом іншої.

Положення втручання в обчислювальному тракті визначає зміст ресурсного висновку. Просторове вилучення токенів і об’єднання зменшують або перерозподіляють послідовність після формування ознак; часове підвибірковування змінює частоту збережених спостережень; багатомасштабна пам’ять поєднує кілька роздільних здатностей або швидкостей оновлення. Контрольні точки активацій і реверсивні блоки не змінюють доступну історію прямого проходу, а змінюють обсяг стану, який потрібно зберігати для обчислення градієнта. Тому однакова відносна економія на вході трансформера, усередині реверсивного ядра та для повного процесу навчання є трьома різними твердженнями.

1.5 Декомпозиція проблеми та вимоги до розроблених методів

Завершальний підрозділ перетворює попередній системний аналіз на перевірні вимоги й гіпотези. Спочатку формулюються умови коректного порівняння, далі кожна з них прив’язується до дослідницької гілки, після чого окреслюються твердження, які мають бути підтверджені або обмежені експериментами.

1.5.1 Виведені вимоги до проєктування

Попередній аналіз виявив сім умов, без яких порівняння довгої пам’яті легко сплутати зі зміною моделі або метрики:

1. Причинно-наслідкова семантика має бути явною;
2. Ресурси потрібно обліковувати на рівні їхнього інтерфейсу;
3. Консистентність потрібно оцінювати за типом помилки;
4. Твердження про довготривалу пам’ять потребує популяції, що ідентифікує різницю досяжності;
5. Порівняння мають вказувати, що саме змінюється одночасно;
6. Оцінювання невизначеності має зберігати залежність;
7. Виміряні та запропоновані компоненти повинні візуально та вербально відрізнятися.

У сукупності ці вимоги задають порядок аналізу. Причинна семантика й облік ресурсів визначають допустимі порівняння; повнота показників визначає,

що саме вважається успіхом; цільова популяція та модель невизначеності показують, чи ідентифіковано механізм. Лише після фіксації цих умов порівняння пакетів може обґрунтувати правило проєктування.

Остання вимога стосується не лише рисунків у рукописі, а й доказового запису. Стан генератора випадкових чисел, кроки вибірки, ідентичність кодека, призначення набору даних та хеш контрольної точки є частиною визначення експерименту, якщо вони можуть змінити висновок. Таблиці й рисунки, на яких ґрунтуються твердження, мають генеруватися із заморожених артефактів. Захищені набори даних потребують журналів призначення та доступу, щоб статус незміненої контрольної вибірки залишався перевірним.

1.5.2 Дослідницькі гіпотези

Одна центральна проблема породжує п’ять перевірних гіпотез про її обмеження. Гіпотези Г3 і Г4 утворюють головну пару протилежних прогнозів для нижніх і верхніх бюджетів контексту. Г1 і Г2 стосуються способів масштабування системи, а Г5 перевіряє стійкість основного висновку до контрольованої зміни допоміжних інтерфейсів. Для кожної гіпотези нижче названо не лише очікуваний результат, а й спостереження, яке звужує допустимий висновок.

Г1, пам’ять активацій. Реверсивне часове відтворення має сповільнювати зростання пам’яті активацій, оскільки проміжні подвоєні стани реконструюються замість зберігання. Гіпотеза потребує одночасної перевірки відтворення стану, відповідності градієнтів, пам’яті та часу за різних горизонтів. Її практичне значення обмежується, якщо домінують нереверсивні інтерфейси, виникає нестабільність або вартість повторного обчислення переважає збереження активацій.

Г2, неоднорідність просторової складності. Ієрархічне подання растрових байтів має виявляти локальні відмінності прогностичної складності: локальні модулі обробляють категоріальні байти, глобальний модуль поєднує фрагменти, а ентропія змінюється в просторі. Необхідними доказами є відтворена якість і вартість фрагментів та стабільні карти ентропії. Відсутність

змістовної просторової структури або переваги над порівняльними моделями обмежила б таке пояснення.

Г3, контекстна досяжність. За фіксованого бюджету ієрархічний пакет має зберігати віддалені свідчення, які вже вийшли за межі короткого детального вікна. Перевірка потребує специфічної для кожної пари популяції та явно зіставленого або задекларованого бюджету. Якщо перевага не виникає саме там, де досяжність пакетів відрізняється, механістичне пояснення послаблюється.

Г4, точність відтворення після насичення досяжності. Коли обидва пакети охоплюють релевантну подію, щільна детальна історія може краще зберігати зовнішній вигляд, ідентичність і дрібну текстуру. Цей прогноз перевіряється у верхніх точках бюджету та на показниках, чутливих до ідентичності. Якби ієрархія залишалася кращою в усіх досліджених режимах, заявлена межа «досяжність–точність відтворення» не отримала б підтримки.

Г5, робастність основних напрямів. Закономірність «досяжність–точність відтворення» не повинна бути артефактом однієї конфігурації алгоритму вибірки або одного кодека. Для цього потрібні зареєстровані перевірки NFE, випадковості алгоритму вибірки та незалежно навченого кодека. Зміна знака або така втрата статистичної визначеності, за якої напрям уже не підтримується, залишає відповідне твердження невирішеним.

Для розширеної експериментальної програми ці гіпотези конкретизовано такими перевірними очікуваннями:

1. За малого токенного бюджету ієрархічний пакет може зменшити похибку повторного входу завдяки доступу до давнішого контексту, однак напрям і величина ефекту мають визначатися окремо для кожного показника.
2. Найкращий розподіл токенів між рівнями може залежати від загального бюджету; перевага однієї стратегії за одного бюджету не переноситься автоматично на інші.
3. Додавання рівня або перекриття часових позицій є виправданим лише тоді, коли отримана інформація компенсує детальні позиції, витіснені з фіксованого бюджету.

4. За однакової кількості детальних токенів їх розташування в часі може по-різному зберігати недавню динаміку та віддалені опорні спостереження.
5. Реверсивна реалізація того самого прямого перетворення має зменшувати пам’ять активацій усередині ядра без зміни його математичної функції; наскрізна економія встановлюється окремим профілюванням.
6. Динамічна маршрутизація за фіксованої квоти перевіряє, чи краще розміщено детальне представлення, але сама по собі не є доказом скорочення пам’яті.
7. Практична перевага інтегрованої моделі встановлюється лише за конкурентної якості прогнозу та виміряного зменшення пам’яті у зіставленому протоколі з однаковими даними, числовою точністю, розміром пакета й режимом навчання.

Гіпотези перевіряють різні механізми однієї системної задачі. Кожна з них пов’язує запропонований механізм зі спостереженням, яке здатне його обмежити. Для Г1 самого зменшення пам’яті недостатньо, якщо реконструкція та поведінка градієнта не залишаються прийнятними. Г3 і Г4 потребують порівнянь за різної досяжності, оскільки той самий пакет може краще зберігати віддалене просторове покриття, але гірше відтворювати точну ідентичність. У Г5 робастність означає збереження напрямів ефектів після зміни інтерфейсу; вона не вимагає, щоб кожен інтервал був статистично значущим.

Г2 має іншу доказову межу. Просторова структура ентропії та працездатність фіксованих блоків можуть показати, що модель розрізняє локальну прогностичну складність. Вони не доводять, що зміна розміру регіонів за цією ентропією вже поліпшує якість або швидкість. Через це Г2 залишається незалежною від Г3–Г4: просторова ієрархія V-BLT та часова досяжність контекстного пакета мають спільний принцип багатомасштабності, але різні змінні, реалізації й експерименти.

Разом гіпотези утворюють карту перевірних рішень. Г3–Г4 задають центральну межу контексту; Г1 стосується пам’яті навчання, Г2 – просторового представлення, а Г5 – стійкості головного висновку до зміни допоміжних

інтерфейсів. Окреме оцінювання зберігає причинність, а інтеграційний прототип у наступних розділах перевіряє вже не кожний ефект заново, а технічну сумісність принципів.

1.5.3 Висновки до розділу

Довгогоризонтне прогнозування відео є частково спостережуваним процесом із самоподачею. Модель бачить кадри, а не повний стан світу, і її власні виходи стають частиною наступних входів. Тому консистентність визначається окремо для зовнішнього вигляду, ідентичності, геометрії, просторового покриття, траєкторії, зайвого переднього плану та відповідності між рівнями. Агрегована якість кадрів залишається потрібним показником, але не виявляє кожної помилки, важливої після зникнення й повторної появи об’єкта.

Для центральної проблеми довгогоризонтної консистентності виокремлено три ресурсні обмеження. Пам’ять активацій зростає вздовж диференційованого часового ланцюга, рівномірна просторова токенізація може нераціонально розподіляти ємність усередині сцени, а збережений контекст обмежує доступні минулі спостереження. Для цих інтерфейсів у літературі запропоновано різні рішення: контрольні точки й реверсивні обчислення обмінюють збереження активацій на повторне обчислення; адаптивні або ієрархічні представлення змінюють просторову токенізацію та обсяг глобальної обробки; стиснена, доступна за запитом, рекурентна та багатошвидкісна пам’ять розширює часовий доступ. У дисертації головним архітектурним рішенням є грубий і детальний контекст, а два інші методи знімають обмеження його можливого масштабування.

Для подальших розділів зафіксовано чотири робочі поняття. **Досяжність** визначає, чи входить потрібне минуле до фактичних часових прив’язок. **Точність відтворення** характеризує деталі, що збереглися в доступному представленні. **Повторне використання** означає, що модель справді застосувала доступні свідчення у прогнозі. **Консистентність** оцінюється за

конкретною властивістю задачі, а не одним універсальним балом. Лише спільне виконання цих умов дозволяє пов’язати результат з механізмом пам’яті.

Наступний розділ розглядає два допоміжні напрями в межах цієї системної логіки. TempVerseFormer відповідає на питання, як зменшити зберігання активацій, коли градієнт має пройти через довгий часовий ланцюг. V-BLT досліджує ієрархічне байтове представлення та сигнал просторової складності. Після цього розділ 3 переходить до центральної архітектурної задачі: як сформувати грубий і детальний контекст, щоб за фіксованого бюджету зберегти давнішу історію й водночас виміряти ціну втраченої деталізації.

Таким чином, подальша послідовність методів відповідає розташуванню ресурсних обмежень у системі. TempVerseFormer перевіряє відтворення активацій у довгому диференційованому ланцюзі, V-BLT — локально-глобальне просторове представлення та сигнал складності, а матриця контекстних конфігурацій — розподіл фіксованого бюджету між рівнями, часовими позиціями й схемами перекриття. Завершальна інтеграційна перевірка має встановити технічну сумісність цих принципів і виміряти їхній спільний ресурсний ефект, не підмінюючи нею окремі причинні експерименти.

У розділі використано положення оглядової публікації автора про критерії та інтерфейси забезпечення консистентності генерації [133]. Інші праці автора згадано лише настільки, наскільки це потрібно для постановки задач наступних розділів; їхні методи й експериментальні результати тут не переказуються.

РОЗДІЛ 2 – МЕТОДИ УСУНЕННЯ ОБМЕЖЕНЬ МАСШТАБУВАННЯ ІЄРАРХІЧНОГО ПРОГНОЗУВАННЯ

У першому розділі довгогоризонтну консистентність за обмеженої пам’яті визначено як одну проблему з трьома обмеженнями. Центральне з них стосується історії, доступної навченому предиктору під час автономного застосування; його безпосередньо розв’язує ієрархічний контекст розділу 3. Тут досліджено два чинники, здатні обмежити масштабування такого рішення: стрічку активацій під час передавання градієнта через тривалий часовий процес і розподіл ємності представлення в межах кадру.

На системному рівні методи діють на різних інтерфейсах. Реверсивні часові обчислення замінюють зберігання частини проміжних станів їхнім відкладеним відтворенням під час зворотного проходу. Vision Byte Latent Transformer (V-BLT) із багатовимірним ротаційним позиційним кодуванням реалізує локально–глобальну ієрархію, а прогнозна ентропія надає внутрішній сигнал просторової складності. У центральному порівнянні пакетів ці компоненти не змінюють предиктор, щоб не змішувати причинні ефекти. Їхні сумісні принципи пізніше перевірено у спрощеному інтеграційному прототипі, чітко відокремленому від опублікованих експериментів.

2.1 Контрольована експериментальна основа

Підрозділ визначає дані, на яких можна окремо спостерігати часову закономірність, просторову складність і похибку представлення. Спочатку описується процедурне формування послідовностей, потім два класи контрольованого обертання, а наприкінці – роль кожного набору даних і межа допустимого узагальнення.

2.1.1 Процедурна генерація відеоданих

Помилка прогнозування природного відео може мати кілька причин. Об’єкт перекривається, камера рухається, освітлення змінюється, а саме майбутнє нерідко має кілька правдоподібних продовжень. Такі варіації важливі для зовнішньої валідації, проте ускладнюють перевірку окремого часового механізму: за невдалим прогнозом важко встановити, що саме не спрацювало.

Процедурне відео зменшує цю неоднозначність. Генератор надає змінні стану, які визначають кожен кадр, тому закон руху, геометрію або умови спостереження можна змінювати вибірково, не збираючи новий відеозапис. Шум та інші випадкові чинники або усуваються, або вводяться контрольовано.

Нехай s_t є повним станом процедурної сцени в момент t, u_t — відомою керувальною дією, а f — заданим законом переходу. Тоді динаміка стану визначається рівнянням

$$s_{t+1} = f(s_t, u_t). \tag{2.1}$$

Спостережуваний кадр x_t отримується з повного стану оператором рендерингу $\mathcal{R}$, тобто $x_t = \mathcal{R}(s_t)$. Оскільки f та $\mathcal{R}$ відомі, експериментатор може змінити закон руху, початкову геометрію або умову спостереження, не змінюючи інші складники задачі. Істинний стан дає змогу перевірити не лише схожість кадру, а й конкретну динамічну властивість. Однакові параметри генерації також забезпечують парне порівняння моделей на ідентичних послідовностях.

Контроль досягається ціною спрощення сцени. Чорний фон, ізольовані об’єкти та наперед задані закони руху полегшують сегментацію й звужують різноманіття текстур, взаємодій та ефектів камери. Через це високий результат на процедурних даних ще не доводить перенесення на природне відео. Їхня роль інша: спочатку показати, чи працює досліджуваний механізм за відомих умов і чи можна локалізувати його помилки, а потім перевірити модель у ширшому середовищі.

Таку логіку відображає послідовність наборів даних у дисертації. Прості обертання ізолюють часову динаміку та просторове представлення. Набори OpenSTL поєднують стандартні синтетичні й реальні задачі прогнозування та перевіряють переносимість моделі за спільним програмним інтерфейсом [1]. Нарешті, LoopMom і довготривалий Moving-MNIST створено спеціально для дослідження пам’яті: складність у них виникає тоді, коли потрібне спостереження зникає з короткого контексту, а згодом знову стає необхідним. Підрозділи 2.1.2–2.1.4 послідовно описують ці ролі.

2.1.2 Обертання двовимірних фігур

Спільним процедурним прикладом у дослідженнях часової динаміки та байтового представлення є двовимірна фігура, що обертається у кадрі. Кожна послідовність починається з випадково згенерованої геометрії об'єкта та початкової орієнтації. Об'єкт залишається в центрі, камера нерухома, а орієнтація змінюється у дискретні моменти часу. Нехай θ_t позначає кут повороту на кроці t, а ω – сталий кутовий приріст за один кадр. Тоді для режиму з постійною швидкістю

$$\theta_{t+1} = \theta_t + \omega, \tag{2.2}$$

Знак ω визначає напрямок обертання. В експериментах із часовим моделюванням його модуль $|\omega|$ випадково обирався в діапазоні від $5°$ до $20°$ за крок. Додаткові режими змінювали величину або знак ω_t : фігура прискорювалася, уповільнювалася, коливалася між напрямками, тимчасово зупинялася або поєднувала ці зміни. Кадри мали формат RGB і розмір 64×64; контекст містив 12 кадрів, навчальний горизонт поступово зростав від одного до п'яти кроків, а оцінювання охоплювало 12 прогнозованих кадрів [135]. Публічний набір інструментів для простих фігур містить дво- та тривимірні процедурні генератори, метадані й команди для відтворення цієї родини наборів даних [171]. Рисунок 2.1 показує один із двовимірних прикладів.

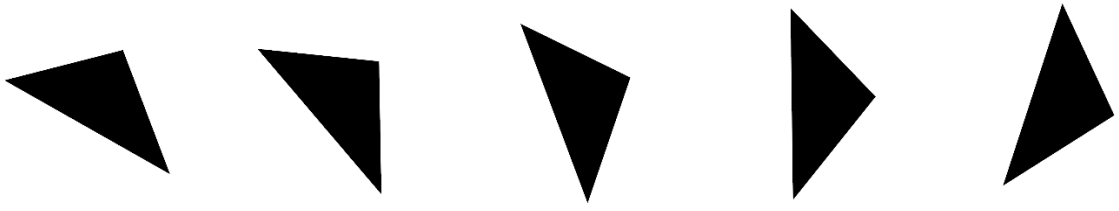


Рисунок 2.1 – Процедурно згенерована обертова двовимірна фігура.

2.1.3 Обертові тривимірні полікуби

Тривимірна тестова модель збільшує структурну варіативність, не відмовляючись від процедурного контролю. Полікуб складається з $n \in \{2, \dots, 6\}$ з'єднаних гранями одиничних кубів, обраних із канонічних форм. Об'єкт центрується у сцені з фіксованою камерою та отримує випадкові початкові обертання навколо всіх трьох осей. Орієнтацію позначено вектором $\boldsymbol{\theta}_t =$

$(\theta_t^x, \theta_t^y, \theta_t^z)$, а випадково вибрану кутову швидкість — $\boldsymbol{\omega}$. Її оновлення має вигляд

$$\boldsymbol{\theta}_{t+1} = \boldsymbol{\theta}_t + \boldsymbol{\omega}. \quad (2.3)$$

На відміну від плоского силуету, полікуб під час обертання почергово відкриває та приховує частини поверхні. Для правильного прогнозу модель має зберігати інформацію про взаємне розташування кубів, одночасно враховуючи самоперекриття, проєкцію та зміни затінення. Тому послідовність є складнішим тестом локально-глобального візуального представлення, хоча фон і закон руху залишаються простими.

Самоперекриття додає перевірку просторової пам’яті. Частина полікуба тимчасово зникає за видимими гранями, однак після зміни ракурсу модель має відтворити її у положенні, сумісному з цілісною геометрією об’єкта. Водночас цей тест навмисно обмежений. Закон обертання регулярний, кліпи короткі, а центрований об’єкт не залишає поле зору повністю. Тому полікуби перевіряють залежне від ракурсу представлення та короткочасне відновлення прихованих поверхонь, але не ізолюють доступ до далекої історії. Для останньої мети у розділах 3 і 4 використовуються LoopMom і довготривалий Moving-MNIST.

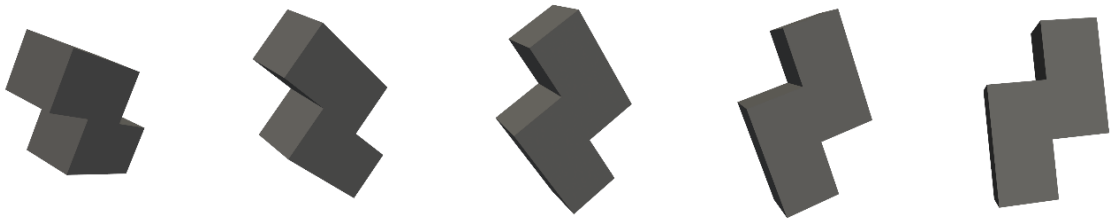


Рисунок 2.2 – Процедурно згенерований обертовий тривимірний полікуб.

2.1.4 Набори даних у дисертації

Набори даних відрізняються не одним рівнем «складності», а доказовою роллю. Обертання потрібні для контрольованої перевірки окремого механізму. Moving MNIST, Moving MNIST-CIFAR, KTH Action і TaxiBJ у середовищі OpenSTL перевіряють стандартну прогнозну спроможність на синтетичних та реальних даних [1, 124, 126, 154]. Тороїдальний тест повторного входу (TRB; внутрішня назва LoopMom) і довготривалий Moving-MNIST з ідентифікаторами об’єктів відповідають на інше питання: чи доступне конкретне давнє

спостереження, коли воно знову стає потрібним. У структурній матриці контекстних конфігурацій TRB ізолює механізм повторного входу, тоді як стандартний Moving MNIST та TaxiBJ призначено для зовнішньої інтегрованої перевірки в OpenSTL; наявний довготривалий Moving-MNIST збережено лише як другорядний результат робастності без нової серії запусків. На рисунку 2.3 розміщено ці набори не на умовній числовій шкалі, а в категоріях за типом сцени та роллю експерименту. Стовпці розрізняють перевірку окремого механізму, стандартну прогностичну компетентність і цільову ідентифікацію довготривалої пам’яті; рядки відокремлюють процедурні та реальні або складені сцени.

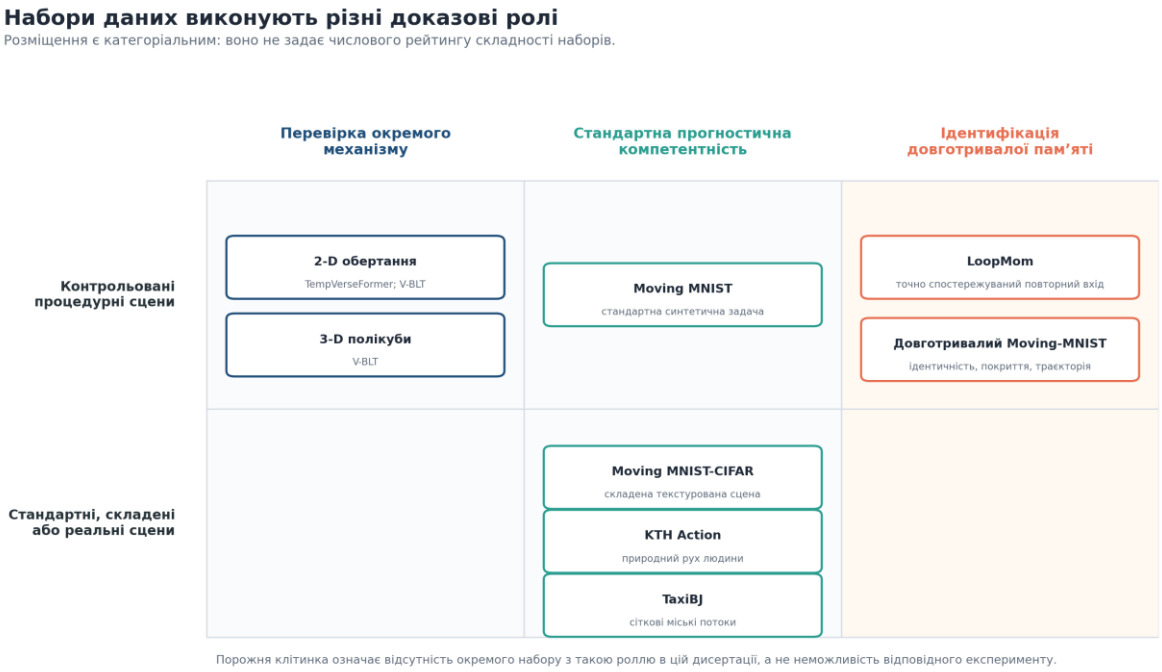


Рисунок 2.3 – Категоріальна карта експериментальних наборів даних.

Категоріальна карта пояснює послідовність перевірок, але не містить деталей протоколів. Таблиця 2.1 доповнює рисунок 2.3: для кожного набору вказано контрольоване явище, модель, доказову роль і межу висновку. Такий поділ потрібний, оскільки візуально складніший набір не обов’язково точніше виявляє втрату давньої історії.

Таблиця 2.1 – Ролі наборів даних та межі доказовості.

Набір даних або сімейство	Контрольоване явище	Оцінюваний метод	Доказова роль	Основне обмеження
Обертові 2-D фігури	постійна та змінна кутова динаміка	TempVerseFormer; V-BLT в окремих конфігураціях	ізоляція механізмів та часова екстраполяція	споріднені процедурні задачі, але конфігурації генератора й протоколи двох публікацій не вважаються тотожними
Обертові 3-D полікуби	тривісне обертання, самооклюзія та затінення	V-BLT, ViViT та UNet-3D	складніша перевірка контрольованості представлення	синтетичні сцени з фіксованою камерою; лише точкові оцінки
Рухомий MNIST / Рухомий MNIST-CIFAR	перенесення об’єктів, зіткнення та текстурований фон	базові моделі TempVerseFormer та OpenSTL	стандартна синтетична компетентність	короткий протокол не ізолює досяжність з використанням довгої пам’яті
KTH Action / TaxiBJ	рухи людей та міські потоки	базові моделі TempVerseFormer та OpenSTL	межа інтерфейсу з реальними даними	жодна з них не забезпечує спостережуваності повторного входу на рівні об’єктів
TRB (LoopMom)	зникнення, повторна поява в циклічному світі та точна видимість	сімейство моделей із розділу 3	причинна ідентифікація збереженої досяжності	контрольована геометрія не відтворює текстурне й семантичне різноманіття природного відео
Довготривалий Moving-MNIST зі сталими ідентифікаторами	довготривала ідентичність, просторове покриття та траєкторія	плоскі та ієрархічні конфігурації з розділу 3	зовнішня межа між досяжністю та точністю відтворення	абсолютна результативність залишається низькою

Експериментальна одиниця залежить від задачі та досліджуваного механізму. Для ранніх робіт опубліковано точкові оцінки без достатніх даних для ретроспективного відновлення невизначеності, тому в цьому розділі вони подаються саме в такому вигляді. У центральних порівняннях розділів 3 і 4 невизначеність оцінюється інакше: під час кластерної бутстреп-передискретизації повторно відбираються цілі відеокліпи, а всі їхні кадри залишаються разом. Це запобігає хибному трактуванню сусідніх кадрів як незалежних спостережень. Окремі ініціалізації навчання утворюють другий рівень варіативності моделі. Довірчі інтервали до ранніх результатів штучно не добудовуються.

2.2 Моделювання реверсивних часових процесів

Тут розглядається перше ресурсне обмеження – зростання пам'яті активацій зі збільшенням диференційованого горизонту. Виклад переходить від механізму цього зростання до реверсивного блока й часового ланцюга, після чого окремо перевіряє реконструкцію станів, градієнти, пам'ять, зовнішню працездатність і межі застосовності.

2.2.1 Активаційна пам'ять у довгих часових ланцюгах

Розглянемо параметризований перехід $h_t = \Phi_\theta(h_{t-1}, c_t)$, де $h_t \in \mathbb{R}^{D_s}$ є часовим станом, c_t позначає відомі умовні дані, а θ – параметри моделі переходу. Втрата може залежати від кінцевого стану, кількох декодованих станів або повної траєкторії. Стандартне зворотне поширення через час застосовує диференціювання у зворотному режимі до розгорнутого композиційного відображення [28]. Градієнт такого відображення визначений однозначно, проблема полягає у зберіганні проміжних значень, потрібних для кожного локального зворотного кроку.

Нехай процес розгорнуто на T часових кроків і він містить L шарів. Через A_l позначимо обсяг активацій шару l, які необхідно зберегти для його зворотного проходу. Тоді домінантну часову складову пам'яті стандартного BPTT та відповідний обсяг обчислень можна наближено записати як

$$M_{\text{act}}^{\text{BPTT}}(T) \approx T \sum_{l=1}^{L} A_l, \tag{2.4}$$

Відповідну обчислювальну роботу $C_{\text{BPTT}}(T)$ визначимо через вартість прямого й зворотного обчислення одного переходу:

$$C_{\text{BPTT}}(T) = T(C_\Phi^{\text{fwd}} + C_\Phi^{\text{bwd}}). \tag{2.5}$$

Тут C_Φ^{fwd} і C_Φ^{bwd} означають вартість прямого та зворотного обчислення одного переходу. Рівняння (2.4) показує лінійне зростання збереженої стрічки активацій за T, а рівняння (2.5) визначає обчислювальну роботу. Водночас $M_{\text{act}}^{\text{BPTT}}$ не є повною пам'яттю пристрою: параметри, градієнти, стан оптимізатора, вхідні дані та робочі буфери є окремими складниками. Отже, реверсивний блок може усунути саме часову стрічку ядра, обсяг якої лінійно

зростає під час навчання авторегресивного прогнозування, але не всі витрати обчислювального тракту.

Альтернативним методом є усічення BPTT, що зменшує використання пам'яті, але водночас скорочує горизонт градієнта [29]. Якщо пропущені залежності важливі, цільова функція фактично змінюється. Збереження контрольних точок градієнта застосовує інший підхід: вибрані граничні стани зберігаються, а проміжні сегменти повторно обчислюються, що в точній арифметиці зберігає похідну на всьому горизонті [30, 31]. Реверсивне відтворення є більш спеціалізованим. Якщо попередній стан відновлюється з наступного стану, то більшість часових граничних станів можна відкинути.

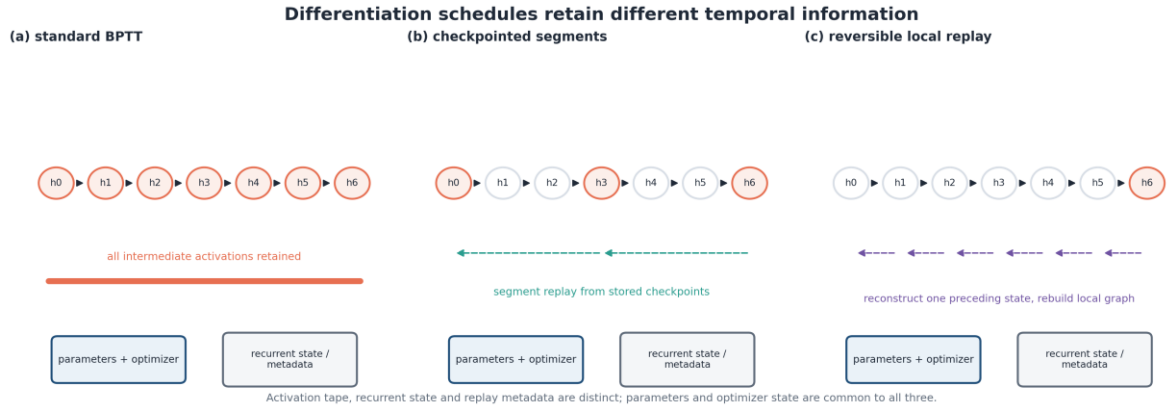


Рисунок 2.4 – Схеми зберігання для диференціювання в часі.

Щоб не ототожнювати стрічку активацій із усією пам'яттю пристрою, пікове використання доцільно подати окремим розкладом:

$$M_{\text{peak}}(T) = M_{\text{param}} + M_{\text{grad}} + M_{\text{opt}} + M_{\text{input}} + M_{\text{workspace}}(T) + M_{\text{tape}}(T). \quad (2.6)$$

У рівнянні (2.6) M_{param}, M_{grad} і M_{opt} відповідають параметрам, їхнім градієнтам та стану оптимізатора; M_{input} охоплює вхідні дані; $M_{\text{workspace}}(T)$ – тимчасові робочі буфери; $M_{\text{tape}}(T)$ – збережену стрічку активацій. Реверсивне відтворення безпосередньо зменшує останній складник. Для цього часовий перехід має бути побудований так, щоб попередній стан можна було відновити без збереження всіх його проміжних значень.

2.2.2 Блок реверсивного перетворення

Реверсивним тут називається блок, вхід якого можна точно відновити з виходу та відомих параметрів. Це не означає, що кожен внутрішній модуль має власне аналітичне обернення. Достатньо організувати обчислення так, щоб

значення одного потоку залишалося доступним під час відновлення іншого. Адитивне зв’язування реалізує цю умову трикутною послідовністю оновлень.

Нехай вхідний стан поділено на два потоки x_1 і x_2, а y_1 і y_2 є відповідними виходами. Функції F_θ та G_θ можуть бути довільними диференційованими модулями, наприклад увагою та багатошаровим перцептроном, зі спільним набором параметрів θ. Пряме перетворення задається рівняннями (2.7)–(2.8), після яких той самий стан відновлюється рівняннями (2.9)–(2.10):

$$y_1 = x_1 + F_\theta(x_2), \tag{2.7}$$

Другий вихідний потік y_2 оновлюється вже з використанням y_1:

$$y_2 = x_2 + G_\theta(y_1). \tag{2.8}$$

Обернення починається з відновлення другого вхідного потоку x_2:

$$x_2 = y_2 - G_\theta(y_1), \tag{2.9}$$

Після підстановки відновленого x_2 отримуємо перший вхідний потік x_1:

$$x_1 = y_1 - F_\theta(x_2). \tag{2.10}$$

Обернення виконується у протилежному порядку. Спочатку з відомих y_1 і y_2 відновлюється x_2, після чого це значення підставляється у формулу для x_1. Функції F_θ і G_θ самі по собі можуть не бути оберненими: їх достатньо повторно обчислити для вже відновленого аргументу. Властивість оборотності належить повному двопотоковому стану, а не довільній проєкції одного з потоків.

На рисунку 2.5 зображено схему роботи блока під час прямого та зворотного проходів. У прямому напрямку модуль уваги оновлює перший потік за інформацією другого, а багатошаровий перцептрон – другий потік за вже обчисленим першим. Під час зворотного проходу ці дії повторюються у зворотному порядку з відніманням відповідних приростів. Тому в пам’яті достатньо залишити вихід блока й умови, необхідні для точного повторного обчислення його модулів.

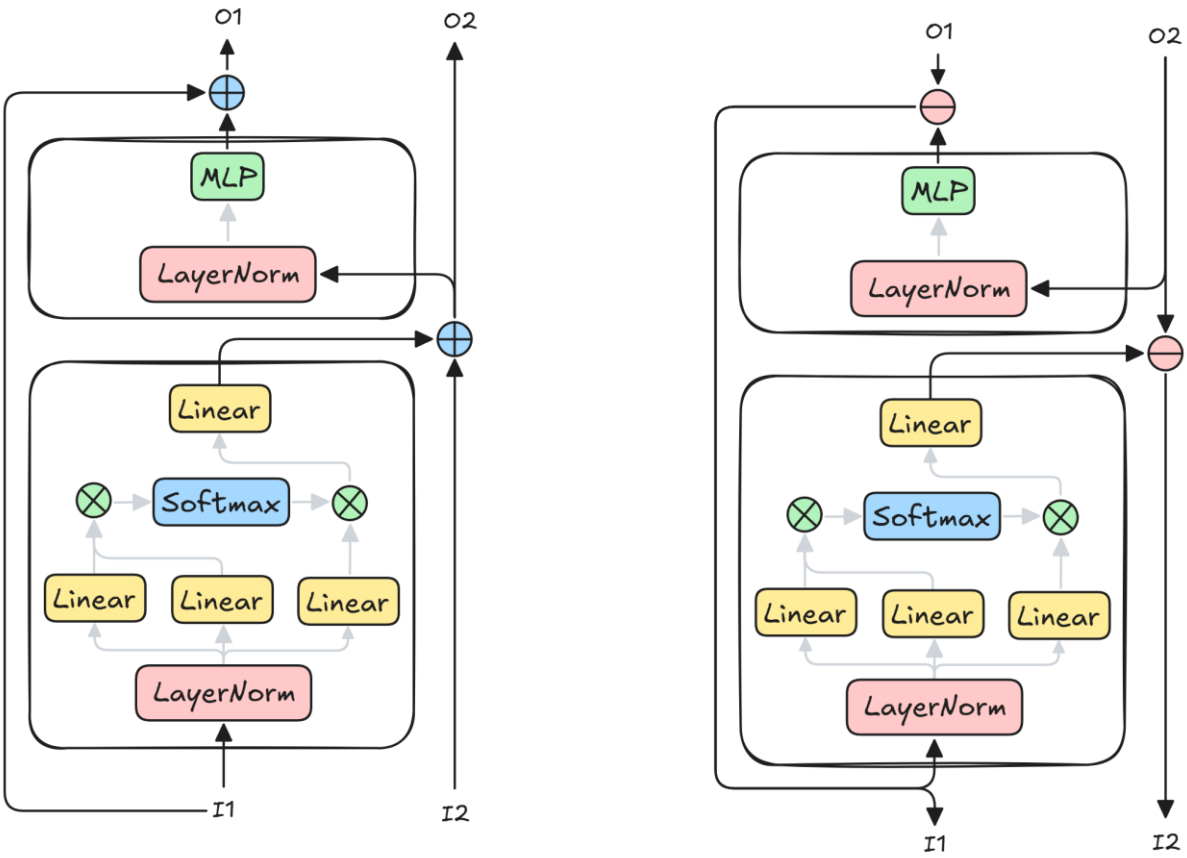


Рисунок 2.5 – Адитивний реверсивний блок трансформера.

Трикутна структура має ще одну алгебраїчну властивість. Якщо $R_\theta: (x_1, x_2) \mapsto (y_1, y_2)$ позначає повний блок, а J_{R_θ} – його матрицю Якобі, то визначник дорівнює одиниці:

$$detJ_{R_\theta} = 1. \tag{2.11}$$

Рівність (2.11) означає локальне збереження об’єму повного стану. У цьому полягають і перевага, і межа адитивного зв’язування. Інформація, потрібна для відновлення входу, не може безслідно зникнути всередині такого блока, тоді як звичайна рекурентність може стискати кілька вхідних конфігурацій в один стан [110]. Якщо системі потрібні стискання або забування, їх слід реалізувати на нереверсивній межі чи кодувати явною додатковою змінною. Алгебраїчна оборотність також не гарантує стійкої часової динаміки, тому стабільність повторного застосування перевіряється окремо.

Межа реверсивного стану особливо важлива для задач довгострокового прогнозування; її детально розглянуто й реалізовано в архітектурі TempVerseFormer. Опублікована архітектура містить варіаційний кодер і

декодер, лінійні проєкції, дублювання спроєктованого потоку, нормалізацію та злиття виходу. Ці операції утворюють корисні інтерфейси, але не всі є бієкціями.

Таблиця 2.2 – Реверсивність станів TempVerseFormer

Тензор або операція	**Реалізоване перетворення**	**Алгебраїчно обернене лише на основі свого виходу?**	**Що зберігається або перераховується при зворотному диференціюванні**	**Включено до твердження про точне відтворення стану?**
Кадр зображення до прихованого простору VAE	Конволюційний варіаційний кодер, $x \mapsto z$	Ні	Звичайні значення автоматичного диференціювання або заморожене чи попередньо обчислене представлення прихованого простору, залежно від режиму навчання	Ні
Проєкція входу з прихованого простору	256-вимірного прихованого простору до 768-вимірного вбудовування плюс навчена позиція	Не встановлено як бієктивне	Вхідні дані на межі обробляються звичайним автоматичним диференціюванням у режимі за замовчуванням	Ні
Створення потоку	Конкатенація $[e, e]$ двох ідентичних 768-вимірних потоків	Ні; дублювання є ін’єктивним, але не є бієкцією двох потоків на кодомен	Проектоване вбудовування існує на межі ядра	Ні
Повторний часовий стан	Стек адитивного зв’язування над подвоєним вбудовуванням	Так у точній арифметиці для перевіреного детермінованого блоку; будь-яке майбутнє стохастичне обумовлення також доведеться відтворити	Кінцевий подвоєний стан; локальні функції блоків повторно обчислюються	Так
Нормалізація та злиття вихідних даних	Стан розміром 2×768 до 256-вимірного вектора прихованого простору	Ні	Звичайні граничні значення автоматичного диференціювання в режимі за замовчуванням; альтернативна утиліта зберігає нереверсивні граничні значення	Ні

Тензор або операція	**Реалізоване перетворення**	**Алгебраїчно обернене лише на основі свого виходу?**	**Що зберігається або перераховується при зворотному диференціюванні**	**Включено до твердження про точне відтворення стану?**
Декодування VAE та втрата зображення	Від прихованого простору до пікселів з подальшим застосуванням складників MSE/LPIPS/KL	Ні	Стандартний граф втрат на межі	Ні

Таблиця 2.2 звужує обґрунтоване твердження до збережуваного подвоєного стану трансформера. Повний обчислювальний тракт прогнозування від VAE до VAE є нереверсивним, однак саме в повторюваному ядрі без цього механізму відбувається зростання стрічки часових активацій. Отже, реконструкція ядра підтверджує виміряний результат щодо пам’яті активацій, але не означає, що кінцевий прогноз зображення однозначно визначає кожну проміжну операцію.

2.2.3 Часове ланцюгове з’єднання

Один реверсивний блок зменшує потребу зберігати внутрішні активації за глибиною мережі, але довгий відеопрогноз потребує ще й повторного переходу в часі. Часове ланцюгове з’єднання означає, що оператор фіксованої ширини багаторазово застосовується до вікна прихованих представлень: вихід одного зсуву стає входом наступного. Кількість параметрів при цьому не зростає з горизонтом, однак звичайне навчання все одно утворює дедалі довший диференційований ланцюг. Саме тут оборотність ядра дає змогу замінити збереження попередніх станів їхнім відтворенням.

TempVerseFormer розміщує реверсивний стек між просторовим кодером та декодером. В опублікованій конфігурації кожен RGB-кадр розміром 64×64 відображається на 256-вимірний стан у прихованому просторі. Навчена лінійна проєкція розширює кожен стан до 768 ознак, ротаційні позиційні вбудовування RoPE ідентифікують N позицій у вікні [107], а спроєктована послідовність дублюється для формування двох потоків зв’язку. Часове ядро містить вісім реверсивних блоків трансформера з вісьмома головками уваги [135]. Повну схему зображено на рисунку 2.6. Кодер переводить кадри до прихованого простору, вхідна проєкція формує два потоки реверсивного ядра, а вихідна проєкція та декодер повертають прогноз до простору зображення. Точне відтворення застосовується лише до повторюваного подвоєного стану

трансформера; VAE, проєкції та злиття виходу залишаються нереверсивними межами.

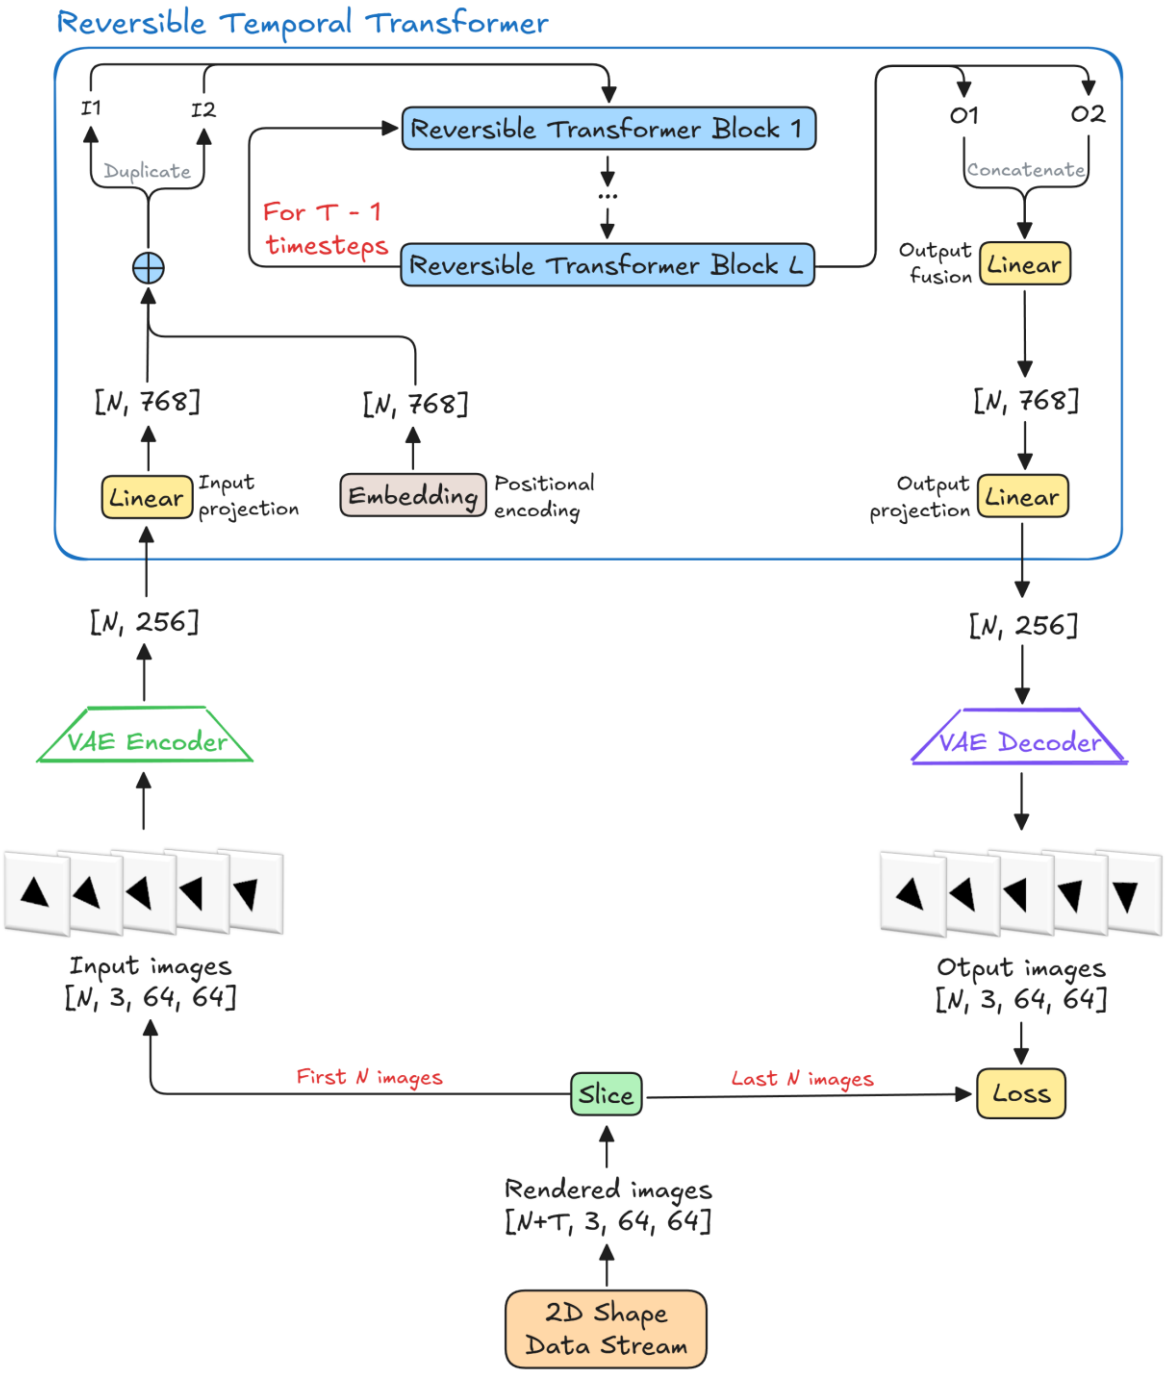


Рисунок 2.6 – Повна архітектура TempVerseFormer.

Позначимо кодер і декодер через e_ϕ та d_ψ, вхідну й вихідну проєкції через P_{in} і P_{out}, а один перехід реверсивного ядра через R_θ. Початкове представлення дорівнює $z^{(0)} = e_\phi(x)$, а початковий стан ядра — $q^{(0)} = P_{\text{in}}(z^{(0)})$. Для $r = 0, \dots, T-1$ стан після наступного часового зсуву оновлюється як

$$q^{(r+1)} = R_\theta(q^{(r)}). \tag{2.12}$$

Після T переходів декодований прогноз $\hat{x}^{(T)}$ формується вихідною проєкцією та декодером:

$$\hat{x}^{(T)} = d_{\psi}\left(P_{\text{out}}(q^{(T)})\right). \tag{2.13}$$

Розмірність стану не змінюється зі збільшенням зсуву. Отже, часова глибина означає повторне застосування одного віконного оператора, а не дедалі довшу послідовність токенів. Параметри спільні між усіма застосуваннями. Водночас градієнти від кінцевого декодованого вікна мають пройти через кожен повторний перехід. Саме тому стандартне автоматичне диференціювання накопичує довшу історію активацій, хоча кількість навчених часових параметрів залишається сталою. Цей процес схематично показано на рисунку 2.7.

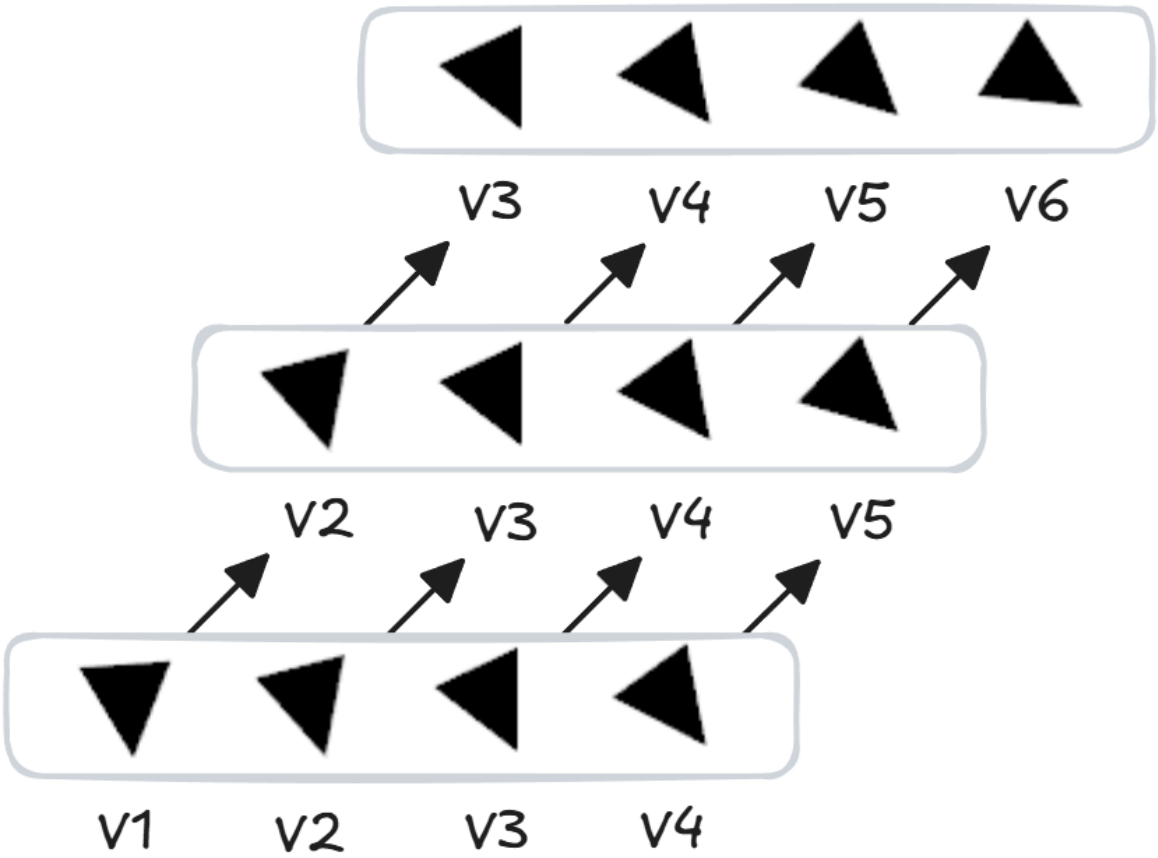


Рисунок 2.7 – Часове ланцюгове з’єднання вікна фіксованої ширини.

Під час навчання використовується контекст із 12 кадрів та навчальна програма, в якій зсув T збільшується від одиниці до п’яти. Декодоване вихідне вікно порівнюється з відповідним цільовим вікном, зміщеним у часі. Для відтворення опублікованого протоколу важливо розділити заявлену ціль і

фактичну реалізацію. У рівнянні (16) статті наведено функцію втрат із трьома членами [135]:

$$\mathcal{L}_{\text{paper}} = \lambda_{\text{MSE}}\mathcal{L}_{\text{MSE}} + \lambda_{\text{LPIPS}}\mathcal{L}_{\text{LPIPS}} + \lambda_{\text{KL}}D_{\text{KL}}(q_{\phi}(z \mid x)\|\mathcal{N}(0, I)). \quad (2.14)$$

Аудит реалізації дає окрему ціль $\mathcal{L}_{\text{code}}$, у якій явно наявна реконструкційна похибка входу VAE:

$$\mathcal{L}_{\text{code}} = \mathcal{L}_{\text{pred}-\text{MSE}} + \mathcal{L}_{\text{input}-\text{VAE}-\text{MSE}} + \lambda_{\text{LPIPS}}\mathcal{L}_{\text{LPIPS}} + \lambda_{\text{KL}}D_{\text{KL}}. \quad (2.15)$$

Рівняння (2.14) відтворює формулу, наведену в публікації. Рівняння (2.15) фіксує фактичний склад перевіреної реалізації, де додатково присутня похибка реконструкції входу VAE, а коефіцієнт KL відрізняється від описаного в статті. Це розходження не змінює алгебру реверсивного ядра, але має значення для точного відтворення навчання. Тому опис публікації та аудит коду подано окремо.

2.2.4 Зворотне поширення незалежне від часового горизонту

Ланцюгове з’єднання у часі створює повторюваний реверсивний стан, але обсяг пам’яті зменшується лише в тому випадку, якщо навчання фактично дозволяє уникнути збереження звичайного графа активацій та їх накопичення в процесі прямого проходження. Процедура з пам’яттю, незалежною від часового горизонту, відокремлює пряме прогнозування від зворотного диференціювання. Під час прямої фази рекурентне ядро обчислюється в умовах відсутності градієнта, проміжні активації блоків відкидаються, а кінцевий стан $q^{(T)}$ зберігається. Під час зворотної фази кожен попередній стан відновлюється алгебраїчно, відповідний локальний прямий розрахунок відтворюється з відстеженням градієнта, накопичуються його векторно-якобіанські добутки, а локальний граф звільняється. На рисунку 2.8 вказано як прямий прохід залишає кінцевий стан, а зворотний послідовно відновлює попередні стани, перебудовує локальний граф і звільняє його перед наступним кроком. Нереверсивні кодер, декодер і проєкції залишаються на межах процедури.

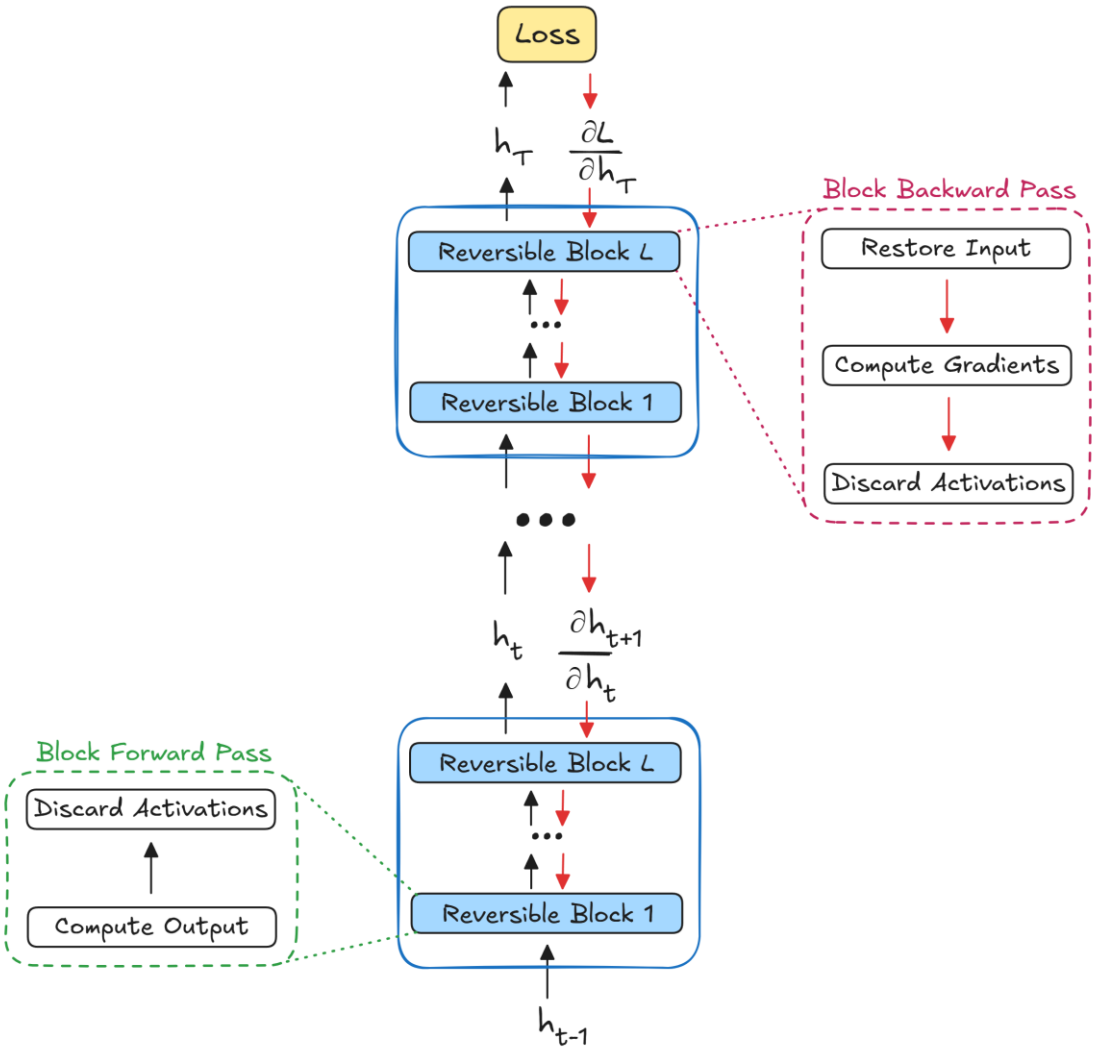


Рисунок 2.8 – Зворотне поширення з пам'яттю, незалежною від часового горизонту, через реверсивний часовий стан.

Для формального опису позначимо через $a_t = \partial \mathcal{L} / \partial q^{(t)}$ ад'юнкт стану на кроці t, через ℓ_t – локальний внесок у втрату, а через R_θ – реверсивний часовий перехід. Тоді ад'юнкт попереднього стану та сумарний градієнт параметрів обчислюються як

$$a_{t-1} = \frac{\partial \ell_{t-1}}{\partial q^{(t-1)}} + \left(\frac{\partial R_\theta(q^{(t-1)})}{\partial q^{(t-1)}} \right)^{\top} a_t, \tag{2.16}$$

Сумарний градієнт параметрів $\nabla_\theta \mathcal{L}$ накопичує внески всіх T повторних переходів:

$$\nabla_\theta \mathcal{L} = \sum_{t=1}^{T} \left(\frac{\partial R_\theta(q^{(t-1)})}{\partial \theta} \right)^{\top} a_t. \tag{2.17}$$

Послідовність алгоритму розрахунку:

1. Обчислити $q^{(0)} = P_{\text{in}}(e_\phi(x_{1:N}))$ з використанням необхідного графа межі.

2. Для $t = 1, \dots, T$ обчислити $q^{(t)} = R_\theta(q^{(t-1)})$ без збереження проміжних активацій ядра.
3. Застосувати P_{out}, декодувати кінцеве прогнозування, обчислити втрату та отримати кінцевий ад'юнкт a_T через нереверсивну вихідну межу.
4. Для $t = T, \dots, 1$ реконструювати $q^{(t-1)} = R_\theta^{-1}(q^{(t)})$.
5. Перерахувати $R_\theta(q^{(t-1)})$ із відстеженням градієнта, накопичити градієнт параметра та обчислити a_{t-1}.
6. Звільнити локальний граф перед обробкою $t-1$, потім поширити відновлений градієнт через звичайну проєкцію вхідних даних та межу VAE.

Наведений нижче результат формулює твердження щодо пам'яті на рівні, що виправдовується цим алгоритмом.

Лема 2.1 (складність стрічки активацій). Нехай R_θ – детермінований реверсивний перехід із L блоків адитивного зв'язування, а D_s – повний обсяг стану одного блока. Припустимо, що межа втрат і всі умови, потрібні для відтворення, займають пам'ять, незалежну від T. Тоді локальний граф і збережений граничний стан мають порядок $O(1)$ за часовою глибиною T, тоді як пряма стрічка BPTT потребує $O(TLD_s)$.

Лема не пропонує нового правила обчислення градієнта. Застосовується звичайне диференціювання у зворотному режимі, але локальний граф щоразу відновлюється лише для одного переходу й одразу звільняється. За зменшення пам'яті сплачують повторним прямим обчисленням, яке відображено в рівнянні (2.18). Практична перевага виникає тоді, коли часовий горизонт достатньо великий, тобто $T \gg 1$, а збережена стрічка активацій справді домінує над нереверсивними межами та робочими буферами.

$$C_{\text{rev}}(T) \approx T(2C_R^{\text{fwd}} + C_R^{\text{local-bwd}}), \tag{2.18}$$

У рівнянні (2.18) C_R^{fwd} є вартістю одного прямого обчислення реверсивного переходу, а $C_R^{\text{local-bwd}}$ – його локального зворотного проходу. Додатковий прямий розрахунок є платою за звільнення стрічки активацій. В наступному

підрозділі наведено результат перевірки, чи супроводжується цей ресурсний обмін прийнятною якістю прогнозування.

2.2.5 Результати контрольованого аналізу часових закономірностей

У контрольованому оцінюванні порівнювали чотири системи: реверсивний TempVerseFormer; зіставлений нереверсивний, але ідентичний архітектурно TempFormer із часовим ланцюгуванням; стандартний трансформер без такого самого інтерфейсу реверсивного ланцюгування; та LSTM [137]. TempFormer і TempVerseFormer мали по вісім блоків, вісім голів уваги та 768 прихованих ознак. Усі моделі використовували спільний інтерфейс VAE й навчалися протягом 30 000 кроків на одній відеокарті NVIDIA RTX 4060 Ti. Оцінювання охоплювало 2 000 процедурно згенерованих послідовностей з однаковою фіксованою ініціалізацією генератора даних для всіх моделей [135].

Контрольоване порівняння не виявило універсального переможця за якістю. TempVerseFormer має найкращу сукупність FID, MSE та SSIM для постійного й перерваного обертання, тоді як за прискорення, уповільнення, коливання або комбінованого руху окремі показники віддають перевагу TempFormer чи LSTM. Отже, головним результатом є працездатність реверсивного часового ядра без систематичної втрати прогнозної спроможності.

Таблиця 2.3 – Опубліковані прогнозні точкові оцінки за режимами обертання

Режим	**Модель**	**FID ↓**	**MSE ↓**	**SSIM ↑**
Постійний	TempFormer	103	0,023	0,84
	TempVerseFormer	**75**	**0,018**	**0,88**
	Стандартний Transformer	87	0,030	0,86
	LSTM	157	0,080	0,76
Прискорений	**TempFormer**	90	**0,021**	**0,857**
	TempVerseFormer	87	0,028	0,853
	Стандартний Transformer	95	0,030	0,851
	LSTM	**86**	0,048	0,821
Уповільнений	TempFormer	90	**0,025**	**0,86**
	TempVerseFormer	87	0,036	0,84

Режим	**Модель**	**FID ↓**	**MSE ↓**	**SSIM ↑**
	Стандартний Transformer	86	0,036	0,85
	LSTM	**85**	0,039	0,84
Коливальний	TempFormer	130	0,024	0,82
	TempVerseFormer	112	**0,021**	**0,84**
	Стандартний Transformer	119	0,068	0,78
	LSTM	**108**	0,081	0,77
Перерваний	TempFormer	98	0,034	0,83
	TempVerseFormer	**91**	**0,032**	**0,84**
	Стандартний Transformer	99	0,056	0,80
	LSTM	107	0,060	0,79
Комбінований	**TempFormer**	**119**	0,060	**0,79**
	TempVerseFormer	123	**0,059**	0,78
	Стандартний трансформер	127	0,086	0,77
	LSTM	156	0,089	0,74

Повна галерея прогнозів для постійного, прискореного, уповільненого, коливального та перерваного обертання наведена в додатку Е. В основному тексті залишено графік для комбінованої динаміки, оскільки саме він показує зміну відносного результату зі збільшенням глибини прогнозування, а не лише окремі зображення. Публікація наводить точкові оцінки без панелі незалежних навчань і довірчих інтервалів, тому невизначеність до цих результатів ретроспективно не додається.

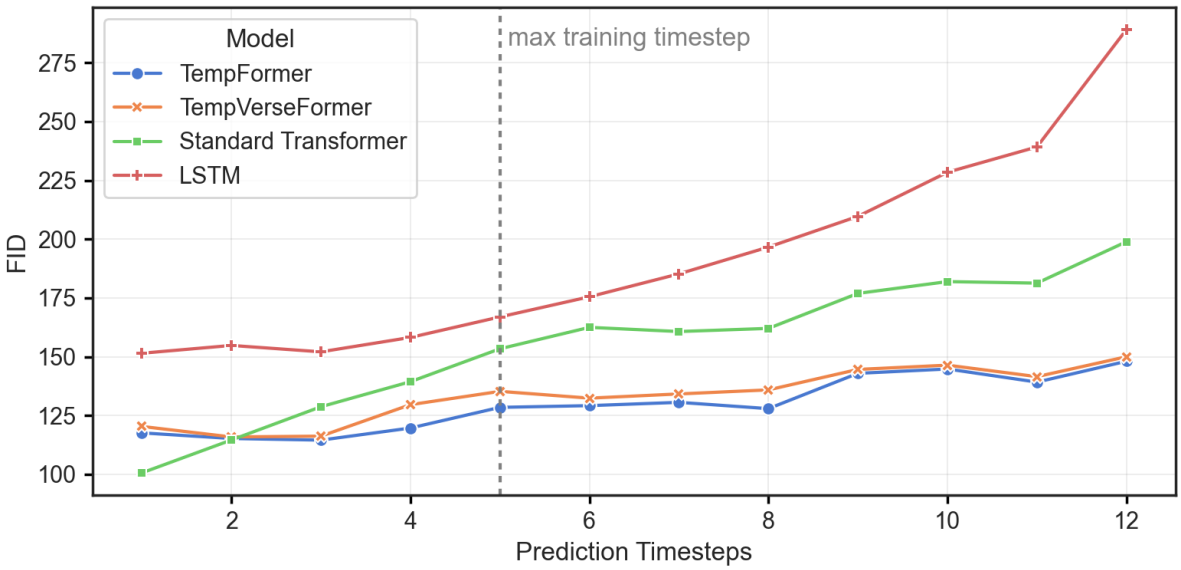


Рисунок 2.9 – FID залежно від глибини прогнозування для комбінованих часових закономірностей.

Розбіжність показників у цьому випадку є науково інформативною. FID порівнює розподіли в просторі ознак і може віддавати перевагу набору різноманітних зразків, навіть якщо відповідні кадри не наближені до своїх цільових значень [94]. MSE винагороджує вирівнювання пікселів і різко штрафує навіть невелике кутове зміщення. SSIM акцентує увагу на локальній яскравості, контрасті та структурі [94, 127–129]. Отже, LSTM може отримати найнижчий зафіксований показник FID за прискорення, маючи при цьому значно гірші показники MSE та SSIM. Визнання цього рядка загальним переможцем приховало б парний характер завдання прогнозування.

2.2.6 Зовнішня валідація OpenSTL

Контрольоване обертання не встановлює здатності моделі працювати з текстурованими сценами або природним рухом. Тому часову модель інтегровано в OpenSTL та оцінено за визначеними в ньому розбиттями й метриками на Moving MNIST, Moving MNIST-CIFAR, KTH Action і TaxiBJ [1, 124, 126, 154]. Опубліковане порівняння охоплює рекурентні ConvLSTM і PredRNN++ [137, 152], а також нерекурентні схожі архітектурно базові моделі ViT та Uniformer.

Таблиця 2.4 – Опубліковані порівняння OpenSTL

Набір даних	**Модель**	**SSIM ↑**	**MSE ↓**	**Найкращий результат у цьому порівнянні**
Moving MNIST	ConvLSTM	0,929	29,80	

Набір даних	Модель	SSIM ↑	MSE ↓	Найкращий результат у цьому порівнянні
	PredRNN++	**0,951**	**22,06**	SSIM та MSE
	TempVerseFormer	0,932	26,08	
	ViT	0,914	35,15	
	Uniformer	0,931	30,38	
Moving MNIST-CIFAR	ConvLSTM	0,920	73,31	
	PredRNN++	**0,957**	**44,19**	SSIM та MSE
	TempVerseFormer	0,950	50,37	
	ViT	0,936	64,94	
	Uniformer	0,944	56,96	
KTH Action	ConvLSTM	0,898	47,65	
	PredRNN++	**0,912**	**39,84**	SSIM та MSE
	TempVerseFormer	0,898	48,97	
	ViT	0,895	56,57	
	Uniformer	0,906	44,71	
TaxiBJ	ConvLSTM	0,9836	0,34	
	PredRNN++	0,9834	0,33	
	TempVerseFormer	0,9835	**0,31**	MSE
	ViT	0,9841	0,32	
	Uniformer	**0,9844**	0,34	SSIM

Це порівняння закриває важливу, але обмежену прогалину в доказах на контрольованих обертаннях. Воно показує, що часову архітектуру можна навчати для растрових об’єктів, текстурованих композицій, дій людей і сіткових полів потоків, не заявляючи домінування на окремому завданні. Протоколи також не приховують унікально релевантне спостереження за межами доступного контексту до моменту, коли воно знову стане потрібним. Отже, докази підтверджують переносимість і прогностичну спроможність; твердження

про пам’ять активацій спирається на прямі вимірювання реверсивних і нереверсивних процесів, а механізм досяжності залишається окремим питанням. Ширше значення результату полягає в тому, що контрольована перевірка не обмежилася одним рендерером.

Чотири набори даних перевіряють різні види компетентності. KTH замінює синтетичні цифри на артикульовані рухи людей, тоді як TaxiBJ є сітковим полем потоку, а не задачею візуалізації об’єктів. Однаково сильний результат у всіх чотирьох випадках був би переконливішим за успіх на одному генераторі обертання. Опублікована закономірність скромніша: архітектура залишається придатною до цих інтерфейсів, але її відносна позиція залежить від даних. Якісні панелі Moving-MNIST, Moving-MNIST-CIFAR, KTH і TaxiBJ перенесено до додатка E; кількісний висновок визначає таблиця 2.4.

2.2.7 Межа активаційної пам’яті та обчислювальної потужності

Центральною особливістю вимірювань TempVerseFormer є те, як по-різному масштабується пам’ять часового ядра. Опубліковані результати відокремлюють пам’ять, зарезервовану для часової моделі, від загальної виділеної пам’яті обчислювального тракту, яка також охоплює VAE та спільні компоненти. Без цього розмежування криву постійного ядра можна було б помилково прийняти за нульове зростання при кожному розподілі пам’яті на рівні пристрою.

Таблиця 2.5 – Опубліковані вимірювання пам’яті GPU для зазначених у таблиці горизонтів, розмір пакета 32

Кроки прогнозування	**Модель**	**Пам’ять часової моделі (ГБ)**	**Загальна пам’ять обчислювального тракту (ГБ)**
1	TempFormer	0,85	4,11
	TempVerseFormer	0,89	3,94
	Стандартний Transformer	0,85	4,10
	LSTM	1,27	4,00
4	TempFormer	0,85	4,59
	TempVerseFormer	0,89	3,95

Кроки прогнозування	Модель	Пам’ять часової моделі (ГБ)	Загальна пам’ять обчислювального тракту (ГБ)
	Стандартний трансформер	0,86	4,58
	LSTM	1,28	4,03
16	TempFormer	2,61	6,50
	TempVerseFormer	0,89	3,98
	Стандартний трансформер	2,60	6,51
	LSTM	1,28	4,13

Обсяг пам’яті часового ядра залишається близьким до заявленого базового значення в міру зростання реверсивного горизонту, на відміну від відповідного нереверсивного трансформера; загальний обсяг пам’яті обчислювального тракту включає спільні компоненти. Прогнозований графік зростання пам’яті зображено на рисунку 2.10.

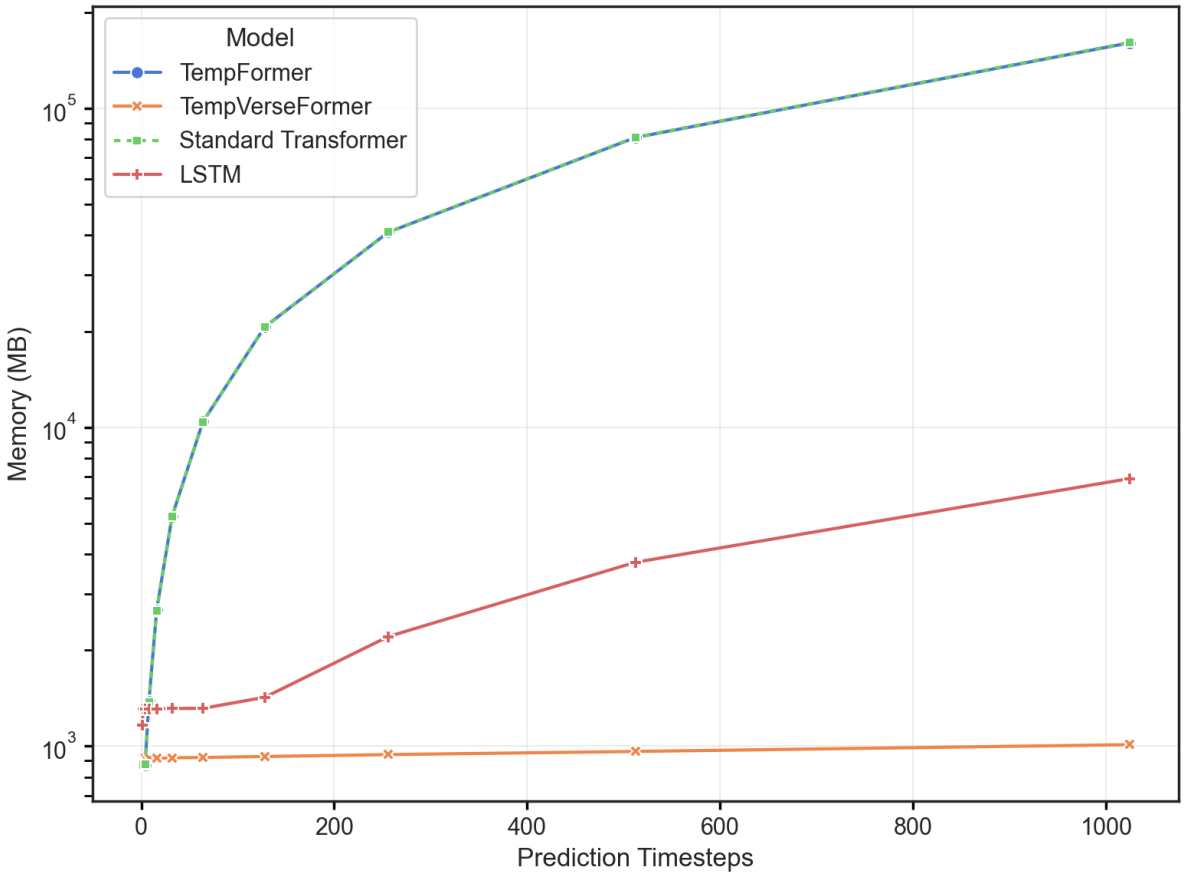


Рисунок 2.10 – Обсяг пам’яті GPU у порівнянні з глибиною прогнозування.

Пологіша крива пам’яті активацій досягається ціною обчислень для відтворення, тому здійсненність і час виконання потрібно оцінювати разом. Залежність часу одного кроку навчання від кількості кроків прогнозування показано на рисунку 2.11.

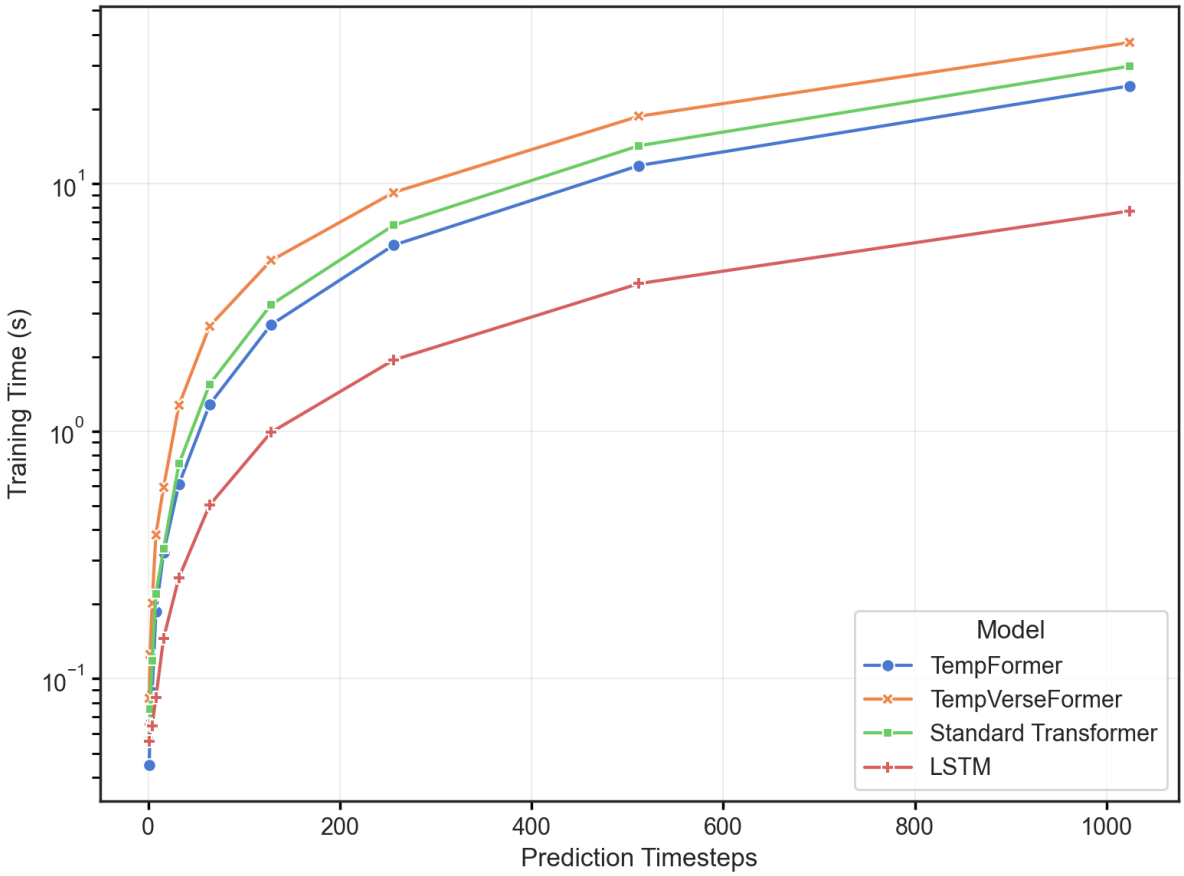


Рисунок 2.11 – Час навчання залежно від глибини прогнозування.

Уже на шістнадцятому кроці порівняння показує робочий ефект без опори на дальню частину кривої. TempVerseFormer використовує на 1,72 ГБ менше заявленої пам’яті часової моделі, ніж TempFormer, тобто приблизно на 66%. Для повного обчислювального тракту різниця становить 2,52 ГБ, або близько 39%, оскільки спільні просторові й навчальні витрати пам’яті залишаються. Перший показник краще ізолює механізм, другий ближчий до обсягу, який спостерігає користувач на практиці.

Опубліковані графіки візуально поширюються на 1024 кроки прогнозування, при цьому реверсивна крива часового ядра залишається приблизно на рівні 1 ГБ. Однак збережені результати не містять точних координат для цих точок широкого горизонту. Тому кількісні порівняння

обмежуються табличними вимірюваннями на одному, чотирьох та шістнадцяти кроках. Більш віддалена частина використовується лише для опису тенденції масштабування, показаної на графіку.

Реверсивність у цьому порівнянні змінює спосіб зберігання проміжних активацій для зворотного проходу, але не додає жодного спостереження до вхідного контексту. Модель із коротким вікном залишається нездатною безпосередньо адресувати подію, що вийшла за його межі, навіть якщо реверсивне ядро дає змогу диференціювати довший обчислювальний ланцюг. Отже, довжина диференційованого розгортання, досяжність збереженої історії та стійкість довгого авторегресивного прогнозу є трьома окремими характеристиками.

2.2.8 Розширення стохастичного відтворення та окремі перевірки рекурентного ядра

У межах реверсивного стеку опублікована часова модель залишається детермінованою. Генеративні відеопереходи часто є стохастичними: вони можуть вибирати випадкове збурення у прихованому просторі, застосовувати стохастичну регуляризацію або отримувати випадковий дифузійний стан. Нехай $\epsilon_t \sim \mathcal{N}(0, I)$ є реалізованим випадковим збуренням, а σ — його масштабом. Якщо відкинути фактично використане значення ϵ_t , буде втрачено інформацію, потрібну для реконструкції.

$$h_t = F_\theta(h_{t-1}) + \sigma\epsilon_t. \tag{2.19}$$

Якщо F_θ є оборотним, а реалізоване збурення ϵ_t відоме, попередній стан h_{t-1} відновлюється як

$$h_{t-1} = F_\theta^{-1}(h_t - \sigma\epsilon_t). \tag{2.20}$$

Рівняння (2.20) коректне лише тоді, коли реалізоване ϵ_t відоме, а саме відображення F_θ є оборотним на розглянутій області. Адитивне зв'язування нижче усуває другу вимогу: для реконструкції стану функції F_θ і G_θ потрібно повторно обчислити, але вони не зобов'язані бути оборотними окремо.

$$y_{1,t} = s_{1,t-1} + F_\theta(s_{2,t-1}, \epsilon_t). \tag{2.21}$$

Другий вихідний потік $y_{2,t}$ використовує вже обчислене значення $y_{1,t}$:

$$y_{2,t} = s_{2,t-1} + G_\theta(y_{1,t}). \tag{2.22}$$

Обернення виконується у зворотному порядку: спочатку відновлюється другий потік, а потім перший.

$$s_{2,t-1} = y_{2,t} - G_\theta(y_{1,t}). \tag{2.23}$$

Після цього перший попередній потік $s_{1,t-1}$ відновлюється з відомого шуму та відновленого $s_{2,t-1}$:

$$s_{1,t-1} = y_{1,t} - F_\theta(s_{2,t-1}, \epsilon_t). \tag{2.24}$$

Загальну пам'ять умов відтворення $M_{\text{replay}}(T)$ розкладемо на прив'язки стану, стан генератора випадкових чисел і стохастичні гейти:

$$M_{\text{replay}}(T) = M_{\text{anchor}}(T) + M_{\text{rng}}(T) + M_{\text{gates}}(T). \tag{2.25}$$

Тут D_ϵ – кількість значень в одному збуренні, b_ϵ – розрядність одного такого значення, а b_{seed} – розрядність збереженої ініціалізації генератора. Альтернативні схеми дають $M_{\text{rng}} = TD_\epsilon b_\epsilon/8$ для збережених інновацій, $M_{\text{rng}} = Tb_{\text{seed}}/8$ для окремої ініціалізації на кожен крок або $M_{\text{rng}} = M_{\text{counter}}$ для лічильникового відтворення. Це альтернативи, а не витрати, які додаються одночасно. У виміряній детермінованій межі пам'яті $M_{\text{rng}} = 0$, проте процедура зберігає повні повторні прив'язки стану. Якщо інтервал між ними обрано як $a = \lfloor\sqrt{T}\rfloor$, D_s позначає кількість значень стану, а b_s – їхню розрядність, то

$$M_{\text{anchor}}(T) \approx \left\lceil \frac{T}{a} \right\rceil \frac{D_s b_s}{8} = O(\sqrt{T} D_s). \tag{2.26}$$

Отже, обґрунтоване загальне твердження стосується сталої за T **тимчасової локальної пам'яті активацій** разом із явно врахованими прив'язками та метаданими відтворення. Воно не означає сталої загальної пам'яті для кожної реверсивної або стохастичної рекурентної системи.

Однієї ініціалізації генератора на часовий крок достатньо лише за тотожних алгоритму випадкових чисел, порядку викликів, форми тензорів, семантики пристрою й точності обчислень. Збереження фактично використаного шуму потребує більше пам'яті, зате менше залежить від прихованих деталей програмного середовища й полегшує аудит траєкторії після зміни коду.

Контракт оборотності стає перевірним після встановлення окремих допусків для детермінованого й стохастичного режимів. Похибка детермінованої

реконструкції у FP64 має бути меншою за 10^{-9}, а у FP32 – меншою за 10^{-4}; для стохастичного переходу зі збереженим шумом допустимий дрейф становить менше 10^{-8}, тоді як навмисно неправильний шум повинен давати похибку понад 10^{-2}; косинус подібності градієнтів має перевищувати $0{,}9999$. Це пороги реалізації, а не нові експериментальні ефекти. Для перших історичних перевірок не збережено окремого незмінного звіту з фіксованою випадковою ініціалізацією, тому числові спостереження не використовуються як самостійні докази.

Таблиця 2.6 – Виміряні значення детермінованої багаторівневої пам'яті та межі часу виконання на RTX 4060 Ti 16 ГБ. Це історичні профілі; без повного первинного запису точності, повторів, пакета й режиму WDDM вони не є зіставним профілем моделі з адаптивним пакуванням. Невідновлені умови позначаються як обмеження відтворюваності.

Розгортання (K)	**Пік BPTT (МБ)**	**Пік із контрольними точками (МБ)**	**Пік реверсивного відтворення (МБ)**	**BPTT (мс/крок)**	**Контрольні точки (мс/крок)**	**Реверсивне відтворення (мс/крок)**
10	3 809	1 354	1 065	549	322	257
20	6 592	1 391	1 078	399	544	479
40	12 162	1 471	1 091	740	1 028	882
80	23 305*	1 637	1 125	43 797*	3 131	2 556
120	OOM	1 801	1 152	-	3 960	2 760
160	OOM	1 967	1 176	-	4 066	3 362

Виконання BPTT із $K = 80$ перевищило обсяг фізичної пам'яті GPU та в режимі WDDM перейшло до спільної пам'яті хоста. Воно завершилося, але вже не відповідало практичному навчанню з даними, розміщеними на пристрої.

Виміряні сумарні значення охоплюють кодер, детерміноване трирівневе рекурентне ядро, декодер, стан Adam, пакет розміром 32 та входи 64×64. Стандартний BPTT стає нездійсненним до $K = 120$. І збереження контрольних точок, і реверсивне відтворення досягають $K = 160$; у наведених точках виміряна реалізація відтворення використовує менше пікової пам'яті й часу, ніж реалізація з контрольними точками. Ці залежні від конфігурації вимірювання не

доводять переваги реверсивного відтворення над оптимально спланованою або налаштованою під конкретне ядро системою контрольних точок.

Точне відновлення одного кроку є необхідною, але не достатньою умовою для довгого розгортання. Алгебрична оборотність сама по собі не гарантує стійкості прямої динаміки. Виконувана 100-крокова діагностика окремо перевіряє реконструкцію стану та зростання малого збурення для необмеженого зв'язування і трьох спектрально обмежених варіантів. Усі переходи залишаються оборотними, проте контрольоване підсилення спостерігається лише за менших перевірених масштабів виходу. Окремого замороженого артефакту T1–T4 з числовими відношеннями не збережено, тому ці значення не використовуються як основний кількісний доказ. Для залишкового відображення $I + F$ із нерівності трикутника випливає лише загальна верхня межа

$$Lip(I + F) \leq 1 + Lip(F) \tag{2.27}$$

Фактичне підсилення може бути меншим через компенсацію складових. Отже, оборотність забезпечує реконструкцію стану, а динамічна стійкість залежить від навченого переходу та накладених на нього обмежень [111, 112].

2.2.9 Застосовність щодо BPTT та системи контрольних точок

Жодна схема зворотного обчислення не є найкращою для кожної моделі. Стандартний BPTT привабливий, коли потрібний горизонт легко вміщується в пам'ять, оскільки не потребує реконструкції проміжних станів. Обрізання є обґрунтованим вибором моделі, якщо залежності за межею сегмента вилучаються навмисно. Збереження контрольних точок працює з довільними диференційовними модулями й дає змогу налаштувати співвідношення між зберіганням і повторним обчисленням. Реверсивне відтворення вимагає чітко окресленого реверсивного стану, стабільної числової реконструкції та точного повторення стохастичних входів [30, 32, 91, 110, 113, 116].

Вирішальним є те, яку частку пам'яті може звільнити обернене відтворення. В опублікованому часовому ядрі та на детермінованому багаторівневому рекурентному межі повторні активації займають достатньо пам'яті, щоб реконструкція могла змінити здійсненність обчислення. У

перевіреному внутрішньому циклі оптимізації натомість домінують локальні графи другого порядку й спільний стан моделі, тому практичнішим вибором є збереження контрольних точок. У розділі 4 це правило вибору за обмежувальним ресурсом використано без трактування реверсивності як універсальної архітектурної переваги.

Таблиця 2.7 – Вибір стратегії часового диференціювання за обмежувальними умовами. Реверсивність обирається залежно від графа навчання та профілю ресурсів, а не на основі припущення про переваги в прогнозуванні.

Метод	**Залежність пам'яті від горизонту**	**Додаткові обчислення**	**Архітектурні умови**	**Належне використання**
Стандартний BPTT	повна стрічка активацій, зазвичай $O(TLD_s)$	базовий рівень	відсутні	весь горизонт зручно вміщується
Укорочений BPTT	обмежений обраним сегментом	базовий рівень у межах сегмента	відсутні	ранні залежності навмисно виключаються
Збереження контрольних точок градієнта	залежить від розкладу	повторно обчислює пропущені сегменти	звичайні диференційовні модулі	потрібен загальний, регульований компроміс між зберіганням і часом
Реверсивне відтворення	локальний граф, граничний стан, прив'язки та метадані відтворення	обернення та локальне повторне пряме обчислення	стабільне обернення збереженого стану	повторні реверсивні активації домінують у довгому графі навчання

У новій інтегрованій моделі реверсивний механізм розміщено всередині повторюваного Transformer-ядра. Звичайний і реверсивний режими використовують ті самі функції перетворення та мають однаковий прямий результат за однакових ваг, входів і режиму стохастичних операцій; відмінність виникає під час зберігання або відтворення активацій для градієнта. Другопорядкова реверсивна рекуренція, досліджена як ранній інтеграційний прототип, залишається окремою реалізацією і не використовується як доказ еквівалентності нового внутрішнього ядра.

Реверсивність усуває зростання стрічки активацій у перевіреному часовому ядрі, але не стискає сам вхідний контекст. Якби кадр 64×64 подавався до глобальної уваги по одному токену на піксель, 12 кадрів утворили б послідовність із 49 152 токенів. Одна матеріалізована матриця уваги для одного прикладу й однієї голови тоді містила б $49152^2 = 2415919104$

елементи: приблизно 9,0 ГіБ у fp32 або 4,5 ГіБ у fp16/bf16, без урахування інших активацій. Це не означає, що ієрархія є єдиним способом зменшення вартості: можливі локальна чи розріджена увага, пошук у пам’яті, рекурентний стан, часове піддискретизування, об’єднання токенів, лінійна увага та моделі простору станів. У цій дисертації обрано багаторівневий шлях: давня історія зберігається грубо, недавня – детально, а локально однорідні просторові значення можуть агрегуватися перед глобальною обробкою. Наступний підрозділ розглядає останню ідею на прикладі V-BLT.

2.3 Ієрархічне просторове представлення та оцінка ентропії

Ця частина переходить від пам’яті навчального графа до просторової ціни детального контексту. Ієрархія V-BLT є локально–глобальною ієрархією всередині одного представлення: локальні байти агрегуються до коротшої глобальної послідовності, після чого деталь відновлюється. Вона не тотожна грубій і детальній історії розділу 3, де змінюються роздільна здатність і часова досяжність, але обидві конструкції спираються на той самий принцип – не всі рівні опису потрібно зберігати й обробляти з однаковою щільністю.

2.3.1 Проблема розподілу фіксованих патчів

У цьому розділі **патч** означає фіксовану просторово-часову область растрових байтів, яку локальний кодер V-BLT перетворює на певне приховане представлення; **токен** є вектором, що надходить до трансформера; **пакет контексту** в розділах 3–4 є окремим поняттям і задає сукупність збережених кадрів, рівнів та часових прив’язок.

Диференційованість довшого часового ланцюга розв’язує лише проблему пам’яті під час навчання довгострокового прогнозування. Наступне вузьке місце є просторовим: воно визначається тим, як візуальна модель розподіляє ємність представлення. Типовий механізм попередньої обробки у відеотрансформерах розбиває кліп на регулярну сітку просторово-часових патчів, вбудовує кожну комірку як вектор і обробляє отриману послідовність [70, 71]. Повторювані патчі можна об’єднувати в регіональні пакети, де кожному токену відповідає чітко визначена геометрична область. Проте вартість визначається кількістю патчів, а

не обсягом непередбачуваного вмісту всередині них. Для кліпу з T кадрів висоти H і ширини W, поділеного на блоки розміром $\tau \times p_h \times p_w$, кількість областей дорівнює

$$N_{\text{patch}} = \left\lceil \frac{T}{\tau} \right\rceil \left\lceil \frac{H}{p_h} \right\rceil \left\lceil \frac{W}{p_w} \right\rceil. \quad (2.28)$$

Статична чорна область і рухомий контур отримують однакову кількість токенів. Це не означає автоматичної неефективності: регулярність може бути корисною, а навчений кодер здатний пригнічувати надлишковий вміст. Сумнів виникає тоді, коли глобальна модель є найдорожчим компонентом архітектури, а щільність локальної інформації різко неоднорідна. За таких умов значна частина обчислень припадає на області, малорелевантні для конкретного завдання прогнозування руху об'єкта.

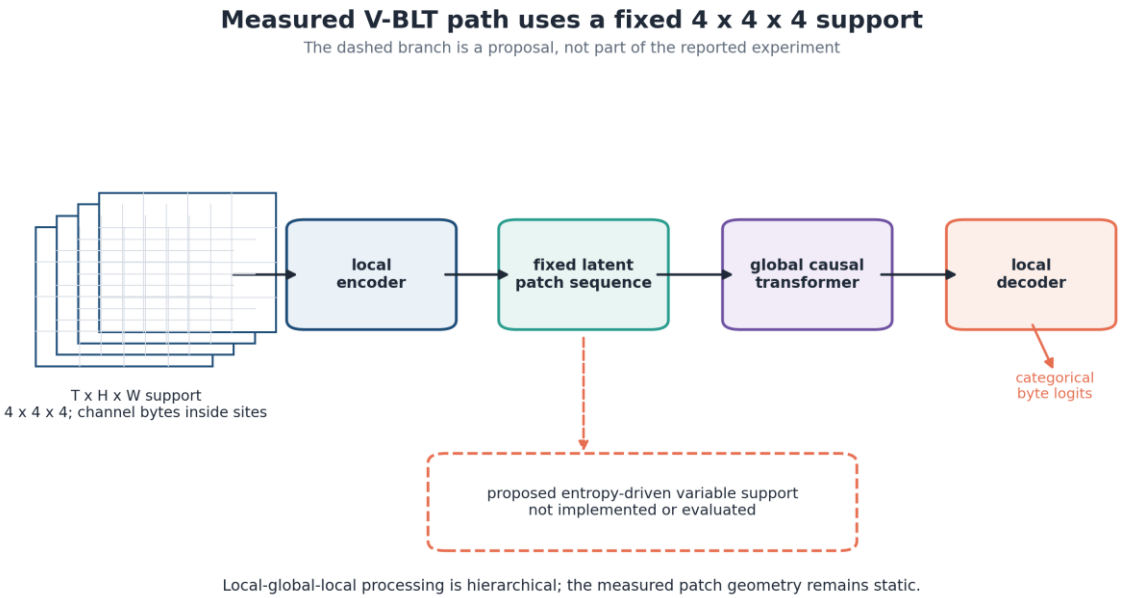


Рисунок 2.12 – Шлях обробки «локальний-глобальний-локальний».

Як зображено на рисунку 2.12, просторово-часовий блок спочатку стискається локальним кодером до одного глобального представлення. Трансформер обмінюється інформацією між такими представленнями, після чого локальний декодер відновлює розподіли байтів у кожній растровій позиції.

2.3.2 Архітектура V-BLT

V-BLT оперує на рівні **байт-каналу пікселів растрового зображення**. Цільовий байт $x_{t,c,y,x}$ є цілим числом із множини $\{0, \dots, 255\}$. Такий вихідний

інтерфейс дає змогу реалізувати нерегресійний вихідний модуль, не прив'язуючи результат безпосередньо до навченої дискретної кодової книги, як у VQ-VAE [73]. Водночас приховане представлення залишається оптимізованим: згортки, проєкції, увага та скінченна ширина прихованого простору утворюють навчуване інформаційне поле.

Нехай X є вхідним кліпом, $\mathcal{P}_m(X)$ – його m-й фіксований просторово-часовий блок, де $m = 1, \dots, N_{\text{patch}}$, а E_α, G_β і D_γ – локальний кодер, глобальний трансформер та локальний декодер. Індекси α, β і γ позначають три окремі набори навчуваних параметрів, щоб не змішувати локальне кодування, глобальну обробку та локальне декодування. Маска M_{causal} робить доступ до майбутніх кадрів неможливим, а R_{ND} вносить окремі часові й просторові координати в послідовність даних. Тоді послідовність перетворень має вигляд:

$$u_m = E_\alpha(\mathcal{P}_m(X)). \tag{2.29}$$

Послідовність глобально контекстуалізованих ознак $g_{1:N_{\text{patch}}}$ утворює трансформер G_β:

$$g_{1:N_{\text{patch}}} = G_\beta(u_{1:N_{\text{patch}}}; M_{\text{causal}}, R_{\text{ND}}), \tag{2.30}$$

Локальний декодер повертає для кожної растрової позиції вектор логітів $\ell_{t,c,y,x} \in \mathbb{R}^{256}$:

$$\ell_{t,c,y,x} = D_\gamma(r_{t,c,y,x}, g_{\pi(t,y,x)}) \in \mathbb{R}^{256}. \tag{2.31}$$

де u_m є представленням блока, g_m – його глобально контекстуалізованою ознакою, $r_{t,c,y,x}$ – локальною ознакою декодера, а $\pi(t, y, x)$ відображає растрову координату на відповідну глобальну область.

Вектор $\ell_{t,c,y,x} \in \mathbb{R}^{256}$ містить логіти всіх можливих значень байта. Перехресна увага передає інформацію між локальними та блоковими представленнями. Отже, глобальний трансформер виконує широке просторово-часове моделювання, тоді як локальні етапи зберігають і відновлюють деталі.

У прямому проході локальний кодер спочатку стискає байти кожного фіксованого просторово-часового блока до представлення u_m. Глобальний модуль обмінює інформацію між такими представленнями за причинної маски. Локальний декодер поєднує глобальний контекст з ознакою конкретної

растрової позиції й повертає 256 логітів для її байта. Таким чином, глобальна послідовність коротша за послідовність усіх байтів, але детальне відновлення залишається локальною обчислювальною роботою.

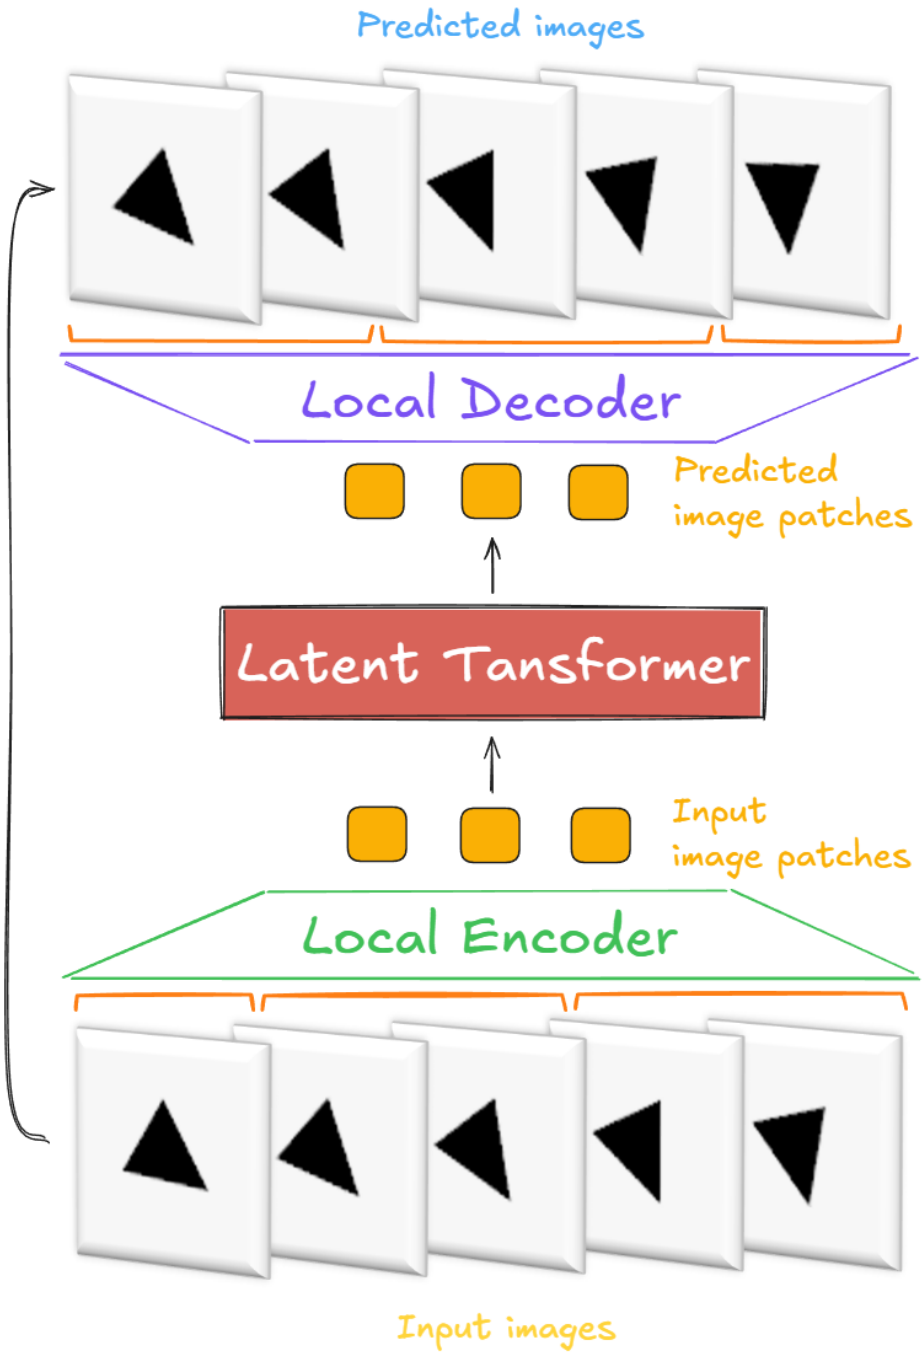


Рисунок 2.13 – Опублікована архітектура Vision Byte Latent Transformer.

На схемі, зображеній на рисунку 2.13, центральний глобальний трансформер працює не з усіма байтами безпосередньо, а з локально агрегованими представленнями. Кодер і декодер утворюють два боки локально-глобально-локального тракту.

Архітектурні дані підтверджують ієрархічний метод представлення. Вони не доводять, що модель сформувала семантично змістовні патчі, що послідовність прихованих представлень є оптимальною або що та сама конструкція без змін масштабується на стиснене відео природного походження.

Таблиця 2.8 – Компоненти V-BLT та рівень їх доказовості. Таблиця розмежовує реалізовану систему з фіксованими ділянками й запропонований, але не перевірений динамічний розподільник.

Компонент	**Функція**	**Статус опублікування**	**Межі доказів**
Інтерфейс «растр-байт» та локальний кодер	збереження категоріальних цілей та агрегація короткодіапазонної структури	реалізовано	приховані ознаки залишаються навченими та мають втрати
Фіксоване призначення пакетів розміром $4 \times 4 \times 4$	визначення глобальних обчислювальних одиниць	повідомлено	точна історична конфігурація запуску не повністю заархівована
Глобальний трансформер прихованих представлень та локальний декодер	обмін широким контекстом та відновлення локальних деталей	реалізовано	причинно-наслідковий внесок на рівні компонентів не ізольовано
RoPE-ND	збереження окремих часових, рядкових і стовпцевих координат	реалізовано	математична умова подільності є сильнішою за поточну програмну перевірку
Категоріальна байтова голова	прогнозує 256 логітів у кожній позиції байта	реалізовано	каліброваність імовірностей не показано
Карта ентропії	діагностує просторову дисперсію прогнозів	вимірян о та візуаліз овано	зв’язок із похибкою є описовим
Контролер динамічних регіонів	змінює розмір регіонів або маршрутизує обчислення	не реалізовано	лише запропоноване розширення

2.3.3 Причинна увага та категоріальна байтова ціль

Після визначення просторових одиниць потрібно задати, які з них можуть обмінюватися інформацією. Повністю двонапрямлена увага допустила б витік із майбутніх кадрів, тоді як суто послідовна маска штучно заборонила б взаємодію між пікселями одного вже спостережуваного кадру. Тому каузальність тут має дві шкали: вільний обмін інформацією всередині доступного кадру та заборону доступу до наступних кадрів. Сплющення кліпу перетворює час і простір на єдиний індекс токена, тому дозвільну маску визначено через часові координати.

Якщо токен i належить до кадру t_i, а токен j – до t_j, глобальна маска уваги має вигляд:

$$M_{ij} = \begin{cases} 0, & t_j \le t_i, \\ -\infty, & t_j > t_i. \end{cases} \tag{2.32}$$

Нерівність $t_j \le t_i$ дозволяє обмін усередині поточного та з усіма попередніми кадрами, тоді як $t_j > t_i$ додає $-\infty$ до відповідного логіту перед застосуванням функції softmax [12]. Отримана матрична маска містить щільні діагональні блоки кадрів у блочно-нижньотрикутній часовій структурі. На рівні глобальної уваги прямий витік майбутньої інформації заблоковано, тоді як фізична правдоподібність і авторегресивна стійкість залишаються властивостями, які модель має вивчити.

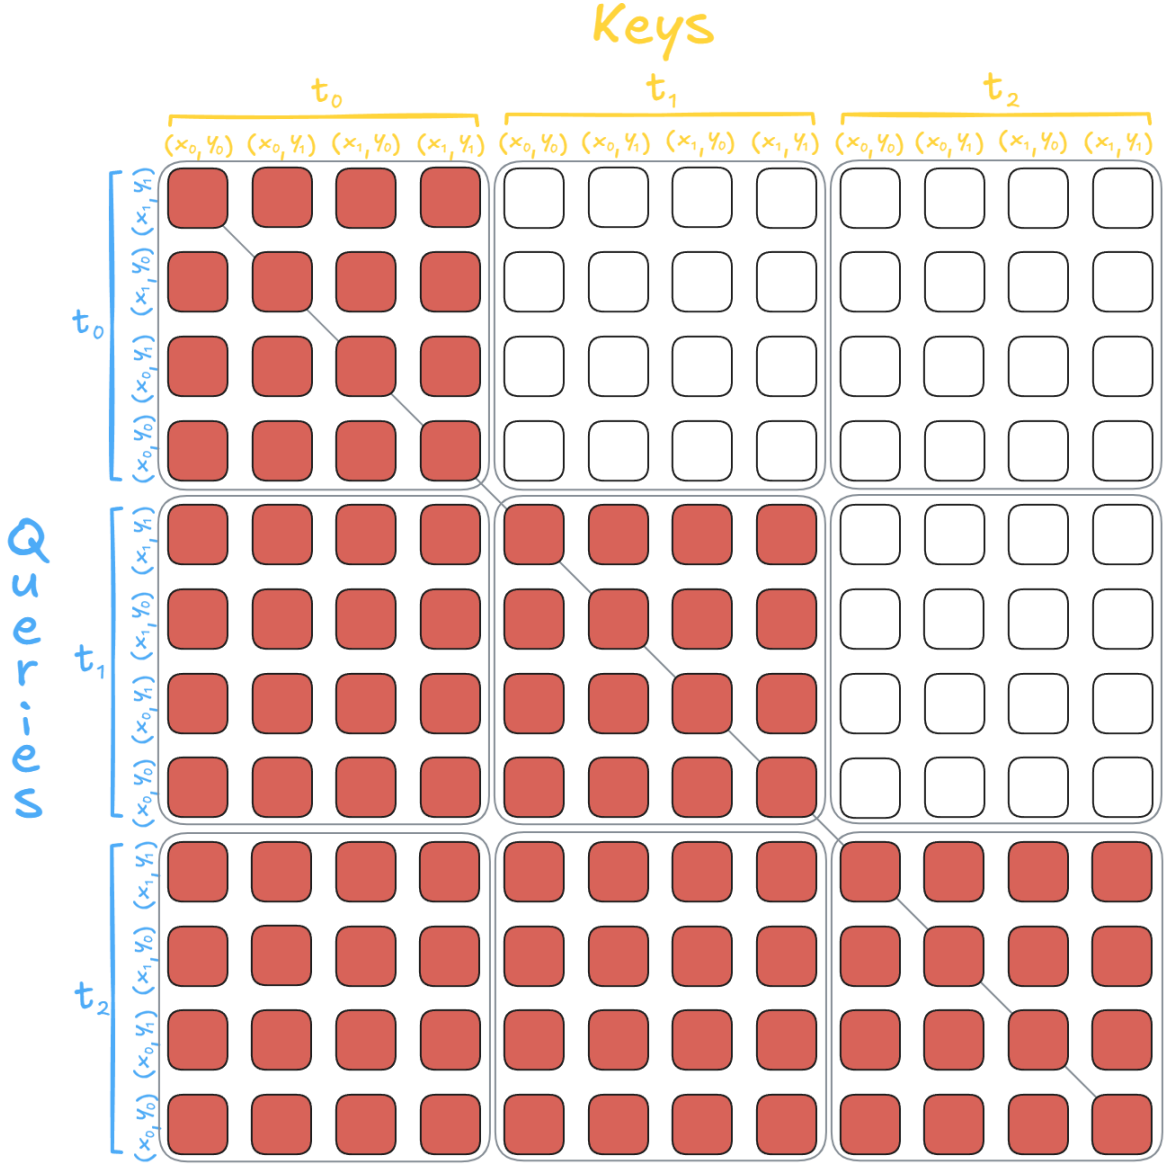


Рисунок 2.14 – Каузальна просторово-часова маска уваги.

Діагональні блоки дозволяють взаємодію між просторовими позиціями одного кадру, нижні блоки відкривають попередні кадри, а верхня частина матриці блокує майбутнє. Цю структуру безпосередньо показано на рисунку 2.14.

Після визначення доступної історії кожна цільова позиція прогнозується як категоріальний розподіл за 256 значеннями байта $k \in \{0, \dots, 255\}$, а навчальна ціль усереднює від'ємну логарифмічну правдоподібність за цільовими позиціями.

$$p_\theta(x_i = k \mid X_{<t}) = \frac{\exp(\ell_{i,k})}{\sum_{r=0}^{255} \exp(\ell_{i,r})}. \tag{2.33}$$

Використовуючи цей розподіл, байтова втрата $\mathcal{L}_{\text{byte}}(\Theta)$ усереднює від'ємну логарифмічну правдоподібність за множиною цільових позицій $\mathcal{I}$:

$$\mathcal{L}_{\text{byte}}(\Theta) = -\frac{1}{|\mathcal{I}|} \sum_{i \in \mathcal{I}} \log p_\theta(x_i = x_i^\star \mid X_{<t_i}), \tag{2.34}$$

де $\mathcal{I}$ містить цільові позиції байтів, а $x_i^\star$ – еталонне ціле значення. На відміну від скалярного регресивного виходу, який повертає одне значення, категоріальний інтерфейс може представляти кілька правдоподібних значень байта в одній позиції та безпосередньо надає розподіл для обчислення прогностичної ентропії. Це корисно для виявлення локально неоднозначних ділянок. Водночас сам розподіл не гарантує каліброваності ймовірностей і не усуває залежність між сусідніми байтами, якщо вихідний модуль прогнозує їх факторизовано.

2.3.4 Багатовимірне ротаційне позиційне кодування

До додавання позиційної інформації механізм самоуваги залишається еквіваріантним відносно перестановки [12, 71, 106]. Навіть після вирівнювання просторово-часової сітки сам порядок токенів не може вказувати, чи знаходиться сусідній токен на один стовпець, один рядок або один кадр далі. Абсолютні вбудовування призначають мітки окремим індексам, а відносні зміщення описують зв'язки між парами [106]. Ротаційне вбудовування позиції працює інакше: алгоритм обертає пари ознак запитів і ключів за фазами, що залежать від позиції, тим самим змінюючи їхній скалярний добуток відповідно до відносного зміщення [107].

Для однієї реальної пари ознак (v_{2j}, v_{2j+1}) визначимо комплексну координату $\tilde{v}_j = v_{2j} + \mathrm{i}v_{2j+1}$. Нехай $j = 0, \ldots, K-1$ нумерує K пар ознак, β задає базу частот, а $\omega_j = \beta^{-j/K}$ – частоту j-ї пари. У скалярній позиції p одновимірне RoPE застосовує обертання (2.35). Рівняння (2.36) і його дійсна матрична форма (2.37) показують, що скалярний добуток залежить від відносного зсуву $q - p$, а не від двох абсолютних координат окремо:

$$\rho_p(\tilde{v}_j) = \tilde{v}_j \exp(\mathrm{i}p\omega_j). \tag{2.35}$$

Для запиту в позиції p і ключа в позиції q добуток повернених комплексних координат залежить від різниці фаз:

$$\rho_p(\tilde{q}_j)\rho_q(\overline{\tilde{k}_j}) = \tilde{q}_j\overline{\tilde{k}_j}\exp(\mathrm{i}(p-q)\omega_j). \tag{2.36}$$

Те саме обертання в дійсних координатах задає матриця $\mathbf{R}_j(p)$:

$$\mathbf{R}_j(p) = \begin{bmatrix} \cos(p\omega_j) & -\sin(p\omega_j) \\ \sin(p\omega_j) & \cos(p\omega_j) \end{bmatrix}. \tag{2.37}$$

З матричної форми випливає тотожність $\mathbf{R}_j(p)^\top \mathbf{R}_j(q) = \mathbf{R}_j(q-p)$. Для відео ознаки запиту q та ключа k поділяються на неперетинні підпростори часу, рядка і стовпця. Якщо $p = (p_t, p_y, p_x)$ є координатою токена, багатовимірне обертання утворюється конкатенацією трьох осьових перетворень:

$$R_{\mathrm{ND}}(p)q = R_t(p_t)q_t \| R_y(p_y)q_y \| R_x(p_x)q_x. \tag{2.38}$$

Відповідний логіт уваги розкладається на складові, що залежать від осі:

$$s(q,k;p,r) = \frac{1}{\sqrt{d_h}} \sum_{a\in\{t,y,x\}} q_a^\top R_a(r_a - p_a)k_a. \tag{2.39}$$

Наприклад, два токени можуть належати тому самому рядку й стовпцю, але сусіднім кадрам, тоді змінюється лише їх часова фазова складова. Для сусідніх просторових областей одного кадру змінюється відповідна координата рядка або стовпця. Такий поділ запобігає ситуації, коли однаковий зсув у лінеаризованій послідовності помилково означає різні фізичні відношення.

Для токенів з кількома роздільними здатностями цілочисельні індекси рядків і стовпців двох сіток не можна порівнювати безпосередньо без спільної системи координат. Грубий токен з індексом 1 може охоплювати ту саму фізичну область, що й кілька індексів детальної сітки. V-BLT уникає цієї проблеми, використовуючи одну геометрію прихованого простору. Для

багаторівневого ієрархічного середовища вона, однак, залишається істотною; один із можливих варіантів розглянуто в розділі 3.

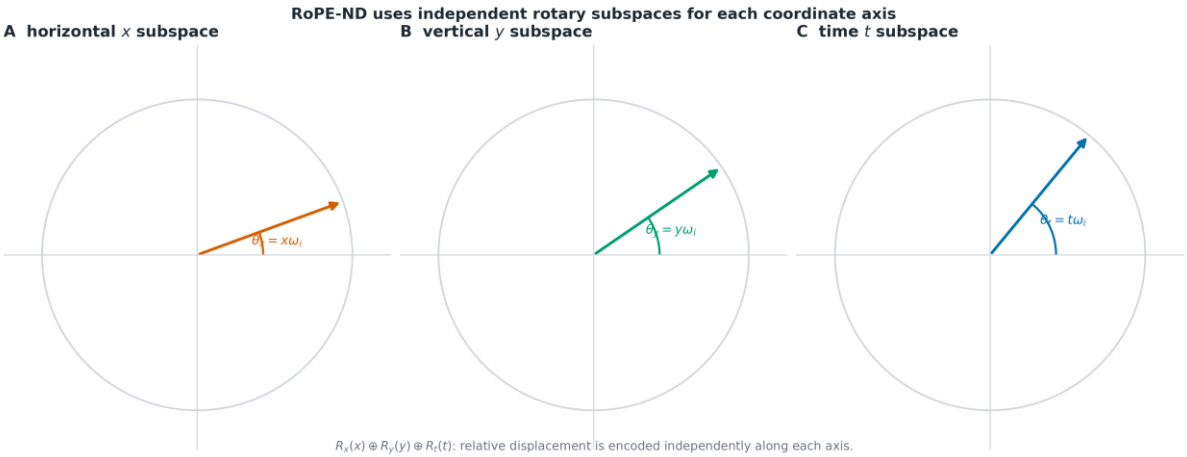


Рисунок 2.15 – Неперетинні координатні підпростори в RoPE-ND.

Кожна пара каналів отримує фазу лише однієї фізичної осі. Завдяки цьому часовий зсув не змішується зі зміною рядка або стовпця після лінеаризації кліпу. Приклад роботи зображено на рисунку 2.15.

2.3.5 Прогностична ентропія як сигнал просторової складності

Категоріальний байтовий вихід задає повний розподіл, а не лише точковий прогноз. Його локальну невизначеність можна узагальнити ентропією Шеннона [9], виміряною в бітах:

$$H_i^{(2)} = -\sum_{k=0}^{255} p_{i,k} \log_2 p_{i,k}. \tag{2.40}$$

Для категоріального розподілу за 256 значеннями виконується $0 \le H_i^{(2)} \le 8$: точкова маса відповідає нижній межі, тоді як рівномірний розподіл досягає верхньої.

Тестований код візуалізації обчислює ентропію в натах, використовуючи натуральний логарифм:

$$H_i^{(e)} = -\sum_{k=0}^{255} p_{i,k} \ln p_{i,k} = (\ln 2) H_i^{(2)}. \tag{2.41}$$

Величини (2.40) і (2.41) відрізняються лише постійним множником $\ln 2$, тому просторове ранжування областей не змінюється.

На рисунку 2.16 показано весь шлях від 256 логітів у кожній позиції до нормованої карти, яку можна накласти на кадр. Після перетворення логітів функцією softmax ентропія обчислюється для кожного байта, агрегується за

каналами та візуалізується у координатах кадру. Через інвертовану шкалу сірого темніша область відповідає вищій невизначеності прогнозу, але ще не доводить, що саме їй слід виділити більше токенів.

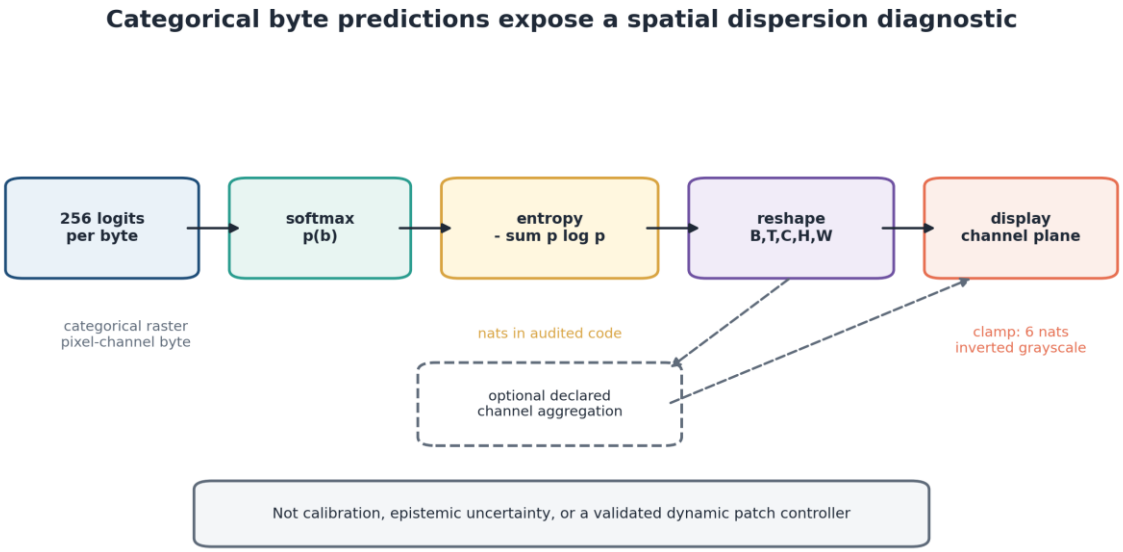


Рисунок 2.16 – Від категоріальних логітів до карти просторової ентропії.

Щоб перетворити цю карту на контролер, самої візуальної структури недостатньо. Калібрування можна перевірити, згрупувавши прогнозовані ймовірності байтів або значення ентропії та вимірявши фактичну помилку. Просторову корисність потрібно встановлювати порівнянням ентропійного розподілу ресурсів із випадковою, заснованою на русі та політиками передбачення за однакового бюджету токенів. Може знадобитися й часове згладжування: зміна межі патча в кожному кадрі створює накладні витрати та нестабільні ідентифікатори токенів. Дослідження проводилося на фіксованих патчах і не містить перевірок зазначених вище гіпотез контролера.

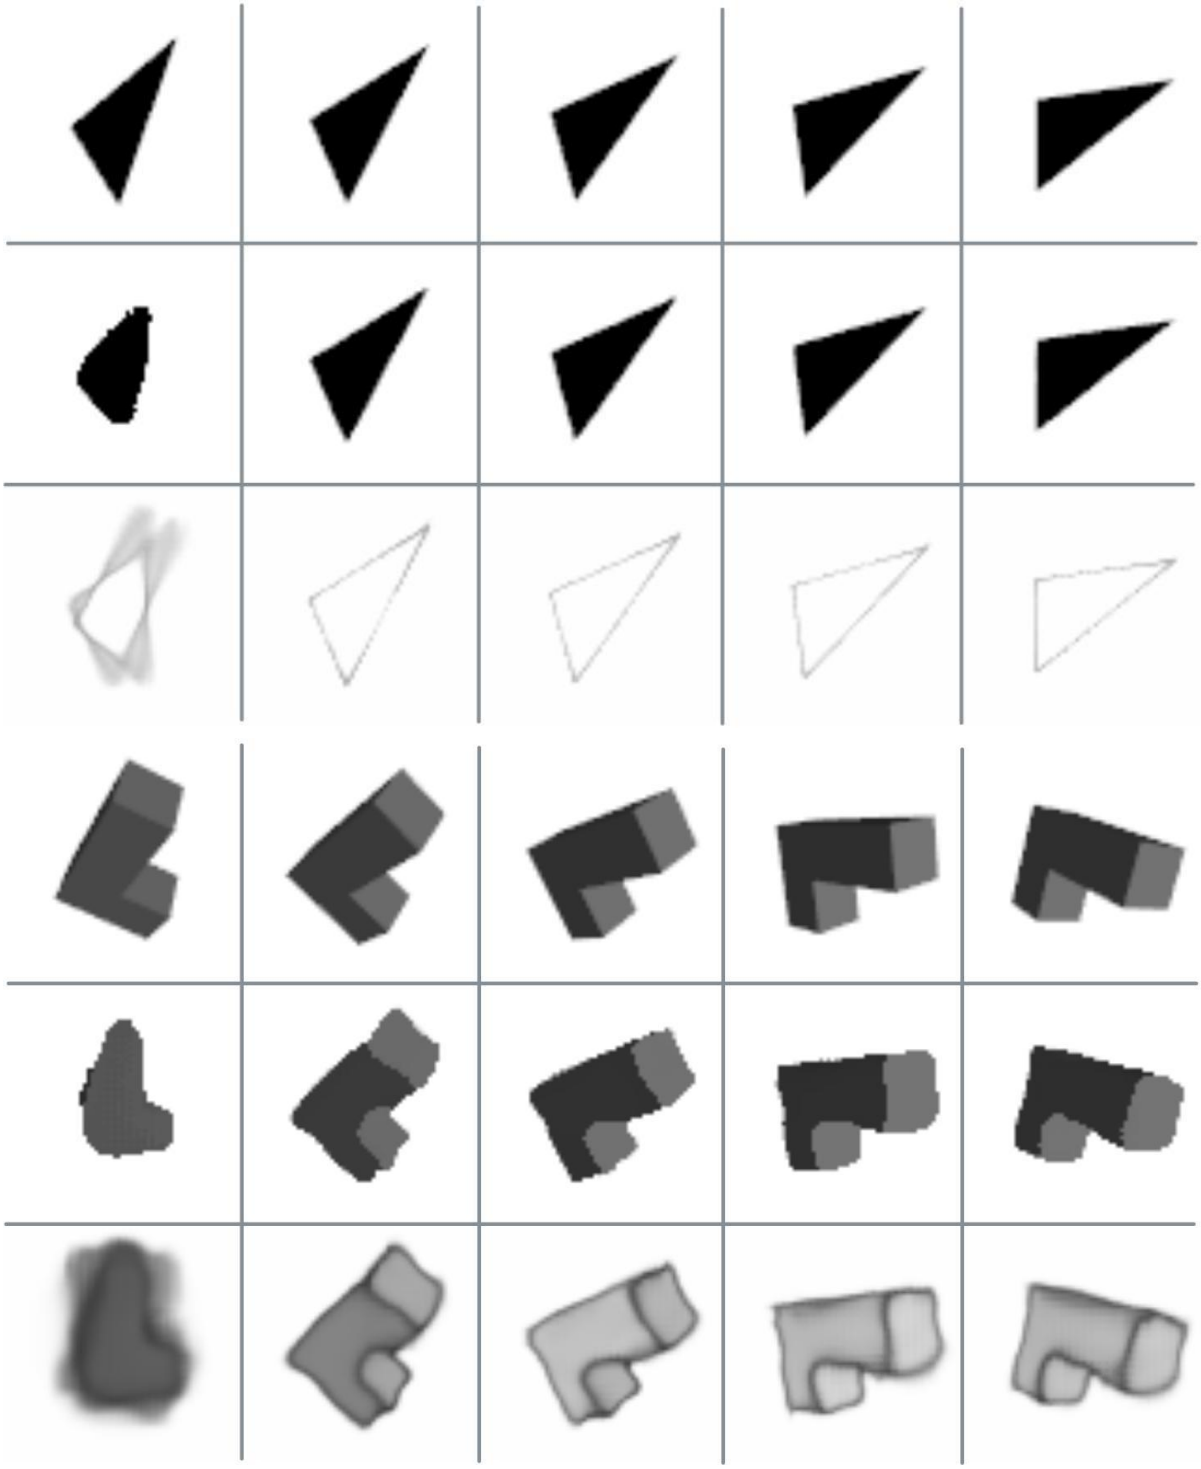


Рисунок 2.17 – Прогнози V-BLT та карти ентропії для двовимірного та тривимірного обертання.

У вибраних прикладах на рисунку 2.17 ентропія просторово зосереджена переважно біля контуру рухомого об’єкта. Така локалізація мотивує виділення більшої детальної ємності інформаційно насиченим ділянкам, але сама по собі не доводить переваги динамічного розподілу.

2.3.6 Експериментальні результати для двовимірних та тривимірних обертань

У дослідженні V-BLT з фіксованими ділянками модель порівнюється з ViViT [70] та UNet-3D [134] на двох наборах даних процедурного обертання. Зазначені розмір моделі та кількість GFLOPs належать до заданої обчислювальної конфігурації, а MSE, SSIM та PSNR є точковими оцінками якості прогнозування.

Спочатку порівнюється вартість заданих конфігурацій. Ці числа не є вимірюванням якості й тому подані окремо.

Таблиця 2.9 – Опубліковані точкові оцінки вартості конфігурацій V-BLT та базових моделей.

Модель	**Розмір моделі (МБ)**	**GFLOPs**
V-BLT	6,5	51,2
ViViT	6,5	59,3
UNet-3D	24,0	70,4

Якість оцінювалась на двох процедурних наборах. Тут моделі зіставлено лише в межах кожного набору.

Таблиця 2.10 – Опубліковані точкові оцінки якості прогнозування на процедурних наборах V-BLT. Значення відтворено за джерелом. Без повної специфікації нормування й порядку усереднення MSE та PSNR їх не можна взаємно перераховувати або безпосередньо зіставляти з MSE OpenSTL; первинні масиви для такого узгодження не відновлено.

Набір даних	**Модель**	**MSE ↓**	**SSIM ↑**	**PSNR, дБ ↑**
2-D фігури	**V-BLT**	**0,039**	**0,98**	**32,3**
	ViViT	0,181	0,87	20,7
	UNet-3D	0,125	0,88	21,8
3-D полікуби	V-BLT	**0,11**	**0,91**	23,4
	ViViT	0,19	0,83	**24,8**
	UNet-3D	0,20	0,75	20,3

V-BLT використовує на 13,7% менше заявлених GFLOPs, ніж ViViT, і на 27,3% менше, ніж UNet-3D. Два записи розміром 6,5 МБ мають однакові значення розміру моделі.

Це порівняння підтверджує життєздатність повної конфігурації V-BLT, а не причинно-наслідковий внесок окремого компонента. Отже, нижчі заявлені показники GFLOP та сприятливі двовимірні метрики підтверджують ефективність протестованої системи; вони не виділяють позиційне кодування чи байтовий інтерфейс. Змішаний тривимірний рейтинг є корисним саме тому, що він запобігає перетворенню доказів на рівні конфігурації на домінування єдиної метрики.

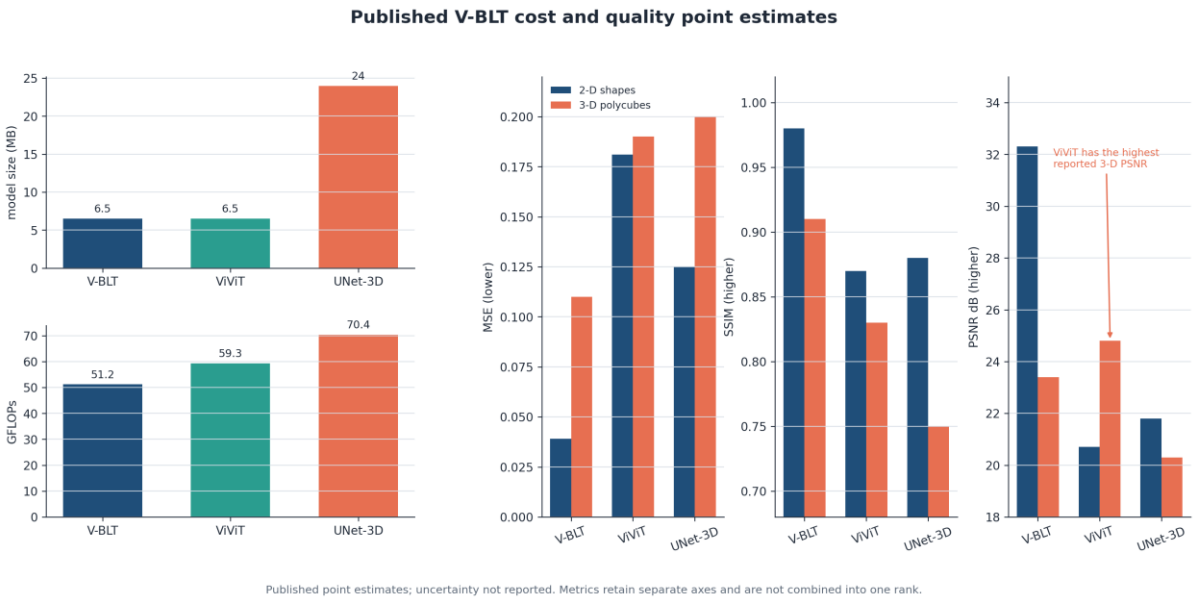


Рисунок 2.18 – Опубліковані точкові оцінки вартості та якості V-BLT. Осі SSIM та PSNR мають скорочені діапазони: довжина стовпчика не відображає відношення повних значень. Англомовні позначення означають якість структури (SSIM), пікове відношення сигнал/шум (PSNR) і вартість обчислення; порівнювати слід числові підписи.

Отже, у двовимірній задачі V-BLT має найкращі три наведені показники, а в тривимірній – найкращі MSE та SSIM, але поступається ViViT за PSNR. Такий результат підтримує працездатність локально–глобальної байтової ієрархії, не доводячи перевагу кожного її компонента окремо.

2.3.7 Порівняння виміряного методу з пропонованим динамічним поділом на регіони

Дослідження з фіксованими патчами підтримує чітко обмежений набір тверджень. V-BLT демонструє ієрархічну архітектуру «локальний–глобальний–локальний» із прямими байтовими цілями, фіксованим просторово-часовим поділом, каузальною глобальною увагою, RoPE-ND, категоріальним

прогнозуванням та просторово структурованими картами ентропії. Кожен із цих елементів було реалізовано або задокументовано в експерименті.

Наступним кроком є динамічне розбиття на області. Нехай $\Pi_t = \{R_{t,1}, \dots, R_{t,m_t}\}$ позначає поділ кадру t на m_t областей, B_t – допустиму їх кількість або еквівалентний токенний бюджет, $\mathcal{L}_{t+1}$ – похибку наступного прогнозу, а $C(\Pi_t)$ – вартість обраного поділу. Тоді контролер має змогу обирати поділ як:

$$\Pi_t^{\star} \in argmin_{\Pi_t:|\Pi_t|\leq B_t} \mathbb{E}\left[\mathcal{L}_{t+1}(\Pi_t)\right] + \lambda C(\Pi_t), \tag{2.42}$$

де λ визначає компроміс між якістю та вартістю, а ентропія є одним із можливих входів політики. Формула (2.42) є гіпотезою розподілу ресурсу, а не описом уже перевіреного компонента V-BLT: у межах опублікованого дослідження динамічний контролер не реалізовано. Запропоноване розширення систематизовано на рисунку 2.19 і в іншій конкретизації реалізовано для інтегрованої моделі розділу 3.

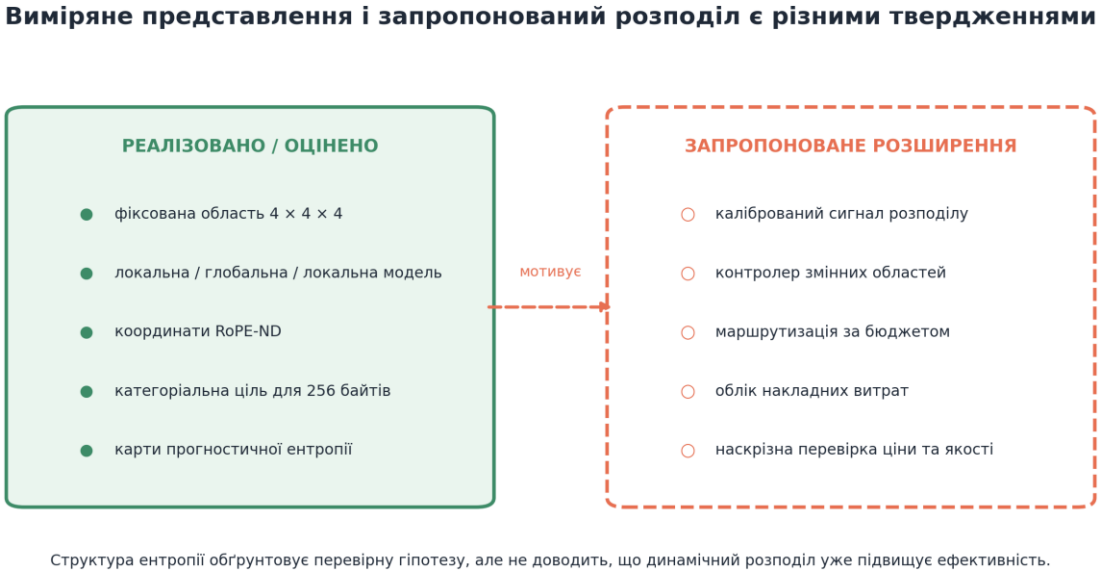


Рисунок 2.19 – Реалізований метод V-BLT та запропоноване адаптивне розширення.

Практична реалізація такого контролера потребує стабільного інтерфейсу. V-BLT використовує фіксовані ієрархічні ділянки, а виміряна просторова неоднорідність прогностичної ентропії лише мотивує подальший розподіл; її не можна ретроспективно трактувати як результат динамічної маршрутизації. В інтегрованій моделі розділу 3 геометрія кандидатних областей також

залишається фіксованою, але для кожної області обчислюється числова оцінка з трьох членів: стандартизованої квадратичної енергії залишку між детальним представленням і збільшеним грубим представленням, стандартизованої абсолютної часової зміни та навчуваної скалярної поправки з детального вмісту. За цією оцінкою розподіляється стала квота детальних областей, а фізичні час, координати центра та рівень кожного відібраного токена передаються позиційному кодуванню. Такий маршрутизатор реалізує керований розподіл у формі, відмінній від формули (2.42), і потребує власного зіставлення з рівномірним та випадковим вибором за однакового бюджету.

2.4 Наслідки для проєктування ієрархічно-контекстної моделі

Після двох окремих досліджень потрібно визначити, які їхні результати справді переходять до центральної контекстної моделі. Цей підрозділ відокремлює перенесені принципи від деталей TempVerseFormer і V-BLT, що залишаються специфічними для власних протоколів, а потім формулює вихідні умови для розділу 3.

2.4.1 Результати, що мають концептуальне значення

Часовий і просторовий методи не є двома новими центрами дисертації. Вони відповідають на обмеження, які виникають, коли головне ієрархічне рішення намагаються масштабувати за часом і простором.

TempVerseFormer показує, як зменшити пам’ять активацій повторюваного часового ядра. Це відкриває можливість передавати градієнт через довший процес, зокрема й у майбутньому ієрархічному предикторі, але не збільшує обсяг збереженої історії. Якщо контекст короткий, віддалена подія все одно недоступна; якщо контекст розширити щільними деталями, зростуть сам стан і робота уваги. Отже, реверсивність і ієрархічне пакування діють послідовно на різні причини одного ресурсного обмеження.

V-BLT, своєю чергою, показує, як локально–глобальна обробка скорочує послідовність глобального процесора і як категоріальний вихід виявляє просторово неоднорідну складність. Коли геометрія токена змінюється, час, рядок і стовпець не повинні згортатися в один невизначений індекс. До

центральної моделі переноситься не набір ваг і не готовий ентропійний контролер, а принцип явної ієрархії та роздільного обліку грубої й детальної ємності.

Жоден із двох методів не визначає, як за фіксованого загального бюджету розподілити збережений контекст між рівнями, віком спостережень і просторовими областями. TempVerseFormer приймає часовий стан, форма якого вже задана, а V-BLT досліджує фіксований просторово-часовий поділ байтів. Тому вибір кількості рівнів, стратегії розподілу, грубої часової досяжності, правила перекриття та розташування детальних позицій залишається окремою експериментальною задачею.

Рівність (1.5) пояснює межу такого синтезу: реверсивне відтворення змінює $M_{\text{activations}}$, а ієрархічне пакетування – $M_{\text{context/state}}$. Ці ефекти вимірюються окремо й не складаються автоматично. Проте їхня композиція змістовна. Немає користі від компактного довгого контексту, якщо навчальний граф не дає оптимізувати довгу траєкторію; так само дешевий градієнт не повертає свідчення, уже втрачене коротким контекстом.

Звідси випливає центральне питання наступних розділів. Ієрархія потенційно збільшує часову досяжність, але стискання може погіршити зовнішній вигляд та ідентичність. Тому її не можна вважати безумовно кращою за плоску модель. TRB ізолює моменти, де потрібне спостереження вже залишило коротке вікно, а збережений результат на довготривалому Moving-MNIST другорядно розділяє просторове покриття, траєкторію та ідентичність без розширення структурної матриці експериментів. Після причинного порівняння контекстних конфігурацій окрема інтегрована перевірка має встановити, чи сумісні фізично упакований ієрархічний контекст, маршрутизація сталої квоти та внутрішнє реверсивне ядро і чи дає їх поєднання конкурентну якість із виміряним зменшенням пам’яті.

2.4.2 Висновки до розділу

Перший метод цього розділу стосується вартості активацій часового навчання. Реверсивний трансформерний блок використовує трикутне адитивне

зв’язування, тому його два вхідні потоки відновлюються з виходів без обернення уваги чи MLP. Коли стек блоків повторюється в часі, реверсивне відтворення реконструює один попередній стан, перебудовує один локальний граф диференціювання, накопичує градієнт і звільняє граф. За визначених детермінованих умов тимчасова складова пам’яті активацій рекурентного ядра має порядок $O(1)$ за часовою глибиною, а не $O(T)$.

Аналіз реалізації звужує цей результат до коректної межі стану. Її достатньо, щоб пояснити опубліковану криву пам’яті: пам’ять часової моделі залишається близькою до 0,89 ГБ у табличних точках 1, 4 і 16 кроків, тоді як зіставлений нереверсивний трансформер досягає 2,61 ГБ на 16 кроках. Результати прогнозування неоднорідні. TempVerseFormer лідирує за всіма опублікованими показниками для постійного й перерваного обертання та залишається конкурентоспроможним в інших режимах, але TempFormer або LSTM мають кращі значення окремих показників за змінного руху. OpenSTL підтверджує придатність архітектури до різних інтерфейсів, зокрема найнижче MSE на TaxiBJ у цьому порівнянні, але не універсальну перевагу на стандартних наборах.

Ентропія на рівні байтів виступає зв’язком між експериментами і розподілом ресурсів. В опублікованих прикладах вона концентрується біля мінливих контурів, оклюзій та прогнозів за обмеженого контексту. Однак карти ентропії лише спостерігалися, а не керували зміною розміру чи дискретизації патчів. Виміряна модель використовувала зафіксовану конфігурацію $4 \times 4 \times 4$; динамічне розбиття на області за ентропією залишається пропозицією. Тому центральний предиктор розділу 3 успадковує принцип явного розділення рівнів та їхньої вартості, але не приписує новому маршрутизатору результати V-BLT. Інтегрована реалізація застосовує окрему тричленну оцінку фіксованих кандидатних областей і перевіряється як самостійний компонент за сталої квоти.

Отже, розділ 2 встановлює дві межі масштабування головного ієрархічного рішення: коли реверсивне відтворення може зменшити активаційну стрічку та що саме підтверджує байтова локально–глобальна ієрархія з ентропійною

діагностикою. Розділ 3 переходить до центрального питання – формування збереженого контексту, який за обмеженої кількості токенів охоплює давнішу історію й водночас залишає достатньо деталей для консистентного довгострокового прогнозу.

Описані представлення й способи відтворення активацій залишають відкритим питання розподілу обмеженого ресурсу. Розділ 3 переводить його в контрольовані зміни місткості, підтримки, деталізації та перекриття; обчислювальна економія перевіряється окремо від доступності інформації. Такий перехід пов’язує компоненти спільною задачею, не ототожнюючи їхні архітектури.

РОЗДІЛ 3 – ІЄРАРХІЧНА КОНТЕКСТНА МОДЕЛЬ ДОВГОГОРИЗОНТНОГО ПРОГНОЗУВАННЯ ВІДЕО

У розділі 2 розглянуто два обмеження, що постають під час масштабування відеомоделі: зберігання активацій у довгому диференційованому ланцюзі та розподіл ємності просторового представлення. Центральне питання дисертації залишається іншим: яка історична інформація доступна моделі після того, як останнє релевантне спостереження залишило коротке контекстне вікно. Модель може точно передбачати найближчий кадр, але втратити об’єкт, його траєкторію або ідентичність на довшому горизонті. Тому цей розділ переходить від допоміжних ресурсних методів до головного архітектурного дослідження – побудови ієрархічного збереженого контексту та визначення меж його доцільності.

Архітектурну межу основного дослідження задано явно. Заморожений дворівневий кодувальник перетворює кожний кадр на грубу сітку 4×4 і детальну сітку 8×8. Один спільний предиктор отримує вибрані грубі й детальні карти минулого та одночасно прогнозує обидва рівні наступного чотирикадрового вікна. Після декодування ці прогнози повертаються до буферів і стають контекстом наступного виклику. Реверсивне часове ядро та байтова токенізація V-BLT у причинне порівняння пакетів не входять, щоб спостережуваний ефект можна було пов’язати саме з формою збереженого контексту. Їхня композиція перевіряється пізніше в окремому розширенні для оцінювання технічної здійсненності.

Ієрархічний контекст має кілька незалежних вимірів: місткість, частку рівнів, часову підтримку, розташування деталей і перекриття. Вони визначають доступну інформацію; спосіб диференціювання визначає іншу величину — пам’ять активацій. Методика §3.6 досліджує структуру пакета, а §3.7 задає предиктор, у якому фізичне пакування, адаптивне членство та реверсивне ядро мають окремі перевірні контракти.

3.1 Збережений контекст як проблема кінцевої моделі

Збережений контекст є станом, який предиктор переносить між послідовними вікнами. Його структура визначає не лише обсяг пам’яті, а й множину минулих подій, до яких модель може звернутися. Спочатку уточнимо цю вимогу через повторний вхід об’єкта, а далі формалізуємо пакет, його вартість і досяжність.

3.1.1 Консистентність як вимога до досяжності пам’яті

Розділ 1 показав, що консистентність має кілька критеріїв. Для відео особливо важлива неперервність стану й траєкторії між віддаленими кадрами; для ієрархічної моделі до неї додається ціна стиснення. Грубий потік може зберегти, *де* перебував об’єкт і як він рухався, але втратити ознаки, потрібні для точного відновлення того, *що* це був за об’єкт. Довгогоризонтна консистентність вимагає більше, ніж правдоподібне продовження останнього кадру. Уявімо фігуру або об’єкт, текстура якого продовжується поза межами видимого поля. Поки він перебуває поза полем зору, кілька візуально допустимих версій світу можуть залишатися консистентними з поточним спостереженням. Після повернення попереднє зображення має обмежене положення, розмір та ідентичність об’єкта. Якщо воно залишається доступним, прогноз може спиратися на збережені відомості. Коли ж спостереження виходить із пам’яті, відновлення того самого об’єкта дедалі більше залежить від вивченого апріорного розподілу та можливості моделі до збереження, компонування та роботи з пам’яттю.

Повторний вхід стає визначальним, коли відповідне спостереження виходить за межі щільного вікна високої роздільної здатності. Плоска модель може збільшити це вікно, але кожен доданий детальний кадр має фіксовану токенну вартість. У багатороздільному пакеті старіші кадри зберігаються з нижчою просторовою роздільною здатністю, а детальні токени відводяться переважно для недавнього минулого [20, 35–37]. Груба історія тоді може містити свідчення, яких зіставлене за токенами плоске вікно фізично не досягає. Водночас стиснення вилучає частину інформації, тому давніша історія сама по

собі не гарантує кращого прогнозу. Перевірка має охоплювати режими, у яких нестача історії та втрата деталей утворюють конкуруючі обмеження.

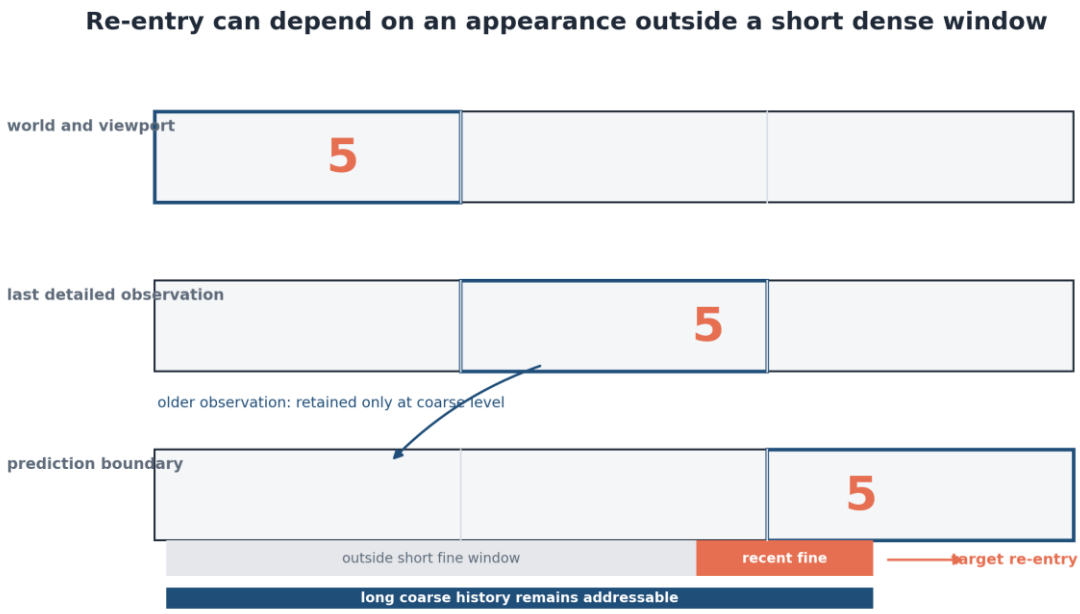


Рисунок 3.1 – Повторний вхід після останнього визначального спостереження залишає коротке щільне контекстне вікно.

Для аналізу потрібні три послідовні умови:

1. Спостереження має фізично зберігатися в одному з потоків;
2. Часова прив’язка повинна робити цей стан доступним поточному прогнозу;
3. Генератор має мати можливість утримувати та використовувати потрібну властивість.

Отже, йдеться про зберігання, досяжність і повторне використання. Результат на виході перевіряє всі три умови разом, тоді як геометрія пакета встановлює лише можливість доступу.

3.1.2 Простір проєктування контекстного пакета

Нехай t позначає перший кадр цільового вікна. Контекстний пакет на цій межі є скінченною множиною потоків. Кожний потік визначається кортежем $\mathcal{S}_i = (\ell_i, s_i, n_i, a_i)$: рівнем представлення ℓ_i , часовим кроком s_i , кількістю збережених слотів n_i та відстанню a_i від цілі до найновішої прив’язки. Пакет об’єднує L таких потоків:

$$\mathcal{P}_t = \{\mathcal{S}_i\}_{i=1}^{L}. \tag{3.1}$$

Ці чотири поля однозначно задають часову геометрію потоку. Множина K_i містить відстані до цілі:

$$K_i = \{a_i + js_i \mid j = 0, \dots, n_i - 1\}. \quad (3.2)$$

Фактичні індекси кадрів утворюють множину $A_i(t) = \{t - k \mid k \in K_i\}$. Якщо один слот рівня ℓ_i містить q_{ℓ_i} просторових токенів, то вартість збереженої історії дорівнює сумі за потоками:

$$B_{\text{ctx}}(\mathcal{P}_t) = \sum_{i=1}^{L} n_i \, q_{\ell_i}. \quad (3.3)$$

Контекст і ціль виконують різні функції. Нехай m_j – кількість цільових слотів рівня j, а q_j – число токенів у кожному з них. Тоді довжина цільової частини має вигляд

$$B_{\text{tgt}} = \sum_j m_j \, q_j. \quad (3.4)$$

Повна довжина послідовності дорівнює $B_{\text{total}} = B_{\text{ctx}} + B_{\text{tgt}}$. Контекстні токени представляють збережений стан, доступний під час прогнозування, а цільові токени рахують невідомі комірки прихованого простору, оцінювані спільно. Загальна кількість логічних токенів визначає довжину послідовності трансформера, що впливає і на навчання, і на застосування. Водночас вона не дорівнює кількості фізично збережених елементів: до живого стану входять значення токенів, координатні метадані, індекси вибору, оцінки маршруту й службові буфери. Повний пік GPU додатково охоплює параметри, градієнти, стан оптимізатора, активації та робочий простір ядер. Тому відношення довжин послідовностей, відношення байтів живого стану та відношення піків GPU звітуються як три різні величини. Сама ефективність контексту не визначає підсумкове використання пам’яті, час виконання чи обчислювальну вартість уваги. Окремо потрібно знати, наскільки давню позицію пакет здатний адресувати. Номінальна досяжність дорівнює найбільшій часовій відстані серед усіх потоків:

$$R(\mathcal{P}_t) = max_i maxK_i = max_i[a_i + (n_i - 1)s_i]. \quad (3.5)$$

Досяжність є номінальною: вона визначає найстарішу задану позицію, але не показує, чи достатній її вміст і чи модель фактично його використовує. У реалізованих щільних ієрархічних пакетах потік на рівні грубого представлення

охоплює 48 попередніх позицій кадрів. Часово розріджений контроль натомість поєднує найновіші детальні кадри зі старішими прив'язками повної роздільної здатності. Зареєстрована мітка «48 кадрів» позначає запланований клас часового інтервалу, таким чином перевірка конфігурації спирається на записані прив'язки.

Однакову номінальну досяжність можна отримати різними способами. Рисунок 3.2 зіставляє щільний плоский контекст, щільну грубу історію з детальним хвостом і часово розріджені детальні прив'язки. Перший зберігає кожний кадр із високою деталізацією, другий – кожний часовий момент у грубішому масштабі, а третій – лише вибрані моменти з повною просторовою роздільною здатністю.

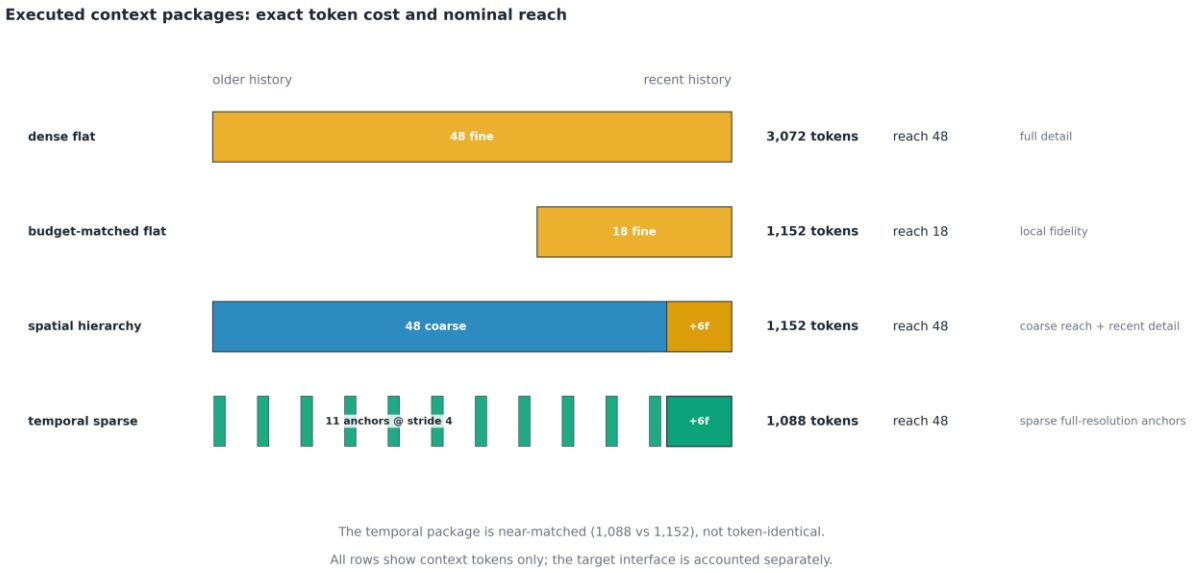


Рисунок 3.2 – Три способи пакетування збереженого відеоконтексту.

Однакова позначка «досяжність 48» на різних рівнях представлення не робить ці пакети інформаційно рівними. Щільний грубий потік представляє кожну часову позицію, але з меншою просторовою частотою та сіткою відповідно. Розріджений детальний потік зберігає повну роздільну здатність лише у вибрані моменти. Наприклад, прив'язки $t-47, t-43, \ldots$ не містять кадрів між ними, тоді як 48 грубих слотів утворюють щільну часову послідовність. Через це порівняння форми пакета перевіряє не лише дальність, а й спосіб втрати інформації.

У таблиці 3.1 визначено величини, використані в описі моделі та результатів. «Рівень» позначає представлення без припущення про семантичну

абстракцію, а «крок» – відстань між прив’язками, не стверджуючи, що токен узагальнює рух між ними. Тому повнороздільні прив’язки, збережені через кожні чотири кадри, не еквівалентні грубому токену, спостережуваному в кожному кадрі. Обидва варіанти розширюють часовий доступ, але відкидають різну інформацію.

Таблиця 3.1 – Поля контекстного пакета та їх інтерпретація.

Поле	**Символ**	**Операційне значення**	**Що це не означає**
Рівень представлення	ℓ_i	Зафіксований рівень кодека та його просторова сітка токенів	Семантична коректність або гарантована консистентність між рівнями
Часовий крок	s_i	Відстань між регулярними прив’язками потоку	Часове усереднення, якщо кодер явно його не виконує
Збережені слоти	n_i	Кількість збережених карт прихованого простору у потоці	Однаковий корисний обсяг даних на всіх рівнях
Лаг найновішої прив’язки	a_i	Відстань від першої цільової позиції до найновішої збереженої прив’язки	Наявність усіх проміжних кадрів
Набір прив’язок	$A_i(t)$	Точні історичні кадри, представлені потоком	Успішне отримання інформації з цих кадрів
Кількість токенів на слот	q_{ℓ_i}	Кількість просторових комірок на вибраному рівні	Байти, ширина трансформера або повна пам’ять активації
Вартість контексту	B_{ctx}	Сума збережених токенів контексту	Загальна довжина послідовності або рівноцінний обчислювальний обсяг
Досяжність	R	Найстаріше надане відставання в геометрії пакета	Точність відтворення, інформаційно-теоретична необхідність або надійне повторне використання

Таблиця 3.1 фіксує межу кожного терміна: токенна вартість не дорівнює байтовій пам’яті, а досяжність не означає успішного відтворення. Саме розрив між геометрично доступним минулим і збереженою в ньому інформацією утворює центральну гіпотезу наступного підрозділу.

3.1.3 Гіпотеза «досяжність–точність відтворення»

Перевага пакета залежить від того, чого саме бракує прогнозу: доступу до давнього свідчення чи його детального вмісту. Нехай $Z_t^\star$ – історичні докази, що стосуються цілі в момент часу t, а $I_t(\mathcal{P})$ вказує, чи лежать вони всередині наданих прив’язок. Величина $Q_t(\mathcal{P})$ позначає релевантну до задачі інформацію, збережену після кодування та пакетування. Очікувану похибку можна концептуально організувати так:

$$\mathcal{R}(\mathcal{P}) = \mathcal{R}_{\text{unavailable}}(\mathcal{P}) + \mathcal{R}_{\text{available}}(\mathcal{P}). \quad (3.6)$$

Рівняння (3.6) є пояснювальною декомпозицією, а не окремою ймовірнісною моделлю. Перший доданок дорівнює $\mathbb{E}[\mathcal{L} \mid I_t = 0]Pr[I_t = 0]$. Другий дорівнює $\mathbb{E}_{Q_t|I_t=1}[\mathbb{E}[\mathcal{L} \mid I_t = 1, Q_t]]Pr[I_t = 1]$ і усереднює умовну втрату за розподілом фактично збереженої інформації. Він охоплює втрату здатності до представлення, похибку моделі та деградацію із самопідсиленням. Більша досяжність може зменшити першу складову, а збереження просторової деталізації – частину другої, але жодна зі змін не гарантує переваги на всіх типах завдань.

Звідси випливають три твердження:

1. За малого бюджету, коли плоске вікно не охоплює релевантну подію, ієрархічний пакет має перевагу через більшу досяжність;
2. У проміжному режимі обидва чинники можуть компенсувати один одного, тому результат може залишитися невизначеним та мати розкид відносно задачі;
3. За великого бюджету пакети детального рівня починають досягати події, що раніше була контекстно недоступна, і результат для щільного детального контексту може стати навіть кращим завдяки збереженню ідентичності та текстури в повному обсязі.

Ці режими перевіряються лише в досліджених умовах роботи; поріг і проміжні переходи між ними не оцінюються.



Рисунок 3.3 – Робочі області пакетів на осях досяжності та точності відтворення. Горизонтальна вісь відповідає часовій відстані до найдавнішого доступного свідчення, вертикальна – повноті збереженої просторової інформації. Рисунок не задає неперервної емпіричної межі; він лише пояснює, чому два пакети однакового бюджету можуть бути корисними в різних режимах.

3.2 Ієрархічний прихований стан

Щоб порівнювати форми контексту, саме представлення кадру має залишатися незмінним. Для цього спочатку визначається дворівневий кодувальний інтерфейс, потім карти прихованого простору перетворюються на токени спільного предиктора. Такий порядок відокремлює втрати стискання від ефекту часової геометрії пакета.

3.2.1 Дворівневий заморожений автоенкодер

Арифметика пакетів набуває сенсу лише при фіксованих рівнях представлення. Реалізовані пакети працюють у безперервному прихованому просторі, який формує згортковий автоенкодер. Для вхідного кадру $x_t \in [-1,1]^{1\times64\times64}$ спільний стовбур енкодера генерує карту ознак розміром 8×8. Одна проєкція розміром 1×1 дає детальний код; наступний етап енкодера з кроком два та ще одна проєкція формують грубий код:

$$\mathcal{E}(x_t) = \left(z_t^{\mathrm{c}}, z_t^{\mathrm{f}}\right). \tag{3.7}$$

Грубий код належить $[-1,1]^{16\times4\times4}$, а детальний — $[-1,1]^{16\times8\times8}$. Обидві проєкції використовують гіперболічний тангенс як функцію активації, тому вихідні координати прихованого простору обмежені граничними значеннями цієї функції. Грубий кадр містить $16 \times 4 \times 4 = 256$ коефіцієнтів, організованих у 16

просторових токенів, а детальний кадр містить $16 \times 8 \times 8 = 1{,}024$ коефіцієнти, організовані в 64 токени. З цього не випливає, що грубий код у загальному сенсі вчетверо менш інформативний.

Кожен рівень має власний декодувальник для відтворення повного зображення. Це дає змогу оцінити грубу й детальну реконструкції незалежно:

$$(\hat{x}_t^{\mathrm{c}}, \hat{x}_t^{\mathrm{f}}) = \big(\mathcal{D}_{\mathrm{c}}(z_t^{\mathrm{c}}), \mathcal{D}_{\mathrm{f}}(z_t^{\mathrm{f}})\big). \tag{3.8}$$

Під час одного кроку навчання випадково обирається одна з двох гілок b. Для грубої гілки суму MAE та MSE множать на чотири, компенсуючи меншу просторову сітку; детальна гілка використовує ту саму пару втрат без множника:

$$\mathcal{L}_{\mathrm{AE}} = \begin{cases} 4(MAE(x, \hat{x}^{\mathrm{c}}) + MSE(x, \hat{x}^{\mathrm{c}})), & b = \mathrm{c}, \\ [2\mathrm{mm}]MAE(x, \hat{x}^{\mathrm{f}}) + MSE(x, \hat{x}^{\mathrm{f}}), & b = \mathrm{f}, \end{cases} \tag{3.9}$$

Гілка b вибирається рівноймовірно: $Pr(b = \mathrm{c}) = Pr(b = \mathrm{f}) = 1/2$. Обидва рівні реконструюють повний кадр, але з різною просторовою місткістю. У предикторі детальна гілка не отримує вже завершеного грубого прогнозу: грубі й детальні токени взаємодіють усередині спільної уваги, а окремі результати зчитуються лише наприкінці. Назви «композиція» і «деталізація» описують очікувану функцію роздільної здатності, а не жорстко задану семантику каналів. Грубий код передусім придатний для глобального положення, форми й траєкторії, тоді як детальний має більшу ємність для текстури та ознак ідентичності. Фактичний розподіл ролей перевіряється об’єктними показниками, а не припускається з назв рівнів.

Окремий декодувальник кожного рівня потрібний для перевірки того, що зберігається у відповідній карті прихованого простору. Грубий стан можна оцінити без участі детального виходу. Після навчання кодувальник і обидва декодувальники заморожуються, інакше кожен пакет міг би змінити власний спосіб стискання, а різниця між моделями змішувала б організацію контексту з повторним навчанням представлення. Заморожування не усуває втрат кодування, але робить їх спільною умовою порівняння.

Перед поданням карт до предиктора кожний канал стандартизується за статистиками навчального набору. Для кожного рівня $\ell \in \{\mathrm{c}, \mathrm{f}\}$ стандартизований канал позначимо через $\tilde{z}_t^{\ell}[c]$:

$$\tilde{z}_t^{\ell}[c] = \frac{z_t^{\ell}[c] - \mu_c^{\ell}}{max(\sigma_c^{\ell}, 10^{-4})}. \quad (3.10)$$

Нижня межа 10^{-4} у знаменнику запобігає діленню на нуль або чисельно нестійке мале значення. Рисунок 3.4 показує, як один кадр переходить у дві сітки з однаковою шириною каналу, а таблиця 3.2 фіксує цей інтерфейс як незмінну умову всіх порівнянь.

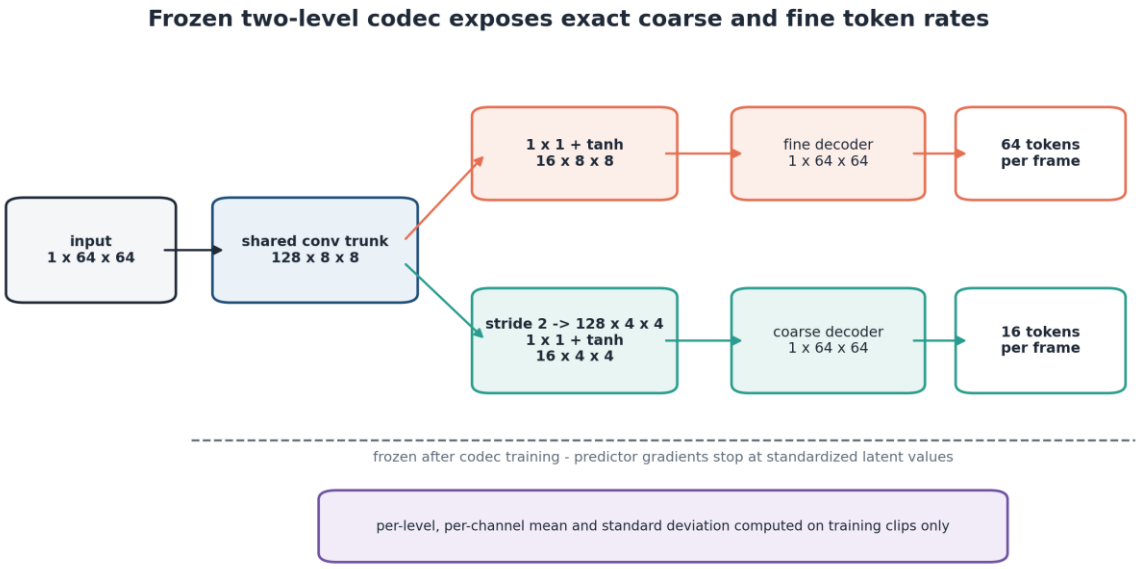


Рисунок 3.4 – Фіксовані розміри дворівневого кодувальника та тензорів прихованого простору.

Таблиця 3.2 – Специфікація зафіксованого інтерфейсу прихованого простору.

Властивість	**Грубий рівень**	**Детальний рівень**	**Наслідки для предиктора**
Форма прихованого простору на кадр	$16 \times 4 \times 4$	$16 \times 8 \times 8$	Та сама ширина каналу, різна просторова сітка
Просторові токени на кадр	16	64	Детальна історія вимагає вчетверо більше контекстних токенів на кадр
Скалярні коефіцієнти на кадр	256	1 024	Корисне навантаження відрізняється ще до проекції на ширину трансформера
Піксельний декодер	Незалежний грубий декодер	Незалежний детальний декодер	Кожен код можна перевірити як реконструкцію повного кадру
Масштабування вхідних даних предиктора	z-стандартизація за кожним каналом навчального набору	z-стандартизація за кожним каналом навчального набору	Шкала шуму та втрати за рівнями використовують порівнянні стандартизовані координати
Навчання після заморожування кодека	Немає	Немає	Порівняння пакетів не можуть змінювати інтерфейс прихованого простору

Властивість	Грубий рівень	Детальний рівень	Наслідки для предиктора
Основний шлях декодування під час розгортання	Лише для діагностики	Заморожений декодер детального рівня	Основні кадрові показники мають один вихідний шлях

Таблицю збережено, оскільки вона є контрактом порівняння: з неї безпосередньо випливають токенна арифметика й спільний шлях декодування. Далі ці фіксовані карти перетворюються на одну послідовність токенів.

3.2.2 Побудова потоку та векторів вбудовування

Кожна просторова комірка карти стає одним токеном. Нехай $z_{t,h,w}^{\ell} \in \mathbb{R}^{16}$ – вектор каналів на рівні ℓ у позиції (h, w). Спільна лінійна проєкція W_{in} переводить його до вектора вбудовування $e_{t,h,w}^{\ell} \in \mathbb{R}^{d}$, а $p_{h,w}^{\ell}$ додає просторову позицію відповідного рівня:

$$e_{t,h,w}^{\ell} = W_{\text{in}} z_{t,h,w}^{\ell} + b_{\text{in}} + p_{h,w}^{\ell}. \tag{3.11}$$

Функція Tok_{ℓ} застосовує це перетворення до всієї карти. Позначимо через $\mathcal{C}_t$ послідовність контекстних токенів: для кожного потоку i спочатку беруться часові зсуви з множини K_i, а всередині кадру – просторова розгортка рівня ℓ_i. Порядок потоків і часових зсувів є частиною контракту пакета, тому $\mathcal{C}_t$ не є невпорядкованою множиною.

Через $\mathcal{T}_t$ позначимо цільову частину. Вона містить W майбутніх кадрів; для кожного кадру спочатку розміщуються грубі, а потім детальні токени. Під час дифузійного навчання ці позиції заповнюються зашумленими картами відповідного рівня, тоді як контекстні позиції залишаються незашумленими. Повну вхідну послідовність S_t утворює їх конкатенація:

$$S_t = \mathcal{C}_t \| \mathcal{T}_t. \tag{3.12}$$

Самого порядку недостатньо, щоб одна мережа відрізнила рівень, роль і часову позицію. Тому до вмісту кожного токена додаються окремі вбудовування рівня, ролі та кадру:

$$h_j^{(0)} = e_j + e_{\text{level}}(\ell_j) + e_{\text{role}}(\rho_j) + e_{\text{frame}}(f_j). \tag{3.13}$$

Після визначення геометрії можна перевірити, чи справді пакет реалізує заявлену досяжність у межах бюджету. Для стандартної конфігурації з 48

грубими та 6 детальними кадрами груба історія дає $48 \times 16 = 768$ токенів, а недавній детальний хвіст додає $6 \times 64 = 384$. Кожна з чотирьох цілей містить $16 + 64 = 80$ токенів. Отже, $B_{\text{ctx}} = 1{,}152$, $B_{\text{tgt}} = 320$ і $|S_t| = 1{,}472$.

Для наперед визначених пакетів формула (3.13) використовує дискретні індекси кадру й рівня. Під час фізичного пакування зі змінним вибором цього недостатньо: разом із кожним токеном потрібно зберігати його рівень, просторовий масштаб, координати центра та фізичний час спостереження. Такі метадані мають переміщуватися тим самим індексом gather, що й значення токена, щоб зміна його місця у запакованій послідовності не змінювала геометричної ідентичності. Неперервне кодування цих координат для інтегрованої моделі визначено в §3.7.5; воно доповнює, а не ретроспективно змінює позиційний інтерфейс WindowDiT.

Перші 1 152 токени є збереженим контекстом, тоді як останні 320 належать цільовому вікну й не збільшують часової досяжності пакета. На рисунку 3.5 зображена схема збірки токенів. На схемі контекстні токени залишаються відомими, а цільові грубі й детальні токени містять зашумлені представлення одного прогнозованого вікна. Колір і порядок потоків показують рівень, роль та часову позицію до їх об’єднання.

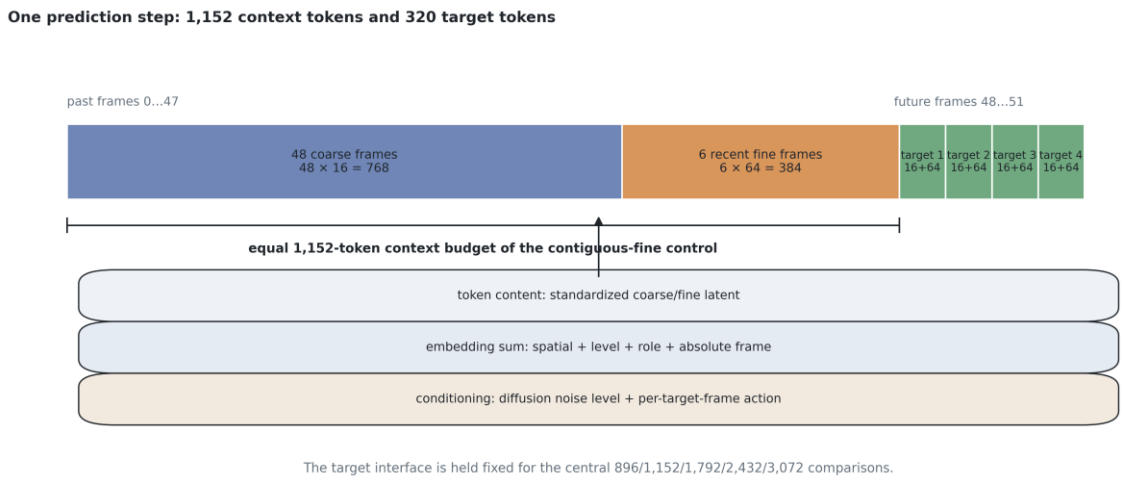


Рисунок 3.5 – Збірка токенів перед спільним механізмом уваги.

Індекс j нумерує токени, $\rho_j \in \{\text{ctx}, \text{tgt}\}$ позначає роль, ℓ_j — рівень, а f_j — індекс кадру. Грубий і детальний рівні обробляє один спільний трансформер, а не дві послідовні моделі. Для кожної позиції формується умовний вектор c_j:

e_{level}, e_{role} і e_{frame} задають рівень, роль та кадр; e_τ кодує крок дифузії τ; e_a вносить керувальну дію u_{t+q} лише для цільового кадру $t+q$. Тоді

$$c_j = e_{\text{level}}(\ell_j) + e_{\text{role}}(\rho_j) + e_{\text{frame}}(f_j) + \begin{cases} e_\tau(0), & \rho_j = \text{ctx}, \\ e_\tau(\tau) + e_a(u_{t+q}), & \rho_j = \text{tgt}, f_j = t+q. \end{cases} \quad (3.14)$$

Для контексту крок дифузії фіксується нулем, оскільки ці токени не зашумлюються. Цільові токени отримують поточний крок τ і дію відповідного майбутнього кадру. Отже, формула (3.14) описує не новий потік даних, а службові ознаки, які дають змогу одній мережі правильно інтерпретувати вже зібрану послідовність.

Довжину кожного потоку фіксує специфікація пакета, тому додаткове заповнення в межах однієї конфігурації не потрібне. Водночас позиція токена у зібраній послідовності не є достатньою міткою його змісту: рівень, роль і кадр подаються явно. Це важливо, коли одна базова мережа використовується для різних сімейств пакетів. Детальний токен із часовою відстанню 47 у розрідженому потоці та детальний токен із відстанню 6 у недавньому хвості мають спільну проєкцію вмісту, але різні кадрові вбудовування. Тому предиктор може розрізняти їхню часову релевантність без призначення різної семантики каналів.

Послідовність збирається в наперед визначеному порядку: спочатку контекстні потоки за рівнями й прив’язками, потім грубі та детальні цілі кожного кадру вікна.

Порядок сам по собі не кодує причинність. Вбудовування ролі відрізняє відоме спостереження від зашумленої або нульової цілі, кадрове вбудовування зберігає часову позицію, а вбудовування рівня відокремлює просторові сітки. Дії додаються лише до відповідних цільових кадрів. В окремій конфігурації з кроком грубого потоку 2 разом із контекстом змінюється й грубий цільовий інтерфейс, тому в розділі 4 цей варіант трактується як порівняння повних конфігурацій, а не як чистий ефект кроку.

3.2.3 Передавання контексту за допомогою спільної уваги

Грубі й детальні токени справді входять до однієї послідовності та обробляються спільним WindowDiT. Грубий прогноз не завершується перед окремим етапом деталізації. У кожному блоці одночасно присутні грубий і детальний контекст, а також зашумлені грубі й детальні цілі; тому кожен шар може обмінюватися інформацією між рівнями й ролями до застосування вихідних модулів прогнозування. Така спільна увага не дублює параметри моделі, але й не є новим твердженням про першу багаторівневу увагу у відео: новизна роботи полягає у зіставленому за бюджетом втручанні та вимірюванні межі досяжності. Часове перекриття рівнів існує навмисно: у стандартному пакеті останні шість кадрів представлені одночасно грубо й детально, тоді як старіша частина доступна лише на грубому рівні. Для матриці прихованих станів H визначимо $Q = RMSNorm(HW_Q)$, $K = RMSNorm(HW_K)$ та $V = HW_V$, де W_Q, W_K, W_V є навчуваними проєкціями, а d_h — шириною однієї голови.

$$Attn(H) = softmax\left(\frac{QK^\top}{\sqrt{d_h}}\right)V. \tag{3.15}$$

Запити та ключі нормалізуються окремо в кожній голові уваги перед обчисленням масштабованого скалярного добутку [161]. Результати кількох голів конкатенуються й лінійно проєктуються за стандартною схемою багатоголової уваги [12]. Усередині поточного чотирикадрового вікна увага є повною: немає ні трикутної маски, яка змушувала б генерувати $t + 1$ перед $t + 2$, ні міжрівневої маски, що заздалегідь прив'язувала б детальну комірку до однієї грубої. Міжрівневі та внутрішньовіконні залежності вивчаються зі службових вбудовувань і даних.

Спільна увага архітектурно відкриває чотири інформаційні шляхи: грубий контекст до грубої цілі, грубий контекст до детальної цілі, детальний контекст до обох цільових рівнів і взаємодію між зашумленими грубими та детальними цілями одного вікна. Жоден шлях не маршрутизується вручну, тому архітектура не є послідовною схемою «спочатку спрогнозувати грубе, потім уточнити детальне». Обидва рівні формуються спільно, а їхня фактична спеціалізація визначається при навчанні та відповідно до задачі.

Структурна причинність між послідовними блоками розгортання забезпечується порядком виконання, а не окремою маскою всередині WindowDiT. Блок із індексом n отримує лише вже сформовані стани блоків із індексами $m \leq n$; майбутні блоки $m > n$ на момент його виконання ще не існують. Тому цей порядок надалі описується алгоритмічно, без введення фіктивної матриці уваги.

Спільне усунення шуму бачить лише зашумлені цілі поточного блока, а регресійний режим – порожні цільові позиції. Чотири майбутні кадри координуються одночасно, тоді як спостережувана інформація надходить лише з минулого. Отже, інтерфейс є каузальним **між блоками**, але не авторегресивним усередині чотирикадрового блока.



Рисунок 3.6 – Спільна увага в межах блоку прогнозування та структурна причинність між блоками.

Рисунок 3.6 розділяє ці два поняття. Суцільні зв’язки всередині блока показують повний обмін між рівнями й чотирма цільовими позиціями; стрілки між блоками спрямовані лише вперед у часі. Це розмежування потрібне перед визначенням межі градієнта, яка є ще вужчою за межу доступної інформації.

3.2.4 Межі градієнта та інформаційна асиметрія

Доступність інформації під час прямого проходу не означає, що градієнт проходить тим самим шляхом. Параметри кодувальника й декодувальників ϕ заморожено, тому для них встановлено $\nabla_{\phi}\mathcal{L}_{\text{pred}} = 0$. Значення прогнозів попередніх вікон входять до нового контексту через оператор зупинки градієнта sg. Для попереднього вікна $m < n$ ця межа означає

$$\frac{\partial \mathcal{L}_n}{\partial sg(\hat{z}_m)} = 0. \tag{3.16}$$

Параметри предиктора θ залишаються змінними оптимізації; це визначає допустимий шлях градієнта, але не стверджує, що його числове значення є ненульовим на кожному кроці. Предиктор навчається безпосередньо у стандартизованому прихованому просторі: дифузійний варіант мінімізує суму MSE для швидкісної параметризації двох рівнів за формулою (3.21), а регресійний контроль – суму SmoothL1 за формулою (3.28). Втрата декодованих пікселів і допоміжне донавчання грубого декодувальника не використовуються. Тому пакет із більшою кількістю грубих слотів не отримує додаткового реконструкційного сигналу лише через частіше використання цього шляху.

Рисунок 3.7 узагальнює межу: градієнти оновлюють проєкції токенів, службові вбудовування, блоки трансформера та вихідні модулі прогнозування, але не змінюють заморожені кодувальник і декодувальники та не перетинають попередні авторегресійні вікна.

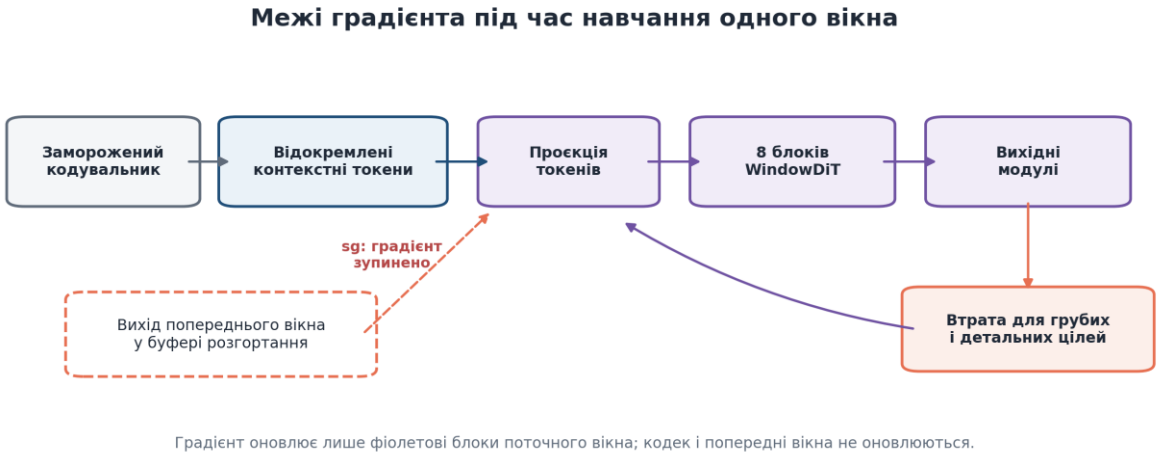


Рисунок 3.7 – Заморожені, відокремлені та треновані шляхи. Суцільний верхній тракт є прямим обчисленням поточного вікна; фіолетовим позначено параметри, які оновлює втрата. Пунктирний вхід із попереднього вікна доступний як числове значення, але відокремлений оператором sg. *Джерело: побудовано автором за реалізованим графом оптимізації.*

Ці межі уточнюють порівняння пакетів, але не усувають зміщення експозиції. Із часом контекст може заповнюватися пошкодженими значеннями, згенерованими самою системою. Тому стійкість розгортання перевіряється в режимі самоподачі та з різними ініціалізаціями навчання [25, 26]. Повне багатовіконне навчання WindowDiT із реверсивним відтворенням не виконувалося. Натомість у §3.7 окремий компактний регресійний прототип

перевіряє, чи працює сам принцип реверсивного розгортання разом зі станом сталої ширини.

Предиктор оптимізується на чистих чотирикадрових вікнах, а попередні прогнозовані вікна не входять до того самого графа градієнта. Отже, довгої диференційованої часової стрічки, яку мало б сенс реконструювати, тут немає. Реверсивність стала б релевантною після зміни цільової функції на багатовіконне навчання.

3.3 Ядро генеративного прогнозування

Після визначення форми стану цей підрозділ задає механізм перетворення контексту на майбутнє вікно. Спочатку вводяться випадкова величина, косинусний розклад і ціль швидкісної параметризації, далі – трансформерна мережа та детермінований алгоритм вибірки DDIM. Регресійна гілка наприкінці слугує контрольним вихідним модулем, а не другою центральною архітектурою.

3.3.1 Цільова функція дифузії у прихованому просторі

Після визначення контексту та інтерфейсу прихованого простору залишається встановити випадкову величину, яку прогнозує модель. Предиктор оцінює блок послідовних майбутніх величин у прихованому просторі, обумовлених історією пакетів і записаними керувальними сигналами. За $W = 4$ його умовний розподіл має вигляд

$$p_\theta\left(z^{\mathrm{c}}_{t:t+W-1}, z^{\mathrm{f}}_{t:t+W-1} \mid \mathcal{P}_t, u_{t:t+W-1}\right). \tag{3.17}$$

Вікно з чотирьох кадрів узгоджує навчальний інтерфейс з одиницею авторегресивного оновлення: після одного виклику всі чотири прогнози додаються до буферів грубої й детальної історії, а найстаріші елементи вилучаються, щоб місткість лишалася сталою. Грубі й детальні цілі одного кадру отримують однаковий рівень дифузійного часу τ, щоб описувати той самий ступінь зашумлення, але їхні тензори шуму генеруються незалежно. Для рівня $\ell \in \{\mathrm{c}, \mathrm{f}\}$ шум ε^ℓ має розподіл $\mathcal{N}(0, I)$; коефіцієнти визначено як $\alpha_\tau = \sqrt{\overline{\alpha}_\tau}$ і $\sigma_\tau = \sqrt{1 - \overline{\alpha}_\tau}$. Така конструкція координує рівні через увагу без штучного копіювання одного шумового тензора між різними сітками.

$$y^\ell_\tau = \alpha_\tau z^\ell_0 + \sigma_\tau \varepsilon^\ell. \tag{3.18}$$

Косинусна форма розкладу походить від Нікола та Дхарівала [149], а граничне обрізання є запобіжником конкретної реалізації. Нехай $r_\tau = \tau/T \in [0,1]$ – нормований крок дифузії, $s = 0.008$ – мале зміщення початку розкладу, а $\psi(r) = \cos^2\left(\frac{\pi}{2}\frac{r+s}{1+s}\right)$ – частка сигналу до нормування. Кумулятивний коефіцієнт збереження сигналу визначено як

$$\overline{\alpha}_\tau = clip_{[10^{-4},0.9999]}\left(\frac{\psi(r_\tau)}{\psi(0)}\right). \tag{3.19}$$

Ділення на $\psi(0)$ нормує початок косинусного профілю, а $clip_{[l,u]}(a)$ обмежує значення a інтервалом $[l,u]$. Нижня межа запобігає повному зануленню сигналу, верхня – виродженому кроку з нульовим шумом. Саме ці обрізані значення використовує код для обчислення α_τ і σ_τ.

Ціль швидкісної параметризації v_τ^ℓ поєднує шум і чисте представлення того самого рівня ℓ:

$$v_\tau^\ell = \alpha_\tau \varepsilon^\ell - \sigma_\tau z_0^\ell. \tag{3.20}$$

Оскільки шум присутній на обох цільових рівнях, трансформеру також надається незашумлений контекстний пакет, нормалізований часовий крок та дії для кожного кадру. Спільна увага охоплює контекстні й цільові позиції, але вихідні модулі використовують лише цільові токени. Функція втрат має вигляд

$$\mathcal{L}_v(\theta) = \mathbb{E}\left[MSE\left(v_\theta^{\mathrm{c}}, v_\tau^{\mathrm{c}}\right) + MSE\left(v_\theta^{\mathrm{f}}, v_\tau^{\mathrm{f}}\right)\right]. \tag{3.21}$$

У реалізації кожний із двох операторів MSE у (3.21) спочатку усереднює квадратичну похибку за всіма елементами відповідного тензора — пакетами, чотирма часовими позиціями, каналами та просторовими комірками. Після цього два скалярні середні для грубого й детального потоків додаються з однаковою вагою. Отже, більша кількість детальних комірок не надає детальному рівню автоматично більшої сумарної ваги, а жодної прихованої нормалізації між рівнями після додавання не виконується.

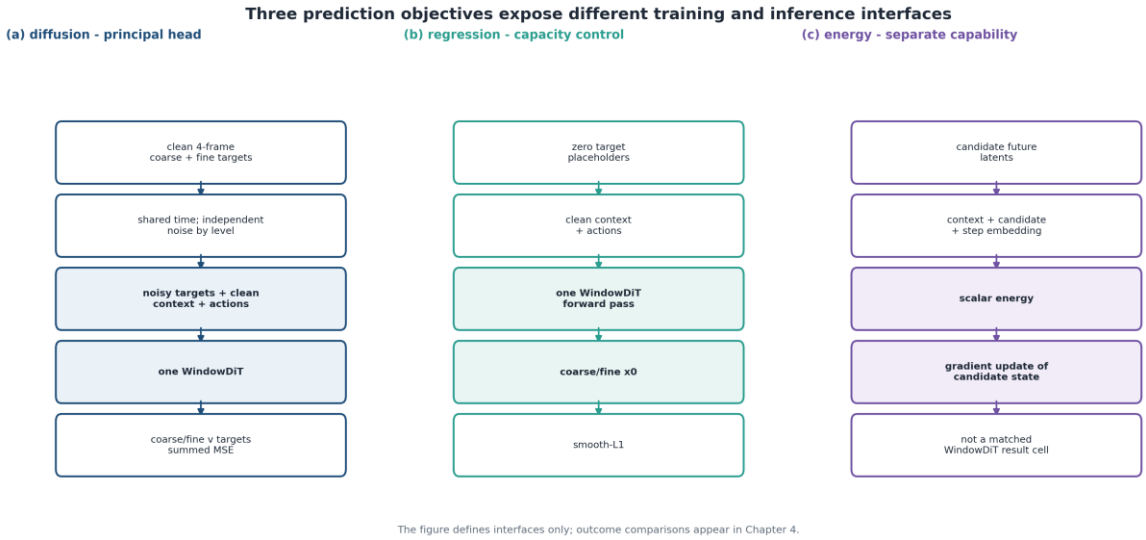


Рисунок 3.8 – Інтерфейси «прогноз-ціль».

Рисунок 3.8 розділяє три інтерфейси «прогноз–ціль». Основний дифузійний модуль оцінює швидкісну параметризацію шуму й чистого коду. Регресійний контроль одразу повертає грубі та детальні карти прихованого простору; він потрібний, щоб перевірити, чи закономірність пакетів не залежить лише від ітеративного знешумлення. Енергетичний механізм оцінює сумісність кандидата з контекстом і застосовується як окрема діагностика, а не як третій взаємозамінний генератор. Тому результати цих модулів порівнюються лише за заздалегідь визначеними ролями й однаковими пакетами.

Для оптимізації використовується алгоритм AdamW [159] зі швидкістю навчання 3×10^{-4}, коефіцієнтом затухання ваг 10^{-4}, лінійним розігрівом протягом 2 000 кроків оновлення, обмеженням норми градієнта на рівні 1,0 та експоненційним затуханням ковзного середнього 0,999. Основний режим використовує розмір пакета 16 для 30 000 оновлень, альтернативний оприлюднений режим із розміром пакета 8 та 60 000 оновлень обробляє приблизно таку саму кількість прикладів, але не є ідентичним за рівнем шуму градієнта, кількістю оновлень або ефективним горизонтом EMA. Під час навчання використовується bfloat16 там, де це підтримується, відповідно до принципу змішаної точності, що передбачає збереження вищої точності для чутливих операцій [162].

3.3.2 Базова мережа Transformer

WindowDiT – авторська назва спільного віконного трансформера, який обробляє зібрану послідовність контекстних і цільових токенів. Це не окрема зовнішня архітектура. Базова структура містить вісім попередньо нормалізованих блоків розмірністю $d = 384$. Її дворівневі варіанти мають приблизно 22 мільйони параметрів, що підлягають навчанню. У кожному

порівнянні пакетів глибина та ширина залишаються фіксованими. Таким чином, масштаб моделі контролюється, а змінною втручання лишається контекст.

Чотири майбутні кадри в одному виклику знешумлюються спільно: їхні цільові токени одночасно входять до повної уваги поточного блока й можуть обмінюватися інформацією. Проте ці майбутні позиції не належать до збереженого контексту і не враховуються в B_{ctx} або досяжності (3.5). Лише після завершення виклику отримані прогнози відокремлюються від графа попереднього вікна та за правилами §3.4 додаються до наступного стану. Отже, спільне знешумлення цільового блока не є витоком еталонного майбутнього й не подовжує спостережувану історію.

Кількість токенів не залежить від кількості параметрів моделі. Збільшення пакета подовжує послідовність і змінює обсяг доступної історії, але не додає нових блоків трансформера чи інших складників її обробки. Майже однакова кількість параметрів у гілках потрібна саме для того, щоб перевагу більшого або інакше організованого контексту не пояснювати більшою мережею.

Кожен блок використовує адаптивну обробку LayerNorm-Zero з сімейства DiT [4], що ґрунтується на нормалізації ознак у межах кожного зразка [160]. Мережа модуляції відображає c_j з (3.14) на вектори зсуву, масштабування та гейту для механізму уваги та MLP. Для прихованого токена h,

$$mod(h;\beta,\gamma) = h \odot (1+\gamma) + \beta, \tag{3.22}$$

спочатку обчислюється залишкове оновлення уваги:

$$h^{'} = h + g_1 \odot Attn\Big(mod(LN(h);\beta_1,\gamma_1)\Big). \tag{3.23}$$

Після нього MLP формує вихід блока h^{+}:

$$h^{+} = h^{'} + g_2 \odot MLP\Big(mod(LN(h^{'});\beta_2,\gamma_2)\Big). \tag{3.24}$$

У дифузійному режимі проєкції модуляції блоків ініціалізуються нулями, тому залишкові гілки починають роботу близько до тотожного відображення за схемою adaLN-Zero [4]. Для регресійного контролю модуляція ініціалізується звичайним способом: пряме передбачення прихованого коду не потребує спеціального нульового старту знешумлювача. Після восьмого блока відбираються лише цільові позиції. Окремі адаптивні нормалізації та лінійні

вихідні модулі грубого й детального прогнозування повертають токени до 16 каналів і формують карти 4×4 та 8×8. Термін «голова уваги» надалі використовується лише для складника багатоголової уваги.

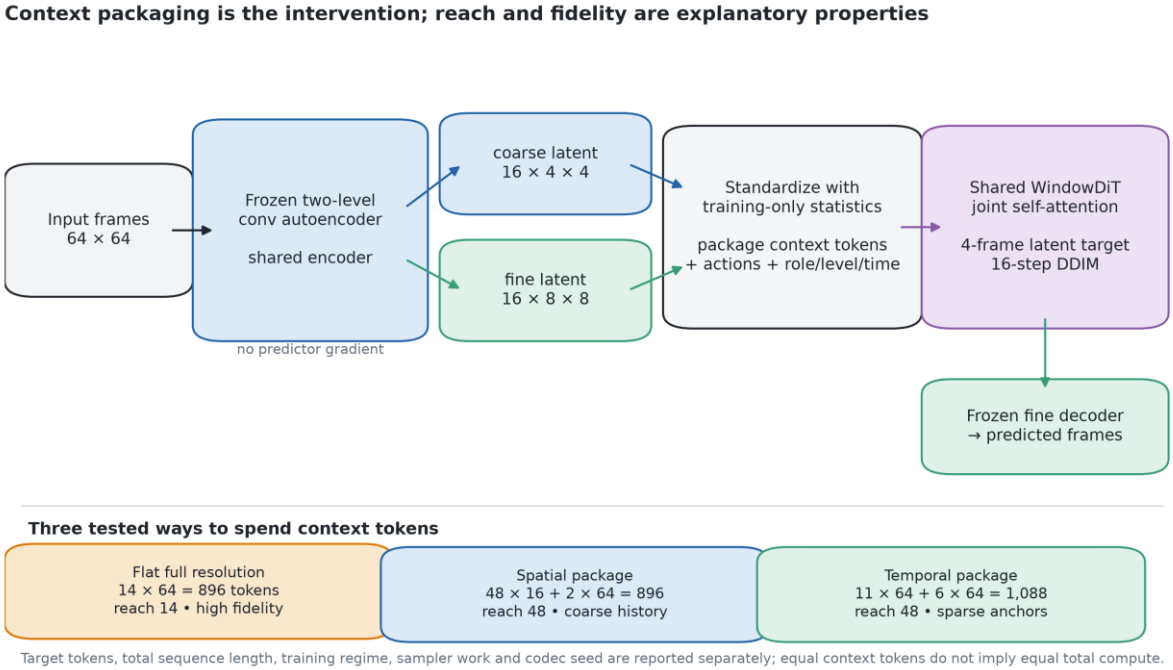


Рисунок 3.9 – Повний предиктор від заморожених кодів до цілі у прихованому просторі з чотирма кадрами.

Кодувальник, декодувальники, WindowDiT та інтерфейс цілі залишаються фіксованими, тоді як у порівняннях на головній межі змінюється лише збережений контекстний пакет. Повний шлях від кадру до двох рівнів цілі показано на рисунку 3.9.

3.3.3 Формування вибірки за допомогою DDIM

Генерування починається з гаусівського шуму для кожного грубого й детального цільового представлення чотирикадрового блока. Детермінований алгоритм вибірки DDIM [52] виконує знешумлення у вибраних точках навчального розкладу зашумлення, тобто послідовності рівнів $\overline{\alpha}_\tau$, використаних під час навчання. Для поточної ітерації y_i у точці τ_i вихід швидкісної параметризації спочатку перетворюється на оцінку чистих даних $\hat{z}_{0,i}$:

$$\hat{z}_{0,i} = \alpha_{\tau_i} y_i - \sigma_{\tau_i} v_\theta(y_i, \mathcal{P}_t, u, \tau_i). \tag{3.25}$$

Відповідна оцінка шуму $\hat{\varepsilon}_i$ дорівнює

$$\hat{\varepsilon}_i = \sigma_{\tau_i} y_i + \alpha_{\tau_i} v_\theta(y_i, \mathcal{P}_t, u, \tau_i). \tag{3.26}$$

Для кроків $i = 1, \ldots, N_{\mathrm{DDIM}} - 1$ наступний стан вибірки визначається як

$$y_{i+1} = \alpha_{\tau_{i+1}} \hat{z}_{0,i} + \sigma_{\tau_{i+1}} \hat{\varepsilon}_i. \quad (3.27)$$

За замовчуванням для обчислення встановлено $N_{\mathrm{DDIM}} = 16$. Отже, один блок із чотирьох кадрів вимагає 16 обчислень мережевої функції, або чотири обчислення на кожен згенерований кадр. Для розгортання з N_{blk} прогнозованих блоків загальна кількість обчислень предиктора дорівнює $\mathrm{NFE}_{\mathrm{roll}} = N_{\mathrm{DDIM}} N_{\mathrm{blk}}$. NFE можна скорочувати й дистиляцією дифузійного алгоритму вибірки [119], однак у цьому дослідженні ваги не дистильовано: чутливість перевіряється зміною кількості кроків того самого DDIM.

За фіксованого початкового шуму, ваг, контексту та числового середовища цей варіант DDIM формує детерміновану траєкторію. Різні початкові шуми породжують різних кандидатів. Тому спільний початковий шум у парному порівнянні зменшує випадкову різницю між пакетами, але не робить незалежні навчання однаковими й не замінює перевірку за кількома ініціалізаціями моделі.

Кандидатом тут називається одне згенероване майбутнє, отримане з окремої ініціалізації початкового шуму. В основних порівняннях пакетів для кожної зареєстрованої ініціалізації алгоритму вибірки оцінюється один такий прогноз. Діагностика механізму окремо застосовує критерій «найкращий із восьми» й перевіряє, чи принаймні один із восьми кандидатів добре відтворює ціль. Це умовна верхня оцінка охоплення множини кандидатів, а не звичайна помилка одного розгортання. Вісім дифузійних кандидатів по 16 кроків DDIM потребують 128 обчислень предиктора на запис, тоді як регресійна діагностика використовує вісім проходів із MC-dropout. Тому звітуються і NFE на кандидата, і загальна робота генерації.

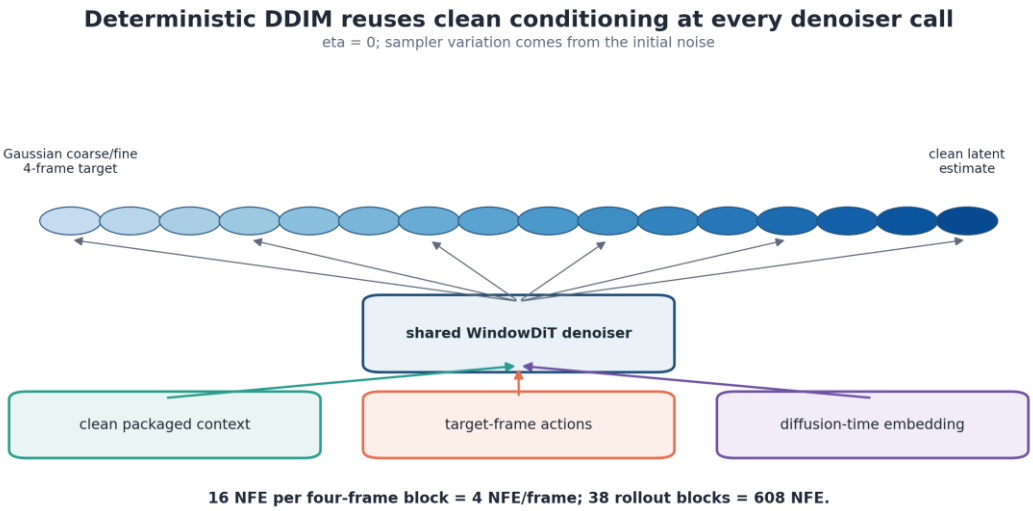


Рисунок 3.10 – Хронологія детермінованого DDIM та підрахунок обчислень функції.

Рисунок 3.10 показує цю різницю в обчислювальному бюджеті: один кандидат проходить усі 16 точок розкладу, а «найкращий із восьми» повторює повну траєкторію вісім разів. Щоб відділити користь контексту від цієї ітеративної процедури, вводиться однопрохідний регресійний контроль.

3.3.4 Регресійний контрольний модуль прогнозування

Регресійний контроль перевіряє найпростіше пояснення: чи може одна умовна оцінка використати той самий пакет без ітеративного уточнення DDIM. Він зберігає токенізацію, ширину й глибину мережі, контекст і геометрію цілі. На місця майбутніх карт подаються нульові початкові токени з окремою роллю «ціль», дифузійний час фіксується на нулі, а два вихідні модулі безпосередньо прогнозують грубий і детальний приховані коди. Оптимізується така втрата:

$$\mathcal{L}_{\text{reg}}(\theta) = SmoothL1(\hat{z}^{\text{c}}, z^{\text{c}}) + SmoothL1(\hat{z}^{\text{f}}, z^{\text{f}}). \tag{3.28}$$

При звичайній оцінці регресійна траєкторія є детермінованою для фіксованих ваг, вхідних даних та числового середовища. Її не можна описувати як вибірку з того самого генеративного сімейства, що й DDIM. Контроль з’ясовує, чи може однопрохідна умовна оцінка використати ту саму упаковану історію, тоді як дифузійний модуль показує результат з ітеративним стохастичним уточненням.

Ця відмінність запобігає неправильному тлумаченню: перевага дифузії над регресією за статистикою «найкращий із восьми» може бути наслідком мультимодального охоплення, ітеративного обчислення, більшого бюджету кандидатів або їх поєднання. Тому висновок завжди прив’язується до конкретного режиму оцінювання та показника якості.

3.4 Авторегресивне розгортання та оновлення пам’яті

Навчальна ціль описує одне майбутнє вікно, тоді як довгий прогноз потребує послідовного оновлення стану. У цьому підрозділі визначаються кільцеві буфери, точні часові прив’язки між контекстом і ціллю та окремий облік контекстних, цільових і загальних токенів. Це усуває неоднозначність щодо того, які кадри реально доступні на кожному кроці самоподачі.

Чотирикадрова ціль одного навчального виклику й довге авторегресивне розгортання не є взаємозамінними горизонтами. Перша визначає ширину спільно прогнозованого блока та локальний граф оптимізації; друге складається з повторних викликів, у яких попередні прогнози вже є вхідними даними. Тому показник на четвертому горизонті характеризує завершення одного виклику, а пізні ділянки 152- або 300-кадрового прогнозу додатково містять накопичення похибок самоподачі. Висновок про довгу авторегресивну стійкість потребує окремої реплікації й не випливає лише з якості одного чотирикадрового блока.

3.4.1 Рекурентність кільцевого буфера

Після навчання той самий предиктор багаторазово застосовується до власних виходів. Щоб довжина збереженого стану не зростала з кожним блоком, для грубого й детального потоків використовуються буфери фіксованої місткості: нові карти додаються, а найстаріші вилучаються за правилами пакета. У стандартній щільній конфігурації місткості дорівнюють $N_{\mathrm{c}} = 48$ і $N_{\mathrm{f}} = 6$, а ширина прогнозованого блока становить $W = 4$ кадри. Предиктор стає довгогоризонтною системою завдяки рекурентному оновленню. Кожен завершений чотирикадровий блок надходить до наступного контексту, після чого цикл передбачення повторюється. Між викликами зберігаються буфери прихованого простору фіксованого розміру, визначені активним пакетом, а граф активацій трансформера завершується разом із поточним викликом.

$$B_{n+1}^{\ell} = tail_{N_{\ell}}\left(B_n^{\ell} \| \hat{Z}_n^{\ell}\right). \tag{3.29}$$

Після оновлення межа вікна переходить до $t_{n+1} = t_n + W$. Оператор $tail_N$ після конкатенації зберігає N найновіших позицій. Детальний буфер відкидає чотири із шести старих значень і додає чотири прогнози, грубий буфер так само

оновлює залишкові позиції. Часово розріджені конфігурації та конфігурації зі зменшеним кроком використовують задекларований планувальник прив'язок, тому до потоку повертаються лише цільові позиції, вирівняні з його часовою сіткою. Щільні пари, на яких ґрунтується основне твердження про досяжність і точність відтворення, оновлюють по чотири грубі й детальні цілі на блок і не змінюють цільового інтерфейсу.

Вхідними даними є кадри розігріву $x_{0:47}$, керувальні сигнали $u_{48:T-1}$, заморожений кодек, нормалізація навчального набору, предиктор EMA, пакет $\mathcal{P}$ і розподіл вибірки. Виходами є прогнози у просторі пікселів $\hat{x}_{48:T-1}$ та вирівняні записи оцінювання. Нижче наведено алгоритм розгортання із самоподачею та пакетованою пам'яттю прихованого простору:

1. Закодувати й стандартизувати початкові кадри, потім ініціалізувати кожен потік за задекларованими прив'язками.
2. На межі t_n зібрати впорядковані контекстні токени та зчитати керувальні сигнали $u_{t_n:t_n+3}$.
3. Згенерувати пари грубих і детальних представлень у прихованому просторі за допомогою DDIM або регресійного вихідного модуля.
4. Зафіксувати згенеровані слоти через планувальник пакетів і видалити застарілі прив'язки, не зберігаючи міжвіконний градієнтний граф.
5. Скасувати стандартизацію та декодувати детальні вектори прихованого простору, зберігаючи геометричні мітки й вхідні дані показників для кожного кадру.
6. Встановити $t_{n+1} = t_n + 4$ та повторювати до заявленого горизонту.

Для стандартного 200-кадрового кліпу TRB, генератор якого докладно визначено в §3.5.2, процес починається з 48 початкових кадрів, після чого 38 блоків розгортання створюють 152 прогнозовані кадри. Пізніші контексти повністю складаються з виходів моделі. Ємність буфера залишається фіксованою, але його вміст поступово оновлюється, а якість змінюється. Тому модель може номінально мати доступ до довгого горизонту й водночас втрачати надійну інформацію зі збільшенням розгортання.



Рисунок 3.11 – Оновлення грубого й детального кільцевих буферів під час розгортання із самоподачею. У кожному рядку сірі комірки відповідають чотирьом вилученим найстарішим позиціям, білі – збереженим, а кольорові – чотирьом новим прогнозам. Схема показує сталі місткості 48 і 6 кадрів, а не гарантію незмінної якості вмісту. *Джерело: побудовано автором за формулою (3.29) та реалізованим шляхом розгортання.*

3.4.2 Геометрія прив’язки та причинно-наслідкова семантика

Довжини буфера недостатньо для відтворення історичного значення. Кожен збережений слот повинен містити або детерміновано отримувати кадр, який він представляє. Для потоку i слот k на цільовій межі t закріплений за адресою $\kappa_{i,k}(t)$:

$$\kappa_{i,k}(t) = t - a_i - ks_i. \tag{3.30}$$

Часове відставання цього слота дорівнює $\delta_{i,k}(t) = t - \kappa_{i,k}(t)$, де $k = 0, \dots, n_i - 1$. Та сама домовленість стосується грубого контексту з кроком 2. Конфігурація hier-s2-min зберігає $t-47, t-45, \dots, t-1$: 24 прив’язки, розподілені на інтервалі 48 позицій, із найдавнішою часовою відстанню 47. Протокол із фіксованою ціллю використовує зареєстровану позначку номінальної досяжності 48 та заздалегідь визначений діапазон $8 < \Delta t \leq 48$. Порівняння залишається тестом усієї конфігурації; його не можна використовувати для визначення верхнього порога досяжності з точністю до одного кадру.

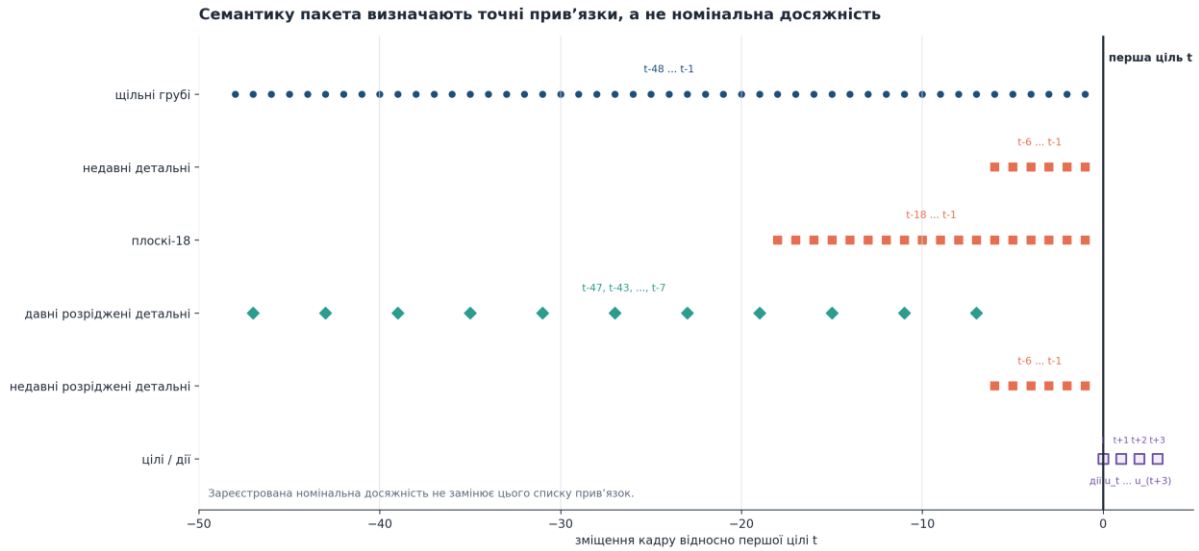


Рисунок 3.12 – Геометрія потокової прив'язки на межі прогнозування з чотирма кадрами.

Рисунок 3.12 має показувати перекриття рівнів, а не їхній взаємовиключний поділ у часі. У hier-long останні шість кадрів представлені і грубо, і детально; попередні 42 кадри – лише грубо. В інших щільних парах перекриття становить відповідно 2, 16, 26 і 36 кадрів для hier-min, hier-c1, hier-c2 та hier-rich. Подання двох рівнів у спільній послідовності є архітектурною реалізацією цієї роботи, але не підставою заявляти першу багаторівневу відеомодель: близькі грубо-детальні та багатомасштабні конструкції існують у попередніх працях [20, 35–37, 150]. Науковий внесок тут полягає у точному контракті пакетів, зіставленому бюджеті та причинному тесті межі «досяжність–точність відтворення».

Геометрія прив'язок уточнює й межі конфігурації B1 з кроком 2. Її контекст містить 24 грубі позиції з кроком 2 та два найновіші детальні кадри. Проте реалізований цільовий інтерфейс повертає дві грубі цільові позиції, а не чотири. Отже, разом із кроком контексту змінюються і кількість цільових токенів, і спосіб агрегування дій для грубих позицій. Варіант із фіксованою ціллю існує лише як підготовлена специфікація. Оскільки його не виконано, у розділі 4 зберігається формулювання на рівні повної конфігурації.

3.4.3 Контекст, ціль та загальна вартість

Фіксовані буфери роблять пам'ять збереженого стану незалежною від тривалості розгортання. Для пакета $\mathcal{P}$ із $C_\ell = 16$ коефіцієнтами кодека на токен і розміром елемента b байтів суцільний корисний обсяг даних прихованого простору становить

$$M_{\text{payload}}(\mathcal{P}) = bC_\ell B_{\text{ctx}}(\mathcal{P}). \tag{3.31}$$

У float32 кожен токен займає 64 байти, а у float16 чи bfloat16 – 32 байти. Основний стан містить 48 грубих і 6 детальних кадрів, тобто 18 432 коефіцієнти прихованого простору: 72 КіБ у float32 та 36 КіБ у 16-бітному форматі. Для

порівняння, щільна детальна історія з 48 кадрів містить 49 152 коефіцієнти, або 192 КіБ у float32.

Повний облік усіх пакетів, включно з інтерфейсом B1, контекстними, цільовими й загальними токенами та корисним обсягом даних, перенесено до таблиці В.8. В основному тексті достатньо зафіксувати принцип зіставлення: flat-min/hier-min, flat-budget/hier-long, flat-c1/hier-c1, flat-c2/hier-c2 і flat-long/hier-rich мають однаковий контекстний бюджет усередині кожної пари, тоді як B1 змінює також цільовий інтерфейс і тому оцінюється лише як повна конфігурація.

Самоувага залежить від загальної довжини послідовності. Якщо константи ядра ігноруються, обчислювальна складність ядра уваги для одного блоку масштабується як

$$C_{\text{attn}}(S, d) = O(S^2 d). \tag{3.32}$$

За однакової ширини d відношення членів уваги для довжин S_1 і S_2 наближено дорівнює $(S_1/S_2)^2$. Це відношення не описує повну пам’ять або час роботи всієї моделі. На рисунку 3.13 показано, як пам’ять залежить від розподілу токенів між рівнями. Ієрархічні пакети зменшують збережений контекст і загальну довжину послідовності, залишаючи спільну ціль видимою. Стовпчики відображають точну кількість токенів на інтерфейсі, а не продуктивність моделі.

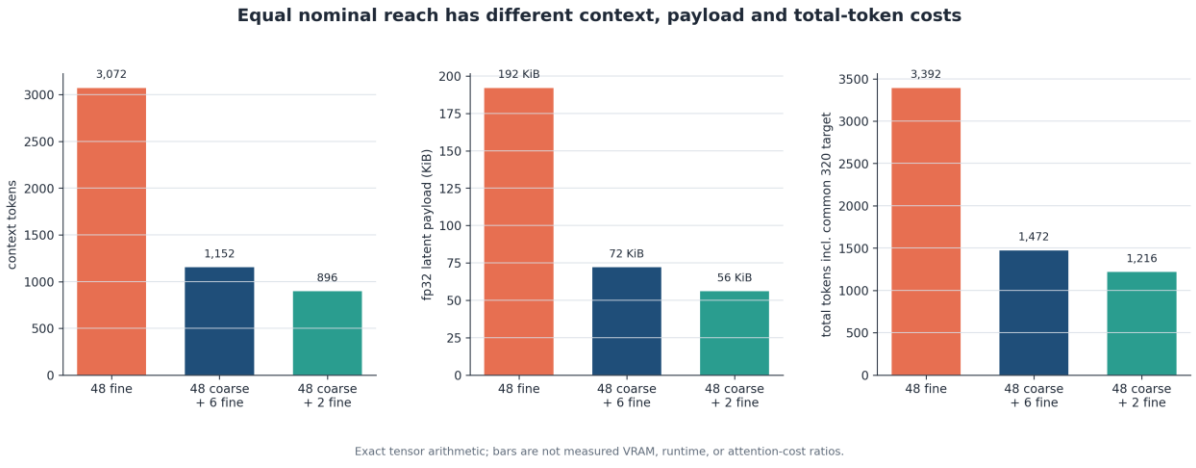


Рисунок 3.13 – Арифметика контексту, корисного навантаження та загальної кількості токенів за однакової номінальної досяжності 48 кадрів.

Ресурсом тут є пам’ять стану, відмінна від пам’яті активацій, обговореної в розділі 2. Під час навчання в одному вікні пам’ять активацій визначається довжиною обчислювального графа, яка становить від 800 до 3 392 токенів у

досліджених дворівневих конфігураціях, і не залежить від кількості блоків, що згодом оцінюються під час розгортання. Тому будь-яку спільну економію потрібно вимірювати безпосередньо.

У таблиці В.8 встановлено арифметику інтерфейсу, а не апаратне прискорення. Однакова кількість контекстних токенів робить зіставлені пари коректними на вході трансформера, а однакові загальні токени додатково контролюють довжину послідовності. Проте фактичні час і пікова пам’ять залежать від розміру навчального пакету, точності, реалізації уваги та робочих буферів. Тому в розділі 4 токенна ефективність подається окремо від будь-якого твердження про повну VRAM.

3.5 Інструменти оцінювання та оцінювані ефекти

Цей підрозділ перетворює архітектурну гіпотезу на вимірюваний протокол. Спочатку визначається популяція, у якій пакети справді відрізняються досяжністю, потім правила масок, об’єктних показників і зіставлення сталої ідентичності, а наприкінці – парне статистичне виведення з повторною вибіркою цілих кліпів. Повні довідкові реєстри винесено до додатків, щоб основний текст зберігав причинний ланцюг.

3.5.1 Чому короткі тести не можуть виявити механізм досяжності

Формула пакета дає змогу обчислити номінальну досяжність, але звичайний стандартний набір може не ідентифікувати її вплив на прогноз. У канонічному Moving-MNIST цифри рухаються й зіштовхуються в межах зображення 64×64, а відбиття від меж утримує їх у кадрі [124]. Невизначеність майбутнього та похибка довгого розгортання присутні, проте немає чіткої популяції, в якій об’єкт залишає короткий контекст, а згодом повертається за геометрією, що дає змогу обчислити доступність довшої історії.

Короткі тестові набори не варто відкидати: вони допомагають оцінити працездатність і встановити межі. Канонічний Moving-MNIST та TaxiBJ показують, чи працює часовий предиктор за відомими зовнішніми протоколами. Варіант довгого Moving-MNIST зі сталими ідентичностями додає 300-кадровий горизонт із самоподачею. Проте жоден із цих наборів не має точної геометрії

видимості, потрібної для перевірки центрального механізму. Саме ця прогалина мотивує генератор TRB, визначений у §3.5.2 [1, 124, 126].

Розмежування ролей запобігає двом протилежним помилкам і робить дослідження прозорішим. Синтетичний набір для дослідження механізму не замінює доказів на усталених задачах прогнозування. Водночас стандартний набір оцінювання не ідентифікує перевагу пам'яті лише тому, що його тестова послідовність є довгою. Тому кожна таблиця й кожне твердження називають властивість, на якій вони ґрунтуються. Інструмент побудовано навколо однієї вимоги: записи мають бути складними для коротшого пакета, доступними для відповіді за довшого пакета та придатними до маркування без перегляду виходу моделі. Для цього потрібен контроль світу, поля огляду й траєкторії, а не більша візуальна реалістичність. Синтетична природа інструмента посилює ідентифікацію механізму, але обмежує зовнішню застосовність результату.

3.5.2 Генератор TRB та геометрія повторного входу

Тороїдальний тест повторного входу (Toroidal Re-entry Benchmark, TRB; внутрішня назва LoopMom) є процедурним набором, у якому геометрія світу робить останню видимість об'єкта аналітично відтворюваною. Кожен кліп TRB починається зі статичного світу $\mathcal{W} \in [0,1]^{64\times192}$ з тороїдальним горизонтальним виміром. Плавний фон утворюють чотири синусоїдальні компоненти з цілочисельними горизонтальними частотами, нормалізовані й масштабовані до інтервалу інтенсивності $[0.15, 0.50]$. Потім три символи MNIST розміщують за фіксованими координатами світу шляхом попіксельного взяття максимуму. Горизонтальне розміщення символів огинає тор, а вертикальне утримує вихідний 28-піксельний фрагмент у межах висоти 64 пікселі. Обраний світ залишається незмінним упродовж усього кліпу.

Спостережуваний кадр – це вікно перегляду розміром 64×64. Нехай $r_t \in \{0, \dots, 191\}$ – збережена координата лівого краю, а $a_t \in \{-1, 0, +1\}$ – записана дія камери. Рух вікна задається рівнянням

$$r_t = (r_{t-1} + 4a_t) mod 192. \tag{3.33}$$

Спостережуваний кадр формується як $x_t(y,x) = \mathcal{W}(y,(r_t + x) mod 192)$. На рисунку 3.14 показано, як зі збережених позицій вікна перегляду визначають події, доступні ієрархічному пакету, але недоступні короткому плоскому вікну, де для верхніх бюджетів окремо порівнюють пакети, що вже охоплюють потрібну історію. Це дає змогу перевіряти конкретні пари замість загального зіставлення на пізньому горизонті.

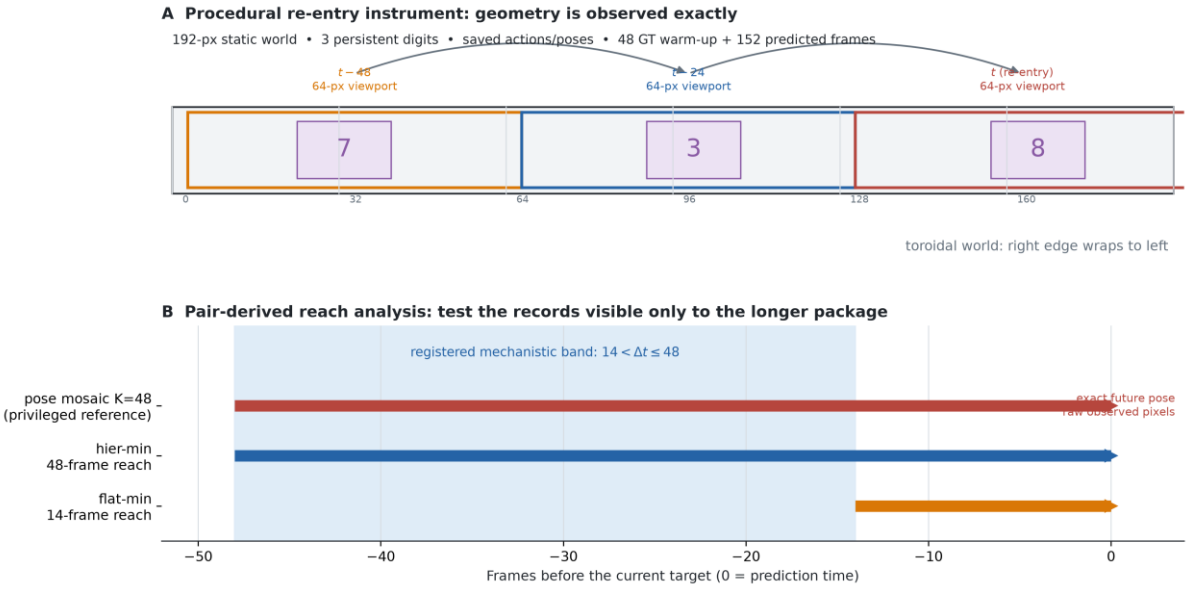


Рисунок 3.14 – Геометрія світу TRB і смуги різниці досяжності для порівнюваних пакетів.

Розроблення й контрольне оцінювання спираються на два шари даних. Основний навчальний набір містить 3 000 кліпів по 100 кадрів. Навчальні й валідаційні індекси розділені на рівні кліпів. Для оцінювання окремо згенеровано п’ять наборів по 500 кліпів і 200 кадрів: дані розроблення, відкладене підтвердження, перевірка стійкості до параметрів алгоритму вибірки, перевірка з незалежним кодеком та аналіз прямого доступу до історії. У кожному маніфесті зафіксовано призначення, ревізію генератора, випадкову ініціалізацію, файл вихідних гліфів, конфігурацію та хеші SHA-256 відповідно до практик документування наборів даних [165].

Сюжетна схема на рисунку 3.15 демонструє, чому одного лише пізнього горизонту недостатньо: оцінювач повинен знати, коли цільовий контент був видимий востаннє та чи потрапляє це спостереження в межі кожного пакета.

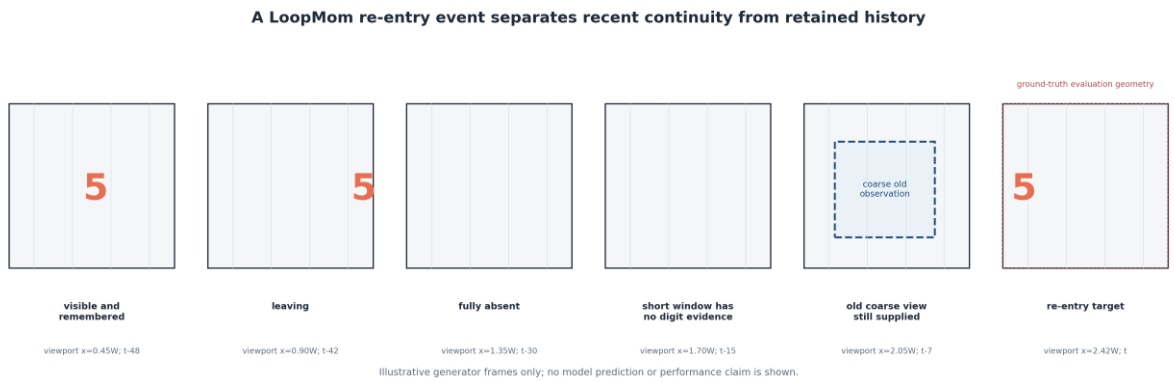


Рисунок 3.15 – Подія зникнення та повторного входу, що охоплює кілька кадрів.

TRB дає точні координати світу й камери для кожного кадру. На їхній основі можна визначити не лише факт повторної появи, а й те, чи потрапляє останнє релевантне спостереження до конкретного пакета. Наступний підрозділ формалізує цю перевірку без використання прогнозів моделі.

3.5.3 Аналітична видимість і популяції різниці досяжності

Аналітичний модуль видимості використовує лише збережені координати вікна перегляду й еталонний світ; виходи моделі до нього не надходять. Для m кадрів перед цільовим моментом t множина охоплених стовпців світу дорівнює

$$cov_m(t) = \bigcup_{u=t-m}^{t-1} \{(r_u + x) mod 192 \mid x = 0, \dots, 63\}. \quad (3.34)$$

Стовпці переднього плану, видимі в цільовому кадрі, визначаються за порогом 0,5:

$$F(t) = \{(r_t + x) mod 192 \mid max_y x_t(y, x) > 0.5\}. \quad (3.35)$$

Різниця $N_m(t)$ містить частину поточного переднього плану, якої не було у вікні останніх m кадрів:

$$N_m(t) = F(t) \setminus cov_m(t). \quad (3.36)$$

Для непорожнього $F(t)$ частка нового переднього плану дорівнює $\nu_m(t) = |N_m(t)|/|F(t)|$. Самої складності запису недостатньо, щоб визначити попередню спостережуваність. Нехай $v_t(c)$ – найпізніший момент часу до t, коли стовпець світу c перебував у полі огляду, а A_t містить стовпці з $N_6(t)$, для яких такий момент існує. Частка доступних для відповіді стовпців дорівнює

$$\rho_t = \frac{|A_t|}{|N_6(t)|}. \quad (3.37)$$

Мітка часу від останньої видимості визначається як $\Delta t_t = median_{c \in A_t}[t - v_t(c)]$. Явно задано $\rho_t = 0$, коли $N_6(t) = \emptyset$, і $\Delta t_t = 0$, коли $A_t = \emptyset$. Запис

вважається придатним для оцінювання, якщо $|N_6(t)| > 0$ та $\rho_t \geq 0.5$. Тому кадр, що містить лише недавні свідчення, не може потрапити до смуги позитивної різниці досяжності, а справді небачена повторна поява реєструється окремо й не враховується як доказ проти пакета пам'яті. Нижче χ позначає індекс кліпу, а t – часову позицію всередині нього.

$$\mathcal{D}_{l:s}^{\text{reach}} = \left\{(\chi, t): R(\mathcal{P}_s) < \Delta t_t \leq R(\mathcal{P}_l), \rho_t \geq 0.5, |F(t)| > 0\right\}. \tag{3.38}$$

Для hier-min порівняно з flat-min зареєстрований діапазон становить $14 < \Delta t \leq 48$. Порівняння всієї конфігурації B1 з flat-short використовує діапазон $8 < \Delta t \leq 48$. Ці діапазони були отримані за допомогою інструмента розроблення та зафіксовані до відкриття відкладеного набору підтвердження. Інші пари отримують власні межі; загальна позначка «складна вибірка» ніколи не замінює різницю в досяжності фактичних гілок.

Протокол парних контрастів E2 та структурна матриця використовують різні популяції, які не можна об'єднувати після аналізу. В E2 межі різниці досяжності задаються окремо для кожної пари пакетів, як у (3.38). Для одноразового підтвердження структурної матриці застосовується спільна маска: модель отримує 96 спостережуваних кадрів, а подія повторного входу позначається тоді, коли цільовий об'єкт був видимий у межах цієї історії, але його остання видимість передує межі 28 недавніх кадрів. Основною метрикою розроблення є horizon4_foreground_mse, тобто передньопланова MSE для четвертого кадру одного виклику. У фінальному підтвердженні додатково подаються середні за всіма чотирма горизонтами для повної сукупності, записів повторного входу та записів без повторного входу.

Редукція основної метрики відповідає реалізації навчальної кампанії. Передній план визначається порогом інтенсивності еталонної цілі понад 0,5; усередині кожного фіксованого обчислювального пакета сума квадратичних помилок ділиться на кількість його передньопланових пікселів, після чого значення пакетів усереднюються з вагами за кількістю прикладів. Підтверджувальна метрика має іншу редукцію: передньопланова похибка спочатку обчислюється для кожної пари «кліп–горизонт», а потім усереднюється

за всіма чотирма горизонтами або за записами, визначеними маскою повторного входу. Через різні одиниці редукції ці показники мають різні ролі й не підміняють один одного.

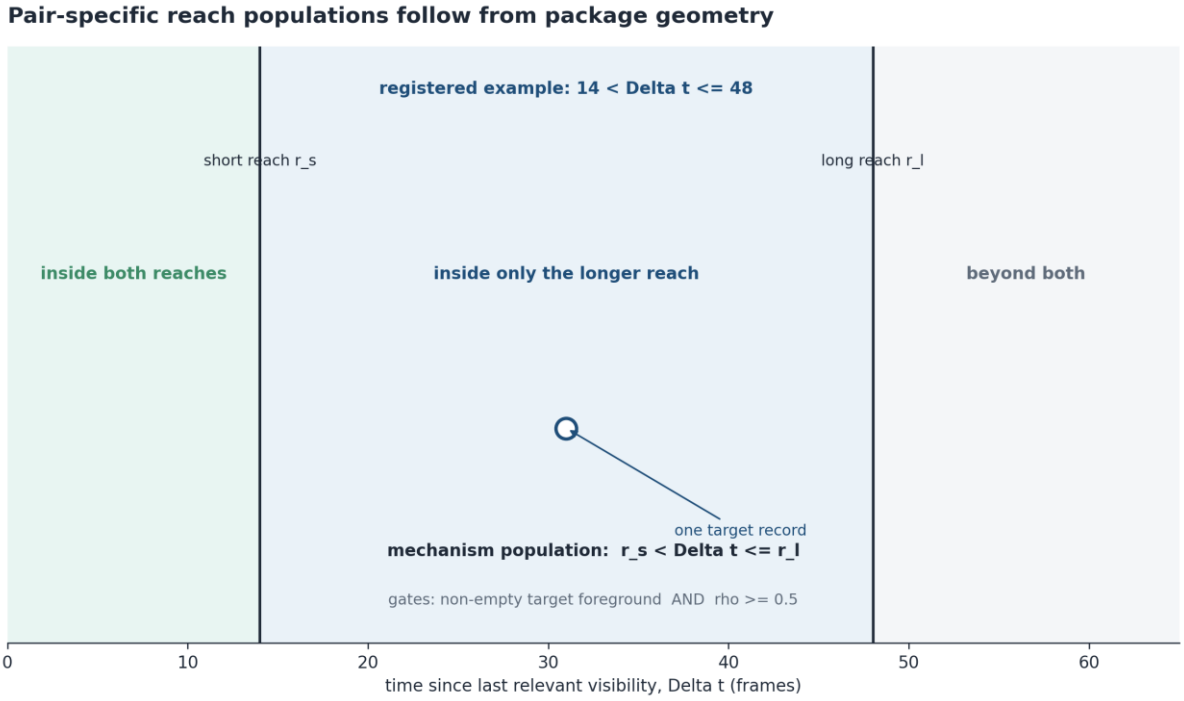


Рисунок 3.16 – Специфічна для кожної пари популяція різниці досяжності.

Лише записи, релевантні свідчення для яких лежать поза межами коротшого пакета, але всередині довшого, ідентифікують запропонований механізм досяжності.

3.5.4 Повні метрики кадру та об’єкта

Як було визначено в першому розділі, жоден окремий показник не охоплює всі форми консистентності. Тому доцільно зосередитися на конкретній проблемі та вибрати показник, чутливий саме до неї. У цій роботі такою проблемою є довгострокове прогнозування з тимчасовим виходом об’єкта за межі поля огляду. Нехай $p, g \in [0,1]^{H \times W}$ – декодовані прогноз і ціль, Ω — повна множина пікселів, а τ – поріг, визначений для популяції. Позначимо прогнозовану, еталонну та об’єднану маски як $P_\tau = \{p > \tau\}$, $G_\tau = \{g > \tau\}$ і $U_\tau = P_\tau \cup G_\tau$. Для квадратичної похибки $e = (p - g)^2$ введемо одну функцію маскованої похибки на непорожній області $A \neq \emptyset$:

$$MSE(A) = \frac{\sum_{(y,x)\in A} e_{y,x}}{|A|}. \tag{3.39}$$

Повнокадрова, передньопланова, фонова та об’єднана похибки отримуються відповідно для $A = \Omega$, G_τ, $\Omega \setminus G_\tau$ і U_τ. Для порожнього еталонного переднього плану $MSE(G_\tau)$ не звітується; для порожнього фону або об’єднання відповідний діагностичний показник за домовленістю дорівнює нулю. Чіткість переднього плану вимірюється як енергія лапласіана з маскуванням для кожного зображення окремо, з використанням сімейства мір фокусування лапласіана [163]. SSIM та PSNR залишаються традиційними діагностичними показниками реконструкції [127]. Візуальний огляд також є обов’язковим: панелі декодованого прогнозу, цільового зображення та останнього контексту зберігаються з тих самих записів, що використовуються для чисельного аналізу. Вони допомагають діагностувати зникнення об’єктів і якісну невідповідність, але відбираються за заздалегідь визначеним правилом і не замінюють статистичного оцінювання.

Зв’язні компоненти додають до покадрових показників інформацію про наявність об’єктів [164]. Для TRB прогнозовані й цільові компоненти зіставляються угорським алгоритмом із вартістю $1 - IoU$ [125]. Зіставлення з нульовим перекриттям відхиляються. Якщо залишається M пар, кількість пропущених об’єктів дорівнює $n_{\mathrm{GT}} - M$, а зайвих – $n_{\mathrm{pred}} - M$. Середнє перекриття й відстань між центроїдами обчислюються лише для прийнятих пар і завжди подаються разом із частками пропущених, зайвих об’єктів та покриття. Інакше модель могла б поліпшити оцінку лише на зіставлених парах, генеруючи менше об’єктів.

Для піксельних масок $TP = |P_\tau \cap G_\tau|$, $FP = |P_\tau \setminus G_\tau|$ і $FN = |G_\tau \setminus P_\tau|$. Прецизійність дорівнює $TP/(TP + FP)$, повнота — $TP/(TP + FN)$, а F1 — їх гармонійному середньому. Реалізація повертає прецизійність 1 за порожнього прогнозу, повноту 1 за порожнього еталона та F1 0, коли сума прецизійності й повноти дорівнює нулю; разом із метриками зберігаються ознаки порожності обох масок.

Повний реєстр метрик, оцінюваних популяцій, сприятливих напрямів, порожніх випадків і відомих обмежень перенесено до таблиці Д.2. В основному

тексті залишено означення, потрібні для розуміння причинного ланцюга; стрілки та правила гармонізації знаків у додатку слугують довідковим контрактом реалізації.

3.5.5 Межі оцінювання об’єктів зі сталою ідентичністю та стандартних наборів

TRB надає точні мітки видимості, але самі компоненти переднього плану не встановлюють ідентичність об’єктів упродовж кліпу після зіткнень і тривалого руху із самоподачею. Тому зовнішня синтетична межа використовує довгий Moving-MNIST зі збереженими в метаданих ідентифікаторами. Навчальні кліпи містять 100 кадрів, а кліпи розробки й захищені кліпи – 348. Після 48 початкових кадрів кожна модель прогнозує 300 кадрів. Плоскі й ієрархічні пакети мають по 1 152 контекстні токени та оцінюються для трьох ініціалізацій навчання.

Оцінювання цих кліпів потребує взаємно однозначного зіставлення, що зберігає ідентичність. Нехай q_g і q_d є центроїдами еталонного та виявленого об’єктів, а D — діагоналлю кадру. Вартість пари поєднує нормовану відстань між центроїдами та IoU:

$$c_{gd} = \frac{1}{2} min\left(\frac{\|q_g - q_d\|_2}{D}, 1\right) + \frac{1}{2}(1 - IoU_{gd}). \quad (3.40)$$

Після угорського зіставлення приймаються лише пари з $c_{gd} \leq 0.65$; їх множину позначено $\mathcal{M}$, а кількість — $M = |\mathcal{M}|$. Покриття дорівнює M/n_{GT}. Похибка траєкторії дорівнює сумі відстаней для прийнятих пар і штрафу D за кожний пропущений еталонний об’єкт, поділеній на n_{GT}. Точність ідентичності дорівнює частці правильно класифікованих прийнятих пар серед усіх видимих маркованих еталонних об’єктів. Останні три показники не звітуються для кадрів без відповідних еталонних об’єктів, за винятком правила покриття з таблиці Д.2.

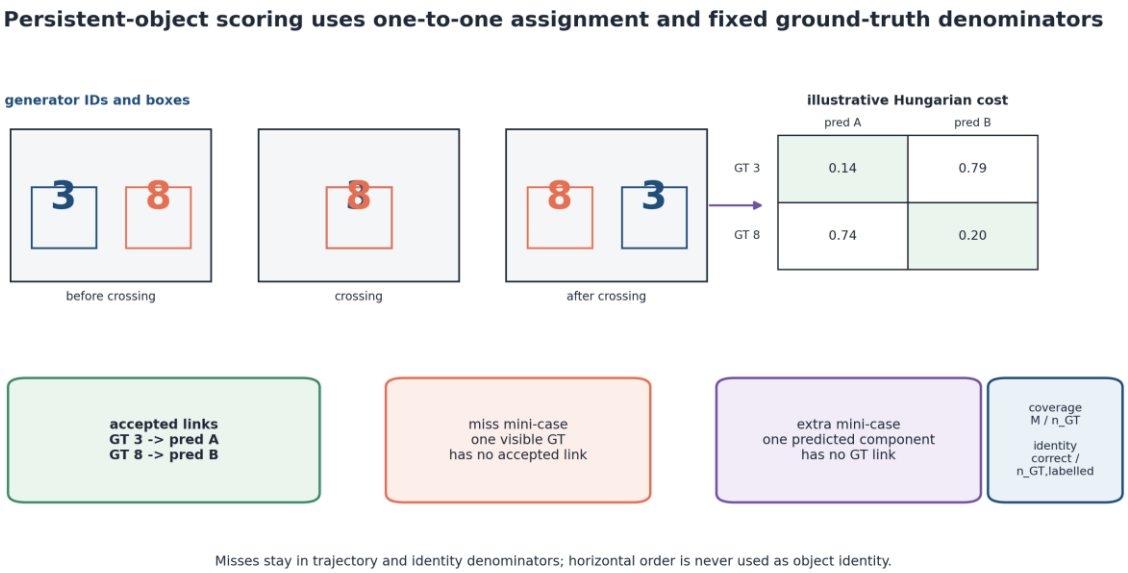


Рисунок 3.17 – Зіставлення об’єктів зі сталою ідентичністю та їх відстеження.

У кожному кадрі угорський алгоритм зіставляє виявлені компоненти з еталонними об’єктами, після чого сталі ідентифікатори дають змогу окремо виміряти покриття, неперервність, ідентичність і похибку траєкторії.

Рисунок 3.17 показує, як зіставлення відокремлює сам факт виявлення від правильної ідентичності та траєкторії. Таблиця 3.3 після нього розміщує цей тест поруч із TRB і стандартними наборами, щоб жоден результат не переносився на іншу експериментальну популяцію без окремого обґрунтування.

Таблиця 3.3 – Набори даних для оцінювання та їхня доказова роль. Зміна набору даних змінює наукове питання; компетентність еталону не перетворюється автоматично на підтвердження механізму.

Інструмент	**Контекст → прогноз**	**Досліджувана властивість**	**Чинна роль**	**Твердження, яке він не може підтвердити**
Розробка TRB	48 → 152	проєктування пакетів і страт, виведених із геометрії	формування гіпотез і діагностика	відкладене підтвердження
Відкладені й захищені набори TRB	48 → 152	точні смуги досяжності, межа і заздалегідь визначені дослідження робастності	підтвердження контрольованого механізму	перевага над природним відео
Довгий Moving-MNIST зі сталою ідентичністю об’єктів	48 → 300	просторове покриття, неперервність, ідентичність і траєкторія	зовнішня синтетична межа	відтворення геометричного механізму досяжності TRB
Канонічний Moving-MNIST	короткий горизонт, специфічний для протоколу	здатність до прогнозування руху	перевірка за еталонними даними та негативний контроль	еквівалентність ієрархій або перевага повторного входу

Інструмент	**Контекст → прогноз**	**Досліджувана властивість**	**Чинна роль**	**Твердження, яке він не може підтвердити**
TaxiBJ	протокол OpenSTL	прогнозування просторово-часового поля	зовнішня компетентність	консистентність об’єктів з довготривалою пам’яттю

Зміна набору даних змінює наукове питання. Дослідження об’єктів зі сталою ідентичністю перевіряє, чи залишається інтерпретація «досяжність–точність відтворення» корисною за явної ідентичності, але все одно утворює лише зовнішню синтетичну межу. У розділі 4 цей тест розглядається як перевірка переносності інтерпретації, а не як реплікація геометричного механізму TRB. Валідація на природному відео потребуватиме рухомих камер, прихованого вмісту, що змінюється в часі, та анотацій контрольованих повторних спостережень.

3.5.6 Статистичний протокол

Статистичний протокол починається з парного вирівнювання експериментальних записів. Обидві гілки використовують той самий кліп і цільовий горизонт, а стохастичні алгоритми вибірки – спільні випадкові числа в зареєстрованих парних комірках. Для показника «менше – краще» ефект обчислюється як значення базової порівнюваної конфігурації мінус значення кандидата; для показника «більше – краще» порядок віднімання змінюється. Тому позитивний знак завжди сприяє зареєстрованому кандидатові. Парне вирівнювання зменшує шум, але не змінює межі порівняння: майже зіставлений пакет лишається майже зіставленим, а супутні зміни повної конфігурації не розкладаються на окремі компоненти [169].

Одиницею повторної вибірки є кліп. Якщо один ранній прогноз зміщує об’єкт, кілька наступних кадрових помилок успадковують те саме збурення й не є незалежними доказами. Тому під час передискретизації всі записи вибраного кліпу залишаються разом. ініціалізації навчання не вкладаються до цього самого циклу: кожне незалежне навчання показується окремо, щоб велика кількість кадрів не створювала хибного враження реплікації моделі.

Структурна матриця має дві незалежні ініціалізації навчання для кожної унікальної конфігурації. У звіті показують обидва значення, їхнє середнє та узгодженість напряму ефекту між ініціалізаціями. Покліпові інтервали характеризують варіативність прикладів за фіксованої навченої моделі й не називаються невизначеністю за ініціалізаціями; за двох навчань не будується асимптотичний 95-відсотковий інтервал на рівні ініціалізацій.

Для показника j величина d_{jci} є парною різницею запису i у кліпі c, а n_c – кількістю таких записів. Зважена за записами оцінка середнього ефекту дорівнює

$$\hat{\Delta}_j = \frac{\sum_c \sum_{i \in c} d_{jci}}{\sum_c n_c}. \tag{3.41}$$

Використовується B бутстреп-повторів. У повторі b повторно відбирається множина цілих кліпів C_b, після чого ефект обчислюється тією самою формулою:

$$\hat{\Delta}_j^{*(b)} = \frac{\sum_{c \in C_b} \sum_{i \in c} d_{jci}}{\sum_{c \in C_b} n_c}. \tag{3.42}$$

Для кожного показника середнє бутстреп-ефектів дорівнює $\bar{\Delta}_j^* = B^{-1} \sum_{b=1}^{B} \hat{\Delta}_j^{*(b)}$. Фіксована бутстреп-оцінка стандартної похибки має вигляд

$$\hat{s}_j^{\text{boot}} = \left[\frac{1}{B-1} \sum_{b=1}^{B} \left(\hat{\Delta}_j^{*(b)} - \bar{\Delta}_j^* \right)^2 \right]^{1/2}. \tag{3.43}$$

Для одночасного контролю зареєстрованої родини показників у кожному повторі береться найбільше відхилення, стандартизоване цією фіксованою оцінкою. Показник із нульовою бутстреп-похибкою не стандартизується й має бути позначений як вироджений, а не ділитися на нуль:

$$T_b^{max} = max_j \left| \frac{\hat{\Delta}_j^{*(b)} - \hat{\Delta}_j}{\hat{s}_j^{\text{boot}}} \right|. \tag{3.44}$$

Квантиль 0,95 розподілу T^{max} визначає одночасний інтервал для кожного показника:

$$\text{CI}_j^{\text{sim}} = \left[\hat{\Delta}_j - q_{0.95}(T^{max}) \hat{s}_j^{\text{boot}}, \hat{\Delta}_j + q_{0.95}(T^{max}) \hat{s}_j^{\text{boot}} \right]. \tag{3.45}$$

Вердикт визначається знаком одночасного інтервалу та заздалегідь заданим напрямом показника. Інтервал, що повністю лежить вище нуля,

підтримує зареєстрованого кандидата; інтервал повністю нижче нуля підтримує базову порівнювану конфігурацію. Перетин нуля залишає результат невирішеним. Реплікація за ініціалізаціями може посилити або обмежити цей вердикт, але тисячі кадрів у межах одного кліпу не створюють реплікації за ініціалізаціями навчання. Тому в розділі 4 кількість кліпів, записів і ініціалізацій моделі подано окремо.

Еквівалентність не виводиться лише з того, що інтервал перетинає нуль. Для цього потрібні обґрунтований найменший ефект, що становить інтерес, у власних одиницях показника та надійне вимірювання в межах цієї границі. Для центральної програми таку границю не було заморожено, тому «невирішено» означає саме невирішений результат. Негативні й змішані результати залишаються завершальними доказами, якщо задовольняють зареєстровані правила рішень; вони не виправдовують незапланований пошук сприятливішої популяції.

3.6 Методика дослідження структури ієрархічного контексту

Обсяг пам’яті, її розподіл, кількість масштабів і спосіб перекриття є різними чинниками. Їх послідовне дослідження пояснює, за яких умов ієрархія зберігає корисне свідчення та яку інформацію втрачає. Нижче спільний протокол пов’язано з окремими контрольованими порівняннями; результати цих порівнянь наведено в §4.8.

3.6.1 Дослідницькі питання та контрольовані чинники

Описані модель та інструменти задають п’ять груп експериментальних гіпотез. Їх сформульовано до відкриття відповідних результатів, тому спостережені ефекти не змінюють початкового напряму перевірки. Позначення H1–H5 збережено для простежуваності щодо зареєстрованої експериментальної програми.

H1, різниця досяжності. Довгий ієрархічний пакет порівнюється з коротшим плоским пакетом у специфічній для цієї пари смузі, де потрібне минуле доступне лише першому. Очікується додатний ефект кандидата, зосереджений між двома межами досяжності. Якщо перевага в цій популяції не

виникає, пояснення результату доступом до давнішої історії для відповідної пари послаблюється.

H2, відновлення точності відтворення. Зіставлені пари пакетів оцінюються в заздалегідь визначених точках токенного бюджету як одна родина одночасних порівнянь. За нижчих бюджетів очікується перевага ієрархії, тоді як після насичення досяжності детальний плоский контекст може відновити перевагу. Проміжна точка може залишитися невизначеною; результати між дослідженими бюджетами не інтерполюються.

H3, форма пакета. Часово розріджені детальні прив’язки зіставляються зі щільною грубою історією за майже однакового бюджету. Напрям вважається стабільним лише тоді, коли його підтримують незалежні ініціалізації та обидва вихідні модулі прогнозування. Зміна знака між цими умовами означає, що використання форми пакета залежить від моделі або траєкторії навчання.

H4, робастність. Основні зареєстровані контрасти повторюються для різних бюджетів і випадкових ініціалізацій алгоритму вибірки, а також для незалежно навченого кодека. Очікується збереження напрямів ефектів із явно наведеною статистичною точністю. Якщо окремий напрям зникає, чутливість локалізується на зміненому інтерфейсі й не переноситься на інші контрасти.

H5, межа самоподачі та зовнішня межа. Ранньо-пізні ефекти довгого розгортання перевіряються за повторними навчаннями, а окреме завдання з об’єктами сталої ідентичності оцінюється за п’ятьма об’єктними показниками. Надійна межа самоподачі потребує реплікації, тоді як просторове покриття може не збігатися з точністю збереження ідентичності. Негативний або змішаний результат зберігається як завершальний вердикт і не замінюється сприятливішою популяцією після аналізу даних.

Усі п’ять гіпотез є умовними. Вони визначають робочі області для конкретного замороженого кодека, сімейства предикторів і контрольованих завдань. Кілька ініціалізацій та захищені набори даних можуть посилити впевненість у висновку, але не перетворюють його на універсальне ранжування ієрархічних і плоских відеомоделей.

Гіпотези H1–H5 зберігають статус своїх зареєстрованих перевірок. Питання про бюджет, розподіл, підтримку, рівні й перекриття деталізують простір проєктування; їх пояснювальне формулювання не означає ретроспективної реєстрації гіпотез. Адаптивне членство та пам’ять активацій перевіряються за окремими контрактами §3.7.

3.6.2 Спільні умови навчання та оцінювання

Спільну тривалість навчання визначено до виконання основної матриці за двома калібрувальними конфігураціями з бюджетом 1 792 токени: плоским недавнім контекстом і збалансованою дворівневою ієрархією. Обидві моделі з ініціалізацією 0 навчалися до 30 000 оновлень, а фіксований валідаційний набір оцінювався через кожні 2 000 оновлень. Моделі мали однакові параметри, цільові кадри, розмір пакета, алгоритм оптимізації та вхідну довжину Transformer; змінювався лише розподіл контексту.

Порядок двох калібрувальних моделей за основною метрикою змінився між 12 000 і 16 000 оновлень: рання перевага однієї конфігурації не збереглася на пізніших зрізах. Це **зміна рангу кривих валідації**, а не операція в коді, перестановка токенів або реверсивне обчислення. Тому зріз 16 000 оновлень було відхилено як недостатній для остаточного зіставлення. Першим спільним зареєстрованим зрізом, що одночасно задовольнив двовідсотковий критерій близькості обох моделей до їхніх найкращих пізніших значень і зберіг порядок на завершальній ділянці, стали 30 000 оновлень. Усі 86 основних запусків навчаються до цього самого кроку без вибору різної ранньої зупинки для окремих конфігурацій.

Крок 30 000 задає спільний бюджет оптимізації, а не доведену збіжність: на кінці траєкторії немає пізніших значень для перевірки подальшого поліпшення. Для розвитку використано чотири фіксовані пакети по 16 вибірок із поверненням — 59 різних кліпів із 300. Ранжування та відкладена перевірка мають різні одиниці агрегації, визначені в §3.5.6; оцінки не об’єднуються лише тому, що обидві названо MSE.

3.6.3 Загальний бюджет і розподіл між рівнями

Місткість контексту (FRT).

Зростання якості зі збільшенням пам’яті саме по собі не пояснює користі ієрархії: додаткові токени може використати й плоске подання. Тому місткість і спосіб її використання потрібно розглядати разом. Бюджетний фронтир зіставляє політики на тих самих точках вартості, а не порівнює довільну довгу ієрархічну історію з довільним коротким вікном. Він перевіряє, чи залишається компроміс між досяжністю та точністю відтворення залежним від масштабу ресурсу.

Наприклад, 1 792 токени дозволяють зберегти 28 детальних часових позицій по 64 токени або 56 грубих позицій по 16 токенів і 896 детальних комірок. Другий пакет охоплює давнішу історію, але не відтворює її з однаковою просторовою точністю. Вкладені грубі та детальні представлення не слід рахувати як різні фізичні моменти. Перевага ієрархії узгоджуватиметься з корисністю такого обміну; перевага плоского пакета — з більшою цінністю деталей у відповідній задачі. Зміна знака між бюджетами чи ініціалізаціями потребує опису локальних умов, а не побудови універсальної точки переходу.

Сімейство фронтиру бюджету (A4-FRT) відповідає на питання, як змінюється якість зі збільшенням фізично упакованого стану і чи розширюють ієрархічні стратегії фронтир плоского недавнього контексту. Досліджуються шість бюджетів: 320, 768, 1 152, 1 792, 2 432 і 3 072 контекстні токени. Для кожного бюджету порівнюються три стратегії: плоска недавня історія, лінійний за віком розподіл деталей та геометричний за віком розподіл із фіксованим коефіцієнтом 0,94. Збалансована стратегія до цього фронтиру не входить і розглядається лише в рівнобюджетному сімействі §3.6.3.

За бюджету B плоска конфігурація зберігає $B/64$ повних детальних часових позицій. Кожна ієрархічна конфігурація витрачає половину бюджету на суцільну грубу основу — $B/32$ позицій по 16 токенів — і половину на $B/2$ вибраних детальних комірок. Лінійна й геометрична стратегії відрізняються лише часовим розташуванням цих комірок. Шість бюджетів і три стратегії утворюють 18 конфігурацій; за двох ініціалізацій це 36 навчальних запусків.

Основним поданням результату є залежність якості від виміряного збереженого стану з показом обох ініціалізацій, а досяжність подається окремою віссю інтерпретації.

Розподіл сталої місткості (ALC).

Бюджетний фронтир залишає відкритим питання, чи обраний поділ ресурсу між рівнями є вдалим. Однакова кількість токенів може відповідати дуже різній часовій підтримці та кількості докладно представлених моментів. Рівнобюджетний дослід розподілу тому відокремлює місткість пакета від його структури: за сталої вартості перевіряється, чи слід витрачати ресурс на грубу основу, недавні деталі або деталі різного віку.

Збалансований і геометричний пакети мають однакові 56 грубих позицій і 896 детальних комірок, проте розміщують деталі по-різному. Їхнє зіставлення інформативніше щодо вікового розкладу, ніж порівняння збалансованої політики з орієнтованою на досяжність, де змінюється також частка рівнів. Висновок формулюється для конкретної пари політик. Відсутність переваги складнішої структури є допустимим результатом: вона означає, що доступна модель не використала запропонований розподіл краще за простіший. Вибір опорної неплоскої політики для дослідів рівнів не перетворює її на переможця над плоскою.

Сімейство розподілу (A4-ALC) фіксує загальний бюджет на рівні 1 792 токенів і порівнює сім політик. Плоска політика містить 28 повних недавніх детальних позицій. Політика з перевагою деталей містить 28 грубих позицій і 21 повну недавню детальну позицію; збалансована — 56 грубих позицій і 896 детальних комірок, розміщених від найновіших; політика з перевагою грубого рівня — 84 грубі та сім повних детальних позицій. Лінійна й геометрична політики мають по 56 грубих позицій і 896 детальних комірок із відповідним віковим розподілом. Орієнтована на досяжність політика містить 96 грубих і чотири повні недавні детальні позиції.

Плоска, лінійна та геометрична політики тотожні відповідним конфігураціям фронтиру й повторно використовують шість уже навчених

моделей за двома ініціалізаціями. Для чотирьох інших політик виконуються вісім нових запусків. Переможець визначається лише на валідаційній вибірці за наперед заданим правилом для двох ініціалізацій. Якщо найкращою є плоска політика, вона зберігає статус наукового переможця; залежні досліди кількості рівнів і перекриття в такому разі використовують найкращу неплоску ієрархічну політику, оскільки лише для неї відповідні механізми визначені.

3.6.4 Часова підтримка та просторово-часова деталізація

Додавання грубої історії (CEX).

Рівнобюджетне порівняння змішує дві протилежні зміни: додавання давньої історії та вилучення деталей. Щоб з’ясувати, чи несе груба давня підтримка корисне свідчення взагалі, недавню детальну частину залишають незмінною. Далі додають лише грубі позиції за її межами. Така конструкція відповідає практичному питанню граничної користі додаткової пам’яті, а не питанню найкращого пакета за однакової вартості.

Перехід від нуля до чотирьох грубих позицій зберігає шість докладних кадрів і додає 64 токени; досяжність зростає з 6 до 10 моментів. Якщо помилка зменшується, це свідчить про корисність доступної додаткової інформації для цього предиктора. Якщо крива насичується, збільшення пам’яті може перестати бути виправданим. Якщо помилка зростає, можливі завади від грубих ознак або труднощі використання довшої послідовності. Жоден напрям не відокремлює автоматично інформаційний ефект від зміни обчислень, тому разом із якістю подається ресурсна ціна.

Сімейство розширення контексту (A4-CEX) утримує незмінними шість повних недавніх детальних позицій, або 384 детальні токени, й додає 0, 4, 8, 16, 32 або 64 грубі позиції. Груба підтримка є взаємовиключною щодо деталей і починається з віку 7, тому відповідні повні бюджети дорівнюють 384, 448, 512, 640, 896 і 1 408 токенів, а досяжність — 6, 10, 14, 22, 38 і 70 кадрів. Шість конфігурацій за двох ініціалізацій утворюють 12 запусків.

У цьому сімействі одночасно змінюються кількість контекстних токенів, довжина послідовності, обчислювальна робота, фізичний стан і досяжність.

Тому воно оцінює граничну користь додавання дедалі давнішої грубої історії та можливе насичення ефекту, але не є рівнобюджетним причинним контрастом. Поряд із якістю звітується приріст якості на доданий байт збереженого стану.

Розміщення сталої квоти деталей (STS).

Навіть за сталої часової підтримки грубого рівня деталі можна витрачати на небагато повних кадрів або на більше частково представлених моментів. Цей вибір важливий, коли точний вигляд об’єкта потрібний лише в окремих місцях, а його рух — у багатьох моментах. Дослід фіксує грубу основу та глобальну квоту деталей і змінює просторову повноту одного вибраного моменту разом із кількістю таких моментів.

Глобальні 256 детальних токенів можна розмістити як чотири позиції по 64 комірки або як 32 позиції по вісім комірок. Ці пакети мають однакову кількість деталей, але різну просторово-часову геометрію. Недавній, рівномірний і геометричний розклади перевіряють, чи важливе також розташування цих позицій за віком. Дослід не є перевіркою навчуваного маршрутизатора: членство задається планом. Стійка перевага певного розкладу характеризує використання заданої геометрії, тоді як змішані напрями вказують на залежність від конкретної щільності та віку деталей.

Сімейство просторово-часового розподілу (A4-STS) має єдиний загальний бюджет 1 792 токени. Повна груба основа з 96 часових позицій займає 1 536 токенів, а глобальна квота детального рівня становить 256 токенів. Локальна квота $K \in \{64,32,16,8\}$ визначає кількість детальних просторових комірок на вибрану часову позицію; відповідно, незмінна глобальна квота охоплює 4, 8, 16 або 32 часові позиції. Для кожного K порівнюються недавнє, рівномірне та геометричне розміщення, що дає 12 конфігурацій і 24 запуски.

Усередині вибраного часу комірки задаються детермінованою фазово-циклічною просторовою решіткою, вкладеною в повну грубу основу. Отже, це сімейство змінює просторове й часове розміщення сталої детальної квоти, але не використовує вміст кадру і не перевіряє навчуваний маршрутизатор §3.7.4. Його

роль полягає у встановленні межі між кількістю деталей на один момент і кількістю моментів із детальним представленням.

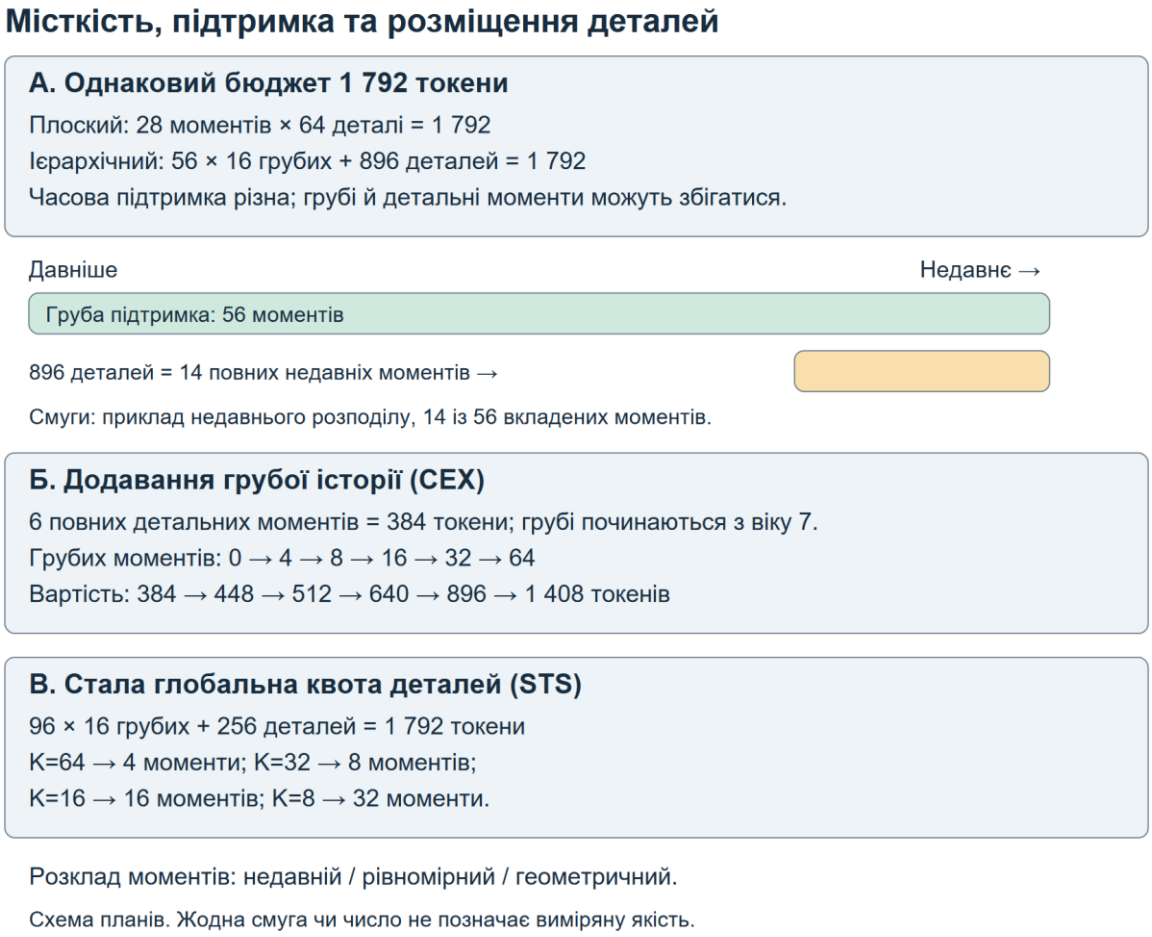


Рисунок 3.18 – Розподіл бюджету та часової підтримки. Кольори позначають рівень подання, а не якість прогнозу. Числа є арифметикою плану: у вкладених схемах грубі й детальні токени можуть стосуватися того самого моменту. Для CEX збільшуються і підтримка, і вартість; для STS стала глобальна квота перерозподіляється між просторовою повнотою та кількістю моментів. *Джерело: авторська схема за визначеннями контекстних пакетів.*

3.6.5 Глибина ієрархії та перекриття представлень

Кількість рівнів (LVL).

Два рівні задають лише один компроміс між точністю та охопленням. Додавання ще грубішого рівня дозволяє підтримати давню історію дешевшими ознаками, але витрачає частину бюджету, раніше доступного іншим рівням. Тому кількість рівнів не можна трактувати як безкоштовне збільшення виразності: за сталого бюджету вона змінює розподіл інформації.

Верхня сітка 2×2 для 96 моментів займає 384 токени, залишаючи 1 408 для грубого й детального рівнів. Конкретний залишковий розподіл визначається правилом залежності від опорної дворівневої політики, а не підбирається за

результатом трирівневої моделі. Якщо третій рівень допомагає, висновок стосується цього перерозподілу й предиктора. Якщо він не допомагає, додатковий масштаб міг втратити більше корисних деталей, ніж додати часової інформації. Один та два рівні повторно використовують контрольні точки, щоб зіставлення не вимагало зайвих навчань і не рахувало той самий доказ двічі.

Сімейство кількості рівнів (A4-LVL) зіставляє один, два і три рівні за бюджету 1 792 токени. Однорівнева модель є плоскою конфігурацією з 28 детальними позиціями; дворівнева — найкращою неплоскою політикою, вибраною в §3.6.3; обидві повторно використовують наявні контрольні точки. Трирівнева конфігурація додає повну верхню основу з 96 позицій сітки 2×2, що займає 384 токени. Решта 1 408 токенів розподіляється між грубим і детальним рівнями зі збереженням співвідношення вибраної дворівневої політики та детермінованим округленням до 16-токенних грубих слотів. Навчається лише пара нових трирівневих моделей.

Верхній потік є лише контекстним, тому чотирикадрова груба й детальна ціль та функція втрат не змінюються. Водночас трирівнева конструкція має 7 557 792 параметри проти 7 556 512 в одно- і дворівневих конструкціях, тобто на 1 280 параметрів більше. Через цю відмінність і зміну самого представлення сімейство трактується як порівняння зареєстрованих конструкцій, а не як ізольований скалярний ефект кількості рівнів.

Спільна часова підтримка (OVR).

Ієрархія визначає не лише масштаби, а й те, чи описують різні рівні один фізичний момент. Вкладене подання може давати взаємодоповнювальні ознаки або дублювати інформацію. Взаємовиключне звільняє місце для інших моментів. Залишкове намагається явно відокремити деталь від її грубої основи. Ці механізми потрібно описувати через фактичний вміст токена, а не лише через назву політики.

Для одного моменту вкладена схема зберігає грубу ознаку та звичайну деталь; залишкова — грубу ознаку та різницю проєкцій; взаємовиключна — деталь замість відповідної грубої підтримки. Звільнена місткість останньої схеми

використовується за визначеним планом. Отже, порівняння перевіряє пакет представлення цілком: одночасно можуть змінюватися часовий доступ і ознаки. Перевагу залишкової схеми не слід називати доказом меншої надлишковості без додаткової діагностики; достатній висновок — її емпірична доцільність за фіксованого бюджету. Несприятливий результат також зберігається, бо визначає межу відповідного кодування.

Сімейство перекриття (A4-OVR) порівнює вкладене, взаємовиключне й залишкове представлення за бюджету 1 792 токени та двох ініціалізацій. Вкладена схема одночасно зберігає звичайні грубі й детальні токени для вибраного фізичного часу. У взаємовиключній схемі детальні токени замінюють грубі на відповідних позиціях, а звільнений бюджет поширює грубу підтримку на інші часові позиції. Залишкова схема зберігає грубу основу, але детальний токен кодує різницю між проєкцією детального вмісту та проєкцією його грубого батьківського представлення в той самий момент.

Основу вибирають лише серед сумісних із цими операціями політик із перевагою деталей, збалансованої та з перевагою грубого рівня. Вкладена конфігурація повторно використовує відповідну модель із §3.6.3, а для взаємовиключного й залишкового режимів навчаються чотири нові моделі. Ці режими змінюють володіння часовими позиціями або семантику детального токена, а не лише бінарну ознаку «перекриття». Якщо через цілочисельну вартість слотів досяжність відрізняється на одну позицію, ця відмінність розкривається й результат не називається чистим ефектом перекриття.



Рисунок 3.19 – Масштаби та перекриття представлень. Верхня частина показує витрати рівнів за бюджету 1 792 токени; залишок трирівневого пакета залежить від опорної політики. Нижні частини порівнюють вміст одного фізичного моменту, а не числові результати: звичайні ознаки, заміну грубої підтримки деталями та різницю проєкцій. *Джерело: авторська схема методики LVL/OVR.*

3.6.6 Незалежна перевірка та діагностика механізму

Сума сімейств становить 49 показуваних комірок: 18 для фронтиру, сім для розподілу, шість для розширення контексту, три для кількості рівнів, три для перекриття й 12 для просторово-часового розподілу. Після повторного використання тотожних конфігурацій матриця містить 43 записи конфігурацій та 86 навчальних запусків за двома ініціалізаціями. Число записів не дорівнює числу незалежних семантичних конструкцій: ALC ReachOptimized і STS K64 Recent задають той самий упорядкований фізичний план. Такі виконання зберігаються в реєстрі, але рахуються як повтори; до розв’язання залежних комірок число різних конструкцій не перевищує 42. Два калібрувальні запуски з ініціалізацією 0 не входять до цих 86 і використовуються лише для обґрунтування тривалості навчання.

Усі рішення щодо ранжування, залежних конфігурацій і короткого списку моделей приймаються на валідаційній вибірці розроблення. Один контроль містить чотири пакети по 16 вибірок із поверненням: 64 звернення охоплюють 59 різних кліпів із 300 за фіксованих генераторів 710000–710003. Це не повний прохід валідаційної вибірки. Повторне оцінювання замороженого короткого списку на всіх 300 кліпах є діагностикою стійкості, а не новим правилом вибору. Після цього свіжий набір із 500 кліпів відкривається один раз лише для зафіксованого короткого списку. Для нього подаються результати на всіх чотирьох горизонтах, а також окремо для спільно визначених популяцій повторного входу та його відсутності. Повні ідентифікатори запусків, хеші конфігурацій, контрольних точок і маніфестів належать до реєстру відтворюваності; в основному тексті використовуються змістові назви сімейств і політик.

Обмежена діагностика механізму (A4-MEC) не навчає нових моделей. Для найкращої плоскої, найкращої ієрархічної та однієї наперед визначеної невдалої або слабшої конфігурації оцінюються обидві ініціалізації, тобто виконується шість проходів. Для одного зафіксованого кліпу й дифузійного часу 0,5 зберігаються нормована ентропія уваги та частка уваги до джерельних сегментів на кожному шарі. Це один прямий прохід денойзера, а не траєкторія DDIM, каузальна абляція давньої історії або самостійний доказ якості; його роль обмежується інтерпретацією вже встановлених результатів.

Валідаційний вибір відповідає на питання, яку конфігурацію перевіряти, але не встановлює її узагальнення. Відкладений протокол використовує 500 кліпів і три зареєстровані ролі: найкращу плоску, найкращу ієрархічну за бюджету 1 792 та ресурсно доцільну в межах п’ятивідсоткового допуску якості. Ролі можуть посилатися на ту саму модель; тоді контрольна точка оцінюється без удаваного збільшення числа незалежних моделей. Допуск відбору не є автоматично межею статистичної не-гіршості. Напрями парних різниць і невизначеність подаються за кожною ініціалізацією, оскільки повторний вибір кліпів не оцінює розкид між навчаннями.

Для перевірки покриття валідації не більш як три зафіксовані конфігурації за двома ініціалізаціями оцінюються на всіх 300 валідаційних кліпах. Це діагностика чутливості короткого списку, а не повторний вибір переможця чи незалежне підтвердження. Механізм аналізується для найкращої плоскої, найкращої ієрархічної та невдалої ієрархічної конфігурацій. Зіставлені приклади показують однакові кліпи й цілі, а правило добору явно відокремлює характер помилки від частоти її виникнення.

Перевірка рекурсивного розгортання потрібна лише для висновку про збереження ефекту за самоподачі. Вона використовує одну зафіксовану пару за двома ініціалізаціями та 100 фіксованих діагностичних кліпів; після спільного початкового контексту передбачені кадри повертаються в пам’ять без підміни еталоном. Одна траєкторія до 64 кадрів дає зрізи 4, 16, 32 і 64. Перед виконанням фіксуються генератор кліпів, початковий час, оновлення пакета й випадковість вибірки. Перевага на четвертому кадрі не гарантує переваги після накопичення помилок; за невиконання цього умовного досліду відповідний висновок залишається поза підтвердженою областю.

3.7 Ієрархічний предиктор з адаптивним пакуванням і реверсивним ядром

Дослідження структури контексту встановлює, як заданий пакет впливає на доступну інформацію. Для виконуваного предиктора потрібно також визначити, як цей пакет формується з кадрів, як за вмістом вибираються деталі та як обчислюються градієнти за обмеженої пам’яті. Сталі просторові області ізолюють працездатність компактного подання; адаптивний маршрут перевіряє інший спосіб членства; реверсивне ядро змінює збереження активацій. Ці механізми пов’язані спільним інтерфейсом, але кожний потребує власного контрольованого зіставлення.

3.7.1 Мета інтеграції та межа архітектури

Основне порівняння WindowDiT навмисно не змінювало часовий механізм, кодування простору або вихідний модуль одночасно з пакетом. Звідси випливає питання композиції: чи можуть компактний ієрархічний стан, нерівномірний просторово-часовий розподіл деталей та реверсивне зберігання активацій

співіснувати в одній виконуваній моделі. Її зовнішній контракт відповідає OpenSTL: тензор $(B, T_{\text{in}}, C, H, W)$ відображається у прогноз $(B, T_{\text{out}}, C, H, W)$. Мета інтеграції — перевірити коректність композиції, якість і фактичну пам'ять у зіставному протоколі, а не повторно довести межу «досяжність–точність відтворення».

Інтеграція не є механічним об'єднанням коду WindowDiT, TempVerseFormer і V-BLT. Від першої лінії вона успадковує явний поділ на грубий і детальний складники, від TempVerseFormer — принцип реконструкції активацій усередині обмеженої реверсивної межі, а від V-BLT — ідею локально-глобальної ієрархії та явної фізичної геометрії токена. Предиктор зі сталими ділянками перевіряє ці зв'язки за сталих областей, дисперсійних ваг і другопорядкового часового переходу. Модель з адаптивним пакуванням натомість фізично вилучає невибрані детальні токени, використовує неперервні Fourier-ознаки координат і реверсивний стек Transformer-блоків із незмінною прямою функцією.

Рисунок 3.20 показує межі прототипу. Звичайними диференційовними операціями залишаються кодування кадру, пакування та розпакування стану, піксельне зчитування й функція втрат. Реверсивною є лише повторювана часова композиція переходу зі станом сталої ширини.



Рисунок 3.20 – Межі інтегрованого прототипу для перевірки технічної здійсненності.

3.7.2 Предиктор зі сталими просторовими областями

Кожний кадр кодується у ті самі карти $z_t^{\mathrm{c}} \in \mathbb{R}^{16\times4\times4}$ і $z_t^{\mathrm{f}} \in \mathbb{R}^{16\times8\times8}$. Груба карта дає 16 токенів. Детальна сітка розбивається на вісім незмінних областей R_r за схемою 2×4; кожна область містить вісім комірок 8×8. Належність комірки до області не змінюється між кадрами.

Усередині області просторова дисперсія визначає лише м'яку вагу. Для детальної комірки $k \in R_r$ з вектором $z_{t,k}^{\mathrm{f}}$ оцінка $d_{t,r,k} = Var_c(z_{t,k,c}^{\mathrm{f}})$ є дисперсією за 16 каналами. За температури $\tau_d > 0$ нормована вага дорівнює

$$w_{t,r,k} = \frac{\exp(d_{t,r,k}/\tau_d)}{\sum_{j\in R_r}\exp(d_{t,r,j}/\tau_d)}. \tag{3.46}$$

Для кожної з восьми областей, $r = 1, \dots, 8$, регіональний опис поєднує звичайне середнє та зважене значення, після чого навчена проєкція E_r повертає його до 16 координат:

$$g_{t,r} = E_r\left(\frac{1}{|R_r|}\sum\nolimits_{k\in R_r} z_{t,k}^{\mathrm{f}} \,\|\, \sum\nolimits_{k\in R_r} w_{t,r,k}\, z_{t,k}^{\mathrm{f}}\right). \tag{3.47}$$

Отже, збережений стан кадру містить 16 грубих токенів і вісім детальних регіональних токенів, по 16 скалярних значень у кожному:

$$\Xi_t = Pack(x_t) \in \mathbb{R}^{24\times16}. \tag{3.48}$$

Стан Ξ_t містить $24 \cdot 16 = 384$ скалярні значення. Після пакування вихідні 64 детальні комірки можуть бути звільнені. Порівняно з необробленим кадром 64×64 відношення корисного навантаження становить $4096/384 = 10{,}67$; порівняно зі щільним одночасним зберіганням грубої й детальної карт — $1280/384 = 3{,}33$.

Ці коефіцієнти описують лише корисне навантаження за однакової числової точності. Вони не є коефіцієнтами повної VRAM і не перемножуються автоматично з виграшем реверсивного зворотного проходу. Для проєктного 48-кадрового контексту стан містив би $48 \cdot 24 = 1152$ токени. Фактичний тест якості нижче використовує протокол 10 вхідних і 10 прогнозованих кадрів, тобто 240 вхідних токенів; він не підтверджує 48-кадрової досяжності.

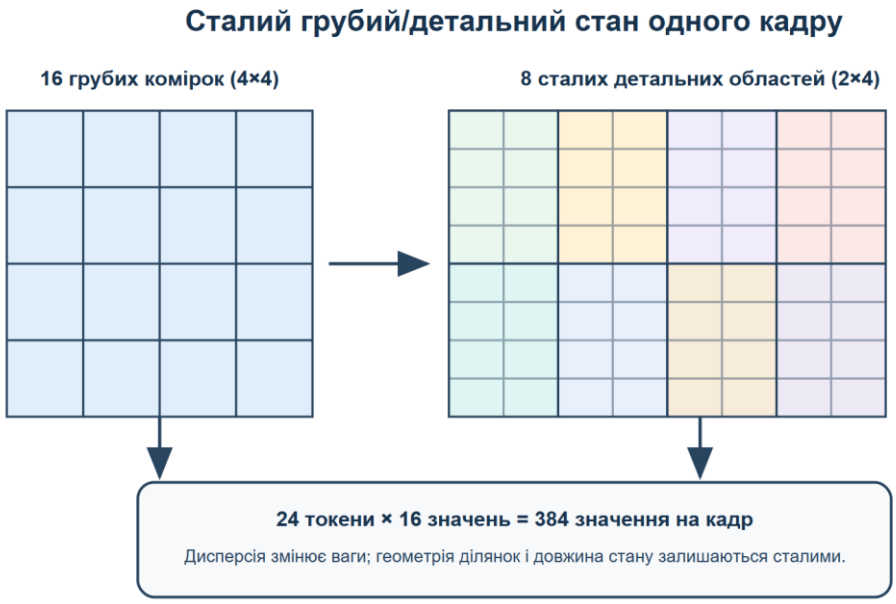


Рисунок 3.21 – Сталий поділ кадру на 16 грубих комірок і вісім детальних регіонів. Усередині регіону змінюються ваги, але не належність комірок і не довжина стану.

Межі компонентів випливають безпосередньо з наведеного контракту. Груба сітка зберігає глобальну основу у 16 токенах, але не гарантує ідентичності; вісім детальних областей залежать від усіх своїх комірок, однак не реалізують динамічного поділу. Пакувальник стискає кадр до 384 значень із втратами реконструкції, а SimVP-сумісний регресійний перехід не є ні WindowDiT, ні дифузійною вибіркою. Реверсивною є лише повторювана часова композиція, а не пакування, зчитування чи функція втрат. Відповідні програмні компоненти й тести наведено в таблиці Ж.2.

Отже, стала ширина визначає формат часового стану, тоді як реверсивність визначає спосіб проходження градієнта крізь повторюваний перехід; жодна з цих властивостей не робить просторове відновлення безвтратним.

Регресійний перехід і реверсивне розгортання прототипу зі сталими ділянками.

Нехай $\boldsymbol{\Xi} \in \mathbb{R}^{N_w \times 24 \times 16}$ є вікном із N_w упакованих кадрових станів. Однопрохідний перехід F_θ спочатку відновлює це відеовікно, застосовує піксельний SimVP-сумісний предиктор і пакує прогноз назад у той самий формат:

$$F_\theta(\boldsymbol{\Xi}) = Pack\big(Predictor_\theta(Unpack(\boldsymbol{\Xi}))\big) \in \mathbb{R}^{N_w \times 24 \times 16}. \quad (3.49)$$

Однакова форма входу й виходу дає змогу застосувати оборотний другопорядковий крок до пари станів (P_k, Q_k). Спочатку перший компонент наступної пари отримує попередній другий компонент:

$$P_{k+1} = Q_k. \tag{3.50}$$

Другий компонент поєднує попередній перший компонент із прогнозом переходу:

$$Q_{k+1} = P_k + F_\theta(Q_k). \tag{3.51}$$

Попередню пару можна точно відновити в межах числової точності. Спочатку відновлюється Q_k:

$$Q_k = P_{k+1}. \tag{3.52}$$

Після підстановки відновленого $Q_k = P_{k+1}$ отримуємо P_k:

$$P_k = Q_{k+1} - F_\theta(P_{k+1}). \tag{3.53}$$

Для першого кроку використовується $P_0 = 0$, тому $Q_1 = F_\theta(Q_0)$ і однокроковий прогноз не змінюється через реверсивну оболонку. Під час зворотного проходу локальний граф переходу відтворюється по одному кроку, а не зберігається для всієї часової послідовності. Однаковий модуль F_θ не означає однакової зовнішньої динаміки: вже $Q_2 = Q_0 + F_\theta(Q_1)$, тоді як звичайне повторне прогнозування дає $F_\theta(Q_1)$. Тому цей історичний прототип порівнює різні рекурентні схеми; його відношення пам’яті 2,58 є описовим інженерним результатом. Порівняння тотожної прямої функції зі зміною лише збереження активацій стосується внутрішнього ядра §3.7.6.

Протокол перевірки та допустимі висновки для прототипу зі сталими ділянками.

Якість оцінюється на канонічному Moving-MNIST за протоколом OpenSTL 10→10 і повному тестовому наборі з 10 000 кліпів. Порівняння охоплює відібраний предиктор упакованого стану, заморожений варіант з адаптером, локально відтворений SimVP-gSTA без пакування та опубліковані рядки ConvLSTM-S, E3D-LSTM, SimVP-IncepU і TAU [1, 137, 141, 153]. Зовнішні рядки не є апаратно зіставленими вимірюваннями пам’яті; їхня роль – межа прогнозної компетентності.

Пам’ять профілюється двома способами. Перший описово зіставляє реверсивну оболонку та звичайний BPTT на 10, 20 і 40 прогнозованих кадрах за спільного модуля переходу, але різних рекурентних схем. Другий зіставляє локальні профілі кількох моделей OpenSTL за розміру мініпакета 2 і 20 кадрів, але інтерпретується описово через відмінності реалізацій. Результати належать до однієї ініціалізації навчання й класу «перевірка технічної здійсненності на етапі розроблення». Вони можуть підтвердити технічну композиційність і конкретний виміряний компроміс, але не робастність за кількома ініціалізаціями, 48-кадрову досяжність, природне відео або загальне лідерство.

Перший прототип із динамічним жорстким вибором K найінформативніших областей залишив повні детальні карти для повторної маршрутизації й збільшив частину хибнопозитивних помилок. Тому він не став основою твердження. У головному тексті цей результат потрібний лише для пояснення переходу до фіксованих областей; повні діагностичні дані винесено до додатка Е.

3.7.3 Ієрархічна піраміда та фізично упакований стан

Інтегрована модель з адаптивним пакуванням застосовує спільний згортковий кодувальник до всіх T_{in} спостережуваних кадрів. Перший вихід має крок 4 відносно піксельної сітки й утворює детальні кандидати $Z^{\text{f}} \in \mathbb{R}^{B\times T_{\text{in}}\times d\times H/4\times W/4}$. Наступний згортковий етап із кроком 2 утворює грубу карту $Z^{\text{c}} \in \mathbb{R}^{B\times T_{\text{in}}\times d\times H/8\times W/8}$. Усі грубі комірки зберігаються, тоді як із просторово-часового об’єму детальних кандидатів вибирається стала глобальна квота K.

Вибір виконується реальною операцією gather: до Transformer надходять лише $T_{\text{in}}HW/64$ грубих токенів і K детальних токенів, а не повна детальна карта з нульовими вагами. Разом із ними фізично зберігаються п’ять неперервних координат, категоріальний рівень, індекси та оцінки вибраного маршруту. Тому аналітичний коефіцієнт токенів порівнює послідовності на вході Transformer, а повний живий стан додатково враховує метадані маршрутизації. Повний живий стан також містить грубу сітку, з якої декодер читає останній кадр; під час навчання граф щільного кодувальника зберігається для зворотного проходу.

Логічні байти тензорів, байти унікальних сховищ і піки алокатора вимірюють окремо з фактичними типами даних. Загальну будову показано на рисунку 3.22.

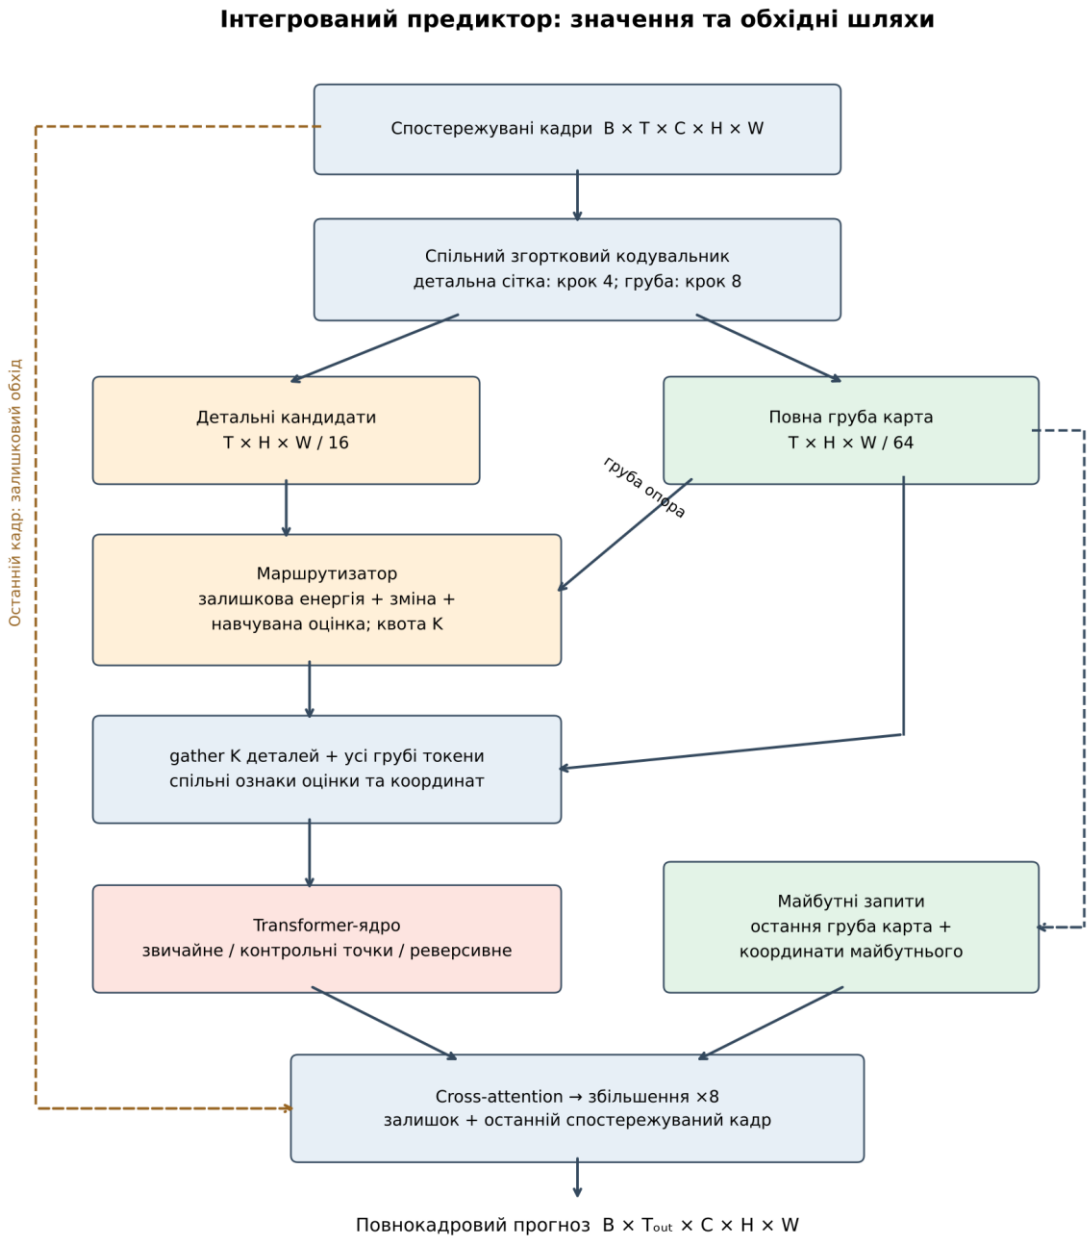


Рисунок 3.22 – Інтегрована архітектура з повним грубим покриттям, фізичним вибором сталої квоти деталей, координатним кодуванням, внутрішньо реверсивним Transformer-ядром і декодером майбутнього. Реверсивна межа охоплює лише стек Transformer-блоків; кодувальник, маршрутизатор, позиційне кодування та декодер залишаються звичайними диференційовними модулями.

Таблиця 3.4 – Тензорний контракт інтегрованої моделі та двох зовнішніх протоколів. Наведені відношення стосуються кількості токенів на вході Transformer, а не повної пам’яті GPU.

Етап	**Загальна форма**	**Moving MNIST 10→10,** 64×64**,** $K = 160$	**TaxiBJ 4→4,** 32×32**,** $K = 16$
Вхідні кадри	$B \times T_{\text{in}} \times C \times H \times W$	$B \times 10 \times 1 \times 64 \times 64$	$B \times 4 \times 2 \times 32 \times 32$
Детальні кандидати	$B \times T_{\text{in}} \times d \times H/4 \times W/4$	2 560 токенів	256 токенів

Етап	**Загальна форма**	**Moving MNIST 10→10,** 64×64**,** $K = 160$	**TaxiBJ 4→4,** 32×32**,** $K = 16$
Повне грубе покриття	$B \times T_{\text{in}} \times d \times H/8 \times W/8$	640 токенів	64 токени
Відібрані деталі	$B \times K \times d$	160 токенів	16 токенів
Запакована пам'ять Transformer	$B \times (T_{\text{in}}HW/64 + K) \times d$	800 токенів	80 токенів
Грубі майбутні запити	$B \times T_{\text{out}}HW/64 \times d$	640 запитів	64 запити
Вихід	$B \times T_{\text{out}} \times C \times H \times W$	$B \times 10 \times 1 \times 64 \times 64$	$B \times 4 \times 2 \times 32 \times 32$

Для обох зафіксованих конфігурацій повна детальна послідовність у 3,2 раза довша за запаковану: $2560/800 = 256/80 = 3{,}2$. Це відношення не включає майбутні запити, метадані, параметри, активації, стан оптимізатора або робочий простір CUDA, тому не подається як 3,2-кратне скорочення повної пам'яті.

3.7.4 Динамічна маршрутизація деталей

Для детальної комірки k у момент t обчислюються рівно три числові складові. Перша є квадратичною енергією різниці між детальним вектором та білінійно збільшеним грубим представленням у тій самій комірці. Друга є середньою абсолютною зміною детального вектора відносно попереднього кадру; для першого кадру вона дорівнює нулю через повторення його самого як попереднього. Третя є скалярним виходом навчуваної мережі g_ϕ, що отримує детальний вміст. Оператор Std віднімає середнє й ділить на стандартне відхилення за всіма детальними кандидатами одного прикладу, обмежене знизу значенням 10^{-6}. Підсумкова оцінка має вигляд

$$s_{t,k} = \lambda_r Std\left(\frac{\|z^{\text{f}}_{t,k} - Up(z^{\text{c}}_t)_k\|_2^2}{d}\right) + \lambda_\Delta Std\left(\frac{\|z^{\text{f}}_{t,k} - z^{\text{f}}_{t-1,k}\|_1}{d}\right) + \lambda_g Std\left(g_\phi(z^{\text{f}}_{t,k})\right). \quad (3.54)$$

Окремого четвертого ненавчуваного «скору вмісту» реалізація не має. За мінімальної квоти m на кожен кадр множина індексів вибору визначається як

$$\mathcal{I}^\star \in argmax_{\mathcal{I}} \sum_{(t,k)\in\mathcal{I}} s_{t,k}\,, |\mathcal{I}| = K, |\mathcal{I} \cap \{(t,k): k = 1, \dots, N_f\}| \geq m \forall t. \quad (3.55)$$

Задача (3.55) допустима лише за $0 \leq m \leq N_f$ та $T_{\text{in}}m \leq K \leq T_{\text{in}}N_f$; недопустимі квоти реалізація відхиляє. Наприклад, за двох кадрів і $m = 1$ квота $K = 1$ недопустима, а $K = 4$ допустима. За однакових оцінок перевагу має

менший фізичний індекс. У програмній реалізації спочатку вибираються m найкращих комірок кожного кадру, після чого решта глобальної квоти заповнюється операцією top-k серед усіх невибраних просторово-часових кандидатів. Індекси top-k є недиференційовними. Щоб навчувана складова отримувала градієнт на фактично вибраному шляху, відібране значення повної тричленної оцінки $s_{t,k}$ в усіх режимах членства проходить однакове навчуване вбудовування і додається до відповідного детального токена. Це не робить дискретне членство диференційовним, але пов'язує оцінки вибраних елементів із функцією втрат.

Передбачено чотири режими членства. static детерміновано бере середини рівних інтервалів глобально сплощеного просторово-часового списку. density ранжує суму перших двох членів (3.54), а hybrid використовує всі три. mixed під час навчання вибирає для цілого пакета static або hybrid, причому ймовірність динамічного шляху дорівнює 0,75; під час оцінювання він однозначно переходить у hybrid. Отже, модель ознайомлюється з обома типами членства під час оптимізації. У виправленому інтерфейсі static, density та hybrid отримують однакові ознаки оцінки; змінюється правило вибору, а не наявність додаткового вбудовування. Для повної квоти їхні токени збігаються. Мінімальна квота (3.55) задає обмеження адаптивного вибору; рівномірний статичний розклад за допустимого K також забезпечує щонайменше m комірок на кадр. Увімкнення динамічного маршруту лише після суто статичного навчання не вважається гарантовано коректним і потребує окремого тесту перемикання.

Стабільність маршруту оцінюється за ентропією розподілу оцінок, глобальним розривом між K-м і $(K+1)$-м значеннями впорядкованої оцінки без квотних обмежень, мінімальною та максимальною кількістю деталей на кадр, часовим і просторовим покриттям, а також зміною членства між сусідніми кадрами через доповнення індексу Жаккара. Глобальний розрив не є межею фактичного вибору за обмеженням (3.55); для повної квоти він неінформативний. Ці діагностики виявляють коливання або концентрацію маршруту, але не є самостійними показниками якості прогнозу.

3.7.5 Фізичне позиційне кодування

Номер токена у запакованій послідовності залежить від маршруту й не може бути його просторово-часовою координатою. Для кожної фізичної комірки формується вектор $q = (x, y, \tau, s_x, s_y)$: дві координати центра, підписаний час і два компоненти масштабу. За частот $\omega_j = 2^j$, $j = 0, \dots, F-1$, неперервне позиційне вбудовування визначається як

$$p(q, \ell) = W_p[\sin(\pi\omega_0 q), \cos(\pi\omega_0 q), \dots, \sin(\pi\omega_{F-1} q), \cos(\pi\omega_{F-1} q)] + e_{\text{level}}(\ell). \quad (3.56)$$

Для комірки (r, c) сітки $h \times w$ використовуються центри $x = (c + 1/2)/w$ і $y = (r + 1/2)/h$, а масштаб дорівнює $(s_x, s_y) = (1/w, 1/h)$. Останній спостережуваний кадр має час 0, давніші кадри — послідовні від'ємні значення, майбутні запити — додатні значення від 1; усі вони діляться на $max(T_{\text{in}}, T_{\text{out}}, 1)$. Рівні кодуються окремим навчуваним категоріальним вбудовуванням: coarse = 0, fine = 1, future-query = 2. Отже, масштаб входить до неперервних Fourier-ознак, а рівень не трактується як ще одна геометрична координата.

Операція вибору переносить метадані разом із токенами. За будь-якої спільної перестановки токенів та їхніх метаданих позиційні ознаки мають переставлятися так само, а декодований результат — залишатися незмінним у межах числового допуску. Для fp32 застосовуються допуски порядку 10^{-6} для прямого результату та $10^{-5} - 10^{-4}$ для градієнтів; для фактичного змішаного bfloat16 допускаються відхилення порядку 10^{-3} – 10^{-2} . Перестановочна інваріантність підтверджує відсутність залежності від номера запакованого слота, але не доводить, що маршрут є оптимальним.

3.7.6 Внутрішньо реверсивне ядро й декодер майбутнього

Запаковані токени з позиційними ознаками надходять до стеку Transformer-блоків. Кожний блок розділяє ширину ознак навпіл і використовує адитивне зв'язування з увагою F_θ та MLP G_θ. Пряме й обернене перетворення згруповано в одній рівності:

$$y_1 \& = x_1 + F_\theta(x_2), \& y_2 \& = x_2 + G_\theta(y_1), , x_2 \& = y_2 - G_\theta(y_1), \& x_1 \& = y_1 - F_\theta(x_2). \quad (3.57)$$

У звичайному режимі застосовуються ті самі блоки з автоматичним диференціюванням і збереженням проміжних активацій. У реверсивному режимі

прямий прохід не зберігає внутрішні стани стеку, а зворотний послідовно відновлює їх за (3.57) і перебудовує локальні графи. Тому обидва режими мають збігатися за прогнозом, функцією втрат і градієнтами за однакових параметрів та стохастичних умов. Кодувальник, маршрутизатор, Fourier-проєкція, майбутні запити, cross-attention і піксельний декодер перебувають поза реверсивною межею.

Для кожного з T_{out} майбутніх кадрів створюється повна груба сітка запитів розміру $H/8 \times W/8$ з рівнем future-query = 2 та додатним фізичним часом. Початковий вміст запиту утворюється проєкцією останньої грубої карти й навчуваним вектором; кілька блоків cross-attention зчитують запаковану пам'ять. Після просторового відновлення три послідовні двократні збільшення роздільної здатності формують повнокадровий залишок, що додається до останнього спостережуваного кадру:

$$\hat{X}_{1:T_{\text{out}}} = X_{T_{\text{in}}} + D_{\psi}\left(CrossAttn(Q^{+}_{1:T_{\text{out}}}, H_{\text{packed}})\right). \quad (3.58)$$

Формула (3.58) задає детермінований однопрохідний прогноз, сумісний із функціями втрат OpenSTL. Вона не є дифузійною вибіркою WindowDiT і не використовує еталонні майбутні кадри як контекст.

3.7.7 Протокол перевірки коректності, ресурсів і якості

Перевірка маршрутизатора охоплює точну глобальну квоту, унікальність індексів, мінімальне покриття кожного кадру, потрапляння навмисно зміненої комірки до динамічного маршруту та скінченний ненульовий градієнт у параметрах навчуваної оцінки за ненульової вихідної проєкції декодера. Окремий тест переставляє запаковані токени разом із метаданими й перевіряє незмінність виходу декодера. Числовий контракт координат перевіряється на CPU окремо для форм Moving MNIST і TaxiBJ: центри та масштаби мають відповідати §3.7.5, минулий час завершуватися нулем, майбутній починатися з одиниці до нормування, а індекси рівнів дорівнювати 0, 1 і 2. Цей тест доповнює, але не замінює перестановочну перевірку.

Для реверсивного ядра перевіряються реконструкція входу, рівність звичайного й реверсивного прямих виходів, градієнтів входу та всіх параметрів у

fp32, а також окремий допуск для CPU bfloat16. Наскрізний малий тест повторює паритет для всього активного тракту з ненульовою вихідною проєкцією; окремий негативний контроль пошкоджує пам’ять і вимагає зміни прогнозу. Нульова проєкція перевіряється лише як ініціалізація копіювання останнього кадру. Контракт OpenSTL перевіряє прямий і зворотний проходи для форм $10 \times 1 \times 64 \times 64$ та $4 \times 2 \times 32 \times 32$, реєстрацію методу, кроки навчання й валідації, конфігурацію оптимізатора та повне відновлення стану з контрольної точки.

Перед основними GPU-запусками протокол додатково вимагає паритету звичайного й реверсивного режимів на CUDA у фактичній змішаній точності та профілювання пікової пам’яті. Тестова узгодженість встановлює коректність інтерфейсів і числову близькість реалізацій; вона не доводить конкурентної якості, корисності маршруту або виграшу повної GPU-пам’яті. Останні твердження потребують окремих вимірювань у розділі 4.

Статичні плани встановлюють, як модель використовує задану геометрію контексту. Навчувана політика ставить інше питання: чи можна розміщувати ту саму квоту деталей відповідно до вмісту. При цьому кількість відібраних токенів не зменшується. Тому перевірка маршрутизації має відокремлювати зміну членства від зміни ознак, а перевірка ресурсів — логічний пакет від повного живого стану. Спільна груба обхідна карта, індекси й метадані зберігаються в обліку.

Числова перевірка порівнює звичайне обчислення, контрольні точки активацій і реверсивне відтворення з тими самими вагами та входами. Ненульова вихідна проєкція потрібна, щоб тест не вироджувався в копіювання останнього кадру. Оцінюються вихід, градієнт входу та градієнти іменованих параметрів; навмисне пошкодження пам’яті повинно змінювати прогноз. CPU-перевірка інтерфейсу не замінює CUDA-перевірки в точності фактичного навчання. Для кожного режиму фіксуються абсолютний і відносний допуски та максимальні розбіжності.

Ресурсний протокол вимірює обидві форми задач, повний розмір пакета та точність. Застосування й навчальний крок з оптимізатором профілюються окремо; звичайне, статичне ієрархічне й адаптивне пакування зіставляються з трьома режимами ядра. Ваги не змінюються під час повторів, а стан оптимізатора створюється однаково. Абсолютний і додатковий піки виділеної та резервованої пам’яті, збережені для диференціювання тензори, унікальні сховища й медіанний час мають різний зміст. Менший обсяг активацій ядра може співіснувати з малим виграшем повної моделі через енкодер і декодер; такий результат не є суперечністю. Синтетичні входи придатні для цього профілю, але не для висновку про прогнозну якість.

Перед повними навчаннями виконуються не більш як чотири обмежені траєкторії: адаптивна модель на Moving MNIST і TaxiBJ та плоский і статичний ієрархічний контролі на Moving MNIST. Однакові короткі бюджети, ініціалізація та політика ознак дозволяють перевірити працездатність і виміряти швидкодію. Вони не є підтверджувальною абляцією кінцевої якості. Виявлена нестабільність зупиняє наступний етап до встановлення причини; вдалий короткий результат не є підставою для розширення пошуку архітектур.

Повна перевірка прогнозу охоплює чотири навчання: Moving MNIST 10→10 та TaxiBJ 4→4, по дві ініціалізації. Розбиття, нормалізація, точність, тривалість і правило вибору контрольної точки фіксуються до відкриття тесту після вимірювання вартості коротких траєкторій. Для Moving MNIST потрібні помилки за горизонтами й зображення рухомих об’єктів; для TaxiBJ — показники в задекларованому масштабі та зіставлення каналів транспортного потоку. Короткі вікна цих задач перевіряють працездатність композиції, а не довготривалу досяжність TRB.

Сильніше твердження про перевагу якості потребує сумісного компаратора з тим самим протоколом. Спочатку перевіряється можливість використати незалежно вибрану контрольну точку. Якщо її немає, висновок обмежується працездатністю, а додаткове навчання базової моделі не вважається автоматичною частиною програми. Числовий паритет дає змогу профілювати

різні режими диференціювання без окремого навчання кожного як іншої прогнозної архітектури.

Таблиця 3.5 – Принципи побудови ієрархічного предиктора. Концептуальна спадкоємність не означає буквального перенесення опублікованих модулів або спільного експериментального підтвердження.

Основа	**Успадкований принцип**	**Реалізація предиктора**	**Межа доказів**
TRB і дослідження пакетів	явний бюджет збереженого контексту	повна груба основа та фізично вибрана квота деталей	FRT перевіряє статичні плани; навчуваний маршрут є окремою перевіркою
TempVerseFormer	відтворення активацій через адитивну оборотність	внутрішні Transformer-блоки з однаковою прямою функцією у трьох режимах	часовий рекурентний модуль не переноситься буквально; повний CUDA-профіль наведено в §4.9.4; окремі операції ядра не виміряні
V-BLT і просторові координати	локально-глобальне представлення та збереження фізичної адреси	згорткова піраміда, Fourier-координати, залишково-часова й навчувана оцінка	це не байтова ціль, не RoPE-ND і не ентропійний маршрутизатор V-BLT

3.8 Висновки до розділу

У розділі 3 збережений контекст розглядається як явно визначена змінна моделі, а не неформальна архітектурна одиниця. Пакет задається рівнями представлення, часовими кроками, збереженими позиціями та геометрією прив’язок. Контекстні, цільові й загальні токени рахуються окремо. Досяжність визначає, які минулі спостереження можуть увійти до прогнозу, а точність відтворення описує релевантну до завдання інформацію, що збереглася після представлення й формування вибірки. Звідси випливає умовне очікування: ієрархія може допомагати там, де декомпозиція та ущільнення інформації в грубих шарах дають змогу вмістити релевантне минуле. Щільний детальний контекст здатний відновити перевагу, коли обидва пакети досягають події, а обмежувальним чинником стає деталізація.

Реалізований центральний предиктор використовує заморожений дворівневий кодувальний інтерфейс, спільну увагу для контекстних і цільових токенів та окремі виходи грубого й детального рівнів. Чотирикадрове вікно є одиницею оновлення буфера. Граф градієнта не проходить через попередні

вікна, тому довгий горизонт формується повторним застосуванням моделі, а не наскрізним багатовіконним навчанням. Це зберігає чистоту порівняння пакетів.

Методична частина пов’язує архітектуру з перевірним механізмом TRB, що надає точну історію видимості. Для кожної контрольованої пари пакетів будується власна множина випадків із різницею досяжності, де показники окремо штрафують пропущений і зайвий передній план, втрату ідентичності та похибку траєкторії. Структурна матриця використовує спільну маску підтвердження відносно 96 спостережуваних і 28 недавніх кадрів. Повторна вибірка на рівні кліпів зберігає залежність кадрів одного розгортання, а незалежні навчання залишаються окремим рівнем невизначеності.

Перевірка технічної здійсненності використовує предиктор зі сталими ділянками. Він зберігав 384 скалярні значення на кадр у сталих грубих і детальних областях, застосовував однопрохідний перехід і відтворював проміжні стани другопорядкової рекуренції. Цей результат не змінює доказової ролі основного дослідження й збережений як окрема вихідна точка.

Матриця структурних порівнянь систематично змінює шість складників: загальний бюджет, розподіл токенів між рівнями, довжину грубої історії за незмінного детального хвоста, кількість рівнів, семантику перекриття та просторово-часове розташування сталої квоти деталей. Після повторного використання тотожних комірок вона містить 43 записи конфігурацій із семантичними повторами й 86 навчань із двома ініціалізаціями, усі на спільному зрізі 30 000 оновлень. TRB є єдиним набором цієї матриці; довготривалий Moving-MNIST не розширюється новими запусками, а зберігається як окрема перевірка межі.

Архітектура з адаптивним пакуванням доповнює дослідження сталих регіонів фізичним збиранням повної грубої основи й сталої глобальної квоти детальних комірок. Тричленний маршрутизатор, неперервні фізичні координати, внутрішньо реверсивний Transformer і cross-attention-декодер утворюють один OpenSTL-сумісний тракт; при цьому реверсивною є лише межа Transformer-ядра. Визначені перевірки встановлюють коректність квоти, позиційної

інваріантності, реконструкції, градієнтів і форм тензорів, але не передбачають результатів якості чи GPU-пам’яті. Після фіксації інтерфейсів і оцінюваних ефектів розділ 4 послідовно зіставляє досяжність, структуру пакета, прогнозну якість та ресурсну вартість; висновки залежать від статусу відповідних вимірювань.

РОЗДІЛ 4 – ЕКСПЕРИМЕНТАЛЬНА ВАЛІДАЦІЯ ТА ВИЗНАЧЕННЯ РОБОЧОЇ ОБЛАСТІ

У цьому розділі викладено завершальні докази дослідження ієрархічного контексту, що становить основу рукопису [136]. Виклад підпорядковано дослідницьким питанням і рівням доказовості, а не хронології експериментів. Оскільки модель із розділу 3 залежить від конкретних проєктних рішень, експерименти перевіряють не лише розмір пакета, а й механізм генерації, користь довшої історії, ціну просторової деталізації та робастність висновків до інших джерел варіативності. Структурна матриця контекстів поглиблює цю постановку вздовж осей загального бюджету, розподілу між рівнями, розширення грубого контексту, кількості рівнів, перекриття та просторово-часового розміщення детальної квоти; її протокол відокремлено від наявних E2–E8, щоб не змішувати різні популяції й режими статистичного виведення.

Основний підсумок можна сформулювати одним реченням: ієрархія забезпечує досяжність, коли релевантна історія інакше була б недоступною, тоді як плоский контекст зберігає точність відтворення, коли потрібний часовий інтервал уже доступний. Це твердження стосується виміряних робочих областей, а не загального ранжування архітектур.

4.1 Експериментальна карта та правила порівняння

Розділ починається з правил читання доказів, а не з окремих чисел. Цей підрозділ пов’язує дослідницькі питання з експериментальними програмами, розмежовує розроблення, підтвердження, робастність і зовнішні межі, а також установлює єдину орієнтацію знаків та словник бюджетів для подальших порівнянь.

4.1.1 Дослідницькі питання, набори даних та рівні доказовості

Послідовність початкових експериментів визначено чотирма питаннями. Перше стосується механізму генерації: чи дає стохастичний дифузійний вихідний модуль корисну перевагу над прямою регресією та чи придатний енергетичний спуск як альтернатива у доступному масштабі? Друге питання перевіряє, чи покращує прогнозування довша доступна історія саме для тих

записів, де вона потрібна. Третє з’ясовує, чи змінюється порядок методів після того, як плоске вікно наближається до тієї самої часової протяжності й зберігає повну просторову деталізацію. Четверте питання визначає межі висновків: чи зберігаються основні напрями ефектів для різних ініціалізацій навчання, параметрів генератора, незалежно навченого кодека та задачі з об’єктами, ідентичність яких простежується в часі.

Матриця структурних порівнянь ставить п’ять додаткових питань. По-перше, який спільний фіксований бюджет навчання зменшує ризик раннього хибного ранжування конфігурацій? По-друге, як змінюється компроміс «досяжність–точність відтворення» на широкій числовій шкалі бюджетів? По-третє, як за сталого бюджету впливає розподіл токенів між грубим і детальним рівнями та збільшення кількості рівнів? По-четверте, як часове перекриття і просторово-часове розміщення сталої детальної квоти змінюють використання контексту? По-п’яте, чи утворюють ієрархічне фізичне пакування, маршрутизація та реверсивне ядро коректну композицію, а їхній внесок у збережений стан і пам’ять активацій — вимірювані, але окремі ефекти? У головному тексті використовуються змістові назви сімейств; повні машинні ідентифікатори належать до конфігураційного реєстру.

Тороїдальний тест повторного входу (TRB; внутрішня назва LoopMom) слугує інструментом для ідентифікації механізму досяжності. Вікно перегляду розміром 64×64 переміщується тороїдальним світом розміром 192×64, що містить текстури та спрайти цифр. У кожен момент дві третини світу перебувають поза вікном, а в основній робочій точці релевантний вміст повертається приблизно через 48 кадрів. Збережені координати дають змогу точно визначити останнє спостереження кожного видимого стовпця світу. Йдеться про геометричну спостережуваність, але не про доведену інформаційно-теоретичну необхідність: апріорний розподіл цифр може робити частину неспостережуваного вмісту передбачуваною. Структурна матриця використовує лише TRB, однакову 96-кадрову систему координат контексту та спільну

чотирикадрову ціль, тоді як стандартний і довгий Moving-MNIST не входять до цієї матриці.

Для стислого посилання на експериментальні програми далі використано коди E2, E4b, E5a, E6, E7a, E7c та E8a; B1 позначає окреме порівняння повних конфігурацій. Коди є ідентифікаторами доказових програм, а не послідовними етапами однієї траєкторії. Повне зіставлення кодів із питаннями, класами доказів і виконаними варіантами перенесено до таблиці В.7.

Класи доказів залишаються відмінними навіть тоді, коли їхні артефакти входять до одного релізу. Ініціалізації алгоритму вибірки характеризують випадковість генерації для фіксованої моделі й не замінюють незалежних навчань. Еталон E8a отримує прямий доступ і тому не є справедливою базовою моделлю. B1 підтверджує лише виконану конфігурацію, оскільки разом із кроком контексту змінює цільовий інтерфейс.

Цей порядок відокремлює вибір механізму від підтвердження контекстного ефекту. Повну візуальну матрицю виконаних гілок, токенних бюджетів, цільових інтерфейсів, ініціалізацій і структурно відсутніх комірок перенесено на рисунок В.1. Вона залишається частиною доказового реєстру, але не перериває основну аргументацію. Інтегрований предиктор зі сталими ділянками до цієї матриці не входить: він використовує інтерфейс OpenSTL, регресійний SimVP і окремий інженерний профіль пам’яті, тому його протокол подано в §4.9. Інтегрована архітектура з адаптивним пакуванням також оцінюється окремо, оскільки її питання стосуються фізичного пакування, маршрутизації, реверсивного ядра з тотожною прямою функцією та зіставної якості на Moving MNIST і TaxiBJ, а не причинного ефекту TRB-пакета.

4.1.2 Словник бюджету та правила порівняння

Порівняння далі називається *зіставленим* лише щодо явно названого ресурсу, а не через повну тотожність конфігурацій. Майже зіставлена пара відрізняється у задекларованому напрямі: strided-flat використовує 1 088 токенів контексту, а hier-long – 1 152, тому дефіцит у 64 токени надає невелику перевагу контролю з часовим прорідженням. Експеримент B1 належить до іншої

категорії. У ньому одночасно змінюються крок контексту, крок цілі, кількість цільових слотів, допоміжна функція втрат, довжина послідовності та обчислювальне навантаження, тому його результат стосується повної конфігурації.

Для показника m через $\overline{m}_{\text{candidate}}$ позначено середнє значення кандидата, а через $\overline{m}_{\text{comparator}}$ – середнє значення порівнюваної конфігурації. Введемо коефіцієнт напряму $s_m = +1$ для метрик «менше — краще» і $s_m = -1$ для метрик «більше — краще». Щоб додатний знак завжди означав перевагу кандидата, ефект визначено як

$$\Delta_m = s_m\left(\overline{m}_{\text{comparator}} - \overline{m}_{\text{candidate}}\right). \quad (4.1)$$

Така орієнтація полегшує читання неоднорідних панелей, однак метрики мають різні шкали й не допускають прямого числового зіставлення. Наприклад, зміну MSE об’єднаної маски на 0,01 не можна прирівняти до зміни точності ідентифікації на 0,01. Для сімейства верхньої межі зареєстрованим кандидатом є плоский пакет. Тому додатний ефект у перевірках робастності свідчить на його користь, хоча в основній таблиці E2 різницю втрат подано як «плоский мінус ієрархічний».

Позначка «очікується» в таблицях означає відсутність перевірених вимірювань. Умови протоколу можна описати до виконання, проте такі місця не підтримують висновку про напрям ефекту. Повний реєстр комірок, залежностей і джерел подано в додатку И.

4.1.3 Обґрунтування спільного зрізу 30 000 кроків

Перед відкриттям відкладеної вибірки E2 технічну готовність вихідних модулів перевірено за діагностикою оптимізації; вона не використовується як підтверджувальний доказ. За 6 000 оновлень два предиктори залишаються невирішеними, тоді як незалежно навчені предиктори за 20 000 оновлень дають позитивний напрям. Це окремі графіки, а не контрольні точки однієї траєкторії. Для структурної матриці A4 спільний бюджет обрано за парною діагностикою: плоску недавню та збалансовану ієрархічну конфігурації з однаковим бюджетом 1 792 токени навчено до 30 000 кроків і оцінено через кожні 2 000 кроків на тому

самому фіксованому валідаційному наборі. Два типи діагностики показано разом на рисунку 4.1.

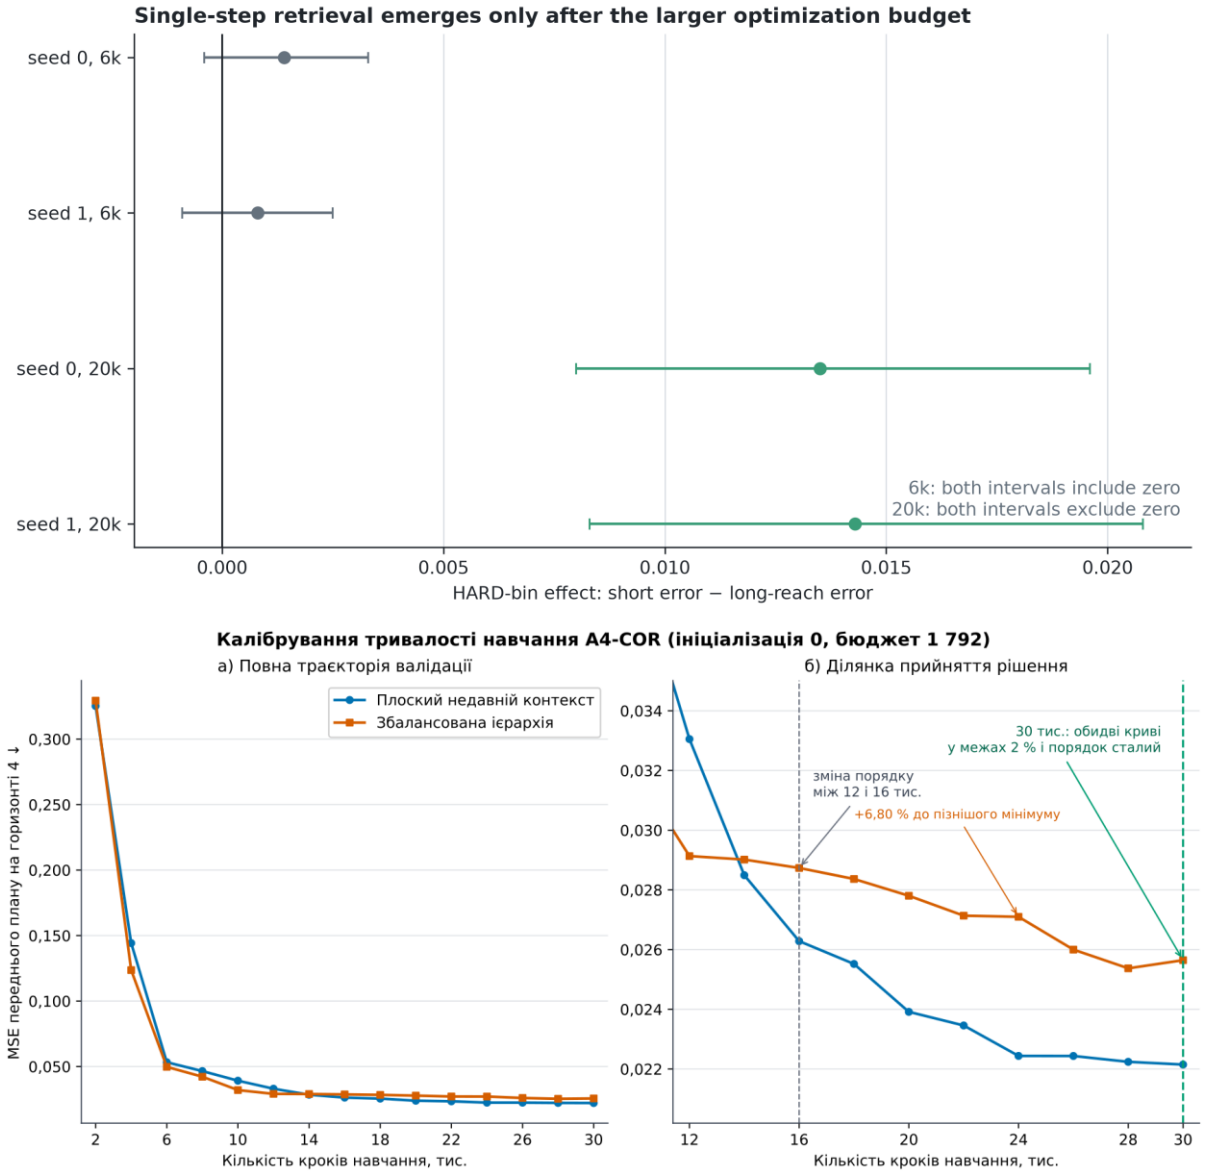


Рисунок 4.1 – Діагностика вибору фіксованого бюджету оптимізації на етапі розроблення. Верхня ілюстрація зіставляє чотири окремі журнали для 6 000 та 20 000 оновлень. Нижня ілюстрація показує всі 15 валідаційних точок двох калібрувальних траєкторій A4-COR до 30 000 кроків і збільшений фрагмент прийняття рішення. Обидві частини обґрунтовують тривалість навчання, але не є доказом переваги певного розподілу контексту. *Джерело: заморожені журнали розроблення та запечатаний аналіз A4-COR.*

Правило прийняття рішення вимагало, щоб кожна конфігурація перебувала в межах 2 % від свого найкращого пізнішого значення, а знак різниці між конфігураціями більше не змінювався. За основною метрикою MSE переднього плану на четвертому горизонті порядок конфігурацій змінився між 12 000 і 16 000 кроків. На 16 000 кроків плоска й ієрархічна криві ще перевищували свої найкращі пізніші значення відповідно на 18,66 % і 13,25 %. На 24 000 кроків

плоска конфігурація вже виконувала двовідсоткову умову, але збалансована ієрархія залишалася на 6,80 % вище свого пізнішого мінімуму. Лише зріз 30 000 кроків одночасно виконав умову для обох кривих і зберіг усталений порядок; найбільша різниця між фінальним і найкращим значенням у вікні 24 000–30 000 становила 1,07 %. Застосування того самого правила до шести метрик також вибрало 30 000 кроків. Однак у кінцевій точці множина значень «на цьому або пізнішому кроці» містить лише поточне значення: відносний розрив автоматично дорівнює нулю, а перевірка подальшого порядку є тривіальною. Узгодження шести метрик не усуває цієї властивості. Отже, 30 000 є спільним фіксованим бюджетом, а не доведеною точкою збіжності; подальше поліпшення залишається можливим.

Обидва калібрувальні запуски використали лише ініціалізацію 0, приблизно 3,79 ГіБ пікової виділеної CUDA-пам’яті та тривали 2,25 і 2,39 год відповідно. Тому вони обґрунтовують спільний навчальний зріз для 86 запусків, але не дають оцінки варіативності між ініціалізаціями й не встановлюють переваги ієрархії. Кінцеве прийняття правила не доводить збіжності; тестову вибірку під час калібрування не відкривали.

4.2 Вибір механізму генерації

Перш ніж порівнювати форми контексту, потрібно зафіксувати вихідний механізм, щоб його зміна не змішувалася з ефектом пам’яті. Тут пряма регресія зіставляється з дифузією за спільного кодека й контрольованої ємності, а енергетичний спуск оцінюється як окрема альтернатива. Наприкінці формулюється вибір, який використовується в основній програмі.

4.2.1 Регресія та дифузія за контрольованої ємності

Для дослідження контексту потрібний вихідний модуль прогнозування, проте його вибір за звичкою додав би непотрібне припущення до кожного наступного порівняння. Обидва варіанти використовують трансформер шириною 256 із шістьма блоками та вісьмома головами уваги. Регресійна і дифузійна моделі містять відповідно 7,27 та 7,53 млн параметрів. Контекст на обох рівнях прихованого простору складається із шести кадрів, а ціль

розташована через чотири дії після останнього кадру контексту. Стандартизація представлень у прихованому просторі за каналами й рівнями є спільною. Відмінність двох шляхів від входу до прогнозу узагальнено на рисунку 4.2.

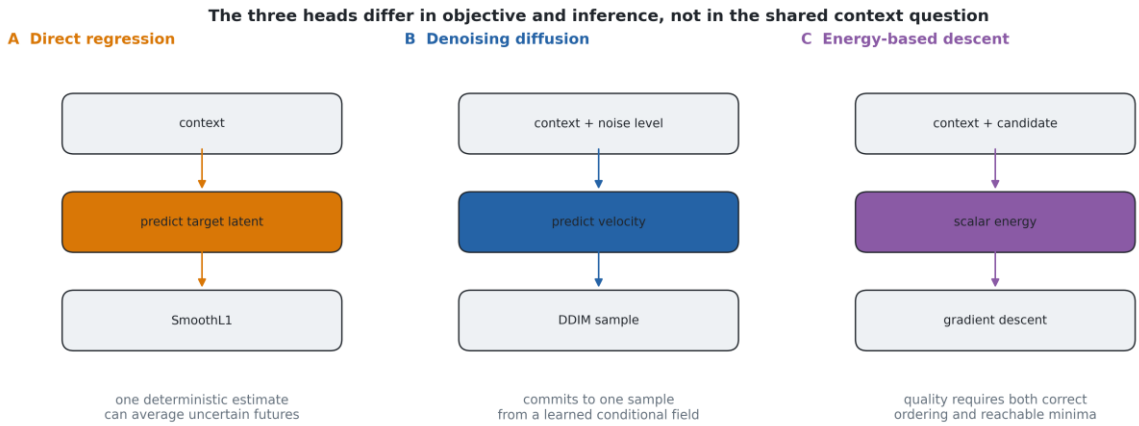


Рисунок 4.2 – Цілі генерації в межах задачі спільного контексту. *Джерело: авторська схема експериментального протоколу.*

«Best-of-N» використано лише як діагностику з вибором найкращого кандидата за відомим еталоном. Для кожного запису обирається декодований зразок із найменшою MSE переднього плану відносно еталона. Позначимо кількість обчислень мережі на одного кандидата через K: для регресії з MC-dropout $K = 1$, а для дифузії K дорівнює кількості кроків DDIM. Для N кандидатів загальна кількість обчислень дорівнює

$$W(N, K) = NK. \tag{4.2}$$

Однакова кількість кандидатів не означає однакового обчислювального навантаження. Зокрема, «best-of-8» за 16 NFE використовує вісім обчислень регресійної мережі та 128 обчислень дифузійної. Тому таблиця 4.1 подає діагностику охоплення, середню поведінку кандидатів і самоподачу окремо; детальну чутливість до NFE перенесено до додатка Е.

Таблиця 4.1 – Основні докази для вибору механізму генерації. Для MSE переднього плану менше значення є кращим, для різкості переднього плану – більше. Однокрокові результати усереднено за шістьма пакетами даних фіксованої оцінюваної вибірки.

Режим і показник	**Регресія**	**Дифузія**	**Незмінне продовження або 95 % ДІ**
Один крок, найкращий із 8, MSE переднього плану	0,0664	**0,0512**	0,2367
Один крок, середнє за 8 кандидатами, MSE переднього плану	0,0714	**0,0640**	–
Один крок, різкість переднього плану	0,1591	**0,1886**	0,0515

Режим і показник	Регресія	Дифузія	Незмінне продовження або 95 % ДІ
Самоподача, один кандидат, ієрархічний пакет	**0,1682**	0,1848	[0,0110; 0,0227] для «дифузія мінус регресія»
Самоподача, один кандидат, плоский пакет	**0,2015**	0,2038	–

Дифузія краще охоплює множину однокрокових кандидатів і дає різкіші зразки, але цей результат отримано за більшої кількості обчислень. За самоподачі з одним кандидатом порядок змінюється: регресія має нижчу помилку для обох пакетів. Отже, таблиця не встановлює універсального переможця, а розрізняє режим дослідження розподілу та детерміноване розгортання.

Візуальну різницю між двома вихідними модулями для однакових вхідних даних показано на рисунку Е.1. У кожному рядку повного монтажу стовпці містять останній кадр контексту, прогноз і еталон, а ліва й права панелі відповідають регресії та дифузії. Записи наведено у фіксованому порядку без відбору за помилкою; вони пояснюють характер прогнозів, але рішення про механізм спирається на агреговані значення таблиці 4.1.

4.2.2 Перевірка енергетичного спуску як альтернативного механізму

Трансформер на основі енергії пропонує інший шлях до генерації: навчати скалярну енергію замість нормалізованої ймовірності [84, 85]. Для контексту c та кандидата майбутнього z енергія $E_\phi(c, z)$ задає напрям оновлення

$$z^{(k+1)} = z^{(k)} - \alpha_k \nabla_z E_\phi(c, z^{(k)}) + \eta_k, \tag{4.3}$$

Тут k є номером ітерації, α_k – кроком спуску, а η_k – зареєстрованим ланжевенівським членом, якщо алгоритм використовує шум [89, 90]. Узгодження скорів пов’язує градієнти енергії з градієнтами густини даних [86, 87]. Для корисної генерації енергія має правильно впорядковувати змістовні кандидати, а спуск від заданої початкової точки – досягати структурованої області ландшафту.

У масштабі 14,66 мільйона параметрів адаптовано офіційну реалізацію Energy-Based Transformer [88] та оцінено два опубліковані сімейства рецептів.

Рецепт S2 збігається до втрати близько 0,597, але розміщує кандидата, що відповідає середньому значенню пакета даних, нижче цільового значення під час кожного з 21 зафіксованого вимірювання. S1 змінює порядок: від оновлень 6 000 до 20 000 цільове значення має найнижчу енергію під час п'ятнадцяти послідовних проб, при цьому розрив між цільовим значенням та середнім значенням становить від 0,22 до 3,09. Отже, впорядкування можна навчити на цьому рівні, але саме по собі воно не доводить, що спуск досягає структурованого кандидата.

Різницю між навченим упорядкуванням і фактичною досяжністю структурованого стану показано на рисунку 4.3.

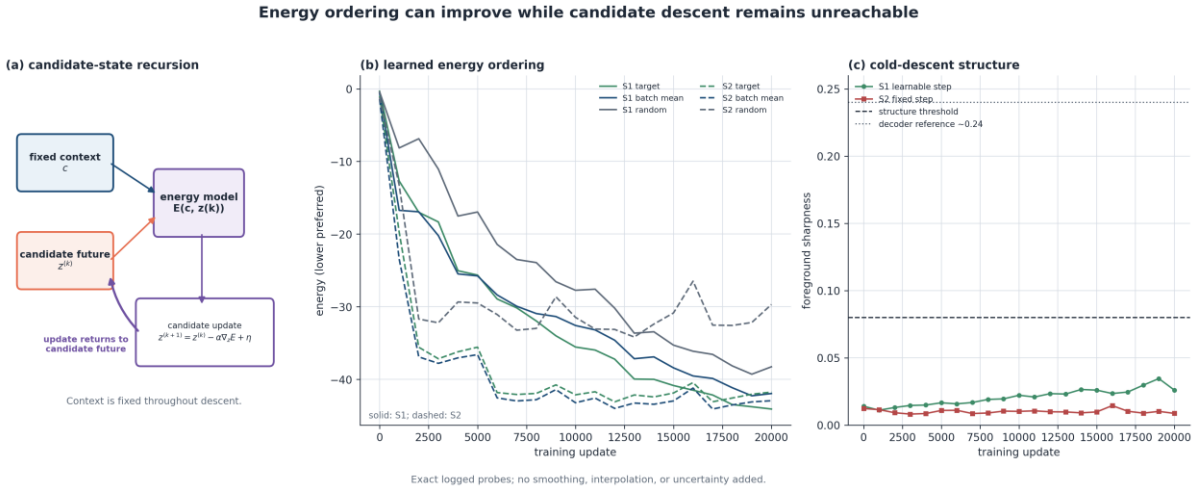


Рисунок 4.3 – Упорядкування за енергією та досяжність спуску. *Джерело: побудовано автором за журналами навчання й діагностики EBT.*

4.2.3 Вибір механізму

Із трьох перевірених механізмів два виявилися придатними для подальших дослідів. Для оцінювання пакетів на відкладених даних обрано дифузію, оскільки вона забезпечила найкращу однокрокову оцінку верхньої межі охоплення. Регресію збережено як контроль: у детермінованому розгортанні із самоподачею та одним кандидатом вона мала нижчу помилку для обох пакетів, як свідчать останні два рядки таблиці 4.1. Енергетичний спуск зафіксовано як негативний результат цієї програми, адже його подальше масштабування перевіряло б розмір моделі, а не гіпотезу пакетування контексту.

Універсального рейтингу вихідних модулів ці результати не встановлюють; вибір залежить від режиму застосування. Ця відмінність визначає

межі подальшої інтерпретації. Досліджена межа бюджетів вимірює ефекти пакетів для дифузії із зазначеною кількістю кроків знешумлення, тоді як регресійні комірки перевіряють, чи зберігається напрям ефекту з детермінованим однопрохідним модулем. Це взаємодоповнювальні перевірки, а не взаємозамінні реплікації.

4.3 Ієрархічна досяжність за фіксованого бюджету контексту

Цей підрозділ перевіряє центральний механізм у найчистішій умові: релевантна подія входить до довгого ієрархічного пакета, але вже не входить до коротшого плоского пакета зі зіставленим бюджетом. Спочатку аналізується заздалегідь визначена популяція різниці досяжності, потім повний набір показників і, нарешті, межа допустимого причинного тлумачення.

4.3.1 Відкладене підтвердження різниці досяжності

Центральний ефект зосереджується там, де релевантний попередній стан уже вийшов за межі короткого плоского вікна, але ще зберігається у грубій історії ієрархічного пакета. Дані розробки вже вплинули на вибір моделі та формулювання цієї гіпотези. Тому коректне підтвердження вимагало нових кліпів. Відкладену вибірку E2 згенеровано й зафіксовано хешем після заморожування контрольних точок, пар пакетів, діапазонів досяжності, показників, макетів таблиць і правил інтерпретації. Точний ідентифікатор наведено в додатку Г. Такий порядок реалізує принцип захищеної вибірки й запобігає її адаптивному повторному використанню [167]. Програмний шлюз забороняв застосовувати E2 для навчання або вибору контрольних точок; кожний дозволений доступ фіксувався разом із його призначенням.

Загальну специфічну для пари популяцію визначено у формулі (3.38). Для пари hier-min/flat-min вона охоплює записи, у яких останнє релевантне спостереження віддалене більш ніж на 14, але не більш ніж на 48 кадрів. Додатково запис включається лише за скінченного значення Δt_{ci}, видимості відповідного стовпця не менш як 0,5 та непорожнього переднього плану. Нехай e_{ci} дорівнює одиниці для таких записів і нулю для решти, де c позначає кліп, а i

– кадр у ньому. Якщо $d_{ci} = m_{ci}^{\text{flat}} - m_{ci}^{\text{hier}}$ є парною різницею помилок переднього плану, оцінка ефекту досяжності має вигляд

$$\hat{\Delta}_{\text{reach}} = \frac{\sum_c \sum_{i \in c} e_{ci} d_{ci}}{\sum_c \sum_{i \in c} e_{ci}}. \tag{4.4}$$

Формула (4.4) усереднює різниці лише всередині визначеної до відкриття даних смуги; кадри, доступні обом пакетам або жодному з них, не розмивають оцінюваний механізм. Ефект обчислено окремо для двох незалежних навчань і зіставлено з результатом на повній оцінюваній популяції. Це порівняння наведено на рисунку 4.4.

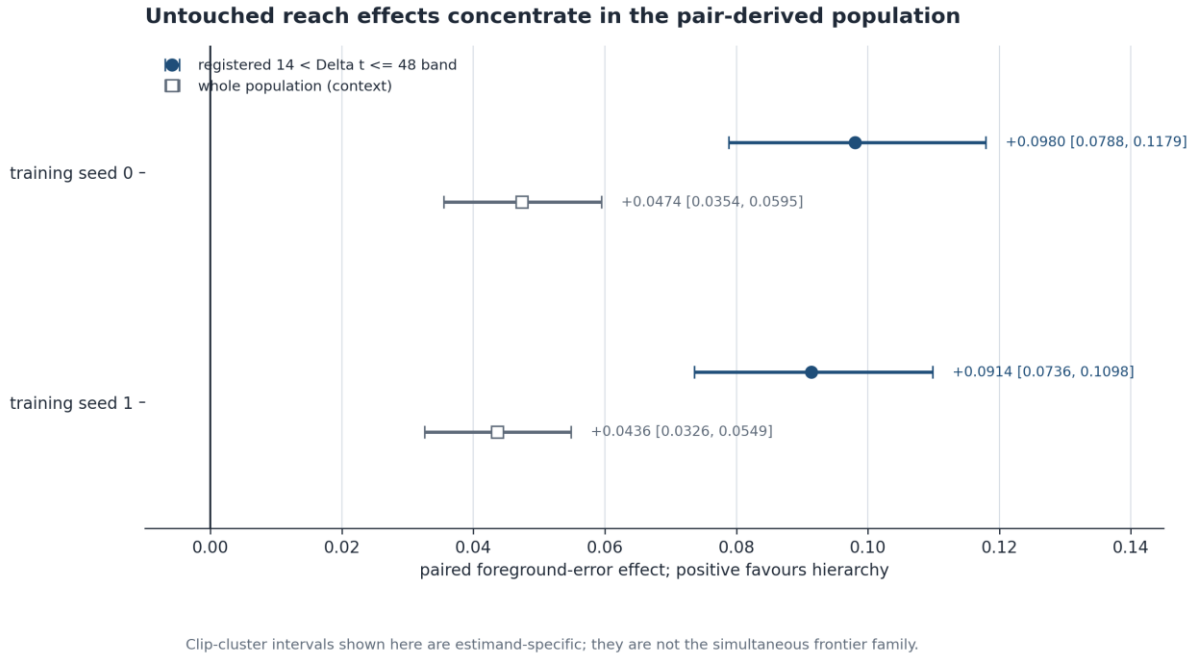


Рисунок 4.4 – Ефекти у визначених для кожної пари вибірках досяжності. Для обох ініціалізацій перевага ієрархії в зареєстрованій смузі досяжності більша, ніж у повній оцінюваній вибірці, що відповідає механізму, передбаченому геометрією пакета. *Джерело: побудовано автором за замороженими результатами E2.*

Пара B1 надає друге підтвердження з важливим застереженням. Її зареєстрована популяція становить $8 < \Delta t_i \leq 48$, а ефекти двох ініціалізацій дорівнюють +0,0692 [0,0543; 0,0845] та +0,0743 [0,0588; 0,0899]. Для повної популяції ефекти становлять +0,0340 та +0,0381. Однак у B1 разом із досяжністю контексту змінюються цільовий інтерфейс із кроком 2, кількість токенів цілі, допоміжна функція втрат і навчальне навантаження порівняно з flat-short. Результат підтверджує повну конфігурацію, але не є ізольованою причинною оцінкою часового кроку.

4.3.2 Підтвердження на повній вибірці та за всіма показниками

Помилка переднього плану сама по собі може приховати модель, яка правильно розміщує об’єкт, але водночас створює хибні об’єкти в інших місцях. Тому таблиця 4.2 охоплює весь зареєстрований набір показників, а не показники, вибрані після перегляду результатів. Знаки гармонізовано: додатні значення свідчать на користь hier-min; для пропущених і зайвих компонентів подано кількість помилок, яких уникає ієрархічний пакет.

Таблиця 4.2 – Повний набір підтверджувальних показників у відкладеній вибірці $14 < \Delta t \leq 48$. Кожен рядок містить 1 006 записів кадрів із 96 кліпів. Інтервали отримано парним статистичним виведенням з урахуванням кластеризації за кліпами для названої навченої моделі; два стовпці ініціалізацій не об’єднуються.

Показник	**Ефект для ініціалізації 0 [95 % ДІ]**	**Ефект для ініціалізації 1 [95 % ДІ]**
MSE для непорожнього еталонного переднього плану	+0,0980 [0,0788; 0,1179]	+0,0914 [0,0736; 0,1098]
MSE для об’єднаної маски	+0,0808 [0,0632; 0,0987]	+0,0773 [0,0613; 0,0940]
MSE для повного кадру	+0,0045 [0,0033; 0,0058]	+0,0042 [0,0032; 0,0052]
MSE еталонного фону	+0,0013 [0,0006; 0,0019]	+0,0012 [0,0006; 0,0017]
Прецизійність переднього плану	+0,1550 [0,1027; 0,2066]	+0,0691 [0,0051; 0,1317]
Повнота переднього плану	+0,2708 [0,2180; 0,3238]	+0,2539 [0,2060; 0,3029]
F1-показник для переднього плану	+0,2458 [0,1975; 0,2954]	+0,2342 [0,1893; 0,2801]
Уникнення пропущених компонентів	+0,4911 [0,3686; 0,6102]	+0,5527 [0,4315; 0,6699]
Уникнення зайвих компонентів	+0,3231 [0,1530; 0,4915]	+0,1968 [0,0334; 0,3701]
Покриття компонентів	+0,2622 [0,1968; 0,3264]	+0,2992 [0,2370; 0,3605]

Сукупність показників робить результат досяжності переконливішим, ніж сама різниця MSE переднього плану. Об’єднана маска контролює галюциновану опору; показник фону перевіряє, чи не отримано виграш за рахунок його реконструкції; прецизійність, повнота й F1 виявляють дисбаланс масок. Кількість пропущених і зайвих компонентів разом із покриттям показує, що пакет частіше відтворює цілісний об’єкт після того, як коротше вікно втратило релевантний вміст сцени.

4.3.3 Інтерпретація досяжності

Визначена для пари смуга є центральною в експерименті. Загальний аналіз наприкінці горизонту поєднував би події, у яких потрібні свідчення доступні обом пакетам, жодному з них або лише одному. Геометрія TRB дає змогу розглянути ці випадки окремо. Більший ефект у смузі спостерігається за обох ініціалізацій навчання й підтверджується показниками, чутливими до хибнопозитивних результатів. Саме цього очікує механізм, передбачений у розділі 3.

Водночас геометрія пакета доводить лише наявність потрібного часового інтервалу у збереженому контексті. Вона не гарантує, що давній стан закодовано без втрат або що предиктор справді його використав. Зв’язок між адресованістю та якістю встановлює парний ефект у визначеній смузі, але навіть він не перетворює грубий потік на повну копію минулого кадру.

Звідси випливає вимога до подальших тестів: пізній кадр є інформативним лише тоді, коли оцінювач може визначити, коли відповідний вміст востаннє спостерігався, і які пакети ще охоплюють це спостереження. Без такого запису ефект, залежний від горизонту, змішує досяжність, точність відтворення, складність сцени та накопичену похибку розгортання. У TRB цю проблему розв’язано аналітично. Матриця FRT розширює числову вісь бюджету, CEX окремо збільшує кількість грубих часових позицій за сталої недавньої деталізації, а підтверджувальна вибірка використовує єдину маску повторного входу; її не об’єднують статистично з історичною парно визначеною популяцією E2. Для природного відео знадобляться відомі траєкторії камер, анотації подій зникнення й повторного входу або контрфактуальні послідовності, що утворюють так само перевірну популяцію.

4.4 Межа «досяжність–точність відтворення» та ефективність пам’яті

Перевага досяжності не може зростати безумовно: після включення потрібного минулого важливішою може стати точність збережених деталей. Тому тут зіставляються п’ять дискретних бюджетних областей, перевіряється

точна токенна й байтова вартість та формулюється область доцільності без інтерполяції неперервної точки переходу.

4.4.1 Одночасно перевірена межа

Досяжність має значення лише тоді, коли вона змінює доступність релевантних спостережень. Щойно плоский пакет охоплює більшу частину або всю потрібну історію, збереження повнороздільних деталей може бути кориснішим за їх стиснення в грубий потік. Сімейство E2 перевіряє це припущення на відкладених даних у п’яти дискретних точках бюджету. Центральний емпіричний синтез цих робочих областей подано на рисунку 4.5.

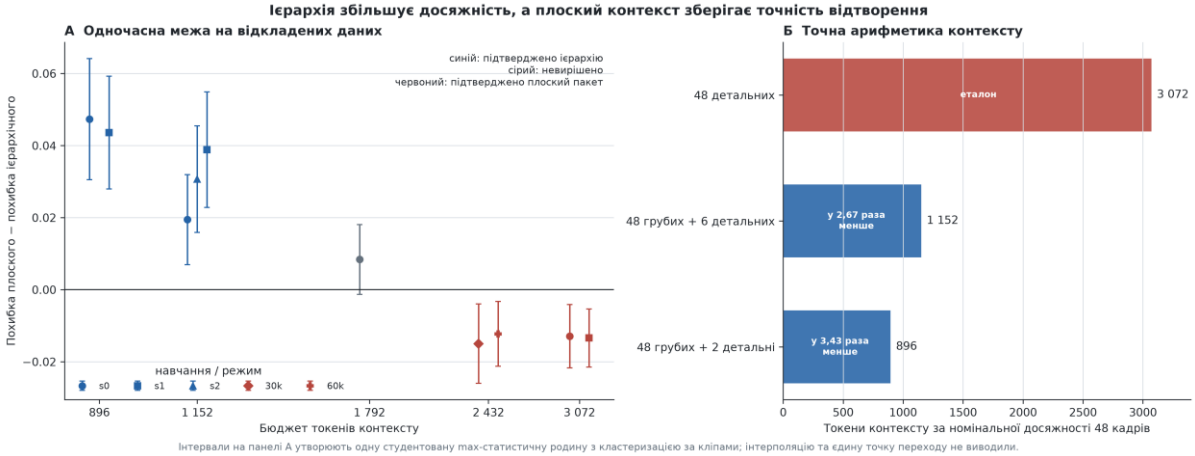


Рисунок 4.5 – Перевірена межа «досяжність–точність відтворення». Ієрархію одночасно підтверджено за 896 та 1 152 токенів, точка 1 792 залишається невизначеною, а плоский контекст підтверджено за 2 432 та 3 072 токенів. Неперервну точку перетину не апроксимували, тому рисунок не можна тлумачити як оцінену безперервну криву. *Джерело: побудовано автором за замороженими результатами одночасного аналізу E2.*

Ліва панель показує не неперервний тренд, а п’ять перевірених бюджетних областей. За 896 та 1 152 токенів одночасні інтервали лежать у напрямі ієрархії. Інтервал у точці 1 792 перетинає нуль, тому вона залишається невизначеною. За 2 432 та 3 072 токенів знак змінюється й одночасні інтервали підтверджують плоский контекст. Різна кількість ініціалізацій не дозволяє оцінювати гладку криву або точний поріг переходу між областями.

Права панель пов’язує цю статистичну картину з геометрією пакета. За однакової номінальної досяжності 48 кадрів пакети з 896 та 1 152 токенами використовують відповідно у 3,43 та 2,67 раза менше контекстних токенів, ніж щільна детальна історія. Таким чином, рисунок 4.5 є головним результатом

ієрархічної лінії: він одночасно показує виграш досяжності в обмеженому бюджеті та ціну просторового стискання після насичення досяжності.

Точні ефекти, одночасні інтервали й режими оптимізації перенесено до таблиці Д.3. Кожен інтервал належить до одного зареєстрованого сімейства зі статистичним виведенням з урахуванням кластеризації за кліпами та максимум-статистикою Стьюдента з критичним значенням 2,741. В основному тексті рисунок 4.5 залишає лише результат, потрібний для аргументації: ієрархію підтверджено в двох нижчих зіставлених бюджетах, середня точка невизначена, а плоский пакет підтверджено у двох верхніх областях.

Два нижні за бюджетом порівняння 480 проти 512 токенів у таблиці Д.3 є лише майже зіставленими й не визначають межу за точного бюджету. Серед точно зіставлених пар 1 152 токени є найбільшим підтвердженим бюджетом на рівні сімейства, що сприяє ієрархії; 2 432 токени – найменшим підтвердженим бюджетом, що сприяє плоскому пакету.

4.4.2 Точна арифметика токенів та корисного навантаження

Ця межа є значущою, оскільки її контекстна вартість є явною. У кодеку з фіксованою структурою кадр високої роздільної здатності містить $q_{\mathrm{f}} = 64$ токени, а грубий кадр – $q_{\mathrm{c}} = 16$. У пакеті $\mathcal{P}$ кількість детальних і грубих кадрів позначено відповідно n_{f} та n_{c} . Скорочення кількості токенів відносно 48 щільних детальних кадрів становить

$$G_{\mathrm{ctx}}(\mathcal{P}) = \frac{48q_{\mathrm{f}}}{n_{\mathrm{c}}q_{\mathrm{c}}+n_{\mathrm{f}}q_{\mathrm{f}}}. \tag{4.5}$$

Формула (4.5) описує стан контексту, а не повну пам’ять GPU. Для перевірки фізичного масштабу таблиця 4.3 переводить токени в корисний обсяг даних прихованого простору та матеріалізованих вбудовувань. Кожен токен має 16 коефіцієнтів кодека; значення стосуються одного прикладу й не містять цільових токенів, проміжних активацій уваги й MLP, параметрів, стану оптимізатора та накладних витрат розподільника.

Таблиця 4.3 – Витрати контексту за однакової номінальної досяжності 48 кадрів.

Пакет	**Контекстні токени**	**Дані прихованого простору fp32 / fp16**	**Вбудовування 384, bf16**	**Відносна вартість**
48 щільних детальних кадрів	3 072	192 / 96 КіБ	2,250 МіБ	1,00×
48 грубих + 6 останніх детальних	1 152	72 / 36 КіБ	0,844 МіБ	у 2,67 раза менше
48 грубих + 2 останніх детальних	896	56 / 28 КіБ	0,656 МіБ	у 3,43 раза менше

Ця арифметика підтверджує два різні твердження. По-перше, ієрархія робить доступною 48-кадрову історію за бюджетів, із якими плоске вікно детальних кадрів досягає лише 14 або 18 кадрів. По-друге, той самий доступний проміжок потребує у 2,67–3,43 раза менше токенів контексту, ніж 48 детальних кадрів. Однакова якість за меншої кількості токенів не перевірялася. Якість прогнозу залежить від потрібної для задачі інформації, що далі показують верхні точки бюджетної межі та E6.

4.4.3 Досяжність і точність відтворення як область доцільності

За 896 та 1 152 токенів плоске вікно не містить релевантної історії повторного входу, яку зберігає грубий потік. Результат для визначеної смуги в підрозділі 4.3 робить цей механізм спостережуваним, а не лише правдоподібним. За 3 072 токенів обидва пакети досягають 48 кадрів. Точка 2 432 розташована між цими двома чистими випадками: плоский пакет досягає 38 кадрів, ієрархічний – 48, однак в основному сімействі E2 підтверджено перевагу плоского пакета. У статичному світі давнє детальне спостереження може краще зберігати вигляд цифри й точну текстуру, ніж щільніша груба історія.

Отже, пріоритет задачі визначає, на що витрачати бюджет. Якщо без давнього кадру неможливо відновити положення або продовжити траєкторію, першою вимогою стає досяжність. Коли потрібна історія вже доступна, додаткові детальні спостереження можуть краще зберегти ідентичність. Загального порога достатності у 38 кадрів із цього не випливає. Перевірки генератора й кодека лише показують, що верхній ефект менший і менш точний, ніж нижні ефекти досяжності.

Характер помилок у двох бюджетних областях додатково ілюструє рисунок Е.2. Для кожного з чотирьох заздалегідь зафіксованих кліпів рядки містять еталон, hier-long і flat-budget, а стовпці – горизонти 1, 24, 60, 100 і 148 кадрів. Вибір прикладів не залежав від величини контрасту між моделями; якісні розгортки пояснюють типи помилок, тоді як висновок про межу визначають агреговані ефекти рисунка 4.5 і таблиці Д.3.

Наявна межа Е2 задає дискретну вихідну карту, але не відповідає окремо на питання про найкращий розподіл сталого бюджету. Для цього в А4 передбачено сім стратегій за 1 792 токени, конструкції з одним, двома й трьома рівнями, вкладене, взаємовиключне та залишкове володіння часовими позиціями, а також матрицю просторово-часового розміщення 256 детальних токенів. Ці порівняння трактуються як ефекти зареєстрованих пакетів: у досліді кількості рівнів і в частині досліду перекриття разом змінюються додаткові властивості конструкції, тому ізольоване причинне тлумачення одного скалярного параметра було б надмірним.

4.5 Форма контекстного пакета та взаємодія з моделлю

Однакова або близька кількість токенів ще не робить пакети функціонально однаковими. Цей підрозділ відокремлює просторове огрублення від часового піддискретизування й перевіряє, чи залежить їхній порядок від вихідного модуля та ініціалізації навчання. Отриманий результат визначає межу перенесення висновку про ієрархію між моделями.

4.5.1 Просторова ієрархія проти часового піддискретизування

Зіставлена бюджетна межа показує, що дешеві грубі токени можуть забезпечувати корисну досяжність. Окремим залишається питання, чи найкраще витрачати фіксований бюджет саме на просторове огрублення. Детальна часова прив’язка також сягає минулого, але залишає проміжки між збереженими кадрами. Порівняння цих пакетів розділяє два типи втрати: просторове стиснення відкидає деталі на кожному давньому часовому кроці, а часове проріджування зберігає вибрані кадри, проте втрачає проміжну динаміку.

Для дифузії всі п’ять ініціалізацій навчання віддають перевагу часово розрідженому пакету повної роздільної здатності. Таблиця 4.4 показує цей стабільний напрям разом із ширшою факторною перевіркою. Регресійний вихідний модуль змінює картину, тому взаємодію «вихідний модуль × пакет» розглянуто окремо в §4.5.2.

Таблиця 4.4 – Факторний експеримент «вихідний модуль × пакет» для п’яти ініціалізацій. Додатні ефекти пакета свідчать на користь часових прив’язок повної роздільної здатності порівняно з просторово грубою щільною історією. Інтервали за кліпами умовні щодо однієї навченої моделі; в останніх трьох рядках одиницями є ініціалізації навчання.

ініціалізація навчання або підсумок	**Ефект пакета для дифузії [95 % ДІ за кліпами]**	**Ефект пакета для регресії [95 % ДІ за кліпами]**	**Взаємодія «вихідний модуль × пакет» [95 % ДІ за кліпами]**
0	+0,0197 [+0,0143; +0,0252]	+0,0107 [+0,0062; +0,0158]	−0,0089 [−0,0151; −0,0025]
1	+0,0046 [+0,0007; +0,0084]	−0,0104 [−0,0146; −0,0062]	−0,0150 [−0,0199; −0,0104]
2	+0,0111 [+0,0070; +0,0151]	−0,0208 [−0,0270; −0,0150]	−0,0319 [−0,0401; −0,0245]
3	+0,0075 [+0,0037; +0,0114]	+0,0248 [+0,0181; +0,0323]	+0,0173 [+0,0106; +0,0245]
4	+0,0060 [+0,0027; +0,0092]	−0,0166 [−0,0229; −0,0108]	−0,0226 [−0,0297; −0,0160]
Середнє за ініціалізаціями	+0,0098	−0,0024	−0,0122
Стандартне відхилення за ініціалізаціями	0,0060	0,0195	0,0186
Інтервал t95 за ініціалізаціями	[+0,0023; +0,0173]	[−0,0266; +0,0217]	[−0,0353; +0,0109]

Розкид ефектів за ініціалізаціями та відмінність між вихідними модулями видно на рисунку 4.6.

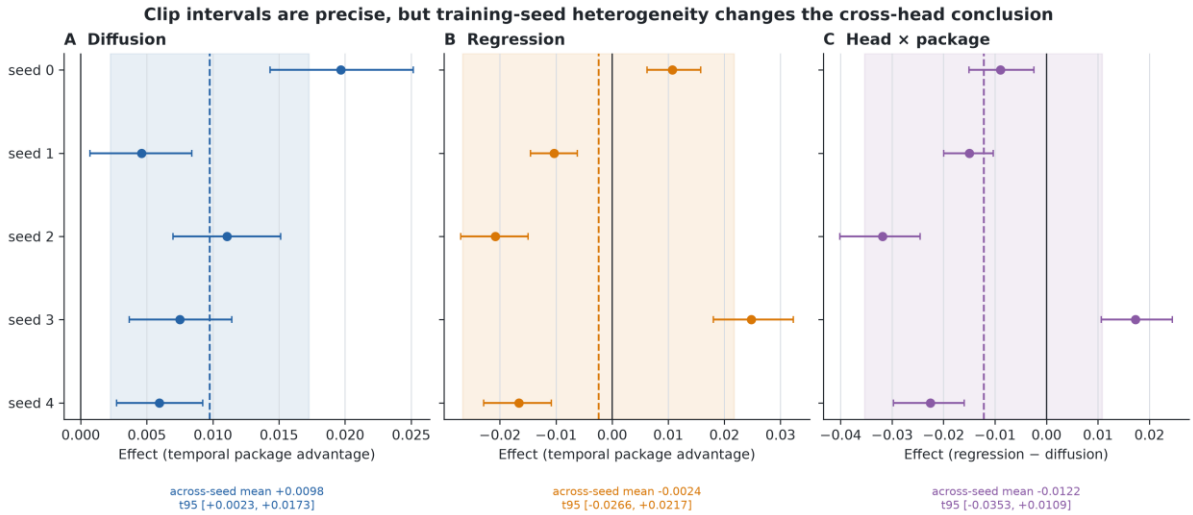


Рисунок 4.6 – Ефекти пакетів для різних вихідних модулів прогнозування та ініціалізацій навчання. *Джерело: побудовано автором за замороженим факторним дослідженням «вихідний модуль × пакет».*

Таблиця 4.4 та рисунок 4.6 показують залежність форми пакета від вихідного модуля й ініціалізації. Повну карту ліцензій на причинне тлумачення перенесено до таблиці B.5 додатка В. У головному тексті достатньо трьох меж. По-перше, hier-min проти flat-min є зіставленим відкладеним порівнянням, але досяжність і роздільна здатність давньої історії змінюються разом. По-друге, strided-flat проти hier-long є майже зіставленим факторним дослідом: часово розріджений пакет має на 64 токени менше. По-третє, B1 і трирівнева гілка змінюють кілька інтерфейсів одночасно, тому їхні результати стосуються повних конфігурацій.

Додана третя глибина зберігає бюджет 1 152 токени, але змінює розподіл втрат, цільові токени та навчальне навантаження. Її гірший результат свідчить проти конкретної повної конфігурації, а не проти ієрархічної глибини як такої. Аналогічно, засліплення потоку може показати його функціональну необхідність, однак не вимірює незалежну інформаційну цінність.

4.5.2 Взаємодія з вихідним модулем прогнозування

Стовпець регресії демонструє гетерогенність, а не нічию. Дві ініціалізації істотно віддають перевагу часовим прив’язкам, три – просторовій ієрархії; через зміну напряму інтервал між ініціалізаціями широкий. Коректне формулювання тут – «гетерогенність за ініціалізаціями навчання». Взаємодія поводиться подібно: чотири оцінки для окремих ініціалізацій від’ємні, одна додатна, проте t-інтервал за ініціалізаціями [−0,0353; +0,0109] перетинає нуль. Отже, рання гіпотеза про стабільний зсув регресії до просторового огрублення не підтвердилася. Використання пакета залежить не лише від збережених токенів, а й від цільової функції, правила формування вибірки та траєкторії оптимізації, за якою модель навчається працювати з ними.

Для вибору моделі дифузійний результат дає підстави використовувати часові прив’язки в цьому контрольованому статичному середовищі. Утім, через гетерогенність регресійних результатів такий вибір потребує перевірки за кількома ініціалізаціями перед перенесенням в інше середовище. Вирішальним розширенням був би рухомий прихований світ. Якщо між прив’язками з кроком 4 відбуваються змістовні зміни стану, часове проріджения має втрачати інформацію, яку зберігає щільний грубий потік. Такий перехресний динамічний тест відокремив би перевагу конкретного інструмента від ширшого принципу пакетування, не змінюючи підтвердженої межі просторової ієрархії.

Саме гетерогенність E4 визначає спосіб подання структурної матриці: предиктор і навчальний рецепт фіксуються для всіх сімейств, обидві ініціалізації показуються окремими точками, а середнє не приховує зміни напряму. Дві ініціалізації є узгодженим компромісом охоплення, але не дозволяють оцінювати надійний розподіл між навчаннями; тому інтервали за кліпами та розкид двох ініціалізацій мають різні статистичні значення.

4.6 Робастність основних напрямів

Після основного підтвердження перевіряється, чи зберігаються напрями ефектів за змін, що не повинні визначати сам механізм досяжності. Окремо варіюються кількість кроків і випадковість алгоритму вибірки та повністю замінюється кодек прихованого простору. Ці досліди локалізують чутливість, але не створюють нових незалежних навчальних реплік.

4.6.1 Бюджет алгоритму вибірки та випадковість

Основна межа E2 використовує детермінований DDIM-16 з однією зареєстрованою ініціалізацією генератора. Тому в E7c до відкриття нового цільового набору зафіксовано чотири контрасти для предикторів із ініціалізацією навчання 0: ефект досяжності за 896 токенів, внутрішній ефект за 1 152 токенів, ефект форми пакета 1 088 проти 1 152 і плоску інверсію точності за 2 432 токенів.

Усього ці контрасти дають 20 парних оцінок, але науковий висновок визначає не їхня кількість, а стабільність зареєстрованого напряму. Усі точкові

оцінки цей напрям зберігають, а для перших трьох контрастів кожна одночасна нижня межа перевищує нуль. Інверсія за 2 432 токенів додатна й визначена на рівні сімейства для всіх трьох бюджетів NFE за ініціалізації генератора 0, але інтервали містять нуль для ініціалізацій 1 (+0,0098 [−0,0001; +0,0196]) і 2 (+0,0077 [−0,0013; +0,0167]). Отже, 18 із 20 одночасних інтервалів не перетинають нуль. Зміна ініціалізації DDIM оцінює випадковість генерації для фіксованої контрольної точки; вона не замінює незалежного навчання моделі з іншою ініціалізацією. Розподіл оцінок за NFE та ініціалізаціями алгоритму вибірки наведено на рисунку 4.7.

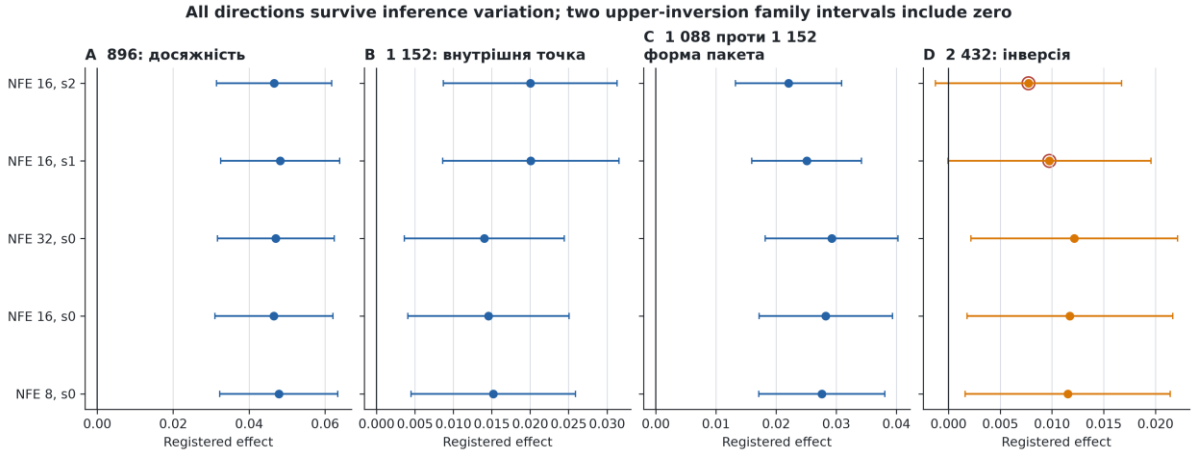


Рисунок 4.7 – Робастність до обсягу знешумлення та випадковості алгоритму вибірки. Напрями всіх точкових оцінок зберігаються для зареєстрованих конфігурацій алгоритму вибірки, хоча два верхні інтервали втрачають одночасну статистичну визначеність. *Джерело: побудовано автором за замороженими результатами E7c.*

4.6.2 Незалежно навчений кодек

E7a втручається на більш ранньому етапі обчислювального тракту. Другий кодек навчається незалежно, для нього заново обчислюється нормалізація прихованого простору, після чого перенавчають сім предикторів із ініціалізацією 0. Одночасно змінюються похибка реконструкції, геометрія координат, масштаб і оптимізація предиктора. Тому це перевірка робастності до повної заміни кодека; числові відмінності не можна приписати окремій властивості прихованого простору.

Повні одночасні інтервали E7c та E7a наведено в таблиці Д.1 додатка Д. Для альтернативного кодека сім із восьми інтервалів не перетинають нуль у зареєстрованому напрямі. Винятком є верхня плоска інверсія: її точкова оцінка

додатна, але інтервал [−0,0006; 0,0165] містить нуль. Співвідношення ефектів оригінального й незалежно навченого кодеків показано на рисунку 4.8.

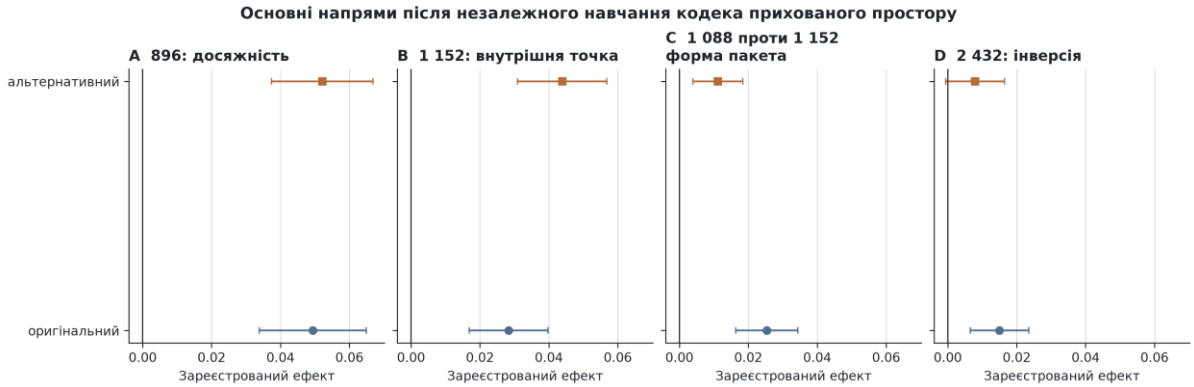


Рисунок 4.8 – Ефекти оригінального та альтернативного кодеків на спільній шкалі. Панелі А–Г відповідають ефекту досяжності за 896 токенів, внутрішньому ефекту за 1 152 токенів, ефекту форми пакета 1 088 проти 1 152 токенів і верхній інверсії за 2 432 токенів. Квадрати та кола позначають відповідно альтернативний і оригінальний кодеки; відрізки є одночасними 95 % інтервалами, вертикальна лінія – нульовим ефектом. Сім із восьми інтервалів не перетинають нуль у зареєстрованому напрямі; верхній контраст альтернативного кодека залишається невирішеним, а не інвертованим. *Джерело: побудовано автором за замороженими результатами E7a.*

Альтернативний кодек описово посилює нижній і внутрішній ефекти досяжності, тоді як ефекти форми пакета та верхніх бюджетних точок зменшуються. Ініціалізація кодека не є окремою реплікою моделі під час прогнозування, тому ці зміни не можна усереднювати або пояснювати після перегляду результатів. Допустимий висновок вужчий: після повної заміни одного неперервного інтерфейсу прихованого простору чотири основні напрями зберігаються на рівні точкових оцінок, а три залишаються визначеними на рівні сімейства. Верхня плоска інверсія точності є спільною межею статистичної визначеності для обох програм робастності.

4.7 Межа та негативні докази

Цей підрозділ навмисно зосереджується на випадках, де сильніше узагальнення не підтверджується. Він охоплює невідтворену пізню інверсію самоподачі, привілейований еталон із прямим доступом, конфлікт між просторовим покриттям та ідентичністю й короткогоризонтні зовнішні набори. Разом вони визначають, чого основна межа не доводить.

4.7.1 Невдала реплікація пізньої межі за самоподачі

Доступна історія може бути наявною, але її користь здатна зникнути під час тривалої генерації із самоподачею. Початкове довгоциклове дослідження з

ініціалізацією 0 начебто виявило таку межу: спочатку ієрархія допомагала, але приблизно після 24 кадрів ставала гіршою. На горизонтах 61–256 ефект для ініціалізації 0 був від'ємним: −0,0064 [−0,0095; −0,0032]. Дві нові ініціалізації, навпаки, дали перевагу ієрархії: +0,0074 [0,0038; 0,0112] та +0,0087 [0,0035; 0,0139]. Ранній і пізній контрасти для всіх трьох навчань наведено на рисунку 4.9.

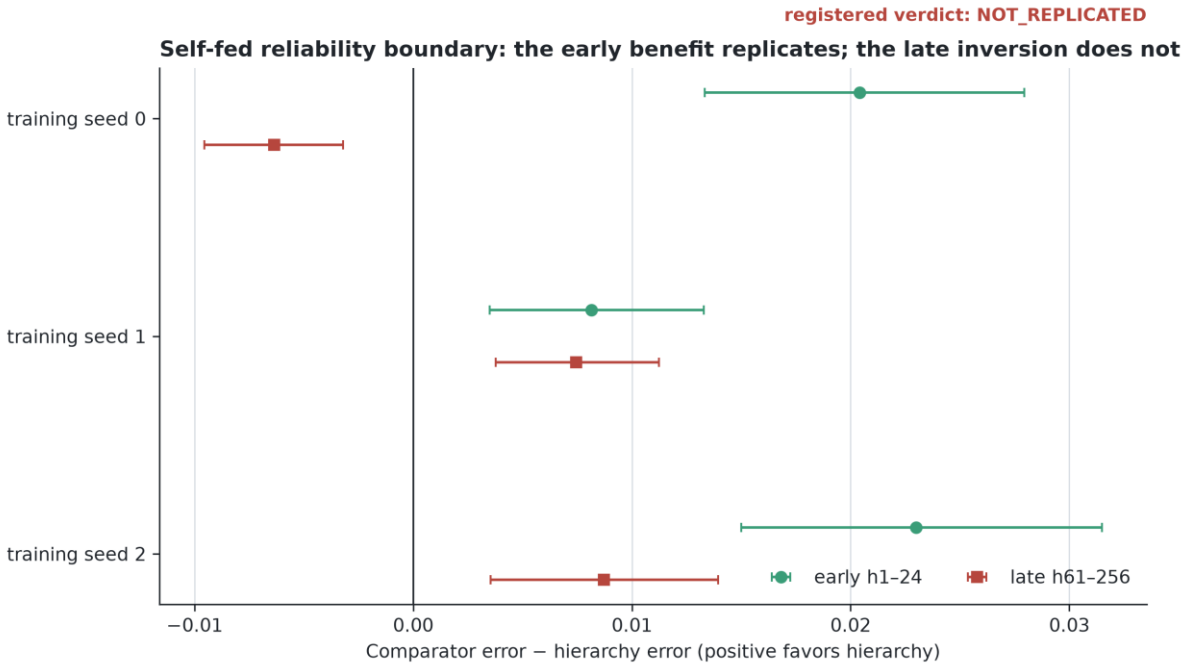


Рисунок 4.9 – Зареєстровані ефекти раннього та пізнього довгоциклового впливу. *Джерело: побудовано автором за замороженими результатами E5a.*

Невдала реплікація змінює рекомендацію дисертації. Ранню перевагу за самоподачі можна вважати відтвореною, але вік розгортання не можна використовувати як калібровану точку перемикання між ієрархічною та плоскою пам'яттю. Ініціалізація 0 також не доводить існування універсального часу деградації. Щоб пояснити відмінність цього запуску, потрібні нове зареєстроване питання, додаткові ініціалізації та діагностики, обрані до спостереження результатів. Підтверджена бюджетна межа і зовнішня перевірка вже відповідають на проєктні питання дисертації, тому продовження цієї гілки дало б радше дослідницьке пояснення, ніж необхідний доказ.

4.7.2 Еталон із прямим доступом до необробленої історії

Навчені моделі поєднують щонайменше три складнощі: стиснення минулого кадру, адресацію потрібного збереженого вмісту та поширення

прогнозів без дрейфу. E8a усуває більшу частину перших двох. Варіанти K6, K14, K38 і K48 відрізняються лише обсягом історії прогріву, що формує мозаїку. K6 дає описовий контекст для зберігання та покриття, а зареєстровані одночасні контрасти досяжності порівнюють K14 і K38 з K48 поряд із чотирма нейронними еталонами. Інтерфейс такого прямого доступу показано на рисунку 4.10.

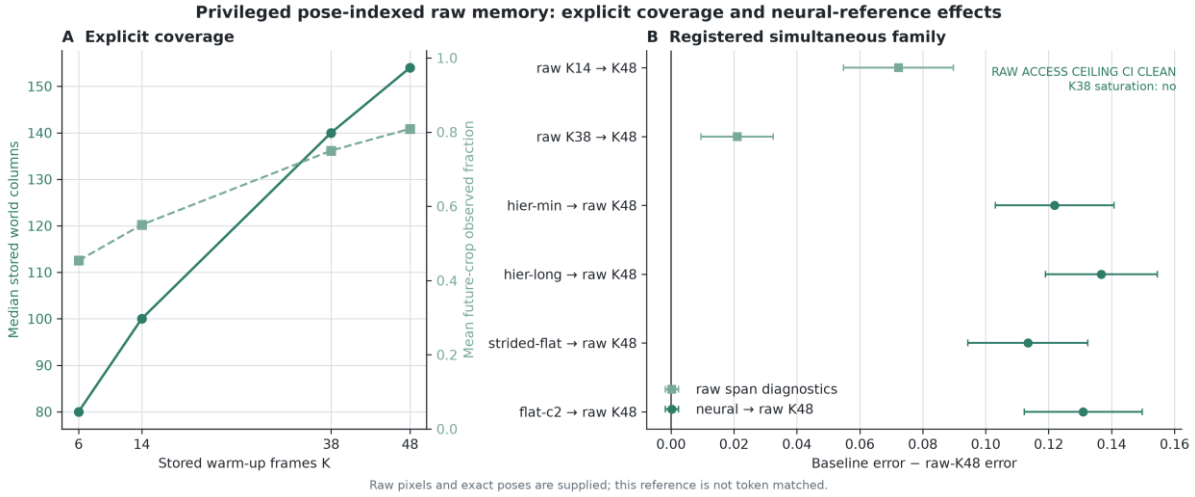


Рисунок 4.10 – Явне зберігання та доступ, індексовані за позою. Панель А показує, як зі збільшенням $K \in \{6,14,38,48\}$ кадрів розігріву змінюються медіанна кількість збережених стовпців світу та середня частка майбутнього вікна, вже покрита мозаїкою. Панель Б подає зареєстровані контрасти: два порівняння необробленої пам'яті K14/K38 з K48 і чотири розриви між нейронними моделями та K48; додатне значення означає меншу помилку еталона K48. Цей еталон має привілейований доступ до точних поз і необроблених пікселів та не зіставлений за токенним бюджетом, тому рисунок діагностує розрив доступу, а не ранжує конкурентні моделі. *Джерело: побудовано автором за замороженими результатами E8a.*

Це не конкурентна базова модель. Мозаїка не має обмеження за токенами, отримує майбутню позу, без втрат зберігає спостережувані пікселі, не потребує навченого декодера й не містить прихованого стану із самоподачею. Її призначення діагностичне. Навіть за номінальної геометричної досяжності нейронного пакета залишається значний розрив між потенційним доступом і навченим повторним використанням.

4.7.3 Межа просторового покриття та ідентичності об'єктів, що зберігаються в часі

TRB робить досяжність вимірюваною, проте його статичний світ і координати вікна не перевіряють, чи зберігає об'єкт ідентичність після зіткнень і тривалого руху із самоподачею. Три плоскі та три ієрархічні предиктори навчено з однаковими кодеком, вихідним модулем, бюджетом контексту 1 152 токени й

48-кадровим прогрівом. Оцінювання охоплює 300 згенерованих кадрів у 100 захищених кліпах.

Усі виявлені компоненти однозначно зіставляються з видимими еталонними об’єктами за замороженою угорською вартістю. Тому модель не може підвищити точність ідентичності, генеруючи лише прості для підтримання об’єкти. П’ятнадцять співпервинних ефектів, тобто п’ять показників для трьох ініціалізацій, утворюють одне одночасне сімейство максимум-статистики. Відносні ефекти потрібно читати разом з абсолютними значеннями, оскільки жодна гілка не розв’язує задачу повністю. Обидва рівні звітності поєднано в таблиці 4.5.

Таблиця 4.5 – Відносні ефекти E6 та абсолютні показники. Таблиця складається з двох явно позначених панелей. Після гармонізації знаків додатні ефекти свідчать на користь ієрархії для кожного показника. В абсолютних комірках значення подано як плоский / ієрархічний. Точність ідентичності та покриття є частками; похибку траєкторії виміряно в пікселях.

Панель А — одночасні попарні ефекти

ініціалізація	MSE переднього плану	MSE об’єднаної маски	Похибка траєкторії	Точність ідентичності	Покриття об’єкта
0	+0,0036 [−0,0074; +0,0146]	+0,0102 [+0,0019; +0,0185]	+2,4786 [+0,2130; +4,7443]	−0,0762 [−0,1106; −0,0418]	+0,0304 [+0,0016; +0,0591]
1	−0,0031 [−0,0127; +0,0065]	+0,0122 [+0,0052; +0,0192]	+1,4223 [−1,0646; +3,9092]	−0,0561 [−0,0934; −0,0188]	+0,0159 [−0,0163; +0,0482]
2	−0,0024 [−0,0131; +0,0083]	+0,0169 [+0,0093; +0,0245]	+4,1325 [+1,5271; +6,7380]	−0,0647 [−0,0955; −0,0338]	+0,0498 [+0,0161; +0,0834]

Панель Б — абсолютні значення показників

ініціалізація	MSE об’єднаної маски, плоска / ієрархічна	Похибка траєкторії, плоска / ієрархічна	Точність ідентичності, плоска / ієрархічна	Покриття, плоска / ієрархічна
0	0,6861 / 0,6759	42,19 / 39,71	0,214 / 0,138	0,619 / 0,650
1	0,6901 / 0,6779	40,20 / 38,77	0,244 / 0,188	0,646 / 0,662
2	0,6931 / 0,6763	43,79 / 39,65	0,222 / 0,158	0,599 / 0,649

Поділ між просторовою неперервністю та збереженням ідентичності узагальнено на рисунку 4.11.

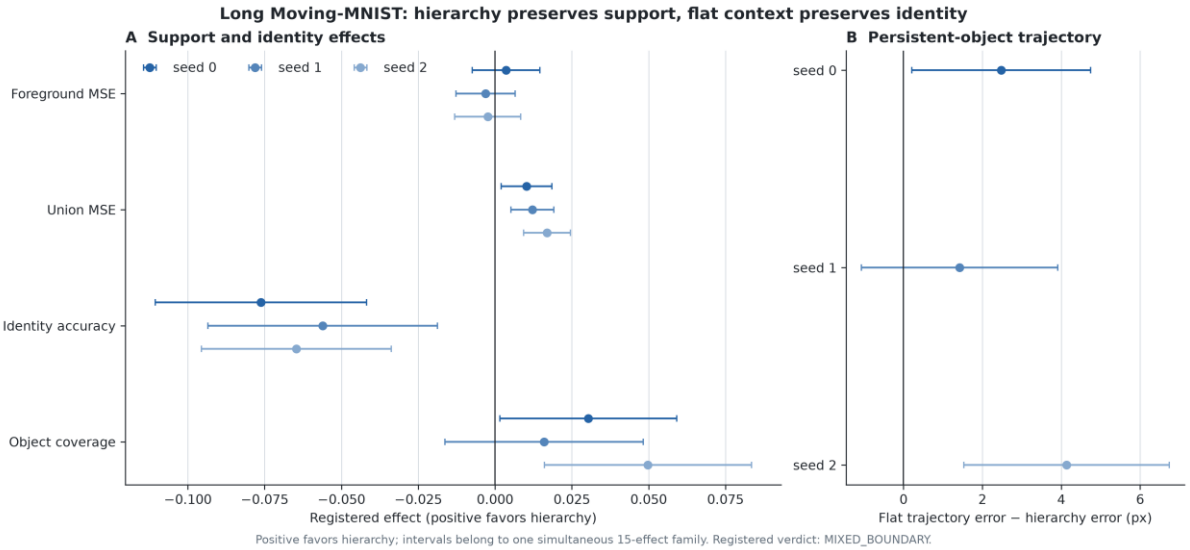


Рисунок 4.11 – Просторове покриття й неперервність проти ідентичності у довгому Moving-MNIST з об'єктами, що зберігаються в часі. Напрям покриття й похибки траєкторії сприяє ієрархії для всіх трьох ініціалізацій, але одночасні інтервали не перетинають нуль лише для ініціалізацій 0 і 2. Плоский контекст краще зберігає ідентичність цифр для всіх трьох ініціалізацій. Низькі абсолютні показники не дають підстав вважати задачу розв'язаною. *Джерело: побудовано автором за замороженими результатами E6.*

4.7.4 Межі працездатності на короткому горизонті та реальних даних

Канонічна послідовність Moving-MNIST 10→10 не містить повторного входу за межі екрану. У гілці плоскої дифузії використано десять детальних кадрів із 640 контекстними токенами, тоді як ієрархічна гілка має десять грубих та шість детальних кадрів загальним обсягом 544 токени. Їхні MSE OpenSTL становлять 180,91 та 181,29, а SSIM – 0,7625 та 0,7607 відповідно. Обидва варіанти перевершують метод незмінного продовження з MSE 286,28 і SSIM 0,6528. Водночас вони значно поступаються спеціалізованим детермінованим предикторам OpenSTL, для яких автори повідомляють MSE від 22 до 30. Це перевірка працездатності й негативний контроль: коли повторний вхід не потрібен, додавання ієрархічного проміжку не дає виміряної переваги в цьому протоколі.

Жодне порівняння не відтворює умови TRB точно. Пакети Moving-MNIST містять 640 і 544 токени контексту. Ієрархічна гілка TaxiBJ використовує вдвічі менший бюджет контексту, ніж плоска; відрізняються також набір даних, горизонт і семантика задачі. Ці тести описують працездатність, а не встановлюють перевагу ієрархії для природного відео. Для такого твердження потрібна спеціально сформована популяція з віддаленою історією, зіставлені

інтерфейси та статистичне виведення з урахуванням кластеризації за кліпами, як у TRB.

Довгий Moving-MNIST у E6 збережено саме через іншу доказову роль: він показує накопичення помилки, покриття, траєкторію та ідентичність у тривалому самоподаваному розгортанні. Структурна матриця A4 прогнозує спільне чотирикадрове вікно і тому вимірює досяжність контексту, але не доводить довготривалої авторегресивної стійкості. Нові запуски довгого Moving-MNIST до A4 не додаються; наявний E6 залишається стислою другорядною межею робастності.

4.8 Вплив структури ієрархії на якість і ресурси

Досліди досяжності та межі деталізації визначають, коли потрібна історія доступна предиктору. Структурні порівняння далі пояснюють, як витратити доступний ресурс: збільшити місткість, змінити частку рівнів, додати підтримку чи перерозподілити деталі. Кожна група відповідає методиці §3.6. У таблицях структурних порівнянь MSE означає помилку переднього плану на горизонті 4 за валідаційною агрегацією; метрики відкладеної перевірки визначаються окремо. Результати різних протоколів не зливаються в один рейтинг; відсутні вимірювання позначено без передбачення їхнього напряму.

4.8.1 Загальний бюджет і розподіл між рівнями

Бюджетний контраст перевіряє, чи однакова місткість дає різну якість за різного використання деталей і часової підтримки (§3.6.3). Таблиця нижче містить усі 18 комірок трьох політик за двома ініціалізаціями. Це описове валідаційне оцінювання при 30 000 оновлень; відкладені висновки розглядаються окремо. Датований зріз та хеші джерел збережено у реєстрі відтворення.

Таблиця 4.6 – Якість політик контексту за спільного бюджету 30 000 кроків. Менша MSE краща; дві ініціалізації наведено окремо. Оцінка використовує фіксовані 64 вибірки з поверненням, а не всі 300 валідаційних кліпів.

Бюджет	**Політика**	**MSE переднього плану h=4, ініц. 0**	**Ініц. 1**
320	плоска недавня	0,05437	0,04587
320	геометрична за віком	0,05138	0,04695

Бюджет	Політика	MSE переднього плану h=4, ініц. 0	Ініц. 1
320	лінійна за віком	0,04530	0,04399
768	плоска недавня	0,02931	0,03684
768	геометрична за віком	0,02676	0,02896
768	лінійна за віком	0,02817	0,02812
1152	плоска недавня	0,02434	0,02448
1152	геометрична за віком	0,02619	0,02484
1152	лінійна за віком	0,02605	0,02585
1792	плоска недавня	0,02225	0,02084
1792	геометрична за віком	0,01957	0,01967
1792	лінійна за віком	0,02027	0,02215
2432	плоска недавня	0,02095	0,02160
2432	геометрична за віком	0,01780	0,01864
2432	лінійна за віком	0,01893	0,01719
3072	плоска недавня	0,01839	0,01764
3072	геометрична за віком	0,01884	0,01726
3072	лінійна за віком	0,01834	0,01776

Залежність якості від бюджету не утворює монотонної бюджетної межі: геометрична політика має нижчу помилку за обох ініціалізацій на 768, 1 792 і 2 432 токенах, а на 1 152 токенах нижчу помилку має плоска політика. На 320 і 3 072 токенах напрям для цієї пари залежить від ініціалізації. Це описове порівняння фіксованих траєкторій без підтверджувального інтервалу. Політики, тривалість навчання та оцінювана популяція відрізняються від контрасту досяжності §4.4; його висновки не переносяться на FRT автоматично.

Первинне ранжування використовує MSE переднього плану на четвертому горизонті: усередині пакета сума квадратичних помилок ділиться на число еталонних пікселів переднього плану, після чого усереднюються чотири пакети. Натомість підтверджувальний оцінювач зберігає окремі помилки кліпів і горизонтів. Ці агрегації не тотожні за різної площі об’єктів. Порожня маска в наявному оцінювачі дає нуль через знаменник, обмежений знизу одиницею; кількість таких випадків слід подавати окремо. Парний аналіз вирівнює

ідентифікатори кліпів, використовує лише горизонт 4 для основної оцінки та повторно вибирає цілі кліпи. Позитивна різниця «плоска мінус ієрархічна» сприятлива для ієрархії. Інтервали для зафіксованих моделей не оцінюють розподіл між навчаннями; без заздалегідь визначеного допуску висновок про не-гіршість не формується.

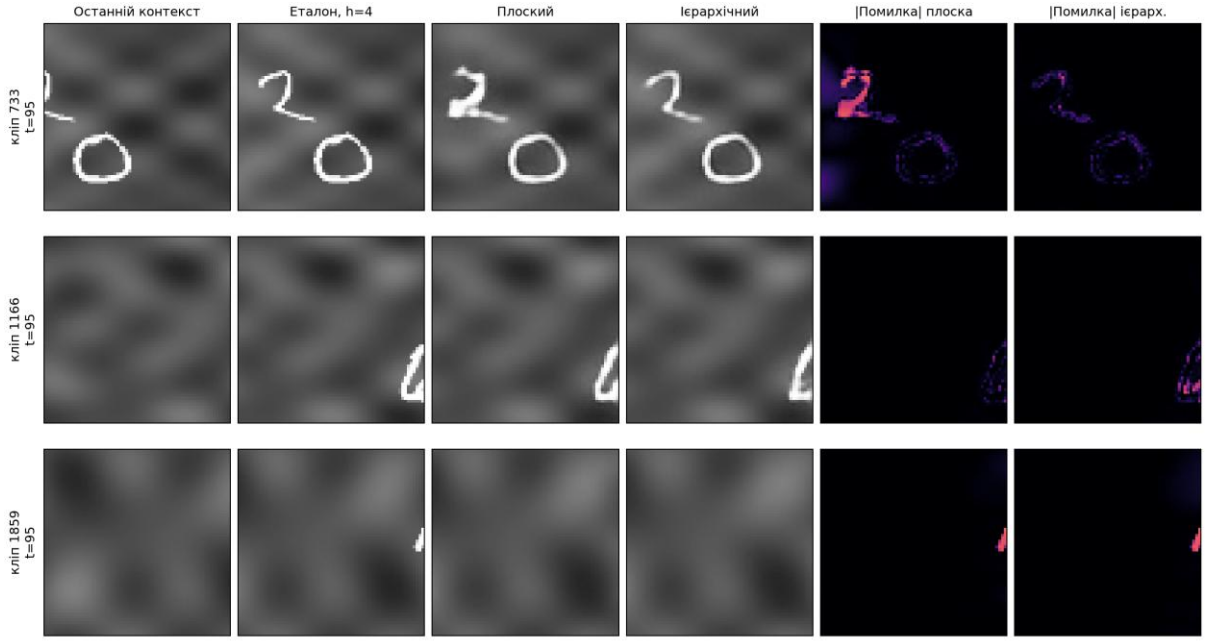


Рисунок 4.12 – Діагностичні приклади двох завершених FRT-моделей за бюджету 1 152 токени, ініціалізації 0 та 30 000 кроків. Показано останнє спостереження й четвертий прогнозований кадр. Рядки вибрано серед 16 збережених валідаційних прикладів за найбільшою перевагою ієрархії, найбільшою перевагою плоского пакета та найбільшою спільною помилкою без повторення рядків. Це навмисно вибрані випадки, а не оцінка їхньої частоти. Яскравість кадрів і абсолютних помилок має спільний діапазон [0; 1]. Ідентифікатори кліпів і часу подано на рисунку; склад давнішої історії задає відповідний план пакета, а не лише зображений останній кадр.

Залежність від загального бюджету ще не визначає його найкращого розподілу. Наступне зіставлення фіксує 1 792 токени й порівнює сім політик (§3.6.3). Воно показує, чи важливіша частка грубої підтримки, частка деталей або їхній вік. Обидві ініціалізації подаються окремо; результат розвитку визначає опорні ролі, але не замінює відкладеного підтвердження.

Таблиця 4.7 – Розподіл 1 792 контекстних токенів.

Політика	**MSE h=4, ініц. 0**	**Ініц. 1**
Плоска недавня	0,02225	0,02084
Перевага деталей	0,02333	0,02411
Збалансована недавня	0,02480	0,02262
Перевага грубого рівня	0,03060	0,03394
Лінійна за віком	0,02027	0,02215

Політика	MSE h=4, ініц. 0	Ініц. 1
Геометрична за віком	0,01957	0,01967
Орієнтована на досяжність	0,02941	0,02177

Серед семи політик ALC найменшу середню помилку має геометричний розподіл за віком (0,01962), тоді як перевага грубого рівня дає 0,03227. Отже, сама широка підтримка не компенсує невдалого розподілу деталей. Для плоскої, лінійної та геометричної політик повторно використано контрольні точки FRT; вони не є додатковими незалежними навчаннями.

4.8.2 Часова підтримка та просторово-часова деталізація

Щоб інтерпретувати розподіл бюджету, спочатку потрібно відокремити користь доданої давньої інформації від втрати недавніх деталей. У CEX шість детальних моментів незмінні, а груба підтримка поширюється за їхні межі (§3.6.4). У цьому досліді більша досяжність має більшу токенну й обчислювальну ціну; зменшення помилки слід читати разом із цією ціною.

Таблиця 4.8 – Якість за розширення грубої підтримки.

Грубих позицій	Токени / досяжність	MSE h=4, 0	Ініц. 1
0	384 / 6	0,04577	0,04479
4	448 / 10	0,04578	0,04560
8	512 / 14	0,04687	0,04356
16	640 / 22	0,04519	0,04423
32	896 / 38	0,04528	0,04382
64	1408 / 70	0,04365	0,04060

Розширення до 64 грубих позицій знижує середню помилку з 0,04528 до 0,04213, приблизно на 7%, за зростання пакета з 384 до 1 408 токенів. На проміжних розмірах зміни малі та не монотонні. Це обмежена користь доданої підтримки за її явної ресурсної ціни, а не доведена універсальна перевага довшого контексту.

Просторово-часовий контраст утримує 96 грубих моментів і 256 детальних токенів. Змінюється число деталей на момент і розклад моментів. Він відповідає

на інше питання: чи потрібні повні детальні кадри, чи достатні часткові ознаки в більшій кількості моментів.

Таблиця 4.9 – Розміщення глобальної квоти 256 деталей.

K / моментів	Недавнє, 0 / 1	Рівномірне, 0 / 1	Геометричне, 0 / 1
64 / 4	0,02753 / 0,02262	0,02989 / 0,02834	0,03754 / 0,02670
32 / 8	0,02456 / 0,01921	0,01862 / 0,02267	0,02055 / 0,02060
16 / 16	0,01919 / 0,01868	0,02112 / 0,02307	0,01845 / 0,01875
8 / 32	0,01994 / 0,02002	0,02136 / 0,02504	0,01941 / 0,02057

За сталої квоти найменшу середню помилку має K=16 з геометричним розміщенням у 16 моментах (0,01860). Чотири повні детальні моменти K=64 не є найкращими; проте подальше розрідження до K=8 також не покращує результат. План K=64 з недавнім розміщенням семантично збігається з орієнтованим на досяжність ALC; розбіжність повторних виконань не означає іншого механізму. Цей статичний контраст не встановлює переваги навчуваного членства (§4.9).

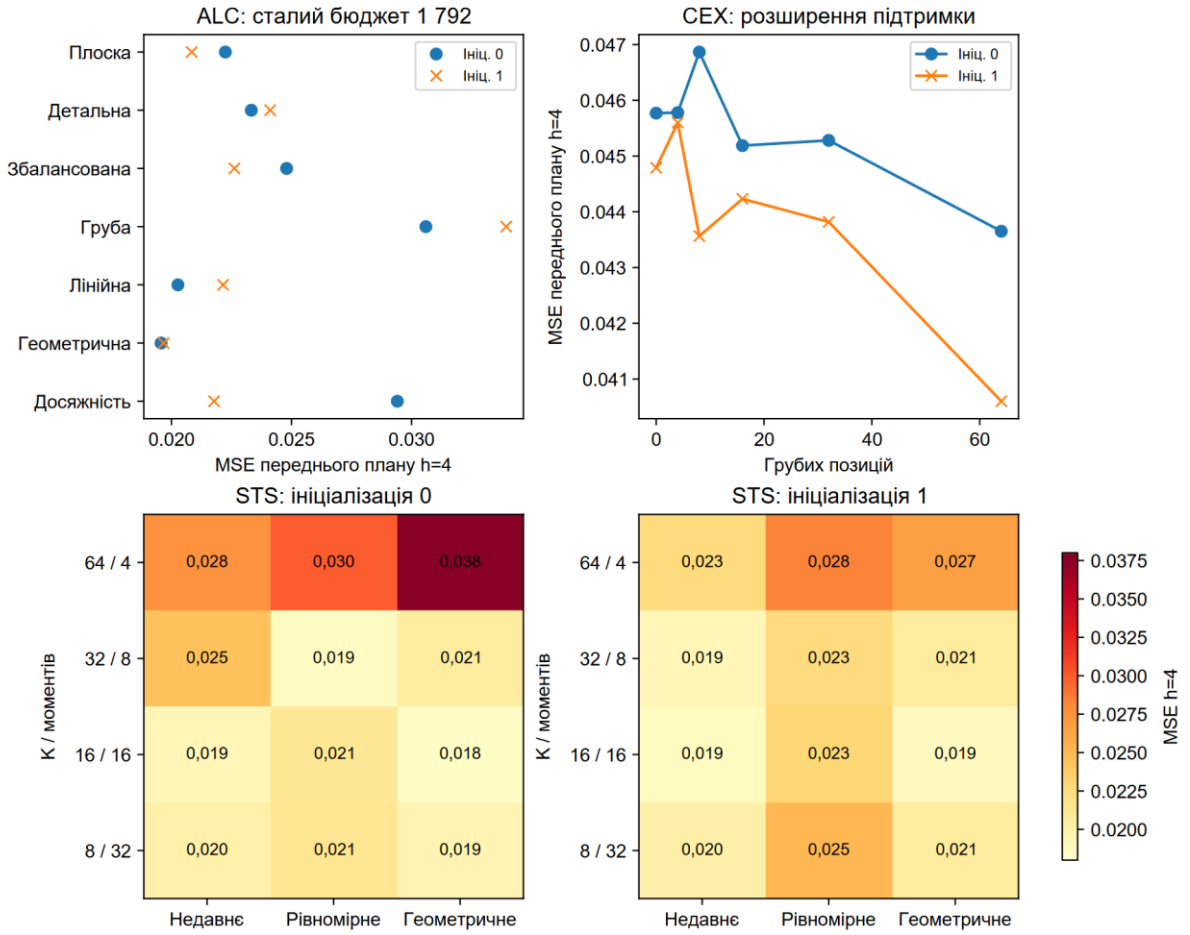


Рисунок 4.13 – Залежність помилки від розподілу й геометрії контексту. ALC і CEX показано для обох ініціалізацій; дві карти STS мають спільну шкалу. K означає число детальних комірок на момент, а число моментів дорівнює 256/K. Це розвиткова MSE переднього плану на горизонті 4 за 30 000 оновлень; вона не є відкладеною оцінкою.

4.8.3 Глибина ієрархії та перекриття представлень

За однакового бюджету додатковий масштаб забирає токени в решти рівнів. За замороженим правилом §3.6.5 опорною політикою LVL обрано geometric_age, а для OVR — balanced_recent серед допустимих для всіх схем перекриття. Вибір виконано за розвитком до відкладеної перевірки.

Таблиця 4.10 – Кількість рівнів за бюджету 1 792.

Рівні	Фізичний розподіл	MSE h=4, 0 / 1
1	28 × 64 деталей	0,02225 / 0,02084
2	Геометрична ALC	0,01957 / 0,01967
3	384 верхніх + 1 408 решти	0,02601 / 0,02504

Той самий принцип вартості застосовується до перекриття. Вкладена схема зберігає два представлення одного моменту; взаємовиключна використовує звільнену місткість для іншої підтримки; залишкова змінює ознаки деталей.

Порівняння характеризує такі пакети цілком, а не чистий ефект «усунення дублювання».

Таблиця 4.11 – Перекриття часових представлень.

Представлення	**MSE h=4, ініц. 0**	**Ініц. 1**
Вкладене	0,02480	0,02262
Взаємовиключне	0,02629	0,02649
Залишкове	0,02513	0,02774

Три рівні дають середню помилку 0,02553 проти 0,01962 у дворівневої опори: додавання масштабу за цього бюджету не допомогло. У OVR вкладена схема (0,02371) краща за взаємовиключну (0,02639) та залишкову (0,02644) у середньому за двома ініціалізаціями. Залишкова схема має змішаний напрям щодо взаємовиключної. Отже, усунення часової повторюваності або додавання масштабу не гарантує виграшу.

4.8.4 Незалежна перевірка та діагностика механізму

Результат на розвитку може залежати від вибірки й правила відбору. Тому фіксовані ролі оцінюються на 500 захищених кліпах після валідаційного вибору (§3.6.6). Позитивна парна різниця «плоска мінус ієрархічна» сприятлива для ієрархії. Інтервали повторно вибирають цілі кліпи в межах ініціалізації; вони не є оцінкою розкиду між незалежними навчаннями.

Таблиця 4.12 – Відкладена перевірка вибраних ролей.

Роль	**MSE h=4, 0 / 1**	**Δ плоска − роль, 0 / 1**
Плоска, B=1792	0,03669 / 0,03406	Опора
Геометрична ALC	0,03346 / 0,03441	0,00323 / -0,00035
STS K16, геометрична	0,02500 / 0,02381	0,01169 / 0,01026

Для чотирьох описових парних контрастів застосовано 10 000 повторних вибірок кліпів і поправку Бонферроні на сімейний рівень 0,05. Скориговані процентильні інтервали: Геометрична ALC: ініц. 0 [0,00052; 0,00679]; ініц. 1 [-0,00287; 0,00230]. STS K16, геометрична: ініц. 0 [0,00557; 0,01895]; ініц. 1 [0,00503; 0,01640]. Геометрична ALC має додатний інтервал лише за ініціалізації 0; STS K16 — за обох. Ресурсна роль також має B=1792, тому її назва не означає

фактичної економії токенів. Допуск відбору 5% не є межею статистичної негіршості. Порожні маски оброблялися нульовим чисельником і знаменником не меншим за один; їхній окремий лічильник у первинних підтверджувальних масивах не збережено.

Таблиця 4.13 – Чутливість за повного покриття валідації.

Фіксована конфігурація	**Кліпів**	**MSE h=4, 0 / 1**
Плоска, B=1792	300	0,03836 / 0,03780
Геометрична ALC	300	0,03617 / 0,03647
STS K16, геометрична	300	0,02344 / 0,02428

Усі три заморожені конфігурації оцінено без повторного відбору. STS K16 зберігає нижчу помилку за обох ініціалізацій; геометрична ALC також нижча за плоску на цих 300 кліпах, хоча у відкладеній перевірці її напрям не відтворився для ініціалізації 1. Абсолютні значення не ототожнюються з відбірковими: тут використано кожний кліп один раз і середнє покліпових похибок, тоді як розвитковий журнал агрегує пікселі переднього плану в пакетах із 64 вибірками з поверненням.

Таблиця 4.14 – Діагностика поведінки контекстних пакетів.

Роль	**MSE повторного входу, 0 / 1**	**Ентропія уваги, 0 / 1**
Плоска	0,10539 / 0,09577	0,60453 / 0,62458
Геометрична ALC	0,09854 / 0,09888	0,67073 / 0,64506
Перевага грубого рівня	0,07751 / 0,07507	0,58258 / 0,65470

Помилка повторного входу агрегована за 76 позначеними записами «кліп–горизонт» із 2 000; це не 76 незалежних кліпів. Ентропія уваги нормована та усереднена за шарами одного фіксованого пробного вікна, а не за всіма 500 кліпами. Груба політика має меншу помилку повторного входу, але гіршу загальну h=4-помилку за геометричну ALC; це вказує на різні вимоги до підтримки та деталізації. У STS K16 помилка повторного входу становить 0,03690 / 0,04538. Увага є діагностикою, а не причинним доказом використання історії.

Таблиця 4.15 – Умовна перевірка рекурсивного прогнозу.

Горизонт	Плоска, 0 / 1	Ієрархічна, 0 / 1
4	очікується	очікується
16	очікується	очікується
32	очікується	очікується
64	очікується	очікується

Цей умовний дослід виконується лише для висновку про самоподачу: 100 фіксованих діагностичних кліпів, одна пара, дві ініціалізації, без додаткового навчання. До виконання таблиця не підтримує довгогоризонтної переваги. Криві помилки за горизонтом та зіставлений приклад траєкторії займають місце лише після отримання справжніх прогнозів.

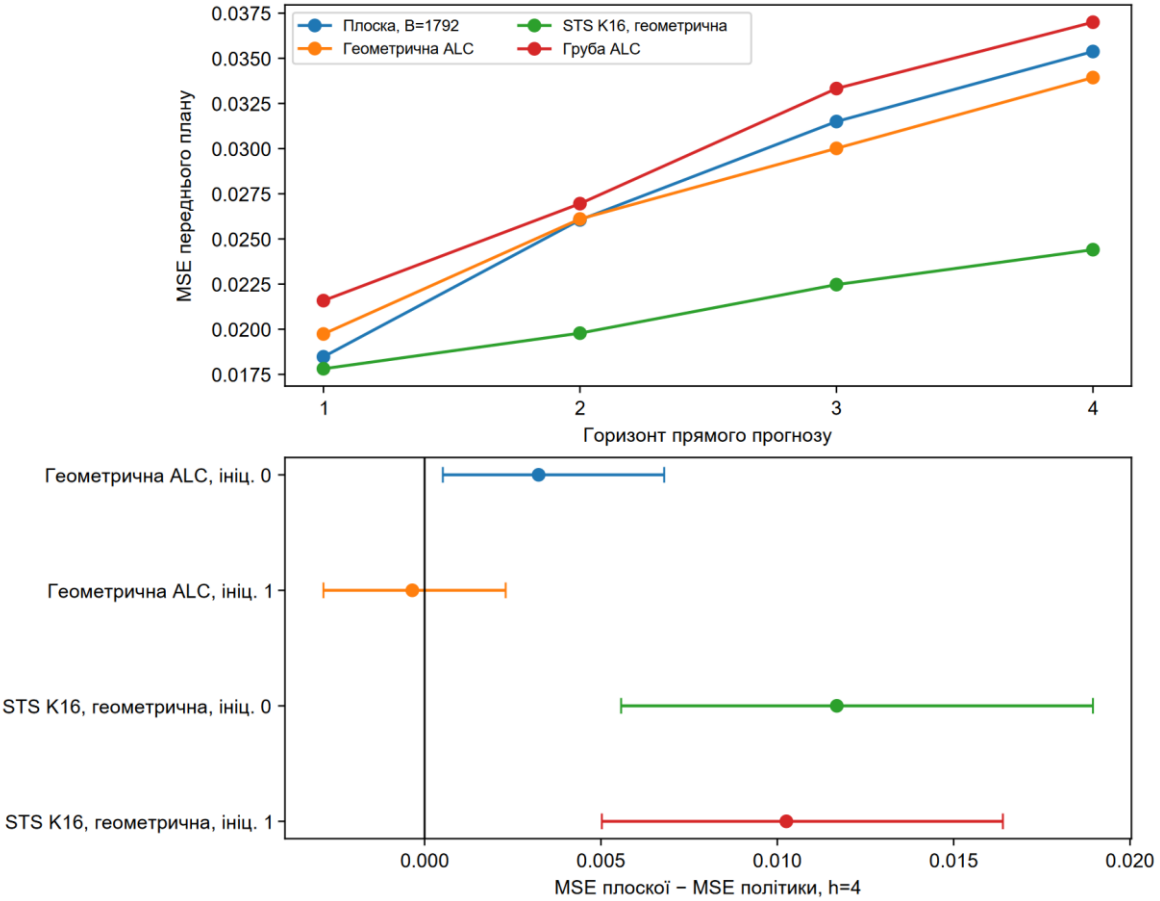


Рисунок 4.14 – Помилка за горизонтом і парні відкладені контрасти. Угорі середні покліпові похибки на 500 захищених кліпах, усереднені за двома ініціалізаціями; внизу окремі парні h=4-різниці та інтервали з поправкою на чотири контрасти. Додатна різниця сприятлива для ієрархічної політики. Горизонти 1–4 є прямим прогнозом, а не 64-кадровою самоподачею.

4.9 Якість і ресурсні властивості ієрархічного предиктора

Структура пакета визначає доступну інформацію, але його практична вартість залежить від реалізації предиктора. Тому тут зіставляються три

властивості: працездатність компактного просторового подання, витрати диференціювання та якість прогнозу на двох задачах. Експеримент зі сталими ділянками дає виміряний приклад компактного інтерфейсу. Контракт адаптивного пакування й внутрішнього реверсивного ядра (§3.7) потребує окремих числових і ресурсних перевірок; показники різних виконуваних динамік залишаються розділеними.

4.9.1 Фізичне пакування та працездатність просторового подання

Можливість зберігати довшу історію та можливість відтворювати активації не гарантують працездатності їх композиції. Просторовий інтерфейс повинен справді обмежувати живий стан і залишати достатньо інформації декодеру. Перевірка зі сталими ділянками ізолює цю вимогу від складності навчання членства деталей. Її результат характеризує компактне подання за заданого протоколу Moving MNIST, тоді як структура тривалого контексту досліджується на TRB.

Варіант із жорсткою маршрутизацією використовував жорсткий вибір K ділянок за інформаційною щільністю. Маршрутизатор знаходив передній план, а варіант із чотирма останніми детальними ділянками наближався до контрольної моделі за MSE та повнотою виявлення. Водночас точність виявлення погіршувалася, жорстка дискретна операція ускладнювала оптимізацію, а повні детальні карти фактично залишалися в стані обчислення. Отже, цей варіант демонстрував роботу сигналу маршрутизації, але не забезпечував доведеного скорочення пам’яті. Фіксована геометрія ділянок дає контрольний спосіб відокремити працездатність подання від навчання політики маршрутизації.

У предикторі зі сталими ділянками кожен кадр 64×64 подано 16 грубими токенами та вісьмома токенами фіксованих детальних ділянок. Кожен токен містить 16 скалярних значень, тому пакет має 24 токени, або 384 збережені значення на кадр. Необроблений кадр містить 4 096 значень, а щільне одночасне зберігання грубого й детального рівнів – 1 280. Відповідні коефіцієнти скорочення корисного навантаження становлять $4096/384 = 10{,}67$ і $1280/384 = 3{,}33$. Для проєктної історії з 48 кадрів це дало б 1 152 токени, однак

фактичний тест якості Moving-MNIST використовує десять вхідних кадрів, тобто 240 токенів. Проєктну місткість не слід ототожнювати з емпірично перевіреною часовою досяжністю.

Якість перевірено за протоколом Moving-MNIST 10→10 у конвенції показників OpenSTL [1]. Після вибору контрольної точки за останніми 500 згенерованими навчальними кліпами канонічну тестову вибірку з 10 000 кліпів використано один раз. Через одну ініціалізацію та публічний статус набору цей результат є обмеженим доказом технічної здійсненності. Показники прототипу й базових моделей зведено в таблиці 4.16.

Таблиця 4.16 – Якість інтегрованого прототипу та базових моделей на Moving-MNIST 10→10. Менше значення є кращим. Офіційні показники OpenSTL наведено за його таблицею моделей [1]; SimVP-gSTA відтворено локально. Різні тренувальні рецепти не дають підстав для причинного ранжування архітектур.

Модель	**Умова**	**MSE**	**MAE**
Інтегрований SimVP із фіксованими ділянками	вибрана контрольна точка, 10 000 кліпів	28,72	80,27
Заморожений SimVP і навчений адаптер ділянок	10 000 кліпів	28,87	78,74
Локальний SimVP-gSTA без пакування	200 епох	26,69	77,36
OpenSTL ConvLSTM-S	200 епох	29,80	90,64
OpenSTL E3D-LSTM	200 епох	35,97	78,28
OpenSTL SimVP-IncepU	200 епох	32,15	89,05
OpenSTL TAU	200 епох	**24,60**	**71,93**

За MSE інтегрований варіант кращий за наведені ConvLSTM-S, E3D-LSTM і SimVP-IncepU, але поступається локальному SimVP-gSTA та TAU. За MAE він випереджає ConvLSTM-S і SimVP-IncepU, незначно поступається E3D-LSTM та виразніше – SimVP-gSTA і TAU. Результат тому підтверджує працездатність компактного інтерфейсу, а не лідерство за якістю.

4.9.2 Часова рекурентність і вимірювання пам’яті

Профіль порівнював звичайне зворотне поширення крізь час із реверсивним відтворенням станів за спільних модулів, початкових параметрів, формату входу та функції втрат. За розміру мініпакета 1 значення втрат збіглися в усіх трьох горизонтах, а норми градієнта першого параметра відрізнялися не

більше ніж на $7{,}4 \cdot 10^{-6}$. Однак реверсивна оболонка реалізує другопорядкове адитивне оновлення: після першого переходу її зовнішня динаміка не тотожна звичайному повторенню однокрокового предиктора. Профіль також обчислював втрату відносно нульових цільових тензорів, а не якість прогнозу майбутніх кадрів. Тому таблиця 4.17 є інженерною характеристикою масштабування пам’яті конкретного прототипу, але не причинно зіставленим доказом економії для тієї самої прямої функції.

Таблиця 4.17 – Пікова додаткова пам’ять інтегрованого предиктора з часовою рекурентністю за різної довжини ланцюга. Вимірювання виконано на NVIDIA GeForce RTX 4060 Ti без градієнтних контрольних точок; наведено приріст max_memory_allocated відносно стану безпосередньо перед прямим проходом, у десяткових мегабайтах. Режими мають різну зовнішню рекурентну динаміку після першого переходу.

Прогнозовані кадри	Реверсивний режим, МБ	Звичайний BPTT, МБ	Відношення BPTT / реверсивний
10	352,15	353,06	1,003
20	549,73	708,74	1,29
40	550,86	1 418,79	**2,58**

Залежність пікової пам’яті від горизонту наочно показано на рисунку 4.15.

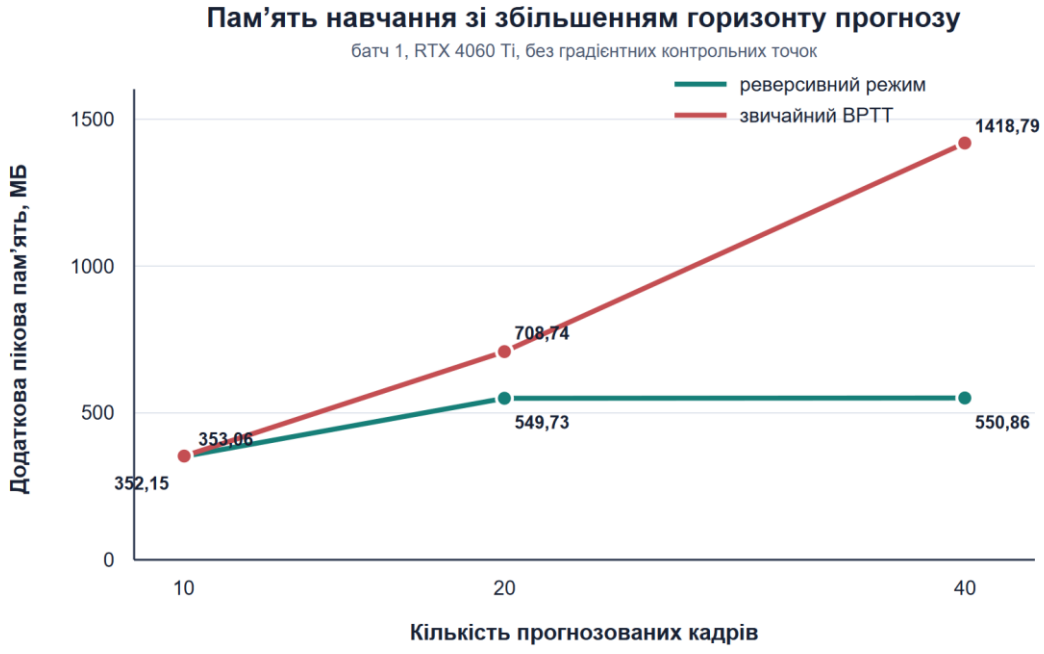


Рисунок 4.15 – Зростання пам’яті інтегрованого предиктора з часовою рекурентністю зі збільшенням довжини ланцюга. За 10 кроків накладні витрати реверсивного режиму майже дорівнюють BPTT. Між 20 і 40 кроками його пік залишається практично сталим, тоді як пам’ять BPTT майже подвоюється. Це виміряна властивість двох конкретних режимів із різною зовнішньою динамікою, а не порівняння тотожної прямої функції чи асимптотична гарантія для довільної архітектури. *Джерело: побудовано автором за профілем integrated_reversible_openstl_memory.json.*

Порівняльний профіль із розміром мініпакета 2 додає зовнішній масштаб, але має неоднакові горизонти для різних моделей. Інтегрований реверсивний варіант і його BPTT-контроль прогнозували 20 кадрів; E3D-LSTM та ConvLSTM обробляли 20-кадрову послідовність, тоді як SimVP-IncepU і SimVP-gSTA прогнозували лише 10 кадрів. Тому повну довідкову таблицю перенесено до таблиці Ж.3 додатка Ж.

Інтегрована модель має нижчі MSE та виміряну пам’ять, ніж E3D-LSTM, хоча її MAE дещо гірша. Рядки SimVP-IncepU та SimVP-gSTA також поєднують нижчі MSE і пам’ять за власного 10-кадрового протоколу, тому зовнішня таблиця не встановлює унікального положення чи спільної межі Парето. ConvLSTM використовує істотно менше абсолютної пам’яті, а SimVP-gSTA та TAU дають кращу якість. Найсильніший допустимий висновок стосується не ранжування зовнішніх моделей і не однакової прямої функції: у предикторі зі сталими ділянками другопорядкове реверсивне виконання мало у 2,58 раза менший виміряний пік на 40 кроках, ніж звичайний BPTT-профіль, за близьких діагностичних втрат і градієнтів. Інтегрована модель з адаптивним пакуванням переносить реверсивність усередину Transformer-ядра саме для того, щоб звичайний і реверсивний режими мали тотожний прямий прохід; її CUDA-пам’ять потребує окремого вимірювання.

4.9.3 Рівень доказовості та межі композиційного виграшу

Перевірка технічної здійсненності показує, що три компоненти можуть бути з’єднані на рівні інтерфейсів. Фіксовані ділянки стискають просторовий стан, регресійний декодер повертає прогноз у простір кадрів, а другопорядкова реверсивна оболонка обмежує зростання виміряного піку. Водночас вона встановлює межу такого складання: скорочення корисного навантаження у 10,67 раза та відношення піків 2,58 отримано для різних величин і різних виконуваних динамік, тому їх не можна перемножувати або подавати як загальну економію GPU.

Дослід має одну ініціалізацію, не перевіряє 48-кадрову досяжність, TRB, TaxiBJ чи природне відео та не ізолює перевагу інформаційної щільності над

фіксованим просторовим розкладом. Отримані числа не додаються до підтверджувальної сім'ї E2–E8. Їхня роль у дисертації вужча: продемонструвати технічну сумісність інтерфейсів і визначити вимоги до моделі з адаптивним пакуванням — фізичне вилучення токенів, позиційне кодування за координатами, маршрутизатор поза реверсивною межею, тотожну пряму функцію звичайного й реверсивного ядра та дві незалежні ініціалізації на Moving MNIST і TaxiBJ.

4.9.4 Числова коректність і ресурсна вартість

Структурні досліди показують поведінку заданого пакета. Для адаптивного предиктора окремо перевіряються членство деталей і реалізація диференціювання (§3.7.7). Копіювання останнього кадру не є достатньою перевіркою ядра: ненульова проєкція має передавати залежність від пам'яті до виходу й градієнтів.

Таблиця 4.18 – Перевірка однакового обчислення.

Умова	**Вихід / градієнти**	**Статус**
CPU FP32	Ненульова проєкція; залежності	Перевірено
CUDA FP32, обидві задачі	atol 3×10^{-5}; rtol 4×10^{-4}	Пройдено
CUDA BF16, обидві задачі	atol 0,01; rtol 0,08	Пройдено

На CUDA зіставлено звичайне ядро, контрольні точки та реверсивне ядро за однакових ваг і входів, пакетів 8 для Moving MNIST та 16 для TaxiBJ. Виходи, входові й активні параметричні градієнти пройшли перевірку з наведеними допусками. Це допуски тесту, а не виміряні максимальні розбіжності: первинний звіт зберіг факт проходження, але не їхні максимуми. Використано фіксовану ненульову проєкцію для числової проби, а не навчений прогноз як свідчення якості.

Таблиця 4.19 – Повний ресурсний профіль предиктора. Навчальний крок, адаптивне пакування, BF16-autocast; Moving MNIST: пакет 8, TaxiBJ: пакет 16. Медіани п'яти повторів після двох прогрівань; пам'ять у GiB, час у секундах.

Задача / режим	**Пік allocated / reserved**	**Додатковий пік / час**
Moving MNIST: звичайний	0,764 / 0,814	0,739 / 0,0670
Moving MNIST: контрольні точки	0,690 / 0,816	0,665 / 0,1034
Moving MNIST: реверсивний	0,673 / 0,797	0,647 / 0,0796

Задача / режим	Пік allocated / reserved	Додатковий пік / час
TaxiBJ: звичайний	0,174 / 0,201	0,150 / 0,1155
TaxiBJ: контрольні точки	0,159 / 0,186	0,135 / 0,0508
TaxiBJ: реверсивний	0,156 / 0,184	0,132 / 0,1213

Повний профіль охоплює 72 умови: дві задачі, FP32 і BF16, плоске, статичне та адаптивне пакування, три режими ядра, застосування й навчальний крок. Вимірювання виконано на RTX 4060 Ti зі сталими початковими вагами, ненульовою вихідною проєкцією та синтетичним входом. Кожний повтор створює стан AdamW заново з нульовою швидкістю навчання; це контрольований ресурсний зонд, а не час епохи повного навчання з Adam. Діагностичний граф вивільняється до вимірювання; базова allocated-пам’ять між трьома режимами адаптивного пакета однакова: 0,0255 GiB для Moving MNIST і 0,0240 GiB для TaxiBJ.

У BF16 реверсивне ядро зменшує повний allocated-пік відносно звичайного з 0,764 до 0,673 GiB для Moving MNIST і з 0,174 до 0,156 GiB для TaxiBJ — приблизно на 12 % і 10 %. У FP32 відповідні піки становлять 1,106→0,945 та 0,250→0,218 GiB. Отже, виграш внутрішнього ядра зберігається на рівні предиктора, але його обмежують інші активації, декодер і робочі буфери. Це не коефіцієнт скорочення всього навчального процесу за довільного горизонту.

Час має окрему невизначеність: для реверсивного TaxiBJ у BF16 п’ять повторів дали 0,052–0,197 с. За такого розкиду медіани не обґрунтовують стійкого ранжування швидкодії. Реєстр зберігає всі повтори й точні байти; окремі операції ядра цим повним профілем не виміряні. За BF16-autocast упаковані токени залишаються FP32, а груба обхідна карта — BF16. Тому аналітичне скорочення кількості токенів не підміняє вимірювання байтів.

4.9.5 Працездатність навчання та якість прогнозу

Короткі траєкторії перевіряють, чи можна навчати конфігурацію та скільки коштуватиме повний протокол. Статичний та адаптивний ієрархічні контролі мають спільні ознаки й змінюють спосіб членства; плоский контроль змінює

також склад пакета; їхні короткі втрати не встановлюють переваги за кінцевою якістю.

Таблиця 4.20 – Обмежені перевірки навчання.

Задача / пакет	Валідаційна MSE / норма градієнта	Оновлень/с / статус
Moving MNIST, адаптивний	0,058327 / 0,164	6,27 / 200 кроків
TaxiBJ, адаптивний	0,001582 / 0,060	11,39 / 200 кроків
Moving MNIST, плоский	0,058286 / 0,240	5,19 / 200 кроків
Moving MNIST, статичний	0,058350 / 0,195	6,70 / 200 кроків

Усі чотири короткі траєкторії завершили 200 оновлень із скінченними втратами й ненульовими градієнтами; тестову вибірку не оцінювали. У таблиці наведено повну валідаційну MSE, останню записану норму градієнта та медіанну швидкість без першого інтервалу. Графіки навчання, точність BF16, розбиття й правило вибору контрольної точки зафіксовано для чотирьох повних навчань. Вони перевіряють прогнозну працездатність композиції; близькі втрати коротких контролів не доводять рівності кінцевої якості.

Таблиця 4.21 – Якість ієрархічного предиктора. Тестова вибірка, контрольна точка з мінімальною валідаційною MSE. MSE та MAE усереднено за пікселями й каналами у нормалізованих одиницях завантажувача.

Задача / горизонт	Ініціалізація	MSE / MAE	SSIM / PSNR, dB
Moving MNIST, 10→10	0	0,009894 / 0,028959	0,8206 / 20,66
Moving MNIST, 10→10	1	0,010035 / 0,029246	0,8190 / 20,60
TaxiBJ, 4→4	0	0,000279 / 0,009606	0,9652 / 37,69
TaxiBJ, 4→4	1	0,000276 / 0,009615	0,9644 / 37,68

Moving MNIST оцінено на 10 000 тестових кліпах, TaxiBJ — на 500; усі прогнозні кадри входять до підсумку. MSE і MAE обчислено без обрізання прогнозу. Для SSIM та PSNR прогноз і ціль обмежено інтервалом [0; 1], після чого показники усереднено за кадрами. Moving MNIST нормалізовано діленням на 255, TaxiBJ — перетворенням (x+1)/2; зворотного переходу до фізичних одиниць потоку немає. Кадрова сума MSE дорівнює піксельній MSE, помноженій на 4096 для Moving MNIST і на 2048 для двоканального TaxiBJ. Їх не слід змішувати з foreground MSE структурної матриці TRB.

Кожна ініціалізація Moving MNIST завершила 200 епох, або 250 000 оновлень; TaxiBJ — 100 епох, або 115 000 оновлень. Вибрано епохи 198 і 199 для Moving MNIST та 55 і 64 для TaxiBJ, рахуючи від одиниці. Відповідні валідаційні мінімуми становлять 0,010104 і 0,010279 та 0,0002652 і 0,0002662. Тест виконано один раз після вибору. Під час навчання змішана політика використовує адаптивний вибір із ймовірністю 0,75 та статичну квоту інакше; під час оцінювання вибір завжди адаптивний.

Близькість двох ініціалізацій підтримує відтворюваність працездатності композиції за цим протоколом, але не встановлює переваги над повністю навченим плоским або статичним контролем. Для Moving MNIST піксельна MSE від першого до десятого кадру зростає з 0,00698 до 0,01279 та з 0,00697 до 0,01329. Це прямий прогноз десяти кадрів, а не довгий рекурсивний прогін. Криві валідації й похибки за горизонтами наведено на рисунку И.1; покліпові тестові похибки не збережено, тому довірчі інтервали з агрегованих чисел не відновлюються.

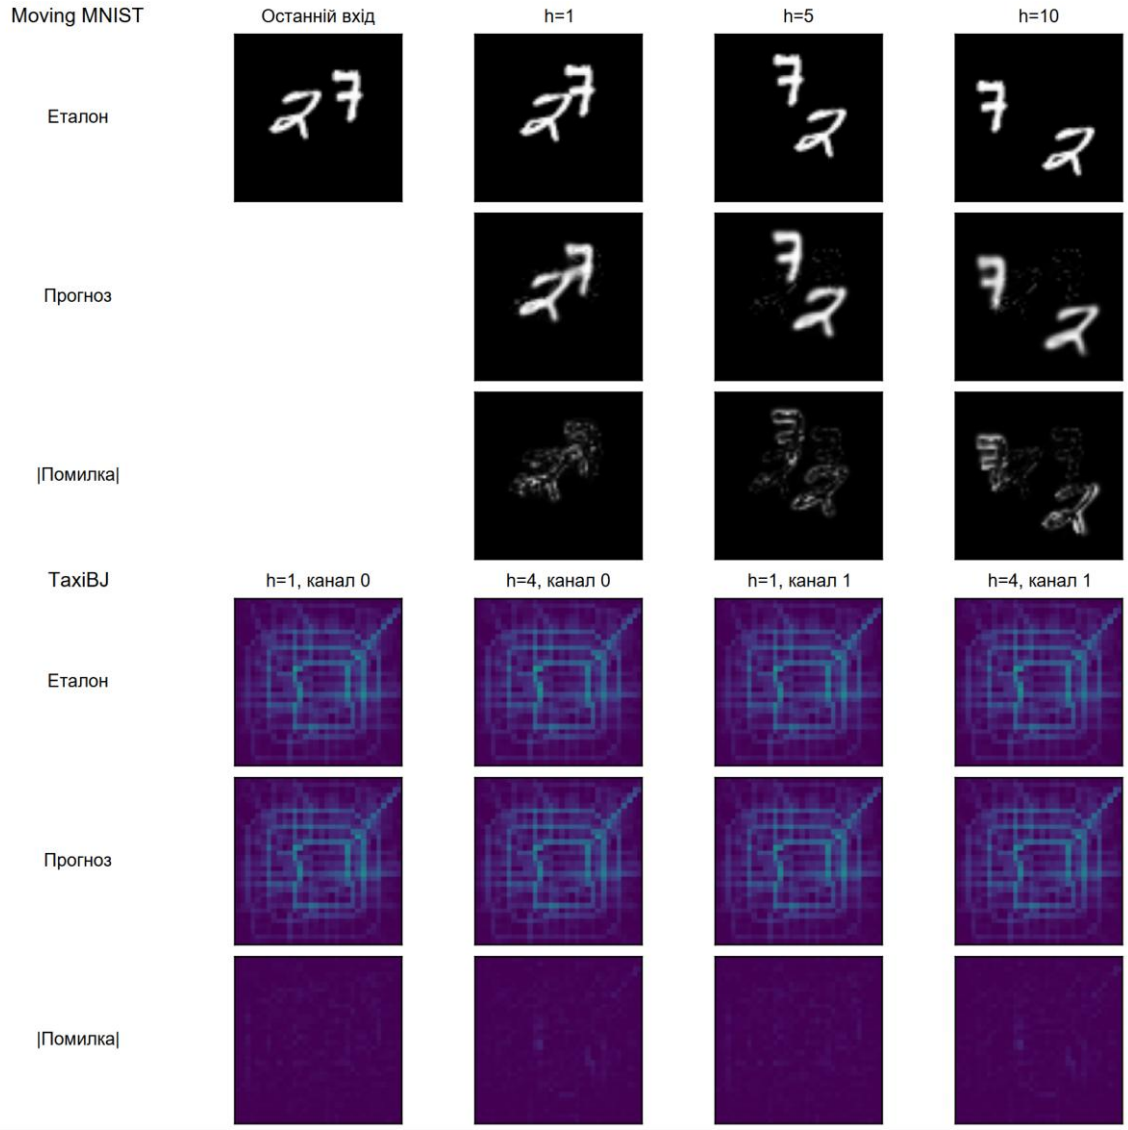


Рисунок 4.16 – Прогнозні приклади для двох задач. Перший кліп фіксованої тестової вибірки, ініціалізація 0, контрольна точка з мінімальною валідаційною втратою; приклади не відбирали за якістю. Угорі Moving MNIST: останній вхідний кадр та горизонти 1, 5 і 10. Унизу TaxiBJ: горизонти 1 та 4 для обох каналів потоку. Для цілі й прогнозу спільна шкала [0; 1]; абсолютна помилка також показана у шкалі [0; 1]. Канали TaxiBJ не є ідентичностями рухомих об’єктів. Приклади ілюструють локалізацію похибки; агреговану оцінку наведено в таблиці 4.21.

Таблиця 4.22 – Сумісність компаратора для твердження про якість.

Умова	**Контрольна точка / протокол**	**Результат**
Сумісний незалежний компаратор	очікується	умовний дослід

Якщо сумісної контрольної точки немає, висновок обмежується працездатністю. Порівняння з опублікованим числом за іншим розбиттям або з коротким контрольним навчанням не замінює повного зіставного досліду.

4.10 Правило вибору методу на системному рівні

Синтез поєднує встановлені ефекти з умовами їх застосування. Незаповнені структурні та інтегровані вимірювання не підтримують

рекомендації самі по собі: відповідні гілки правила залишаються перевірними кандидатами. Змішані напрями FRT не дозволяють звести всі бюджети до однієї монотонної межі.

Результати попередніх підрозділів описують різні дефіцитні ресурси, тому їх не можна згорнути в один універсальний рейтинг. Цей підрозділ перетворює емпіричні межі на послідовність діагностики: спочатку визначається, чи бракує досяжності, деталізації або пам’яті активацій, а вже потім обирається відповідне втручання.

4.10.1 Діагностика обмежувальних умов

Результати не визначають одну модель, яка має замінити всі інші. Натомість вони задають послідовність питань, що повинні передувати вибору архітектури. Спочатку потрібно з’ясувати, яка помилка є найдорожчою для задачі. Система, що має зберігати зайнятість простору, геометрію або траєкторію, допускає інші втрати, ніж система, якій необхідно відтворювати обличчя, клас цифри чи дрібну текстуру. Ця відмінність визначає релевантний критерій консистентності: просторове покриття або ідентичність.

Повна діагностика містить чотири окремі перевірки. Потрібно встановити, чи лежить релевантне спостереження поза доступним плоским вікном; чи в цільовій задачі домінує просторове покриття або точна ідентичність; чи обмеження виникає у збереженому стані під час застосування або в активаціях під час навчання; чи є інформаційна щільність настільки неоднорідною й часово стабільною, щоб динамічне розміщення детальної квоти було кориснішим за детермінований розклад. Відповіді стосуються різних величин, тому одна позитивна перевірка не замінює решту.

Далі потрібно перевірити, чи доступне потрібне минуле. Коли свідчення повторного входження лежать поза поточним плоским вікном, поліпшення локальної точності не поверне їх до контексту. Просторово груба, але часово щільна історія може збільшити досяжність; часово розріджені детальні прив’язки також її збільшують, проте втрачають іншу інформацію. Щільний грубий потік є безпечнішим, коли важливі зміни між прив’язками. Розріджені

детальні прив’язки доцільніші, коли старіші стани змінюються повільно, а точний вигляд у вибрані моменти є визначальним.

Окреме питання навчання полягає в тому, чи відповідає диференціація в межах бажаного часового процесу бюджету пам’яті активацій. Коли кінцевий предиктор навчається на обмежених вікнах, описаних у розділі 3, реверсивний часовий ланцюг є непотрібним. Довша часова диференціація може вимагати контрольних точок або реверсивного відтворення, обидва з яких працюють на активаціях, а не на контекстному стані, виміряному в цьому розділі.

Нарешті, просторове пакування має зменшувати фактично збережений стан, а не лише логічну кількість токенів. Жорсткий вибір ділянок не пройшов цю перевірку, бо прототип утримував повні детальні карти. Фіксований пакет із підрозділу 4.9 справді обмежує корисне навантаження до 384 значень на кадр і є прикладом компактного інтерфейсу. Модель з адаптивним пакуванням фізично вилучає детальні токени сталої квоти, але її повний живий стан додатково містить службові індекси, метадані та грубу сітку на межі декодера; отже, аналітичне відношення токенів не замінює end-to-end профілю. Жоден із цих фактів сам по собі не доводить, що динамічне розміщення краще за фіксовану геометрію. Розмежування двох виміряних ресурсних осей узагальнено на рисунку 4.17.

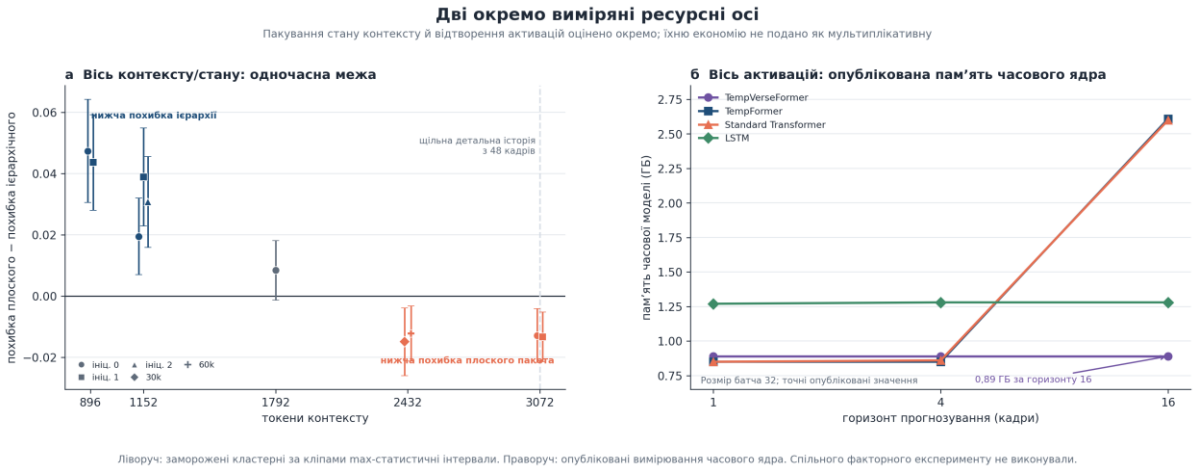


Рисунок 4.17 – Дві окремо виміряні осі ресурсів. Пакування контексту зменшує обсяг збереженого стану під час застосування, тоді як реверсивне відтворення зменшує активації під час навчання. Перевірка технічної здійсненності підтвердила сумісність цих механізмів у спільному прототипі, але їхні коефіцієнти не описують одну величину й не перемножуються. *Джерело: авторський синтез вимірювань розділів 2 і 4.*

З цього розмежування випливає послідовність практичного вибору, подана на рисунку 4.18: спочатку визначають дефіцитний ресурс, а вже потім обирають втручання.

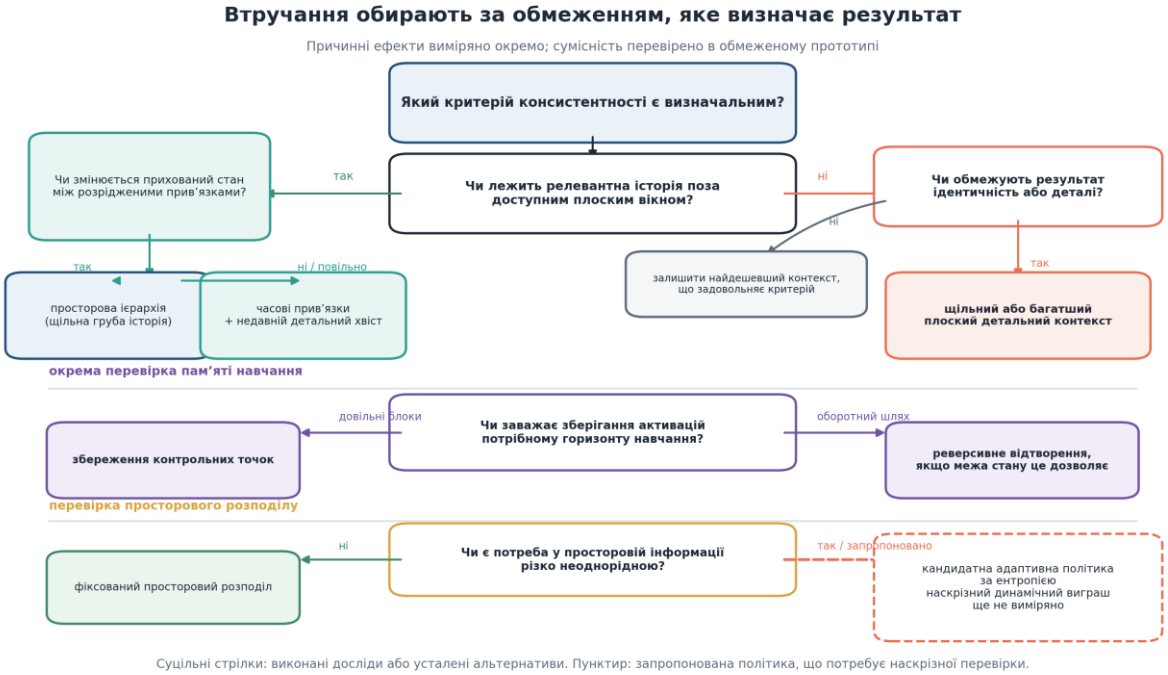


Рисунок 4.18 – Алгоритм вибору методу за обмежувальним ресурсом. Спочатку визначають дефіцитний ресурс: досяжність, деталізацію або пам'ять активацій. Лише після цього обирають ієрархію, щільний контекст, градієнтні контрольні точки чи реверсивне відтворення. *Джерело: авторська схема за результатами розділів 2–4.*

4.10.2 Узагальнене правило застосовності

Вибір методу починається з двох головних запитань: який ресурс обмежує систему та яка властивість прогнозу є критичною. Якщо релевантне минуле не вміщується у плоске вікно, кандидатом для перевірки є просторово ієрархічний або часово прорідженний контекст. Перший зберігає щільну часову підтримку ціною деталей, другий – точні прив'язки ціною проміжної динаміки. Коли потрібне минуле вже доступне й критичною стає ідентичність, щільний плоский контекст є важливим контрольним кандидатом.

Пам'ять активацій утворює іншу вісь рішення. Градієнтні контрольні точки підтримують довільні нереверсивні блоки, тоді як реверсивне відтворення замінює збереження частини станів повторним обчисленням. Просторове подання за інформаційною щільністю залишається перспективним розподільником, але динамічна політика не підтверджена інтеграційним

дослідом. Повну матрицю втручань, їхню вартість, рівень доказовості та придатну область перенесено до таблиці В.6 додатка В.

Це правило запобігає категоріальним помилкам. Пакування контексту не усуває зростання пам’яті активацій у довгому диференційованому ланцюзі, а реверсивне відтворення не може надати спостереження, відсутні під час застосування. Карта ентропії не стає перевіреним динамічним розподільником без реалізованої політики та виміряного компромісу між обчисленнями і якістю. Нарешті, коефіцієнт скорочення збережених значень не можна подавати як такий самий коефіцієнт зменшення всієї пам’яті GPU.

4.10.3 Взаємозв’язок між розробленими методами

Розроблені методи стосуються сусідніх, але різних інтерфейсів однієї системної задачі. Критерії консистентності визначають, яку властивість прогнозу потрібно зберігати. Реверсивне обчислення знижує вартість активацій під час диференціації тривалого процесу. V-BLT та RoPE-ND досліджують просторове представлення, координатну структуру й неоднорідність складності. Кінцевий предиктор, своєю чергою, визначає, які історичні спостереження у прихованому просторі поміщаються в заданий бюджет контексту. Саме для останнього питання розділ 4 встановлює емпіричні області доцільності.

Основні твердження спираються на окремі контрольовані досліди: TempVerseFormer не був компонентом підтверджувальної моделі E2–E8, а V-BLT/RoPE-ND не визначав її позиційне кодування. Водночас підрозділ 4.9 перевіряє технічну здійсненність композиції: компактне просторове представлення та реверсивний часовий блок працювали в одному навченому прототипі. Це не ототожнює протоколи і не дозволяє переносити на цю модель підтверджувальні висновки TRB.

Отже, композиція виконує конкретну, обмежену роль. Основний WindowDiT ізолює причинний ефект контекстного пакета; інтегрований SimVP зі сталими ділянками перевіряє сумісність компактного стану, однопрохідного декодування та реверсивного ланцюга, але змінює зовнішню динаміку. OpenSTL-сумісна модель з реверсивним ядром усуває цю розбіжність:

маршрутизація й декодування залишаються поза реверсивною межею, а реверсивність змінює спосіб диференціювання внутрішнього Transformer-ядра, не його пряму функцію. Контрольовані пакети, предиктор зі сталими ділянками й адаптивне ядро досліджують різні інтерфейси спільної задачі. Перенесення висновку між ними потребує відповідного зіставлення, а коректна композиція сама по собі не встановлює переваги якості.

4.11 Набір програмних засобів та практичне застосування

Практичне значення результатів залежить від того, чи відтворюються їхні інтерфейси в програмному забезпеченні. Тут коротко описано поділ публічних і заморожених просторів імен, роль конфігурацій, артефактів і тестів, а також межі заявленого впровадження. Детальний реєстр команд і компонентів залишається в додатку Ж.

4.11.1 Архітектура програмного забезпечення

Організація програмного забезпечення відтворює логіку наукового аналізу. Підтримуваний пакет hvp надає інтерфейси без побічних ефектів для опису контексту й геометрії досяжності, оцінювання повних кадрів і об’єктів, що зберігаються в часі, статистичного виведення з урахуванням кластеризації за кліпами, одночасного аналізу та фіксації походження через контентну адресацію. Опис експерименту відокремлено від його результатів. Імпорт пакета не завантажує набори даних, не ініціалізує CUDA, не під’єднується до сервісу експериментів і не запускає обчислення. У версії 0.3.0 стабільний публічний CLI повідомляє версію та перевіряє шлюз авторизації; навчання й оцінювання залишаються дослідницькими робочими процесами.

Відтворюваність перевіряється на кількох рівнях. Валідатори відхиляють порівняння несумісних пакетів, а тести показників охоплюють порожні маски, хибнопозитивні результати, зіставлення об’єктів у часі, пропуски, зайві компоненти та покриття. Перевірка наукової конфігурації завершується відмовою, якщо дослідження має термінальний стан, пропущене, не зареєстроване або не авторизоване. На момент релізу 0.3.0 десять конфігурацій пройшли перевірку авторизації, 83 CPU-тести завершилися успішно, вихідні

файли Python пройшли компіляційну перевірку, а пакет wheel було зібрано й установлено в ізольованому середовищі. Після релізу до робочої гілки додано модулі перевірки предиктора зі сталими ділянками; відповідний стан із 99 CPU-тестами не слід ототожнювати із замороженим релізом 0.3.0.

Дослідження структури контексту використовує окремий manifest-driven контур: 43 записи конфігурацій розв'язуються у 86 запусків, включно із семантичними повторами із двома ініціалізаціями, а залежні LVL/OVR-комірки формуються лише після ALC. Контролер пропускає завершені запуски, відновлює незавершений запуск із останньої контрольної точки, фіксує конфігурацію, хеші, стандартний вивід, помилки, локальні JSONL-показники, валідаційні зображення й дзеркалює дозволені дані у відокремлений проєкт W&B. До запуску кампанії 201 тест, компіляційний контроль, п'ять репрезентативних CUDA-перевірок, fail-closed preflight даних і перевірка відновлення завершилися успішно. Цей контур не змінює заморожених артефактів E2–E8.

Інтегровану модель з адаптивним пакуванням реалізовано в окремій гілці OpenSTL із власними конфігураціями Moving MNIST і TaxiBJ та окремим відновлюваним контролером. Двадцять модельних, контрактних і CLI-тестів OpenSTL та п'ять тестів контролера завершилися на CPU без видимого CUDA-пристрою; перевірено також відновлення до точної запланованої кількості оновлень і паритет прямого виходу та градієнтів звичайного/реверсивного ядра у fp32 і допустимому CPU bf16. Початкові наскрізні тести мали нульову вихідну проєкцію й могли проходити лише завдяки копіюванню останнього кадру. Виправлена перевірка окремо контролює цю ініціалізацію, а паритет перевіряє з ненульовою проєкцією, ненульовими градієнтами кодувальника, маршрутизатора та ядра, порівнянням іменованих градієнтів і негативним контролем пошкодження пам'яті. Це перевіряє конкретні програмні властивості, але не конкурентну якість і не скорочення CUDA-пам'яті. Процес придатний до аудиту, однак великі локальні набори даних і контрольні точки ще не

опубліковано для завантаження. Для зовнішнього доступу потрібні адреси архівів, ліцензії, хеші та перевірені інструкції.

4.11.2 Впровадження та використання в освітніх цілях

Інструментарій має дослідницьке й навчальне призначення. Він містить повторно використовувані генератори, інтерфейси пакетів, засоби оцінювання розгортань і статистичні процедури, завдяки чому перевірка механізму не змішується з оцінюванням загальної продуктивності. Перед додаванням нового пакета потрібно визначити геометрію прив’язок, кількість контекстних і цільових токенів, допустимий тип порівняння та оцінювану популяцію. Ця дисципліна є окремим практичним результатом дисертації.

Звіти про впровадження документують використання в ТОВ «ОРНЕТІКА» та в навчальному процесі Вінницького національного технічного університету від 14 жовтня 2025 року та 19 вересня 2025 року. Затверджена сфера застосування охоплює методи реверсивного трансформера та токенізації ентропії. Ці звіти не можна переосмислювати як валідацію розгортання предиктора, описаного в розділі 3. Остаточні адміністративні додатки повинні відтворювати наданий автором підписаний текст та скановані копії.

4.12 Обмеження та загрози валідності

Завершальний підрозділ збирає обмеження, розподілені між окремими експериментами, і групує їх за внутрішньою, конструктною, статистичною та зовнішньою валідністю. Його мета – відокремити локально підтверджені механізми від тверджень, для яких потрібні нові ініціалізації, природне відео або інший зареєстрований протокол.

4.12.1 Внутрішня валідність та валідність конструкту

Специфічний для пари інструмент спостережуваності надає найпереконливіші докази внутрішньої валідності. Навіть у центральній парі просторова роздільна здатність і номінальна досяжність змінюються разом. Щоб відрізнити використання спостережуваної історії від сильного апріорного припущення, яке приводить до того самого прогнозу, потрібні були б контрфактуальні приховані світи. У B1 змішування виражене сильніше: разом із

кроком контексту змінюються крок і слоти цілі, допоміжна функція втрат, довжина послідовності та оптимізаційне навантаження. Повна конфігурація є валідною й перевіреною, але приписувати її ефект лише часовому кроку не можна. Зонд глибини має подібне обмеження: глибину представлення, розподіл цілей та навчальне навантаження не розділено.

Якісні докази навмисно залишаються вторинними. Галерея з фіксованим індексом гарантує, що відображену вибірку можна відтворити, проте невизначеність вибору залишається, оскільки не було зареєстровано квантильне правило відбору. У будь-якому разі, невелика галерея не може охопити кумулятивний розподіл помилок. Необроблена мозаїка є інформативною з аналогічної причини: вона видаляє навчену адресацію. Однак прямий доступ до майбутнього положення та зберігання без втрат роблять її непридатною для ранжування моделей.

4.12.2 Статистична та зовнішня валідність

Кількість ініціалізацій навчання нерівномірна: дві для основного результату за 896 токенів, три для 1 152 і п’ять для факторного експерименту форми пакета; середні та верхні точки мають одну або дві ініціалізації. Інтервали зі статистичним виведенням з урахуванням кластеризації за кліпами описують невизначеність щодо кліпів для кожної навченої моделі, але не замінюють реплікацію за ініціалізаціями. Тому невирішена точка 1 792 разом із нижчою точністю верхніх ефектів робастності має залишатися видимою в кожному підсумку бюджетної межі. Перевірка генератора використовує фіксовані контрольні точки та ініціалізацію предиктора 0. Перевірка кодека охоплює один незалежно навчений кодек із ініціалізацією предиктора 0 і не встановлює, яка саме його властивість зменшила верхній ефект.

Бюджетна межа є дискретною. Вона визначає перевірені точки та сімейство рішень, але не унікальний перетин, монотонну криву чи асимптотичний закон. Арифметика токенів контексту вимірює безпосереднє зберігання стану та матеріалізовані вбудовування; вона не характеризує швидкодію, FLOP уваги, повну пам’ять GPU або однакову якість. Тесту на

еквівалентність не проводили, тому інтервал, що перетинає нуль, не означає «методи однакові».

Матриця структурних порівнянь A4 також має наперед визначені межі. Вона використовує дві ініціалізації на комірку, чого достатньо для показу узгодженості або зміни напряму, але недостатньо для надійного оцінювання розподілу між навчаннями. TRB є контрольованим синтетичним середовищем; стандартний Moving MNIST синтетичний, а TaxiBJ охоплює лише одну реальну двоканальну задачу. Довгий Moving-MNIST не входить до структурної матриці, тому її чотирикадрове цільове вікно не встановлює довготривалої авторегресивної стійкості. Шість бюджетів, сім розподілів і варіанти квоти залишаються дискретними конструкціями, а вибір моделі й маршруту виконується лише на валідаційних даних. Висновки про пам’ять залежать від GPU, типу даних, розміру мініпакета та конкретного профайлера.

Дослідження предиктора зі сталими ділянками має додаткові обмеження: одну ініціалізацію, публічний тестовий набір, короткий протокол 10→10 та незбіг горизонтів у частині зовнішніх профілів пам’яті. Фіксовані ділянки прибрали нестабільність дискретної маршрутизації, але разом із нею усунули прямий тест переваги адаптації до інформаційної щільності. Другопорядкова реверсивна оболонка змінює зовнішню динаміку й тому не дає причинного порівняння тотожної прямої функції зі звичайним BPTT. Через це наявні результати §4.9 підтверджують сумісність інтерфейсів і вимірюють компроміси конкретного прототипу, а не встановлюють нову область переваги.

Для адаптивної інтегрованої архітектури програмний паритет ще не є емпіричним результатом якості чи пам’яті. Співвідношення 800 проти 2 560 токенів для Moving MNIST та 80 проти 256 для TaxiBJ дорівнює 3,2 лише для вхідної послідовності Transformer; воно не охоплює всю структуру PackedContext, грубу сітку на межі декодера, параметри, градієнти, стан оптимізатора й тимчасові робочі області. Маршрути static, density і hybrid за однакової фізичної квоти мають однакову форму запакованого тензора, тому їх порівняння перевіряє якість розміщення, а не економію пам’яті. Перевагу

пам’яті можна приписувати меншій квоті лише після вимірювання меншого фізичного тензора зі збереженням допустимої якості.

4.12.3 Висновки розділу

У сукупності експерименти дають основу для вибору, а не визначають архітектуру-переможця. У контрольованій однокроковій оцінці верхньої межі охоплення дифузія краще відтворює цільовий розподіл, ніж регресійний вихідний модуль із близькою кількістю параметрів, але за нерівного загального обсягу обчислень під час генерування. У детермінованому розгортанні із самоподачею та одним кандидатом кращою є регресія. Енергетичний спуск у перевіреному масштабі не досягає структурованих цілей навіть тоді, коли один із алгоритмів навчається правильного енергетичного порядку. Отже, механізм генерації потрібно обирати відповідно до режиму застосування.

Окреме калібрування тривалості навчання показало, що зріз 16 000 кроків був недостатнім для структурної матриці: порядок двох конфігурацій змінився між 12 000 і 16 000 кроків, а на 24 000 кроків одна з них ще перебувала на 6,80 % вище свого пізнішого мінімуму. Усі шість валідаційних метрик за спільним правилом вибрали 30 000 кроків. Це є обґрунтуванням протоколу, а не висновком про перевагу плоскої чи ієрархічної конфігурації.

Перевірена бюджетна межа містить дві області доцільності. Ієрархію підтверджено за 896 та 1 152 токенів контексту, точка 1 792 залишається невизначеною, а плоский контекст підтверджено за 2 432 і 3 072 токенів. За однакової номінальної досяжності 48 кадрів два ієрархічні пакети використовують у 2,67 та 3,43 раза менше токенів контексту, ніж щільна детальна історія. Це не означає однакової якості, інформаційної місткості, обчислювальних витрат або економії повної пам’яті.

Два граничні результати уточнюють цю картину. У E5a рання перевага ієрархії повторилася за трьома ініціалізаціями, але пізня інверсія, виявлена для ініціалізації 0, не відтворилася й тому не є підтвердженою межею самоподачі. У захищеному E6 напрям покриття та неперервності сприяв ієрархічному контексту в усіх трьох навчаннях, проте одночасні інтервали не перетинали нуль

лише для ініціалізацій 0 і 2; перевагу плоского контексту за ідентичністю підтверджено для всіх трьох ініціалізацій. Отже, довша досяжність і детальна ідентичність є різними вимогами, а абсолютні значення E6 не дають підстав вважати задачу розв'язаною.

Результати короткого Moving-MNIST і TaxiBJ дають додаткові свідчення працездатності, але не підтверджують довготривалу пам'ять. Обмежені горизонти та незіставлені бюджети контексту не дають змоги використати ці тести для центрального причинного твердження. Так само TRB і довгий Moving-MNIST не відтворюють різноманітність природного відео: рух камери, оклюзії зі змінною тривалістю, появу нових об'єктів і складну текстуру. Подальшу зовнішню валідність найкраще перевіряти на природному відео з подіями зникнення й повторного входу, ширшій панелі кодеків та необроблених еталонів, а також у зареєстрованому дослідженні поблизу точки 1 792 токени.

Інтегрований предиктор зі сталими ділянками доповнює, але не замінює ці висновки. Він досяг MSE 28,72 на Moving-MNIST за 384 збережених значень на кадр; окремий другопорядковий реверсивний режим мав у 2,58 раза нижчий пік за 40 кроків, ніж його BPTT-профіль, але не зберігав тотожну зовнішню динаміку. Порівняння з OpenSTL показало конкурентну, але не найкращу якість та відсутність універсальної переваги в абсолютній пам'яті. Отже, центральна ієрархічна модель залишається розв'язанням обмеження контекстної досяжності, а фізичне просторове пакування й внутрішня реверсивність є перспективними засобами для двох інших ресурсних меж, перевагу остаточної композиції яких потрібно встановлювати окремим зіставним профілем і навчанням.

ЗАГАЛЬНІ ВИСНОВКИ

У дисертації довгогоризонтне прогнозування відео розглянуто як задачу збереження консистентної траєкторії за обмежених ресурсів. Центральне архітектурне питання стосується історичної досяжності: чи можна за фіксованого бюджету залишити доступним віддалений стан, потрібний для подальшого прогнозу. Саме на це спрямовано ієрархічний контекст. TempVerseFormer і V-BLT усувають інші обмеження тієї самої задачі: перший зменшує пам’ять активацій під час навчання тривалого процесу, другий обґрунтовує ієрархічне просторове представлення та дає сигнал інформаційної щільності. Основні докази для трьох методів отримано окремо; їхню технічну сумісність перевірено в предикторі зі сталими ділянками, а інтегровану архітектуру з адаптивним пакуванням побудовано з фізичним пакуванням, координатним кодуванням, маршрутизацією сталої квоти та реверсивністю лише всередині Transformer-ядра.

Система може втратити консистентність із різних причин. Релевантна подія виходить за межі контексту, стиснуте представлення втрачає потрібні деталі або бажаний горизонт навчання не вміщується в пам’ять активацій. Ці обмеження не є трьома незалежними темами. Вони виникають у тому самому довгому процесі, проте потребують різних втручань і окремого обліку доказів.

1. **Формалізовано системну задачу та критерії консистентності.** Прогнозування відео подано як частково спостережуваний динамічний процес, у якому кадр відкриває лише область прихованого стану світу. Через авторегресійний зворотний зв’язок рання помилка змінює розподіл подальших вхідних даних, тому подібність окремих кадрів не характеризує довгогоризонтну поведінку повністю. Критерії на рівні задачі розрізняють зовнішній вигляд, ідентичність, геометрію, просторове покриття, часову неперервність, траєкторію, хибний передній план і міжрівневу консистентність. Окремо визначено зберігання, адресованість і повторне використання стану, а витрати віднесено до параметрів, оптимізатора, контексту, активацій або тимчасових робочих буферів. Така декомпозиція

задає порядок проєктування: спочатку встановити тип помилки, потім знайти обмежувальний ресурс і лише після цього обирати втручання.

2. **Розроблено центральний предиктор з ієрархічним контекстом і визначено його область доцільності.** Заморожений дворівневий кодек формує грубі та детальні карти прихованого простору, які можна декодувати незалежно. Один спільний дифузійний трансформер обробляє токени минулого й зашумленої цілі, а після кожного чотирикадрового вікна прогноз повертається до кільцевих буферів. Специфікація пакета фіксує рівень представлення, часовий крок, кількість кадрів та геометрію прив'язок. Завдяки цьому історичну досяжність і витрати контексту можна обчислити до запуску моделі.

У відкладеній вибірці різниці досяжності ієрархічний пакет покращив зареєстрований показник на 0,0980 і 0,0914 для двох ініціалізацій навчання. Напрям підтримали MSE об'єднаної маски, прецизійність, повнота, кількість пропущених і зайвих компонентів та покриття. Одночасний аналіз підтвердив ієрархію за 896 і 1152 токенів контексту, залишив точку 1792 невизначеною та підтвердив щільний плоский контекст за 2432 і 3072 токенів. Неперервну точку перетину не оцінювали. За номінальної досяжності 48 кадрів пакети з 48 грубими та шістьма або двома останніми детальними кадрами потребують 1152 і 896 токенів, що у 2,67 і 3,43 раза менше за 3072 токени щільної детальної історії. Це доводить ефективність досяжності на перевіреному інтерфейсі, але не однакову якість, швидкодію чи економію всієї пам'яті GPU.

Для структурної матриці обґрунтовано спільний фіксований бюджет оптимізації. Порядок плоскої та збалансованої ієрархічної конфігурацій змінився між 12 000 і 16 000 кроків, а на 24 000 кроків ієрархічна крива ще перевищувала свій пізніший мінімум на 6,80 %. Лише 30 000 кроків виконали парне правило двовідсоткової близькості й стабільності порядку; той самий зріз вибрали всі шість валідаційних метрик. Кінцева точка автоматично задовольняє це правило, оскільки пізніших вимірювань немає. Тому спільний бюджет не доводить збіжності або переваги будь-якої конфігурації.

У валідаційному FRT-зіставленні за 30 000 оновлень геометрична політика має нижчу помилку за обох ініціалізацій на 768, 1 792 і 2 432 токенах, плоска — на 1 152; на 320 і 3 072 напрям залежить від ініціалізації. Такий описовий результат (§4.8.1) не утворює монотонної бюджетної межі й не замінює відкладеного підтвердження. Отже, загальний ресурс і конкретний розподіл потрібно інтерпретувати разом.

У структурному зіставленні за 1 792 токенів найменшу розвиткову помилку має геометричне розміщення 16 деталей у кожному з 16 моментів. На 500 захищених кліпах воно зменшує h=4-помилку щодо плоскої опори на 0,01169 та 0,01026 за двома ініціалізаціями; обидва скориговані інтервали додатні. Геометрична ALC не відтворює переваги за другою ініціалізацією. Додавання третього рівня та заміна вкладеного подання взаємовиключним або залишковим не дали середнього виграшу. Отже, підтримку історії слід поєднувати з відповідним розміщенням деталей, а не максимізувати число рівнів.

Граничні досліди пояснюють ціну стискання. У E5a рання перевага ієрархії відтворилася за трьома ініціалізаціями, але пізня інверсія для ініціалізації 0 не відтворилася. У захищеному E6 просторове покриття й неперервність сприяли ієрархії для всіх трьох навчань, хоча одночасні інтервали не перетинали нуль лише для ініціалізацій 0 і 2. Плоский детальний контекст краще зберігав ідентичність цифр для всіх трьох ініціалізацій. Ці контрасти показують умовний обмін між досяжністю та деталізацією: інформація, що визначає ідентичність, може бути втрачена навіть за кращого просторового покриття.

3. **Розроблено методологію оцінювання ефектів, що залежать від історичної досяжності.** Тороїдальний тест повторного входу (TRB; внутрішня назва LoopMom) задає відомий світ, траєкторію вікна перегляду та геометрію повторного входу. Для кожної історичної пари пакетів аналітично формується вибірка, у якій потрібне свідчення вже недоступне коротшому пакету, але доступне довшому. У структурній матриці спільна 96-кадрова система координат, незмінна чотирикадрова ціль і єдина маска

недавньої межі дають змогу зіставляти широкий набір розподілів без зміни задачі. Повний набір кадрових та об’єктних показників розрізняє відсутній вміст і зайвий передній план. Розширення з об’єктами, ідентичність яких простежується в часі, окремо вимірює покриття, ідентичність та похибку траєкторії.

Парні ефекти обчислюються за вирівняними записами, але повторна вибірка виконується на рівні кліпів, щоб не руйнувати часову залежність помилок самоподачі. Ініціалізації навчання залишаються окремим рівнем невизначеності. Для зареєстрованих сімейств E2–E8 використано одночасні інтервали на основі максимум-статистики. Для чотирьох описових контрастів структурної матриці застосовано окрему поправку Бонферроні. Дані розроблення, відкладеного підтвердження, цільових перевірок, робастності та зовнішніх меж не об’єднуються в один клас доказів; невизначені та невідтворені результати збережено у фінальному записі.

4. **Встановлено метод реверсивних часових обчислень і межу його застосовності.** Адитивне зв’язування дає змогу під час зворотного проходу реконструювати подвоєний стан трансформера з кінцевого стану. Точна інверсія стосується повторюваного ланцюга; VAE, вхідна проєкція, вихідне злиття, декодер і функція втрат лежать поза цією межею. У вимірюваннях TempVerseFormer пам’ять часової моделі залишалася близько 0,89 ГБ для одного, чотирьох і шістнадцяти кроків, тоді як зіставлені нереверсивні варіанти досягали приблизно 2,60–2,61 ГБ за шістнадцяти кроків. На опублікованому графіку вона трималася близько 1 ГБ до показаних 1024 кроків, але точні необроблені координати великих горизонтів не збереглися.

Економія активацій не є безкоштовною. Відтворення потребує додаткових обчислень, контрольованої детермінованості або метаданих випадкового стану, а числовий дрейф потрібно вимірювати. Опубліковані докази охоплюють детерміноване реверсивне ядро TempVerseFormer та вимірювання його пам’яті; стохастична реконструкція й перевірка еквівалентності градієнтів є окремими

дисертаційними розширеннями. Ці перевірки не утворюють одного спільного факторного досліду. Метод тому слід застосовувати там, де функцію втрат справді потрібно диференціювати крізь тривалий процес, а не як універсальне поліпшення якості прогнозу.

5. **Розроблено ієрархічне растрово-байтове представлення, RoPE-ND і сигнал просторової складності.** V-BLT поєднує локальне кодування, глобальну обробку прихованих представлень та локальне декодування до байтів каналів растрових пікселів. Категоріальна ціль із 256 класами не потребує навченого вихідного словника. RoPE-ND виділяє часовим і просторовим координатам неперетинні обертальні підпростори, тому відносне положення входить у механізм уваги без змішування осей. Фіксовані пакети $4 \times 4 \times 4$ перевірено на обертових двовимірних трикутниках і тривимірних полікубах. Опубліковані оцінки за кількома показниками конкурентні з ViViT і UNet-3D, однак не встановлюють універсального лідерства; зокрема, найкращий наведений 3-D PSNR належить ViViT.

Категоріальна ентропія розподілів байтів концентрувалася біля контурів, що рухаються, та у невизначених ранніх прогнозах. Це корисний внутрішній сигнал інформаційної щільності, але не калібрована невизначеність і не готова політика розподілу ресурсів. У V-BLT геометрія патчів залишалася фіксованою. Перевірка зі сталими ділянками також використала фіксовані ділянки й тому не підтвердила перевагу динамічного ентропійного маршрутизатора. В архітектурі з адаптивним пакуванням маршрутизатор реалізовано окремо через залишкову енергію між рівнями, часову зміну та навчувану поправку; його індекси перебувають поза реверсивною межею, а перевагу над статичною квотою потрібно встановлювати емпірично.

6. **Підтверджено технічну сумісність просторового пакування та реверсивного навчання в обмеженому прототипі й визначено інтерфейс адаптивного пакування з внутрішнім реверсивним ядром.** Представлення з 16 грубих і восьми фіксованих детальних токенів зберігає

384 значення на кадр, що у 10,67 раза менше за 4096 значень необробленого кадру. На Moving-MNIST 10→10 інтегрований SimVP зі сталими ділянками досяг MSE 28,72 та MAE 80,27 на 10 000 тестових кліпах. Він перевершив наведені ConvLSTM-S, E3D-LSTM і SimVP-IncepU за MSE, проте поступився локальному SimVP-gSTA і TAU. Другопорядкова реверсивна оболонка мала додатковий пік 550,86 МБ проти 1418,79 МБ у BPTT-профілі на 40 кроках, тобто у 2,58 раза менше, однак після першого переходу ці режими мали різну зовнішню динаміку й не становили порівняння тотожної прямої функції.

Ці коефіцієнти описують різні ресурси й не перемножуються. Одна ініціалізація, короткий синтетичний протокол, фіксовані ділянки та відмінна реверсивна динаміка обмежують результат перевіркою технічної здійсненності, а не новим підтверджувальним твердженням. В моделі з адаптивним пакуванням фізичне вилучення сталої квоти виконується до Transformer, кожний токен несе координати центра, часу, масштабу й рівня, а адитивна реверсивність застосовується лише до внутрішніх блоків із тотожною прямою функцією. CPU-перевірки підтвердили форми OpenSTL, квоту, стійкість до узгодженої перестановки токенів із метаданими та паритет виходу й градієнтів; паритет також пройдено на CUDA у FP32 і BF16. Чотири 200-крокові траєкторії підтвердили скінченні втрати та дієві градієнти без оцінювання тестової вибірки. Повні навчання завершено у двох ініціалізаціях на кожній задачі: тестова піксельна MSE становить 0,009894–0,010035 для Moving MNIST і 0,0002763–0,0002792 для TaxiBJ у нормалізованих одиницях. Контрольований повний CUDA-профіль у BF16 показав зменшення allocated-піку реверсивного режиму приблизно на 12 % і 10 % відповідно; часові повтори TaxiBJ мають значний розкид. Це підтверджує прогнозну працездатність та обмежений ресурсний виграш композиції. Без повністю навченого зіставного контролю ці результати не встановлюють переваги адаптивного членства чи найкращої кінцевої якості.

Структурні порівняння місткості, розподілу, підтримки, рівнів і перекриття задають послідовну перевірку області доцільності ієрархії (§4.8). Незалежне

оцінювання (§4.8.4) та інтегрований протокол (§4.9) мають окремі доказові ролі. Комірки без перевірених вимірювань не додають емпіричних висновків: числова коректність не доводить переваги якості, а короткий прогноз не встановлює стійкості самоподачі.

Практичне значення

Робота пропонує експериментальну й програмну основу для проєктування довгогоризонтних предикторів. У конфігураціях фіксуються прив'язки пакетів, витрати, набори даних, генератори, ідентифікатори кодеків і призначення доказів. Авторизація із забороною за замовчуванням, контентно-адресовані специфікації запусків, незмінні артефакти, повні реалізації показників та перевірки сумісності зменшують семантичний дрейф між експериментами й рукописами. Комплекси simple-shape-dataset-toolbox, TRB і генератор довгого Moving-MNIST створюють синтетичні послідовності з контрольованими рухом, геометрією спостереження та ідентифікаторами об'єктів. Програма структурних порівнянь має керовану маніфестом матрицю 43 записів конфігурацій/86 запусків із семантичними повторами, відновлення з останньої контрольної точки, локальні журнали, валідаційні зображення й окреме W&B-відстеження. Інтегрована модель з адаптивним пакуванням має окремі OpenSTL-конфігурації Moving MNIST/TaxiBJ та відновлюваний контролер; обидва програмні контури мають дослідницький, а не виробничий статус.

Правило вибору можна сформулювати стисло. Стан, потрібний у майбутньому, слід стискати настільки, щоб зберегти його до потрібного горизонту; активації, які потрібні лише для зворотного проходу, можна відтворювати; детальну інформацію варто залишати там, де її втрата визначає помилку. Якщо релевантна подія лежить поза детальним вікном, доцільний ієрархічний або інший стиснений контекст. У підтверджувальних контрастах досяжності щільна деталізація відновлювала перевагу за частини бюджетів; це не універсальне правило для всіх політик і протоколів. Реверсивність потрібна лише тоді, коли обмеженням стає пам'ять навчального ланцюга.

Обмеження та напрямки подальших досліджень

Зовнішня валідність залишається основним обмеженням. TRB і довгий Moving-MNIST ізолюють явища пам’яті, але не відтворюють складних текстур, монтажних переходів, нежорсткого руху або неоднозначності природного відео. Коротковіконні оцінювання Moving-MNIST і TaxiBJ характеризують прогнозну працездатність, але не встановлюють довготривалої пам’яті. Наступний протокол має поєднати природне відео або інтерактивні світи з перевірними свідченнями віддаленої історії та показниками ідентичності.

Для інтегрованої моделі з адаптивним пакуванням потрібні дві незалежні ініціалізації на Moving MNIST 10→10 і TaxiBJ 4→4, окремі профілі плоского/ієрархічного стану, звичайного/реверсивного ядра та статичної/динамічної маршрутизації. Сумісна незалежна базова модель потрібна лише для сильнішого твердження про перевагу якості; за її відсутності висновок обмежується працездатністю. Короткі контрольні навчання перевіряють стабільність і швидкодію, а не повноцінну причинну перевагу маршруту. За однакової квоти зміна маршруту змінює розміщення деталей, а не їхню кількість. Економія пам’яті потребує окремого вимірювання фактично збереженого стану й повного піку. Реверсивний режим доцільно порівняти з градієнтними контрольними точками лише за однакових моделі, контрольної точки, точності, горизонту й навчальної операції.

Нарешті, перевірені бюджети контексту задають дискретну межу, а не універсальну криву Парето. Додаткові ініціалізації біля невизначеної точки 1792 токени, інші кодеки та ширший набір форм пакетів зробили б її точнішою. Ці продовження не потрібні для вже сформульованих висновків, проте мають зберігати головну дисципліну роботи: спочатку діагностувати обмежувальну умову, а потім перевіряти одне втручання там, де його механізм можна спостерігати.

СПИСОК ВИКОРИСТАНИХ ДЖЕРЕЛ

Усі джерела мають стабільні числові ідентифікатори в дисертації. Бібліографічні назви наведено мовою оригіналу; українські джерела подано українською. У тексті посилання оформлено у квадратних дужках.

1. Tan C., Li S., Gao Z., et al. OpenSTL: A Comprehensive Benchmark of Spatio-Temporal Predictive Learning. *NeurIPS 36 (D&B)*, 2023.
2. Ho J., Jain A., Abbeel P. Denoising Diffusion Probabilistic Models. *NeurIPS 33*, 2020.
3. Rombach R., Blattmann A., Lorenz D., Esser P., Ommer B. High-Resolution Image Synthesis with Latent Diffusion Models. *CVPR*, 2022.
4. Peebles W., Xie S. Scalable Diffusion Models with Transformers (DiT). *ICCV*, 2023.
5. Згуровський М. З., Панкратова Н. Д. *Основи системного аналізу: підручник*. Київ: Видавнича група BHV, 2007. 544 с. ISBN 978-966-552-153-2.
6. Zgurovsky M. Z., Pankratova N. D. *System Analysis: Theory and Applications*. 1st ed. Springer Berlin, Heidelberg, 2007. XXII, 447 p. DOI: 10.1007/978-3-540-48880-4.
7. Mesarović M. D., Macko D., Takahara Y. *Theory of Hierarchical, Multilevel Systems*. Academic Press, 1970.
8. Simon H. A. The Architecture of Complexity. *Proceedings of the American Philosophical Society* 106(6):467–482, 1962.
9. Shannon C. E. A Mathematical Theory of Communication. *Bell System Technical Journal* 27:379–423, 623–656, 1948.
10. Kalman R. E. A New Approach to Linear Filtering and Prediction Problems. *Journal of Basic Engineering* 82(1):35–45, 1960.
11. Ashby W. R. *An Introduction to Cybernetics*. Chapman & Hall, 1956.
12. Vaswani A., Shazeer N., Parmar N., et al. Attention Is All You Need. *NeurIPS 30*, 2017.
13. Dao T., Fu D. Y., Ermon S., Rudra A., Ré C. FlashAttention: Fast and Memory-Efficient Exact Attention with IO-Awareness. *NeurIPS 35*, 2022.

14. Dai Z., Yang Z., Yang Y., Carbonell J., Le Q. V., Salakhutdinov R. Transformer-XL: Attentive Language Models Beyond a Fixed-Length Context. *ACL*, 2019.
15. Rae J. W., Potapenko A., Jayakumar S. M., Lillicrap T. P. Compressive Transformers for Long-Range Sequence Modelling. *ICLR*, 2020.
16. Wu Y., Rabe M. N., Hutchins D., Szegedy C. Memorizing Transformers. *ICLR*, 2022.
17. Kitaev N., Kaiser Ł., Levskaya A. Reformer: The Efficient Transformer. *ICLR*, 2020.
18. Beltagy I., Peters M. E., Cohan A. Longformer: The Long-Document Transformer. arXiv:2004.05150, 2020.
19. Gu A., Dao T. Mamba: Linear-Time Sequence Modeling with Selective State Spaces. arXiv:2312.00752, 2023.
20. Saxena V., Ba J., Hafner D. Clockwork Variational Autoencoders. *NeurIPS 34*, 2021.
21. Harvey W., Naderiparizi S., Masrani V., Weilbach C., Wood F. Flexible Diffusion Modeling of Long Videos (FDM). *NeurIPS 35*, 2022.
22. Po R., Nitzan Y., Zhang R., Chen B., Dao T., Shechtman E., Wetzstein G., Huang X. Long-Context State-Space Video World Models. arXiv:2505.20171, 2025.
23. Oshima Y., Iwasawa Y., Suzuki M., Matsuo Y., Furuta H. WorldPack: Compressed Memory Improves Spatial Consistency in Video World Modeling. arXiv:2512.02473, 2025.
24. Wu T., Yang S., Po R., Xu Y., Liu Z., Lin D., Wetzstein G. Video World Models with Long-term Spatial Memory. arXiv:2506.05284, 2025.
25. Ranzato M., Chopra S., Auli M., Zaremba W. Sequence Level Training with Recurrent Neural Networks (exposure bias). *ICLR*, 2016.
26. Bengio S., Vinyals O., Jaitly N., Shazeer N. Scheduled Sampling for Sequence Prediction with Recurrent Neural Networks. *NeurIPS 28*, 2015.

27. Huang X., Li Z., He G., Zhou M., Shechtman E. Self Forcing: Bridging the Train-Test Gap in Autoregressive Video Diffusion. *NeurIPS 2025* (spotlight); arXiv:2506.08009.

28. Werbos P. J. Backpropagation Through Time: What It Does and How to Do It. *Proceedings of the IEEE* 78(10), 1990.

29. Williams R. J., Peng J. An Efficient Gradient-Based Algorithm for On-Line Training of Recurrent Network Trajectories (truncated BPTT). *Neural Computation* 2(4), 1990.

30. Chen T., Xu B., Zhang C., Guestrin C. Training Deep Nets with Sublinear Memory Cost. arXiv:1604.06174, 2016.

31. Griewank A., Walther A. Algorithm 799: revolve – An Implementation of Checkpointing for the Reverse or Adjoint Mode of Computational Differentiation. *ACM TOMS* 26(1), 2000.

32. Gomez A. N., Ren M., Urtasun R., Grosse R. B. The Reversible Residual Network: Backpropagation Without Storing Activations. *NeurIPS 30*, 2017.

33. Koutník J., Greff K., Gomez F., Schmidhuber J. A Clockwork RNN. *Proceedings of Machine Learning Research* 32(2):1863–1871, ICML, 2014.

34. Kim T., Ahn S., Bengio Y. Variational Temporal Abstraction. *NeurIPS 32*, 2019.

35. Zakharov A., Guo Q., Fountas Z. Long-Horizon Video Prediction Using a Dynamic Latent Hierarchy. arXiv:2212.14376, submitted 2022, revised 2023.

36. Yan W., Hafner D., James S., Abbeel P. Temporally Consistent Transformers for Video Generation (TECO). *ICML*, 2023.

37. Chandratreya I. P., Charatan D., Van Hoorick B., Zakharov S., Guizilini V., Isola P., Sitzmann V. MilliVid: Hierarchical Latents for Long-Range Consistency in Video Generation. arXiv:2606.09056, 2026.

38. Liu Y., Zhang K., Li Y., Yan Z., Gao C., Chen R., Yuan Z., Huang Y., Sun H., Gao J., He L., Sun L. Sora: A Review on Background, Technology, Limitations, and Opportunities of Large Vision Models. arXiv:2402.17177, 2024.

39. Lipton Z. C. The Mythos of Model Interpretability. *Communications of the ACM* 61(10), 2018.

40. Rudin C. Stop Explaining Black Box Machine Learning Models for High Stakes Decisions and Use Interpretable Models Instead. *Nature Machine Intelligence* 1, 2019.

41. von Bertalanffy L. *General System Theory: Foundations, Development, Applications*. George Braziller, 1968.

42. Goodfellow I., Pouget-Abadie J., Mirza M., et al. Generative Adversarial Networks. *NeurIPS 27*, 2014.

43. Kingma D. P., Welling M. Auto-Encoding Variational Bayes. *ICLR*, 2014.

44. Kendall A., Gal Y. What Uncertainties Do We Need in Bayesian Deep Learning for Computer Vision? *NeurIPS 30*, 2017.

45. Guo C., Pleiss G., Sun Y., Weinberger K. Q. On Calibration of Modern Neural Networks. *Proceedings of Machine Learning Research* 70:1321–1330, ICML, 2017.

46. Bhadra S., Kelkar V. A., Brooks F. J., Anastasio M. A. On Hallucinations in Tomographic Image Reconstruction. *IEEE Transactions on Medical Imaging* 40(11):3249–3260, 2021. DOI: 10.1109/TMI.2021.3077857.

47. Ebel P., Sainte Fare Garnot V., Schmitt M., Wegner J. D., Zhu X. X. UnCRtainTS: Uncertainty Quantification for Cloud Removal in Optical Satellite Time Series. *IEEE/CVF Conference on Computer Vision and Pattern Recognition Workshops*, pp. 2086–2096, 2023. DOI: 10.1109/CVPRW59228.2023.00202.

48. Huot F., Hu R. L., Goyal N., Sankar T., Ihme M., Chen Y.-F. Next Day Wildfire Spread: A Machine Learning Data Set to Predict Wildfire Spreading From Remote-Sensing Data. *IEEE Transactions on Geoscience and Remote Sensing* 60:1–13, 2022. DOI: 10.1109/TGRS.2022.3192974.

49. Shaddy B., Ray D., Farguell A., et al. Generative Algorithms for Fusion of Physics-Based Wildfire Spread Models with Satellite Data for Initializing

Wildfire Forecasts. *Artificial Intelligence for the Earth Systems* 3(3):e230087, 2024. DOI: 10.1175/AIES-D-23-0087.1.

50. Bond-Taylor S., Leach A., Long Y., Willcocks C. G. Deep Generative Modelling: A Comparative Review of VAEs, GANs, Normalizing Flows, Energy-Based and Autoregressive Models. *IEEE TPAMI* 44(11), 2022.
51. Ji Z., Lee N., Frieske R., et al. Survey of Hallucination in Natural Language Generation. *ACM Computing Surveys* 55(12), 2023.
52. Song J., Meng C., Ermon S. Denoising Diffusion Implicit Models. *ICLR*, 2021.
53. OpenAI (Brooks T., Peebles B., et al.). Video Generation Models as World Simulators (Sora technical report), 2024.
54. Ho J., Salimans T., Gritsenko A., Chan W., Norouzi M., Fleet D. J. Video Diffusion Models. *NeurIPS 35*, 2022.
55. Blattmann A., Rombach R., Ling H., Dockhorn T., Kim S. W., Fidler S., Kreis K. Align Your Latents: High-Resolution Video Synthesis with Latent Diffusion Models. *CVPR*, 2023.
56. Blattmann A., Dockhorn T., Kulal S., et al. Stable Video Diffusion: Scaling Latent Video Diffusion Models to Large Datasets. arXiv:2311.15127, 2023.
57. Singer U., Polyak A., Hayes T., et al. Make-A-Video: Text-to-Video Generation without Text-Video Data. *ICLR*, 2023.
58. Ho J., Chan W., Saharia C., et al. Imagen Video: High Definition Video Generation with Diffusion Models. arXiv:2210.02303, 2022.
59. Villegas R., Babaeizadeh M., Kindermans P.-J., et al. Phenaki: Variable Length Video Generation from Open Domain Textual Descriptions. arXiv:2210.02399, 2022.
60. Yu L., Lezama J., Gundavarapu N. B., et al. MAGVIT: Masked Generative Video Transformer. *CVPR*, 2023.
61. Yu L., Lezama J., Gundavarapu N. B., et al. Language Model Beats Diffusion – Tokenizer Is Key to Visual Generation. *ICLR*, 2024.
62. Bruce J., Dennis M., Edwards A., et al. Genie: Generative Interactive Environments. *ICML*, 2024.

63. Hu A., Russell L., Yeo H., et al. GAIA-1: A Generative World Model for Autonomous Driving. arXiv:2309.17080, 2023.

64. Ha D., Schmidhuber J. World Models. arXiv:1803.10122, 2018.

65. Hafner D., Lillicrap T., Ba J., Norouzi M. Dream to Control: Learning Behaviors by Latent Imagination. *ICLR*, 2020.

66. Hafner D., Pasukonis J., Ba J., Lillicrap T. Mastering Diverse Domains through World Models. arXiv:2301.04104, 2023.

67. Micheli V., Alonso E., Fleuret F. Transformers Are Sample-Efficient World Models. *ICLR*, 2023.

68. Pasukonis J., Lillicrap T., Hafner D. Evaluating Long-Term Memory in 3D Mazes (Memory Maze). arXiv:2210.13383, 2022.

69. Dosovitskiy A., Beyer L., Kolesnikov A., et al. An Image is Worth 16×16 Words: Transformers for Image Recognition at Scale (ViT). *ICLR*, 2021.

70. Arnab A., Dehghani M., Heigold G., et al. ViViT: A Video Vision Transformer. *ICCV*, 2021.

71. Liu Z., Ning J., Cao Y., et al. Video Swin Transformer. *CVPR*, 2022.

72. Pagnoni A., Pasunuru R., Rodriguez P., et al. Byte Latent Transformer: Patches Scale Better Than Tokens. arXiv:2412.09871, 2024.

73. van den Oord A., Vinyals O., Kavukcuoglu K. Neural Discrete Representation Learning (VQ-VAE). *NeurIPS 30*, 2017.

74. Yan W., Zhang Y., Abbeel P., Srinivas A. VideoGPT: Video Generation using VQ-VAE and Transformers. arXiv:2104.10157, 2021.

75. Razavi A., van den Oord A., Vinyals O. Generating Diverse High-Fidelity Images with VQ-VAE-2. *NeurIPS 32*, 2019.

76. Child R. Very Deep VAEs Generalize Autoregressive Models and Can Outperform Them on Images. *ICLR*, 2021.

77. Vahdat A., Kautz J. NVAE: A Deep Hierarchical Variational Autoencoder. *NeurIPS 33*, 2020.

78. Sønderby C. K., Raiko T., Maaløe L., Sønderby S. K., Winther O. Ladder Variational Autoencoders. *NeurIPS 29*, 2016.

79. Peng Z., Ma J., Sun H., et al. Compression and Retrieval: Implicit Memory Retrieval for Video World Models. arXiv:2606.23105, 2026.

80. Yu J., Gao J., Bai J., et al. MemLearner: Learning to Query Context Memory for Video World Models. arXiv:2606.31734; ECCV 2026.

81. Wei Z., Guo X., Li X., et al. Geometry-Aware Implicit Memory for Video World Models. arXiv:2606.02436, 2026.

82. Zhang S., Zhang Z., Huang S., et al. MBench: A Comprehensive Benchmark on Memory Capability for Video World Models. arXiv:2606.00793, 2026.

83. Chen H., Zhou K., Hua H., et al. MemoBench: Benchmarking World Modeling in Dynamically Changing Environments. arXiv:2606.27537, 2026.

84. LeCun Y., Chopra S., Hadsell R., Ranzato M., Huang F. A Tutorial on Energy-Based Learning. In *Predicting Structured Data*, MIT Press, 2006.

85. Ackley D. H., Hinton G. E., Sejnowski T. J. A Learning Algorithm for Boltzmann Machines. *Cognitive Science* 9(1), 1985.

86. Hyvärinen A. Estimation of Non-Normalized Statistical Models by Score Matching. *JMLR* 6, 2005.

87. Song Y., Ermon S. Generative Modeling by Estimating Gradients of the Data Distribution. *NeurIPS 32*, 2019.

88. Gladstone A., Nanduru G., Islam M. M., Han P., Ha H., Chadha A., Du Y., Ji H., Li J., Iqbal T. Energy-Based Transformers are Scalable Learners and Thinkers. arXiv:2507.02092, 2025.

89. Du Y., Mordatch I. Implicit Generation and Modeling with Energy-Based Models. *NeurIPS 32*, 2019.

90. Nijkamp E., Hill M., Zhu S.-C., Wu Y. N. On Learning Non-Convergent Non-Persistent Short-Run MCMC Toward Energy-Based Model. *NeurIPS 32*, 2019.

91. Chen R. T. Q., Rubanova Y., Bettencourt J., Duvenaud D. Neural Ordinary Differential Equations. *NeurIPS 31*, 2018.

92. Mangalam K., Fan H., Li Y., et al. Reversible Vision Transformers. *CVPR*, 2022.

93. Khalil H. K. *Nonlinear Systems* (3rd ed.). Prentice Hall, 2002.

94. Heusel M., Ramsauer H., Unterthiner T., et al. GANs Trained by a Two Time-Scale Update Rule Converge to a Local Nash Equilibrium (FID). *NeurIPS 30*, 2017.

95. Saharia C., Chan W., Chang H., et al. Palette: Image-to-Image Diffusion Models. *SIGGRAPH*, 2022.

96. Ruiz N., Li Y., Jampani V., et al. DreamBooth: Fine Tuning Text-to-Image Diffusion Models for Subject-Driven Generation. *CVPR*, 2023.

97. Hu E. J., Shen Y., Wallis P., et al. LoRA: Low-Rank Adaptation of Large Language Models. *ICLR*, 2022.

98. Zhang L., Rao A., Agrawala M. Adding Conditional Control to Text-to-Image Diffusion Models (ControlNet). *ICCV*, 2023.

99. Hertz A., Voynov A., Fruchter S., Cohen-Or D. Style Aligned Image Generation via Shared Attention. *CVPR*, 2024.

100. Marr D. *Vision: A Computational Investigation into the Human Representation and Processing of Visual Information*. W. H. Freeman, 1982.

101. Radford A., Kim J. W., Hallacy C., et al. Learning Transferable Visual Models From Natural Language Supervision (CLIP). *ICML*, 2021.

102. Hessel J., Holtzman A., Forbes M., Le Bras R., Choi Y. CLIPScore: A Reference-free Evaluation Metric for Image Captioning. *EMNLP*, pp. 7514–7528, 2021. DOI: 10.18653/v1/2021.emnlp-main.595.

103. Otani M., Togashi R., Sawai Y., et al. Toward Verifiable and Reproducible Human Evaluation for Text-to-Image Generation. *CVPR*, pp. 14277–14286, 2023.

104. Thrush T., Jiang R., Bartolo M., et al. Winoground: Probing Vision and Language Models for Visio-Linguistic Compositionality. *CVPR*, pp. 5238–5248, 2022.

105. Goodfellow I., Bengio Y., Courville A. *Deep Learning*. MIT Press, 2016.

106. Shaw P., Uszkoreit J., Vaswani A. Self-Attention with Relative Position Representations. *NAACL*, 2018.

107. Su J., Ahmed M., Lu Y., et al. RoFormer: Enhanced Transformer with Rotary Position Embedding. *Neurocomputing* 568, 2024 (arXiv:2104.09864, 2021).

108. Rajbhandari S., Rasley J., Ruwase O., He Y. ZeRO: Memory Optimizations Toward Training Trillion Parameter Models. *SC20*, 2020.

109. Korthikanti V., Casper J., Lym S., McAfee L., Andersch M., Shoeybi M., Catanzaro B. Reducing Activation Recomputation in Large Transformer Models. arXiv:2205.05198, 2022.

110. MacKay M., Vicol P., Ba J., Grosse R. B. Reversible Recurrent Neural Networks. *NeurIPS 31*, 2018.

111. Behrmann J., Grathwohl W., Chen R. T. Q., Duvenaud D., Jacobsen J.-H. Invertible Residual Networks (i-ResNet). *ICML*, 2019.

112. Behrmann J., Vicol P., Wang K.-C., Grosse R., Jacobsen J.-H. Understanding and Mitigating Exploding Inverses in Invertible Neural Networks. *AISTATS*, 2021.

113. Maclaurin D., Duvenaud D., Adams R. P. Gradient-Based Hyperparameter Optimization Through Reversible Learning. *ICML*, 2015.

114. Wallace B., Gokul A., Ermon S., Naik N. End-to-End Diffusion Latent Optimization Improves Classifier Guidance (DOODL). *ICCV*, 2023.

115. Wallace B., Gokul A., Naik N. EDICT: Exact Diffusion Inversion via Coupled Transformations. *CVPR*, 2023.

116. Zhuang J., Dvornek N. C., Tatikonda S., Duncan J. S. MALI: A Memory-Efficient and Reverse-Accurate Integrator for Neural ODEs. *ICLR*, 2021.

117. Prabhudesai M., Goyal A., Pathak D., Fragkiadaki K. Aligning Text-to-Image Diffusion Models with Reward Backpropagation (AlignProp). arXiv:2310.03739, 2023.

118. Clark K., Vicol P., Swersky K., Fleet D. J. Directly Fine-Tuning Diffusion Models on Differentiable Rewards (DRaFT). *ICLR*, 2024.

119. Salimans T., Ho J. Progressive Distillation for Fast Sampling of Diffusion Models. *ICLR*, 2022.

120. Efron B. Bootstrap Methods: Another Look at the Jackknife. *The Annals of Statistics* 7(1):1–26, 1979.

121. Cameron A. C., Gelbach J. B., Miller D. L. Bootstrap-Based Improvements for Inference with Clustered Errors. *Review of Economics and Statistics* 90(3):414–427, 2008.

122. Westfall P. H., Young S. S. *Resampling-Based Multiple Testing: Examples and Methods for p-Value Adjustment*. Wiley, 1993.

123. Romano J. P., Wolf M. Exact and Approximate Stepdown Methods for Multiple Hypothesis Testing. *Econometrica* 73(4):1237–1282, 2005.

124. Srivastava N., Mansimov E., Salakhutdinov R. Unsupervised Learning of Video Representations using LSTMs (Moving MNIST). *ICML*, 2015.

125. Kuhn H. W. The Hungarian Method for the Assignment Problem. *Naval Research Logistics Quarterly* 2(1–2):83–97, 1955. DOI: 10.1002/nav.3800020109.

126. Zhang J., Zheng Y., Qi D. Deep Spatio-Temporal Residual Networks for Citywide Crowd Flows Prediction (TaxiBJ). *AAAI*, 2017.

127. Wang Z., Bovik A. C., Sheikh H. R., Simoncelli E. P. Image Quality Assessment: From Error Visibility to Structural Similarity. *IEEE Transactions on Image Processing* 13(4):600–612, 2004. DOI: 10.1109/TIP.2003.819861.

128. Zhang R., Isola P., Efros A. A., Shechtman E., Wang O. The Unreasonable Effectiveness of Deep Features as a Perceptual Metric. *CVPR*, 2018.

129. Unterthiner T., van Steenkiste S., Kurach K., et al. Towards Accurate Generative Models of Video: A New Metric and Challenges. arXiv:1812.01717, 2019.

130. Denton E., Fergus R. Stochastic Video Generation with a Learned Prior (SVG). *ICML*, 2018.

131. Lee A. X., Zhang R., Ebert F., et al. Stochastic Adversarial Video Prediction (SAVP). arXiv:1804.01523, 2018.

132. Alonso E., Jelley A., Micheli V., et al. Diffusion for World Modeling: Visual Details Matter in Atari (DIAMOND). *NeurIPS 37*, 2024.

133. Kulyk L. R., Mokin O. B. Methods for Ensuring Consistent Generation in Diffusion Models. *Visnyk of Vinnytsia Politechnical Institute*, No. 4, pp. 75–85, 2024. DOI: 10.31649/1997-9266-2024-175-4-75-85.

134. Kulyk L. R., Mokin O. B. Scaling Video Prediction with Spatio-Temporal Patches. *Visnyk of Vinnytsia Politechnical Institute*, No. 5, pp. 129–139, 2025. DOI: 10.31649/1997-9266-2025-182-5-129-139.

135. Kulyk L. Temporal Modeling with Reversible Transformers. *Neural Computing and Applications* 38, article 30, 2026. DOI: 10.1007/s00521-025-11707-3.

136. Kulyk L. R. When Does Hierarchical Video Memory Pay? Reach–Fidelity Trade-offs and an Integrated Resource-Efficient Predictor. Manuscript in preparation, 2026. **[ДАНІ ВІД АВТОРА: затвердити остаточну назву, список авторів, назву видання та статус публікації на момент подання.]**

137. Shi X., Chen Z., Wang H., Yeung D.-Y., Wong W.-K., Woo W.-C. Convolutional LSTM Network: A Machine Learning Approach for Precipitation Nowcasting. *NeurIPS 28*, 2015.

138. Wang Y., Long M., Wang J., Gao Z., Yu P. S. PredRNN: Recurrent Neural Networks for Predictive Learning Using Spatiotemporal LSTMs. *NeurIPS 30*, 2017.

139. Wang Y., Jiang L., Yang M.-H., Li L.-J., Long M., Fei-Fei L. Eidetic 3D LSTM: A Model for Video Prediction and Beyond. *ICLR*, 2019.

140. Le Guen V., Thome N. Disentangling Physical Dynamics from Unknown Factors for Unsupervised Video Prediction. *CVPR*, pp. 11474–11484, 2020.

141. Gao Z., Tan C., Wu L., Li S. Z. SimVP: Simpler Yet Better Video Prediction. *CVPR*, pp. 3170–3180, 2022.

142. Gao Z., Shi X., Wang H., Zhu Y., Wang Y. B., Li M., Yeung D.-Y. Earthformer: Exploring Space-Time Transformers for Earth System Forecasting. *NeurIPS 35*, 2022.

143. Rao Y., Zhao W., Liu B., Lu J., Zhou J., Hsieh C.-J. DynamicViT: Efficient Vision Transformers with Dynamic Token Sparsification. *NeurIPS 34*, 2021.

144. Ryoo M. S., Piergiovanni A. J., Arnab A., Dehghani M., Angelova A. TokenLearner: Adaptive Space-Time Tokenization for Videos. *NeurIPS 34*, 2021.

145. Yin H., Vahdat A., Alvarez J. M., Mallya A., Kautz J., Molchanov P. A-ViT: Adaptive Tokens for Efficient Vision Transformer. *CVPR*, pp. 10809–10818, 2022.

146. Bolya D., Fu C.-Y., Dai X., Zhang P., Feichtenhofer C., Hoffman J. Token Merging: Your ViT but Faster. *ICLR*, 2023.

147. Dehghani M., Djolonga J., Mustafa B., et al. Patch n' Pack: NaViT, a Vision Transformer for Any Aspect Ratio and Resolution. *NeurIPS 36*, 2023.

148. Beyer L., Izmailov P., Kolesnikov A., et al. FlexiViT: One Model for All Patch Sizes. *CVPR*, pp. 14496–14506, 2023.

149. Nichol A. Q., Dhariwal P. Improved Denoising Diffusion Probabilistic Models. *Proceedings of Machine Learning Research* 139:8162–8171, ICML, 2021.

150. Villar-Corrales A., Karapetyan A., Boltres A., Behnke S. MSPred: Video Prediction at Multiple Spatio-Temporal Scales with Hierarchical Recurrent Networks. *BMVC*, paper 34, 2022. arXiv:2203.09303.

151. Yin S., Wu C., Yang H., et al. NUWA-XL: Diffusion over Diffusion for eXtremely Long Video Generation. *ACL*, pp. 1309–1320, 2023. DOI: 10.18653/v1/2023.acl-long.73.

152. Wang Y., Gao Z., Long M., Wang J., Yu P. S. PredRNN++: Towards a Resolution of the Deep-in-Time Dilemma in Spatiotemporal Predictive Learning. *Proceedings of Machine Learning Research* 80:5123–5132, ICML, 2018.

153. Tan C., Gao Z., Wu L., Xu Y., Xia J., Li S., Li S. Z. Temporal Attention Unit: Towards Efficient Spatiotemporal Predictive Learning. *CVPR*, pp. 18770–18782, 2023.

154. Schuldt C., Laptev I., Caputo B. Recognizing Human Actions: A Local SVM Approach. *International Conference on Pattern Recognition*, Vol. 3, pp. 32–36, 2004. DOI: 10.1109/ICPR.2004.1334462.

155. Babaeizadeh M., Saffar M. T., Nair S., Levine S., Finn C., Erhan D. FitVid: Overfitting in Pixel-Level Video Prediction. arXiv:2106.13195, 2021.

156. Voleti V., Jolicoeur-Martineau A., Pal C. MCVD: Masked Conditional Video Diffusion for Prediction, Generation, and Interpolation. *NeurIPS 35*, 2022.

157. Höppe T., Mehrjou A., Bauer S., Nielsen D., Dittadi A. Diffusion Models for Video Prediction and Infilling. *Transactions on Machine Learning Research*, 2022. arXiv:2206.07696.

158. Ge S., Hayes T., Yang H., et al. Long Video Generation with Time-Agnostic VQGAN and Time-Sensitive Transformer. *ECCV*, pp. 102–118, 2022.

159. Loshchilov I., Hutter F. Decoupled Weight Decay Regularization. *ICLR*, 2019.

160. Ba J. L., Kiros J. R., Hinton G. E. Layer Normalization. arXiv:1607.06450, 2016.

161. Zhang B., Sennrich R. Root Mean Square Layer Normalization. *NeurIPS 32*, 2019.

162. Micikevicius P., Narang S., Alben J., et al. Mixed Precision Training. *ICLR*, 2018. arXiv:1710.03740.

163. Pech-Pacheco J. L., Cristóbal G., Chamorro-Martínez J., Fernández-Valdivia J. Diatom Autofocusing in Brightfield Microscopy: A Comparative Study. *International Conference on Pattern Recognition*, Vol. 3, pp. 314–317, 2000. DOI: 10.1109/ICPR.2000.903548.

164. Rosenfeld A., Pfaltz J. L. Sequential Operations in Digital Picture Processing. *Journal of the ACM* 13(4):471–494, 1966. DOI: 10.1145/321356.321357.

165. Gebru T., Morgenstern J., Vecchione B., et al. Datasheets for Datasets. *Communications of the ACM* 64(12):86–92, 2021. DOI: 10.1145/3458723.

166. Pineau J., Vincent-Lamarre P., Sinha K., et al. Improving Reproducibility in Machine Learning Research: A Report from the NeurIPS 2019 Reproducibility Program. *Journal of Machine Learning Research* 22(164):1–20, 2021.

167. Dwork C., Feldman V., Hardt M., Pitassi T., Reingold O., Roth A. Generalization in Adaptive Data Analysis and Holdout Reuse. *NeurIPS 28*, 2015.

168. Nosek B. A., Ebersole C. R., DeHaven A. C., Mellor D. T. The Preregistration Revolution. *Proceedings of the National Academy of Sciences* 115(11):2600–2606, 2018. DOI: 10.1073/pnas.1708274114.

169. Glasserman P. *Monte Carlo Methods in Financial Engineering*. Springer, 2003. DOI: 10.1007/978-0-387-21617-1.

170. Bouthillier X., Delaunay P., Bronzi M., et al. Accounting for Variance in Machine Learning Benchmarks. *Proceedings of Machine Learning and Systems* 3:747–769, 2021.

171. Kulyk L. *Simple Shape Dataset Toolbox: Procedural 2-D and 3-D Shape-Sequence Generators*. Software repository, MIT License, 2026. Available at: https://github.com/leo27heady/simple-shape-dataset-toolbox.

172. Kulyk L. *TempVerseFormer: Temporal Modeling with Reversible Transformers*. Software repository, MIT License, 2026. Available at: https://github.com/leo27heady/TempVerseFormer.

173. Kulyk L. *visionBLT: Vision Byte Latent Transformer Implementation*. Software repository, 2026. Available at: https://github.com/leo27heady/visionBLT.

174. Hertzmann A. Toward a Theory of Perspective Perception in Pictures. *Journal of Vision* 24(4):23, 2024. DOI: 10.1167/jov.24.4.23.

ДОДАТКИ

У додатках зібрано матеріали, які перевантажували б основний науковий виклад. Вони не розширюють обсяг виконаних експериментів. Якщо певний пункт залежить від інституційного документа, авторського рішення або остаточного статусу публікації, потрібні дії автора зазначено прямо, а не виведено з вмісту репозиторію.

Додаток А – Публікації, результати дисертації та особистий внесок

Позначення, що використовуються в цьому додатку, стосуються списку публікацій, представленого у вступі, а не порядку організації наукового розділу. Їхній зв’язок із результатами та особистим внеском подано в таблиці А.1.

Таблиця А.1 – Публікації, використані результати та особистий внесок здобувача.

Публікація	**Роль у дисертації**	**Результати, використані в дисертації**	**Внесок здобувача**	**Збережена кваліфікація**
[A1] Кулик і Мокін, *Масштабування прогнозування відео за допомогою просторово-часових патчів*	Розділ 2: метод просторового представлення	фіксовані растрово-байтові патчі 4 × 4 × 4, локальна–глобальна–локальна обробка V-BLT, RoPE-ND, категоріальне прогнозування, карти ентропії, опубліковані оцінки витрат і якості	розроблення методу та програмного забезпечення, процедурні експерименти, кількісний і якісний аналіз, підготовка рукопису; внесок наукового керівника у формування системної концепції та рецензування	динамічне ентропійне формування областей запропоновано, але не реалізовано; поточна конфігурація репозиторію за замовчуванням сама по собі не встановлює опубліковану довжину часового патча
[A2] Кулик, *Temporal Modeling with Reversible Transformers*	метод зменшення пам’яті активацій у розділі 2	ядро реверсивного трансформера, часовий ланцюг, результати контрольованого обертання, порівняння з OpenSTL, вимірювання пам’яті й часу	розроблення, реалізація, експерименти, аналіз і рукопис, виконані автором	точна реконструкція стосується збережуваного подвоєного стану трансформера; кодер/декодер, навчені проєкції, злиття та функція втрат лежать поза реверсивною межею; якість неоднорідна, а відтворення потребує додаткових обчислень

Публікація	**Роль у дисертації**	**Результати, використані в дисертації**	**Внесок здобувача**	**Збережена кваліфікація**
[A3] Кулик та Мокін, *Методи забезпечення консистентності генерації в дифузійних моделях*	Розділ 1: концептуальна відправна точка	зовнішній вигляд/стиль, ідентичність, геометрія/форма та концептуальна консистентність; порівняння методів керування на основі вхідних даних, ваг, структури, інверсії та уваги	технічний огляд, синтез та пропозиція категорії концептуальної консистентності; внесок наукового керівника у наукове формулювання та редакційну рецензію	якісний огляд статичних зображень, а не систематичний огляд чи часовий експеримент; дисертація поширює свої критерії на відео, замість того щоб розглядати їх як готові часові докази
[A4] Кулик, підготовлювана стаття про ієрархічну відеопам'ять та інтегровану ресурсоефективну архітектуру	Розділи 3–4: емпірична основа й інтеграція	явні пакети контексту, спостережуваність TRB, перевірену межу «досяжність–точність відтворення», матрицю структурних порівнянь бюджетів і розподілів, а також окремо контрольоване фізичне пакування, маршрутизацію й внутрішньо реверсивне ядро	модель, генератори, програмне забезпечення оцінювання й статистики, проєктування та виконання експериментів, інтеграція OpenSTL, кураторство артефактів, аналіз і рукопис	**[ДАНІ ВІД АВТОРА: перед поданням затвердити назву, остаточний склад авторів, видання, бібліографічний статус і заяву про внесок; незавершені A4 та інтегровані результати не включати як фактичні.]**
Предиктор зі сталими ділянками, не окрема запланована стаття	Підрозділи 3.7.2 і 4.9.1–4.9.3	фіксоване грубо-детальне пакування, адаптація SimVP, якість однієї ініціалізації та інженерний профіль другопорядкового реверсивного ланцюга	постановка інтеграційного інтерфейсу, реалізація, профілювання, аналіз і формування маніфесту доказів	обмежена перевірка технічної здійсненності; 2,58× не є порівнянням тотожної прямої функції, а перевірка адаптивної інтеграції входить до підготовлюваної [A4], а не утворює п'яту статтю

Власне дисертаційний внесок охоплює системний синтез методів, аудит реалізацій TempVerseFormer і V-BLT, явне розмежування пам'яті контексту/стану та активацій, стохастичне розширення реверсивного відтворення, формування правила вибору за робочою областю, предиктор зі сталими ділянками та остаточний фізично запакований OpenSTL-інтерфейс. Ці

доповнення не можна ретроактивно приписувати опублікованим статтям незалежно від їхнього бібліографічного статусу.

Додаток Б – Адміністративні записи та акти про впровадження

Остаточна інституційна версія має містити перевірені відомості про обидві держбюджетні теми, роль здобувача в кожній із них, усі шість конференційних публікацій та повний перелік праць. Потрібно також додати підписані акти впровадження; відновлювати їхній зміст із пам’яті не можна. До основного тексту включаються лише акти та охоплені ними компоненти, підтверджені підписаними інституційними документами. Поточний стан цих записів наведено в таблиці Б.1, а робочий порядок їх завершення — в окремому редакційному чеклісті, який не входить до тексту дисертації.

Таблиця Б.1 – Адміністративні записи, які потребують остаточного підтвердження.

Необхідний запис	**Стан у репозитарії**	**Необхідні дії автора**
УДК та формулювання титульного аркуша	попереднє значення у вступній частині	перевірити на відповідність затвердженому запису ВНТУ; код 124/галузь 12 не замінювати на F4 автоматично, а звірити з документами освітньо-наукової програми й роком вступу
Державно-бюджетний проект 1	відсутній авторитетний номер або підписаний текст у репозитарії	додати назву, номер, дати та роль здобувача
Проект державного бюджету 2	у репозитарії відсутні офіційний номер або підписаний текст	ввести назву, номер, дати та роль здобувача
Публікації конференції	неповний адміністративний перелік	заповнити всі шість записів та підтвердити, чи належить до них DSMSI-2023
Статус статті [A4]	спільний рукопис про A4 та інтегровану модель перебуває в підготовці	після завершення експериментів ввести остаточну назву, видання, список авторів, статус і формулювання особистого внеску
Акт про впровадження ТОВ «ОРНЕТИКА»	дата та наукова сфера, описані в розділі 4	ввести скановану копію з підписом та присвоєну літеру додатка; зберегти точний обсяг акту
Акт про впровадження ВНТУ	дата та наукова сфера, описані в розділі 4	ввести скановану копію з підписом та присвоєну літеру додатка; зберегти точний обсяг акту

Необхідний запис	Стан у репозитарії	Необхідні дії автора
Статистика кінцевого документа	недоступна до інституційного верстання	вставити загальну кількість сторінок та сторінок основного тексту, кількість рисунків/таблиць, кількість посилань та літери додатків
Ліцензії на повторно використані рисунки	зафіксована декларація авторських прав та ліцензії джерел	жодних додаткових дій щодо дозволів для збережених рисунків, створених автором під ліцензією CC BY; зберегти вказівку на авторство в кінцевому верстанні

Додаток В – Реєстр конфігурацій та правил інтерпретації

Цей додаток містить самодостатню сітку виконаних конфігурацій тороїдального тесту повторного входу (TRB; внутрішня назва LoopMom) і правила, за якими їх можна порівнювати. Розширений електронний реєстр із парними ефектами, шляхами артефактів та журналами доступу збережено у файлі `APPENDIX_CH4_CONFIGURATION_AND_EVIDENCE_REGISTRY.md`; він доповнює, але не замінює наведені нижче записи. Базові ліцензії на інтерпретацію визначено в таблиці В.1.

Таблиця В.1 – Ліцензії на інтерпретацію експериментальних порівнянь.

Ліцензія порівняння	Допустиме тлумачення	Заборонений висновок
MATCHED	ефект зареєстрованої пари пакетів за названого зіставленого бюджету й інтерфейсу	універсальна архітектурна перевага
NEAR_MATCHED	напрям ефекту за розкритої малої різниці бюджетів	точний причинний ефект однакового бюджету
MATCHED_CAPACITY	порівняння механізмів за близької ємності основи та спільного контексту	тотожність цілей або обчислень під час застосування
WHOLE_CONFIGURATION	результат повної виконаної конфігурації	ефект одного компонента, що змінювався разом з іншими
DEVELOPMENT_FACTORIAL	ефект та взаємодія за ініціалізаціями на адаптивно використаній вибірці	відкладене підтвердження
DEVELOPMENT_DIAGNOSTIC	діагностика механізму зі збереженням названих змішаних чинників	підтверджений причинний закон
ROBUSTNESS_ONLY	чутливість уже вибраних контрастів до названого втручання	новий вибір моделі або ширше узагальнення
REGISTERED_REPLICATION	незалежний від результату вердикт щодо замороженого передбачення	переозначення після отримання несприятливого результату

Ліцензія порівняння	Допустиме тлумачення	Заборонений висновок
PRIVILEGED_REFERENCE	діагностична цінність явної адресації або додаткової інформації	токенно зіставлене ранжування моделей
EXTERNAL_BOUNDARY	поведінка за зміненого завдання та набору кінцевих показників	пряма реплікація геометрії LoopMom
DESCRIPTIVE_BOUNDARY	компетентність або відмова поза центральним механізмом	еквівалентність, перевага або підтвердження механізму

У таблиці В.2 досяжність вимірюється у кадрах, а контекстні й загальні витрати – у токенах. Глибина подана як кількість просторових рівнів / часових швидкостей. Повторення назви гілки означає інший режим оптимізації, а не дубль запису.

Таблиця В.2 – Повний реєстр виконаних гілок LoopMom.

ID	Гілка та пакет	Вихід	Досяжність	Контекст	Загалом	Глибина	Ініціалізації	Режим
LM01	hier-short: 6 грубих + 6 детальних	дифузійний	6	480	800	2 / 1	0–1	B16×30k
LM02	flat-short: 8 детальних	дифузійний	8	512	832	1 / 1	0–1	B16×30k
LM03	flat-short-reg: 8 детальних	регресійний	8	512	832	1 / 1	0	B16×30k
LM04	hier-s2-min: 24 грубі з кроком 2 + 2 детальні	дифузійний	48	512	800	2 / 2	0–1	B16×30k
LM05	hier-s2-min-reg	регресійний	48	512	800	2 / 2	0	B16×30k
LM06	spat18: 18 грубих + 6 детальних	дифузійний	18	672	992	2 / 1	0	B16×30k
LM07	spat18-reg	регресійний	18	672	992	2 / 1	0	B16×30k
LM08	flat-min: 14 детальних	дифузійний	14	896	1 216	1 / 1	0–1	B16×30k
LM09	hier-min: 48 грубих + 2 детальні	дифузійний	48	896	1 216	2 / 1	0–1	B16×30k
LM10	strided-flat: 11 детальних прив’язок із кроком 4 + 6 детальних	дифузійний	48	1 088	1 408	1 / 2	0–4	B16×30k

ID	Гілка та пакет	Вихід	Досяжність	Контекст	Загалом	Глибина	Ініціалізації	Режим
LM11	strided-flat-reg	регресійний	48	1 088	1 408	1 / 2	0–4	B16×30k
LM12	flat-budget: 18 детальних	дифузійний	18	1 152	1 472	1 / 1	0–2	B16×30k
LM13	flat-budget: 18 детальних	дифузійний	18	1 152	1 472	1 / 1	0	B8×60k
LM14	reg-flat: 18 детальних	регресійний	18	1 152	1 472	1 / 1	0–1	B16×30k
LM15	hier-long: 48 грубих + 6 детальних	дифузійний	48	1 152	1 472	2 / 1	0–4	B16×30k
LM16	hier-long: 48 грубих + 6 детальних	дифузійний	48	1 152	1 472	2 / 1	0	B8×60k
LM17	reg-long: 48 грубих + 6 детальних	регресійний	48	1 152	1 472	2 / 1	0–4	B16×30k
LM18	hier3: 48 верхніх + 24 грубі + 9 детальних	дифузійний	48	1 152	1 488	3 / 1	0	B16×30k
LM19	flat-c1: 28 детальних	дифузійний	28	1 792	2 112	1 / 1	0	B16×30k
LM20	hier-c1: 48 грубих + 16 детальних	дифузійний	48	1 792	2 112	2 / 1	0	B16×30k
LM21	flat-c2: 38 детальних	дифузійний	38	2 432	2 752	1 / 1	0	B16×30k
LM22	hier-c2: 48 грубих + 26 детальних	дифузійний	48	2 432	2 752	2 / 1	0	B16×30k
LM23	flat-c2: 38 детальних	дифузійний	38	2 432	2 752	1 / 1	0	B8×60k
LM24	hier-c2: 48 грубих + 26 детальних	дифузійний	48	2 432	2 752	2 / 1	0	B8×60k
LM25	flat-long: 48 детальних	дифузійний	48	3 072	3 392	1 / 1	0–1	B8×60k
LM26	hier-rich: 48 грубих + 36 детальних	дифузійний	48	3 072	3 392	2 / 1	0–1	B8×60k

Сітка є повною щодо виконаної програми, але не прямокутною. Структурно відсутні комірки зафіксовано окремо в таблиці B.3, щоб їх не сприймали як незавершені результати.

Таблиця В.3 – Структурно відсутні та остаточно закриті експериментальні комірки.

Запропонована комірка	Завершальний стан	Наслідок для висновку
flat-320	**NOT_EXECUTED / OUT_OF_SCOPE**	точка межі на 320 токенах не заявляється
hier-s4-min	**NOT_EXECUTED / OUT_OF_SCOPE**	закон для грубого потоку з кроком 4 не заявляється
hier3-reg	**NOT_EXECUTED / OUT_OF_SCOPE**	міжмодульний висновок для третього рівня не заявляється
E5b/E5c	**NOT_AUTHORIZED after E5a**	невдала реплікація пізньої інверсії є завершальною
E9	**SKIPPED_POST_FREEZE_NO_INCREMENTAL_UTILITY**	додаткові GPU-докази для поточних тверджень не потрібні
B1 із фіксованою ціллю	**NOT_EXECUTED / OUT_OF_SCOPE**	B1 назавжди залишається порівнянням повних конфігурацій

Таблиця В.4 доповнює реєстр гілок групуванням за науковими порівняннями. «C/F» позначає кількість грубих і детальних слотів контексту; C0 є початковим кодеком, C1 – незалежно навченим. Якщо не зазначено інше, використано DDIM-16 з ініціалізацією алгоритму вибірки 0.

Таблиця В.4 – Повна матриця виконаних компонентів і конфігурацій.

Дослідження або група	Кодек	Пакет; досяжність	Токени контексту / цілі / загалом	Вихід	Цільовий інтерфейс	Вибірка	Дані	Ініціалізації	Статус
hier-short / flat-short	C0	6C+6F, R6 / 8F, R8	480/320/800 проти 512/320/832	дифузія	4 щільні цілі	DDIM-16	Loop Mom	0–1	майже зіставлена нижня діагностика
B1 hier-s2-min / flat-short	C0	24C+2F, R48 / 8F, R8	512/288/800 проти 512/320/832	дифузія; регресійний контроль	крок цілі 2 та допоміжний інтерфейс у B1	DDIM-16 / один прохід	Loop Mom	дифузія 0–1; регресія 0	підтверджено ефект повної конфігурації
spat18 / flat-budget	C0	18C+6F, R18 / 18F, R18	672/320/992 проти 1 152/320/1 472	дифузія та регресія	4 щільні цілі	DDIM-16 / один прохід	Loop Mom	0	діагностика абстракції
hier-min / flat-min	C0	48C+2F, R48 / 14F, R14	по 896/320/1 216	дифузія	4 щільні цілі	DDIM-16	Loop Mom	0–1	відкладене підтвердження нижньої області

Дослідження або група	Кодек	Пакет; досяжність	Токени контексту / цілі / загалом	Вихід	Цільовий інтерфейс	Вибірка	Дані	Ініціалізації	Статус
hier-long / flat-budget	C0	48C+6F, R48 / 18F, R18	по 1 152/32 0/1 472	дифузія; регресійний контроль	4 щільні цілі	DDIM-16 / один прохід	Loop Mom	дифузія 0–4 / 0–2; регресія 0–4 / 0–1	підтвердження та факторні контролі
strided-flat / hier-long	C0	11F з кроком 4 + 6F, R48 / 48C+6F, R48	1 088/32 0/1 408 проти 1 152/32 0/1 472	дифузія та регресія	4 щільні цілі	DDIM-16 / один прохід	Loop Mom	0–4	майже зіставлений факторний експеримент
hier3 / hier-long	C0	48 верхніх +24C+9F / 48C+6F; R48	1 152/33 6/1 488 проти 1 152/32 0/1 472	дифузія	різний розподіл цілей	DDIM-16	Loop Mom	0	діагностика повної трирівневої конфігурації
hier-c1 / flat-c1	C0	48C+16F, R48 / 28F, R28	по 1 792/32 0/2 112	дифузія	4 щільні цілі	DDIM-16	Loop Mom	0	невизначена відкладена точка
hier-c2 / flat-c2	C0	48C+26F, R48 / 38F, R38	по 2 432/32 0/2 752	дифузія	4 щільні цілі	DDIM-16	Loop Mom	0, два режими	плоский пакет підтверджено
hier-rich / flat-long	C0	48C+36F, R48 / 48F, R48	по 3 072/32 0/3 392	дифузія	4 щільні цілі	DDIM-16	Loop Mom	0–1	плоский пакет підтверджено
E5a	C0	довга ієрархія / щільна база; R224	зареєстрована пара	дифузія	довгоциклове розгортання	зареєстрована	довгоцикловий Loop Mom	0–2	ранній ефект відтворено, пізню інверсію не відтворено
E7c	C0	4 контрасти, 896–2 432	як вище	дифузія	без змін	NFE 8/16/32; ініціалізації 0–2	захищений Loop Mom	предиктор 0	20 ефектів, напрямкова робастність

Дослідження або група	Кодек	Пакет; досяжність	Токени контексту / цілі / загалом	Вихід	Цільовий інтерфейс	Вибірка	Дані	Ініціалізації	Статус
E7a	C1 і контроль C0	7 предикторів, 4 контрасти	як вище	дифузія	без змін	DDIM-16	захищений Loop Mom	предиктор 0	8 ефектів повної заміни кодека
E8a	необроблені пікселі й C0	K6/K14/K38/K48	без зіставлення	прямий пошук і дифузійні еталони	точна майбутня поза	прямий пошук / DDIM-16	захищений Loop Mom	детермінований / 0	еталон із прямим доступом
E6	C0	18F, R18 / 48C+6F, R48	по 1 152 контекстних токенів	дифузія	300 кадрів після 48 кадрів прогріву	зареєстрована	довгий Moving-MNIST	0–2	змішана зовнішня межа
mm-flat / mm-hier	тестовий кодек	10F / 10C+6F	640 проти 544	дифузія	OpenSTL 10→10	один кандидат	Moving-MNIST	0	описовий короткий контроль
TaxiBJ, 4 гілки	двоканальний кодек	4F / 4C+1F	256 проти 128	дифузія та регресія	OpenSTL 4→4	DDIM / один прохід	TaxiBJ	0	описова межа на реальних даних
B1 із фіксованою ціллю	–	запропонований контроль	–	–	ізолював би зміну цілей	–	Loop Mom	–	не виконано; не потрібний для конфігураційного твердження
flat-320, hier-s4-min, hier3-reg	–	комірки заповнення сітки	–	–	–	–	Loop Mom	–	не виконано / поза сферою

Дослідження або група	Кодек	Пакет; досяжність	Токени контексту / цілі / загалом	Вихід	Цільовий інтерфейс	Вибірка	Дані	Ініціалізації	Статус
E5b та E9	–	запропоновані розширення	–	–	–	–	–	–	не авторизовано; E9 остаточно пропущено

Таблиця B.5 відокремлює причинно зіставлені контрасти від діагностик повних конфігурацій. Її рядки не утворюють одного повністю перехресного факторного експерименту.

Таблиця B.5 – Карта доказів форми контексту та ліцензії на порівняння.

Питання	Порівняння	Зафіксовано	Змінюється одночасно	Ліцензія	Допустимий висновок
Вихід за межі плоского вікна	hier-min / flat-min	бюджети, кодек, вихід, кліпи, популяція	досяжність і деталізація давньої історії	**MATCHED**, E2	перевага зосереджується там, де лише ієрархія адресує минуле
Абстракція за фіксованого проміжку	spat18 / flat-budget	проміжок 18 кадрів, хвіст, кодек	672 проти 1 152 токенів	**DEVELOPMENT_DIAGNOSTIC**	внутрішньої переваги абстракції не встановлено
Часове проти просторового стиснення	strided-flat / hier-long	R48, детальний хвіст, модель, кодек	тип стиснення; 1 088 проти 1 152 токенів	**NEAR_MATCHED**, факторний дослід	дифузійний напрям стабільний, регресійний неоднорідний
Простір × час, крок 2	B1 / flat-short	512 контекстних токенів, парні записи	цілі, допоміжна втрата, довжина й навантаження	**WHOLE_CONFIGURATION**, E2	підтверджено повну B1, не чистий ефект кроку
Додана глибина	hier3 / hier-long	1 152 токени, R48, дифузійна основа	цілі, розподіл токенів і навантаження	**DEVELOPMENT_DIAGNOSTIC**	конкретна трирівнева конфігурація гірша на −0,0196 [−0,0248; −0,0146]; загального закону немає
Внесок потоку	засліплення грубого, детального або верхнього потоку	модель і записи	обнулення поза навчальним розподілом	**DEVELOPMENT_DIAGNOSTIC**	функціональна необхідність не дорівнює інформаційній цінності

Питання	Порівняння	Зафіксовано	Змінюється одночасно	Ліцензія	Допустимий висновок
Розподіл бюджету	межа E2	кодек, вихід, показники, дискретні пари	кількість ініціалізацій за бюджетом	одночасне сімейство E2	спершу оплачувати досяжність, після її насичення – деталі

Повну системну матрицю вибору збережено в таблиці B.6, щоб правила застосовності не перевантажували §4.10.

Таблиця B.6 – Застосовність розроблених і порівняльних втручань.

Втручання	Ресурс	Перевага	Вартість або відмова	Доказовість	Придатна область
Щільний плоский контекст	контекст/стан	повна ідентичність і текстура	лінійна токенна вартість досяжності	верхня межа E2 та ідентичність E6	потрібна історія вже доступна, деталі критичні
Просторовий ієрархічний контекст	контекст/стан	щільна довга груба історія	стиснення давніх деталей	E2 за 896/1 152; межа E6	минуле поза детальним вікном; важливе покриття
Часове проріджування з детальним хвостом	контекст/стан	давні прив’язки повної деталізації	пропуски проміжної динаміки	факторний результат розроблення	стан змінюється повільно між прив’язками
Просторово-часовий пакет із кроком 2	контекст і цілі	дешевша повна конфігурація R48	кілька інтерфейсів змінено разом	B1 як повна конфігурація	лише як виконаний цілісний інтерфейс
Подання за інформаційною щільністю	просторовий розподільник	потенційна локальна деталізація	політика й стабільність маршрутизації не розв’язані	карти ентропії; діагностика маршрутизації	майбутні неоднорідні сцени
Фіксований грубо-детальний стан із реверсивністю	просторовий стан та активації	384 значення на кадр і стабільніший пік	фіксована геометрія; одна ініціалізація	перевірка технічної здійсненності	інтеграційний прототип, не заміна E2
Градієнтні контрольні точки	активації	загальне переобчислення	залишкові активації та схема контрольних точок	відомий базовий підхід; без прямого факторного тесту	довільні нереверсивні блоки

Втручання	Ресурс	Перевага	Вартість або відмова	Доказовість	Придатна область
Реверсивне часове відтворення	активації	реконструкція проміжних станів	обчислення відтворення й чисельні обмеження	TempVerseFormer та інтеграційний контроль	довге диференціювання з відтворюваним станом
Явна пам’ять із прямим доступом	зберігання й адресація	верхня межа використання історії	привілейована поза та необроблені пікселі	E8a, діагностичний еталон	аналіз механізму, не ранжування моделей

Для довідкового зіставлення ідентифікаторів нижче наведено карту експериментальних програм, вилучену з основного тексту.

Таблиця В.7 – Коди експериментальних програм, питання та класи доказів.

Код або група	Наукове питання	Клас доказів	Варіанти або ініціалізації
Вибір механізму	Який вихідний модуль придатний для подальшого порівняння пакетів?	розроблення	регресія, дифузія, два енергетичні варіанти
A4-COR	Яка тривалість навчання стабілізує абсолютні значення й порядок конфігурацій?	калібрування розроблення	плоска недавня та збалансована ієрархічна конфігурації; ініціалізація 0; 15 зрізів до 30 000 кроків
A4-FRT/ALC/CEX	Як бюджет, розподіл між рівнями й розширення грубого контексту змінюють компроміс «досяжність–точність відтворення»?	матриця розроблення TRB	шість бюджетів; три FRT-стратегії; сім ALC-розподілів; шість довжин CEX; ініціалізації 0–1
A4-LVL/OVR/STS	Як впливають кількість рівнів, володіння часовими позиціями та просторово-часове розміщення деталізації?	залежна матриця розроблення TRB	1/2/3 рівні; nested/exclusive/residual; чотири квоти на кадр × три часові стратегії; ініціалізації 0–1
A4-MEC і підтвердження	Чи використовують вибрані моделі давній контекст і чи зберігається результат на свіжих кліпах?	діагностика механізму та одноразове підтвердження	три зафіксовані контрольні точки × дві ініціалізації; 500 нових кліпів
E2	Чи допомагає ієрархія, коли коротше плоске вікно не містить релевантного минулого, і де відновлюється перевага деталей?	відкладене підтвердження	ініціалізації навчання 0–2 залежно від бюджетної точки
B1	Чи працездатна конфігурація з кроком 2 і зміненим цільовим інтерфейсом?	відкладений тест повної конфігурації	ініціалізації навчання 0–1

Код або група	Наукове питання	Клас доказів	Варіанти або ініціалізації
E4b	Чи залежить ефект форми пакета від вихідного модуля та ініціалізації?	факторний експеримент розроблення	п’ять ініціалізацій навчання
E5a	Чи відтворюється пізня інверсія під час самоподачі?	зареєстрована реплікація	ініціалізації навчання 0–2
E7c	Чи чутливі напрями до бюджету й випадковості алгоритму вибірки?	робастність	NFE 8/16/32; ініціалізації алгоритму вибірки 0–2
E7a	Чи зберігаються напрями за іншого кодека прихованого простору?	робастність	один альтернативний кодек; ініціалізація предиктора 0
E8a	Що залишається за явного зберігання та адресації історії?	еталон із прямим доступом	K6, K14, K38 і K48
E6	Чи розділяє форма пакета просторове покриття та ідентичність?	захищена зовнішня межа	ініціалізації навчання 0–2
Короткі стандартні набори	Чи працює модель поза основною геометрією TRB?	описова межа працездатності	одна ініціалізація на гілку
Інтегрована модель з адаптивним пакуванням	Чи сумісні фізичне ієрархічне пакування, маршрутизація та реверсивне ядро і який їхній окремий внесок у якість та пам’ять?	програмна коректність, компонентний профіль і зовнішня перевірка	Moving MNIST 10→10 і TaxiBJ 4→4; повна модель з ініціалізаціями 0–1; короткі контролі працездатності та ресурсний профіль

Повний числовий контракт пакетів винесено окремо, оскільки він потрібний для відтворення, але надмірно деталізує основну аргументацію §3.4.3.

Таблиця В.8 – Точний облік пакетів, токенів і корисного обсягу контекстних даних для основної межі та інтерфейсів B1. Значення описують інтерфейс моделі, а не повну VRAM або час виконання.

Пакет	Точний опис контексту	Номінальна досяжність	Токени контексту / цілі / загальні	Корисний обсяг даних прихованого простору, fp32 / bf16	Вбудовування контексту шириною 384, bf16	Роль порівняння
flat-short	8 суцільних детальних кадрів	8	512 / 320 / 832	32 / 16 КіБ	0,375 МіБ	Базова плоска конфігурація B1
hier-s2-min	24 грубих кадри з кроком 2 + 2 останніх детальних	48	512 / 288 / 800	32 / 16 КіБ	0,375 МіБ	Повна конфігурація B1; ціль відрізняється

Пакет	Точний опис контексту	Номінальна досяжність	Токени контексту / цілі / загальні	Корисний обсяг даних прихованого простору, fp32 / bf16	Вбудовування контексту шириною 384, bf16	Роль порівняння
flat-min	14 суцільних детальних кадрів	14	896 / 320 / 1 216	56 / 28 КіБ	0,656 МіБ	зіставлений нижній плоский контроль
hier-min	48 щільних грубих кадрів + 2 останніх детальних	48	896 / 320 / 1 216	56 / 28 КіБ	0,656 МіБ	зіставлена нижня ієрархія
flat-budget	18 суцільних детальних кадрів	18	1 152 / 320 / 1 472	72 / 36 КіБ	0,844 МіБ	зіставлений центральний плоский контроль
hier-long	48 щільних грубих + 6 останніх детальних	48	1 152 / 320 / 1 472	72 / 36 КіБ	0,844 МіБ	основна просторова ієрархія
strided-flat	11 старих детальних прив’язок + 6 недавніх детальних кадрів	зареєстрований клас з інтервалом 48 кадрів	1 088 / 320 / 1 408	68 / 34 КіБ	0,797 МіБ	майже зіставлений часовий пакет
flat-c1	28 суміжних детальних кадрів	28	1 792 / 320 / 2 112	112 / 56 КіБ	1,313 МіБ	зіставлений проміжний плоский контроль
hier-c1	48 щільних грубих + 16 останніх детальних	48	1 792 / 320 / 2 112	112 / 56 КіБ	1,313 МіБ	зіставлена проміжна ієрархія
flat-c2	38 суцільних детальних кадрів	38	2 432 / 320 / 2 752	152 / 76 КіБ	1,781 МіБ	зіставлений верхній плоский контроль
hier-c2	48 щільних грубих + 26 останніх детальних	48	2 432 / 320 / 2 752	152 / 76 КіБ	1,781 МіБ	зіставлена верхня ієрархія

Пакет	Точний опис контексту	Номінальна досяжність	Токени контексту / цілі / загальні	Корисний обсяг даних прихованого простору, fp32 / bf16	Вбудовування контексту шириною 384, bf16	Роль порівняння
flat-long	48 суміжних детальних кадрів	48	3 072 / 320 / 3 392	192 / 96 КіБ	2,250 МіБ	щільний еталон з однаковою досяжністю
hier-rich	48 щільних грубих + 36 останніх детальних	48	3 072 / 320 / 3 392	192 / 96 КіБ	2,250 МіБ	відповідна ієрархія з максимальним бюджетом

Executed experimental coverage and explicit non-executed cells

Study / role	Dataset	Package / contrast	Ctx tokens	Head	Train seeds	Codec	Sampler / NFE	Evidence state
E2 lower reach	LoopMom holdout	hier-min / flat-min	896	diff	0–1	original	DDIM 16 / s0	untouched confirmed
E2 interior	LoopMom holdout	hier-long / flat-budget	1,152	diff	0–2	original	DDIM 16 / s0	untouched confirmed
E2 middle	LoopMom holdout	hier-c1 / flat-c1	1,792	diff	0	original	DDIM 16 / s0	unresolved
E2 upper	LoopMom holdout	hier-c2 / flat-c2	2,432	diff	0; 30k/60k	original	DDIM 16 / s0	flat confirmed
E2 dense reach	LoopMom holdout	hier-rich / flat-long	3,072	diff	0–1	original	DDIM 16 / s0	flat confirmed
B1 whole configuration	LoopMom holdout	hier-s2-min / flat-short	512	diff	0–1	original	DDIM 16 / s0	configuration confirmed
E4b shape × head	LoopMom development	temporal 1,088 / spatial 1,152	near-match	diff + reg	0–4	original	DDIM 16 / s0	seed robustness
E7a codec	LoopMom protected	four registered contrasts	896–2,432	diff	0	alternate	DDIM 16 / s0	codec robustness
E7c inference	LoopMom protected	four registered contrasts	896–2,432	diff	0	original	NFE 8/16/32; s0–2	sampler robustness
E5a reliability	long-loop hgrid3 set	long-reach / dense comparator	registered pair	diff	0–2	original	registered sampler	not replicated
E8a explicit access	LoopMom protected	raw K14/K38/K48 + neural refs	not matched	raw + diff refs	seed-0 refs	raw / original	exact pose / DDIM 16	privileged reference
E6 external boundary	Long Moving-MNIST	hierarchical / flat	1,152	diff	0–2	original	registered sampler	mixed boundary
B1 fixed-target	LoopMom	stride-2 / flat-short	512	diff	—	—	—	not executed; claim scoped
E9 extension	natural video	post-freeze extension	—	—	—	—	—	skipped; no incremental utility

Only executed cells support empirical claims. Dashes and red-tinted rows are structural gaps, not zero effects; no Cartesian completion is implied.

Рисунок В.1 – Виконане експериментальне покриття та структурно відсутні комірки. Рядки з кольоровим тлом позначають невиконані або закриті розширення, а не нульові ефекти. Схема є візуальним індексом реєстру, а не окремим емпіричним результатом. *Джерело: побудовано автором за реєстром виконаних конфігурацій і заморожених доказів.*

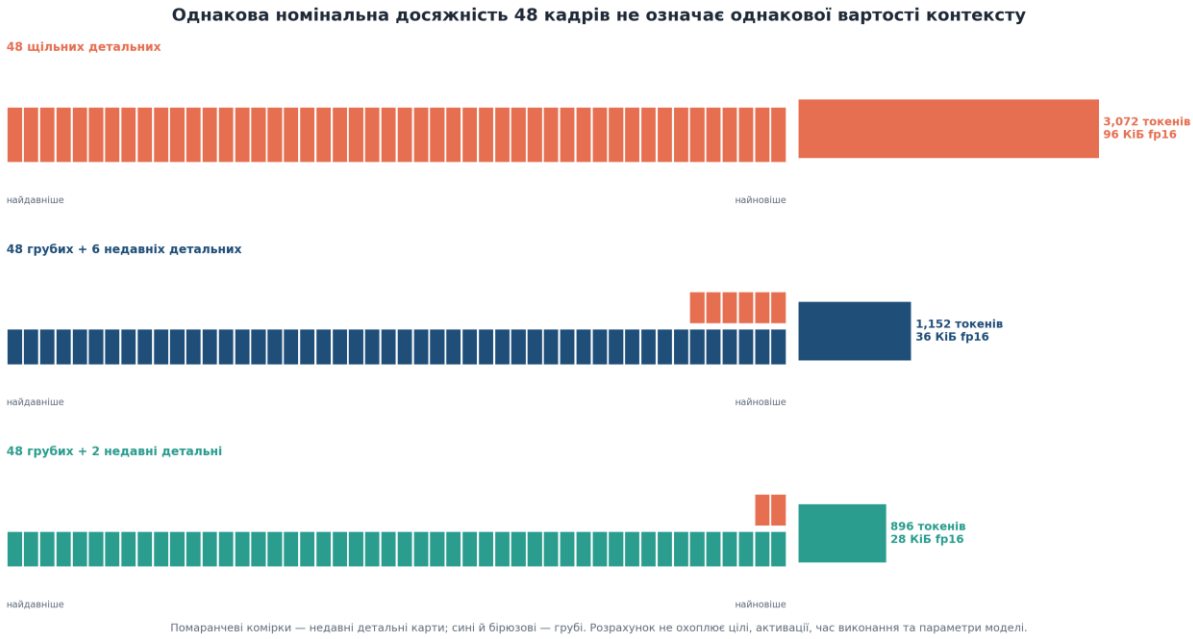


Рисунок В.2 – Розподіл контекстного бюджету за однакової номінальної досяжності 48 кадрів. Помаранчеві комірки позначають детальні карти, сині й бірюзові – грубі; праві смуги показують точну кількість токенів і корисний обсяг fp16 без цілей, активацій і параметрів. Рисунок пояснює арифметику таблиці 4.3, але не є вимірюванням повної VRAM. *Джерело: авторська візуалізація за контрактом пакетів.*

Парні ефекти, одночасні інтервали, факторний експеримент «вихідний модуль × пакет», перевірки алгоритму вибірки та кодека, негативна реплікація E5a, еталон E8a й зовнішня межа E6 наведені в розділі 4. Їхні точні артефактні прив’язки подано в додатку Г та розширеному електронному реєстрі.

Додаток Г – Індекс доказів та походження

Таблиця Г.1 пов’язує кожну роль доказу з описом для читача та машиночитаним артефактом або журналом доступу.

Таблиця Г.1 – Зв’язок наукових тверджень із людськими та машиночитаними записами.

Роль доказу	**Запис, зрозумілий для людини**	**Запис, зрозумілий для машини, або запис доступу**
Відкладене підтвердження E2	docs/confirmation/E2_RESULTS.md	artifacts/confirmation_e2/ та його маніфест набору даних
Зареєстрована реплікація E5a	docs/confirmation/E5A_RESULTS.md	artifacts/e5a_trust_replication/results.json та перевірка завершення
Межа об’єктів зі сталою ідентичністю E6	docs/confirmation/E6_PHASEC_V2_RESULTS.md	захищені артефакти результатів E6, зазначені в маніфесті релізу
Робастність кодека E7a	docs/confirmation/E7A_RESULTS.md	маніфест експерименту, перевірка завершення та заморожені артефакти результатів
Робастність алгоритму вибірки/NFE E7c	docs/confirmation/E7C_RESULTS.md	artifacts/e7c_sampler_nfe/results.json, журнал доступу та перевірка завершення
Еталон з явним доступом E8a	docs/confirmation/E8A_RESULTS.md	маніфест експерименту та заморожені еталонні артефакти

Роль доказу	**Запис, зрозумілий для людини**	**Запис, зрозумілий для машини, або запис доступу**
Закриття програми	docs/FINAL_PROGRAMME_REPORT_2026-07-18.md	artifacts/release_manifest_2026-07-19.json та experiments/authorization.json
Перевірки релізу	docs/RELEASE_QA_REPORT_2026-07-18.md	Ревізія вихідного коду та хеші файлів у маніфесті релізу
Калібрування A4-COR	підрозділ 4.1.3 і нижня частина рисунка 4.1	artifacts/dissertation/a4_cor/article4_schedule_calibration_2026-09-01.json (SHA-256 8556E9B07B0E01BB65511F23C075FC96CD5F325483D70F245669B444CF65429B) та два JSONL-журнали з хешами в локальному README.md
Матриця A4	підрозділи 3.6.2–3.6.9 і службовий реєстр внесення результатів	маніфест, конфігурації, контролер, журнал стану й контракт W&B у робочій гілці hierarchical-video-prediction-path-b; результат сімейства вноситься лише після штатного завершального аналізу
Якість інтегрованого прототипу	підрозділ 4.9.1, таблиця 4.16	simvp_packed_pixel_finetune_s0_metrics.json (SHA-256 1C36D65632FA46AF0202F080D72CB486D1C0384B426BE0A845E683F6F44E8E8C), fixed_region_adapter_blended_mmnist_s0_metrics.json (SHA-256 AC9BF2BAA404A023C060434A4C17B99B47F14C9CD7270655DF4062E1A0A3A294) і openstl_baseline_comparison.json (SHA-256 96E3E6672E9D85A1657DB844175D6426D16EE419CE5F3BA85AD6677DE6C8AB9A)
Пам’ять інтегрованого предиктора зі сталими ділянками	підрозділ 4.9.2, таблиці 4.17 і Ж.3	integrated_reversible_openstl_memory.json (SHA-256 FEDD7547A4C79BAC61C2E009EE742E27C5CE5A81A698508AC20042C4061B0AC9), integrated_reversible_openstl_memory_b2.json (SHA-256 F8D6095A4DD70F59B18EC96982BC290030A721C6E4DFBF03C9B34CC7BB7A9997) і наведений вище openstl_baseline_comparison.json; профіль порівнює різну зовнішню динаміку й не є причинним порівнянням тотожної прямої функції
Маніфест інтеграційної перевірки	межа класу технічної здійсненності	integrated_feasibility_manifest_20260823.json (SHA-256 32098422B4383F499A8E9101FFD42872CCAAC44DAFF6227FC2FAFBAAAF0B3CDC)

Роль доказу	Запис, зрозумілий для людини	Запис, зрозумілий для машини, або запис доступу
Інтерфейс адаптивного інтегрованого предиктора	підрозділи 3.7.3–3.7.7, рисунок 3.22 і таблиця 3.4	OpenSTL-integrated/openstl/models/hvp_integrated_model.py, OpenSTL-integrated/tests/test_models/test_hvp_integrated.py та операційний план; паритет на CPU не є доказом CUDA-пам’яті або якості прогнозу

Розробка, відкладене підтвердження, зареєстрована реплікація, робастність, привілейований еталон, зовнішня межа та перевірка технічної здійсненності є різними ролями доказів. Їхні артефакти можуть зберігатися разом, але допустимі межі висновків не об’єднуються. Інтеграційні файли архівовано поза репозитарієм через їхній розмір; наведені назви та хеші є стабільними ідентифікаторами, а не публічними адресами завантаження.

Додаток Д – Договір про статистичну звітність

У кожному парному аналізі одиницею повторної вибірки залишається кліп. Мінімальний звіт для статистичного контрасту містить кандидата й базову порівнювану конфігурацію, допустиму інтерпретацію порівняння, фільтр популяції, кількість кліпів і записів, показник та сприятливий напрям, точкову оцінку, тип інтервалу, зареєстроване сімейство, ініціалізацію навчання, конфігурацію алгоритму вибірки, ідентифікатор кодека й підсумкове рішення. Статистичне виведення враховує кластеризацію за кліпами. Правила для порожніх масок і знаменники зіставлення змінюються разом із визначенням показника. Повні інтервали двох програм робастності зведено в таблиці Д.1.

Таблиця Д.1 – Повні одночасні інтервали для втручань в алгоритм вибірки та кодек. Позитивний ефект свідчить на користь зареєстрованого кандидата; для контрасту 2 432 кандидатом є плоский контекст.

Втручання	Досяжність 896	Внутрішній ефект 1 152	Часовий 1 088 проти просторового 1 152	Плоска інверсія 2 432	Статус
DDIM NFE 8, ініціалізація вибірки 0	+0,0478 [0,0323; 0,0634]	+0,0152 [0,0045; 0,0259]	+0,0276 [0,0171; 0,0381]	+0,0115 [0,0016; 0,0214]	усі визначені
DDIM NFE 16, ініціалізація вибірки 0	+0,0465 [0,0310; 0,0621]	+0,0146 [0,0041; 0,0251]	+0,0283 [0,0172; 0,0394]	+0,0117 [0,0018; 0,0217]	усі визначені

Втручання	**Досяжність 896**	**Внутрішній ефект 1 152**	**Часовий 1 088 проти просторового 1 152**	**Плоска інверсія 2 432**	**Статус**
DDIM NFE 32, ініціалізація вибірки 0	+0,0471 [0,0317; 0,0625]	+0,0140 [0,0036; 0,0245]	+0,0292 [0,0182; 0,0403]	+0,0122 [0,0022; 0,0221]	усі визначені
DDIM NFE 16, ініціалізація вибірки 1	+0,0482 [0,0325; 0,0638]	+0,0201 [0,0086; 0,0315]	+0,0251 [0,0160; 0,0342]	+0,0098 [−0,0001; 0,0196]	верхній ефект невизначений
DDIM NFE 16, ініціалізація вибірки 2	+0,0466 [0,0314; 0,0618]	+0,0200 [0,0087; 0,0313]	+0,0221 [0,0133; 0,0309]	+0,0077 [−0,0013; 0,0167]	верхній ефект невизначений
Оригінальний кодек на E7a	+0,0494 [0,0339; 0,0649]	+0,0283 [0,0169; 0,0397]	+0,0253 [0,0163; 0,0343]	+0,0150 [0,0065; 0,0235]	усі визначені
Незалежно навчений кодек	+0,0521 [0,0374; 0,0669]	+0,0439 [0,0310; 0,0569]	+0,0112 [0,0039; 0,0184]	+0,0079 [−0,0006; 0,0165]	верхній ефект невизначений

Таблиця Д.2 – Повний реєстр метрик, популяцій та чутливості до помилок. Стрілка показує сприятливий напрям; порожні випадки є частиною контракту показника, а не редакційними винятками.

Метрика	**Популяція оцінювання**	**Напрям**	**Правило порожнього випадку**	**Основна виявлена помилка**	**Основне обмеження**
MSE для повного кадру	кожен декодований кадр	↓	завжди визначено	глобальна похибка пікселів	фон може домінувати
MSE еталонного переднього плану	непусте G_τ	↓	невизначено для порожнього еталона	пропущений або спотворений вміст цілі	ігнорує помилковий передній план в інших місцях
MSE фону відносно еталона	кожен кадр	↓	нуль лише за порожнього знаменника	галюцинації поза еталонним просторовим покриттям	може недооцінювати неправильно локалізований передній план
MSE на об’єднанні масок	кожен кадр	↓	нуль лише за порожнього об’єднання	пропуски та надлишки в спільній області	залежить від порога
Прецизійність / повнота / F1 переднього плану	кожен кадр із явними ознакам и маски	↑	1 для порожнього відповідного класу; F1 = 0 за нульової суми складників	хибні спрацьовування / пропуски / баланс	піксельне перекриття не встановлює ідентичності об’єкта

Метрика	Популяція оцінювання	Напрям	Правило порожнього випадку	Основна виявлена помилка	Основне обмеження
Енергія маскованого лапласіана	непорожній еталонний передній план	↑, інтерпретується відносно еталону кодека	не визначено для порожнього еталона	розмиття або злиття	може винагороджувати високочастотні артефакти
Кількість компонентів GT / передбачених	кожен кадр	рівність	нуль є допустимим	виживання об’єктів та галюцинації	зв’язані компоненти можуть розділятися або зливатися
Пропущені / зайві компоненти	кожен кадр	↓	явні підрахунки	пропуски / хибні об’єкти	відсутність сталої ідентичності в часі
IoU зіставлених компонентів	прийняті пари	↑	діагностичний показник за відсутності пар	форма та перекриття	вибір на основі виживання, якщо не показано покриття
Відстань до центроїда зіставлених об’єктів	прийняті пари	↓	діагностичний показник за відсутності пар	локалізація	вибір на основі виживання, якщо пропуски не караються
Покриття об’єкта	видимі еталонні об’єкти	↑	дорівнює одиниці, якщо еталонного об’єкта немає	виживання виявлення	не дає інформації про ідентичність класу
Ідентичність із штрафом за пропуск	видимі марковані еталонні об’єкти	↑	невизначена, коли немає видимих об’єктів	ідентичність об’єктів, що зберігаються в часі, з урахуванням пропусків	залежить від класифікатора та зіставлення
Похибка траєкторії зі штрафом за пропуск	видимі еталонні об’єкти	↓	нуль, коли еталонних об’єктів немає	локалізація та пропущені об’єкти	штраф за пропуск, рівний діагоналі кадру, визначається завданням

Таблиця Д.3 – Точні результати перевіреної межі на відкладених даних. Додатна різниця втрат «плоский мінус ієрархічний» свідчить на користь ієрархії; усі інтервали належать до одного зареєстрованого одночасного сімейства.

Бюджет	**Плоский / ієрархічний пакет, досяжність**	**Ініціалізація й режим**	**Ефект [одночасний 95 % ДІ]**	**Рішення**
480 / 512	flat-short 8 / hier-short 6	0, B16×30k	−0,0038 [−0,0081; +0,0005]	невизначене майже зіставлене порівняння
480 / 512	flat-short 8 / hier-short 6	1, B16×30k	−0,0060 [−0,0105; −0,0015]	плоский пакет; майже зіставлене порівняння
896	flat-min 14 / hier-min 48	0, B16×30k	+0,0474 [+0,0305; +0,0642]	ієрархію підтверджено
896	flat-min 14 / hier-min 48	1, B16×30k	+0,0436 [+0,0280; +0,0592]	ієрархію підтверджено
1 152	flat-budget 18 / hier-long 48	0, B16×30k	+0,0195 [+0,0070; +0,0320]	ієрархію підтверджено
1 152	flat-budget 18 / hier-long 48	1, B16×30k	+0,0389 [+0,0228; +0,0549]	ієрархію підтверджено
1 152	flat-budget 18 / hier-long 48	2, B16×30k	+0,0307 [+0,0159; +0,0455]	ієрархію підтверджено
1 792	flat-c1 28 / hier-c1 48	0, B16×30k	+0,0084 [−0,0013; +0,0181]	невизначено
2 432	flat-c2 38 / hier-c2 48	0, B16×30k	−0,0150 [−0,0260; −0,0039]	плоский пакет підтверджено
2 432	flat-c2 38 / hier-c2 48	0, B8×60k	−0,0122 [−0,0213; −0,0032]	плоский пакет підтверджено
3 072	flat-long 48 / hier-rich 48	0, B8×60k	−0,0129 [−0,0217; −0,0041]	плоский пакет підтверджено
3 072	flat-long 48 / hier-rich 48	1, B8×60k	−0,0134 [−0,0215; −0,0053]	плоский пакет підтверджено

Додаток Е – Додатковий метод та матеріал щодо негативних результатів

Для повного інституційного додатка або додаткових матеріалів статті доступні такі матеріали. Розширені результати вибору вихідного механізму наведено в таблиці Е.1.

Таблиця Е.1 – Розширені результати вибору механізму генерації. Рядки чутливості до NFE походять із меншого замороженого набору й не об’єднуються з основною оцінюваною вибіркою.

Режим	Регресія	Дифузія	Незмінне продовження або 95 % ДІ
Один крок, найкращий із 8, MSE переднього плану	0,0664	**0,0512**	0,2367
Проста підмножина	0,0232	**0,0120**	–
Складна підмножина нових смуг	0,1808	**0,1549**	–
Середнє за 8 кандидатами	0,0714	**0,0640**	–
Різкість переднього плану	0,1591	**0,1886**	0,0515
Найкращий із 8, 4 NFE	0,0680	**0,0546**	–
Найкращий із 8, 8 NFE	0,0680	**0,0514**	–
Найкращий із 8, 16 NFE	0,0680	**0,0503**	–
Самоподача, один кандидат, ієрархічний пакет	**0,1682**	0,1848	[0,0110; 0,0227] для «дифузія мінус регресія»
Самоподача, один кандидат, плоский пакет	**0,2015**	0,2038	–

Повні якісні монтажі збережено в додатку, щоб у головному тексті не переривати аргументацію великими багаторядковими зображеннями. Їхній порядок визначено індексами записів до перегляду результатів; вони є ілюстративними, а не статистичними доказами.

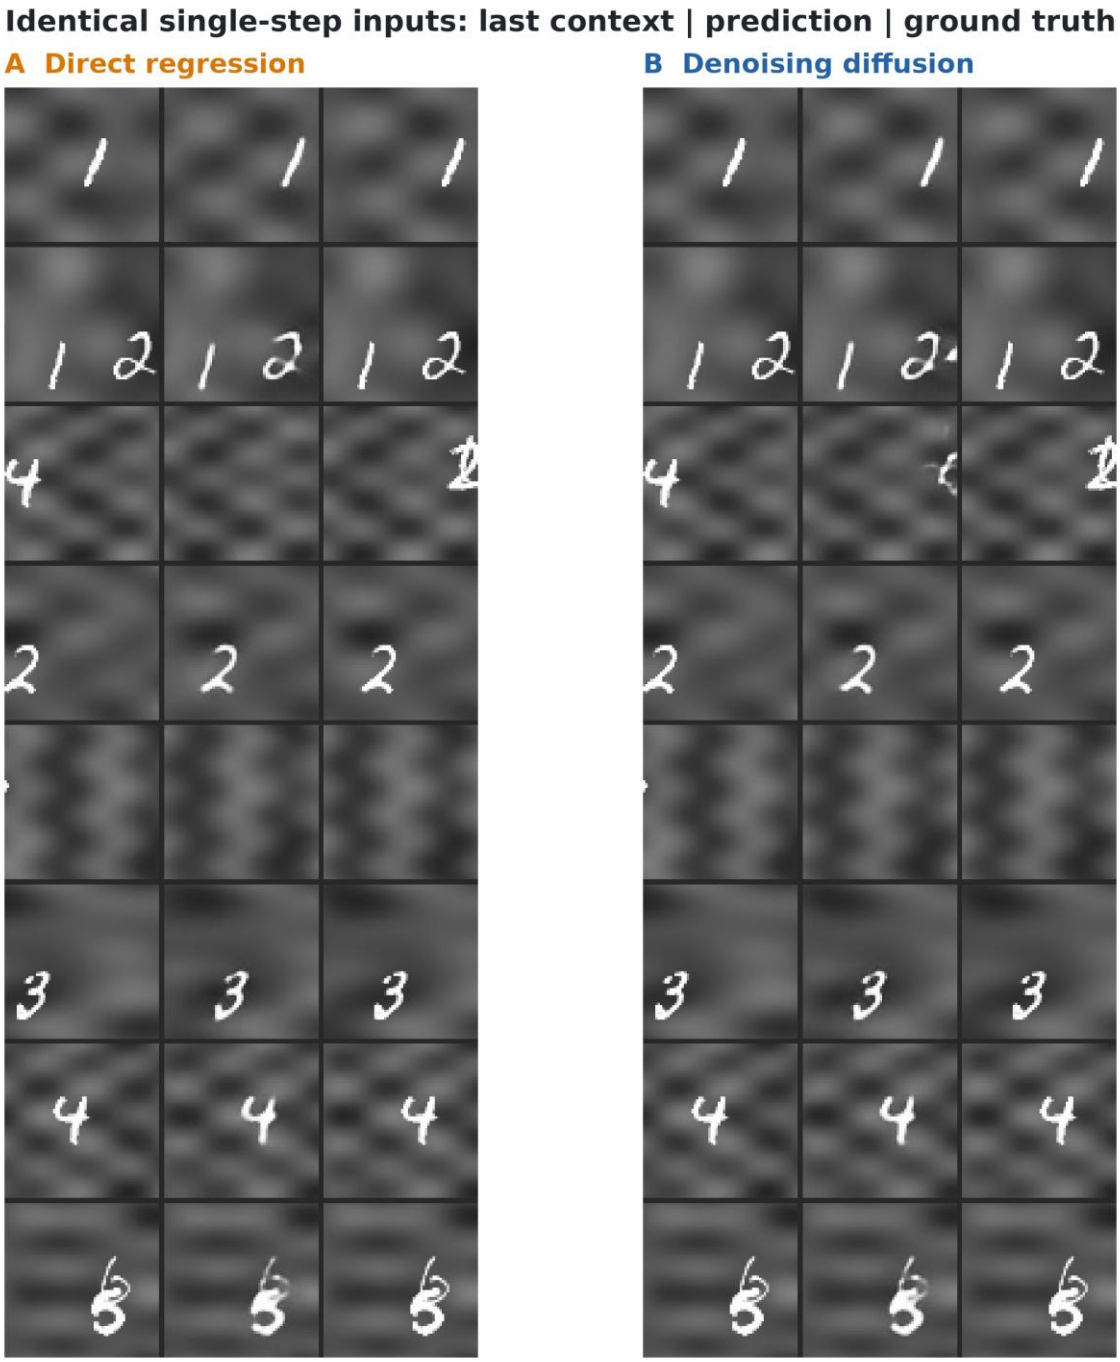


Рисунок Е.1 – Повний монтаж однокрокових прогнозів регресії та дифузії. Ліва й права панелі відповідають регресії та дифузії. У кожному рядку стовпці містять останній кадр контексту, прогноз і еталон; рядки йдуть у зафіксованому порядку оцінюваних записів. Монтаж має пояснювальне значення, тоді як вибір механізму спирається на агреговані показники таблиці 4.1. *Джерело: заморожені однокрокові результати дослідження механізмів генерації.*

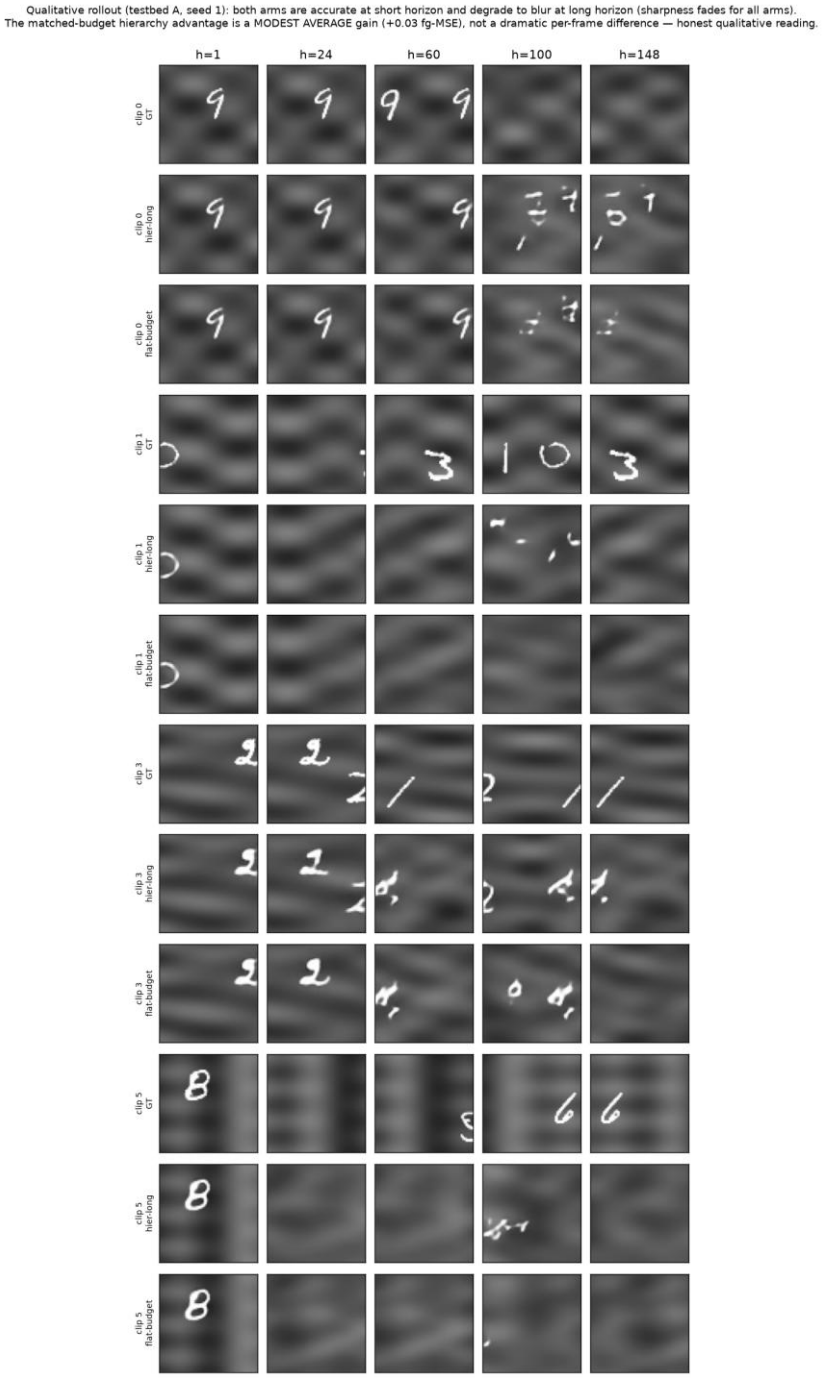


Рисунок Е.2 – Повний монтаж розгорток для чотирьох фіксованих кліпів. Для кожного кліпу три послідовні рядки містять еталон, hier-long і flat-budget; стовпці відповідають горизонтам 1, 24, 60, 100 і 148 кадрів. Використано кліпи з індексами 0, 1, 3 і 5 та ініціалізацію навчання 1; це фіксована підвибірка, а не добір найкращих чи найгірших прикладів. Монтаж показує характер помилок, але не замінює одночасних інтервалів таблиці Д.3. *Джерело: заморожені розгортки Е2.*

- шість детальних таблиць метрик контрольованого обертання та чотири незмінені галереї TempVerseFormer зі змінним рухом;
- перевірений контракт реверсивного стану, допуск числової реконструкції, тести відповідності градієнтів, метадані стохастичного відтворення та розмежування виміряних і екстрапольованих точок пам’яті;

- точний тензор V-BLT, маска, RoPE-ND, агрегація за ентропійними каналами, опублікована таблиця та квитанції аудиту конфігурації джерела;
- повні журнали впорядкування та спуску трансформера на основі енергії, включаючи виправлену діаграму оновлення станів-кандидатів;
- таблиці вторинного алгоритму вибірки, кодека, переднього плану, компонентів та кінцевих точок доступу до необроблених даних;
- додаткові якісні послідовності, обрані за фіксованими індексами або за заявленим правилом агрегату-квантиля;
- діагностики відхиленої жорсткої маршрутизації routing_*: варіанти uniform, recent2 і recent4, селектори на основі випадкового вибору, руху, дисперсії, ентропії та їх комбінацій, а також результати LoopMom і Moving-MNIST; вони показують здатність знаходити передній план, але не підтверджують скорочення фактичного буфера стану;
- негативні та проміжні адаптери переходу smoke_*, probe_* і ранні контрольні точки фіксованих ділянок, які не використовуються для вибору підсумкової моделі;
- перший стохастичний профіль memory_profile_20260823.json, який не є обов'язковим доказом через невідтворену недетермінованість; основний текст використовує лише детерміновані профілі з явною перевіркою втрат і градієнтів.

Додаток Ж – Програмне забезпечення та карта відтворення

Публічний простір імен hvp визначає стабільні інтерфейси контексту, оцінювання, походження та валідації. Заморожений простір імен hvp_rev зберігає реалізації, що породили докази, та шляхи сумісності. Каталог experiments/ містить конфігурації авторизації й наукових досліджень, artifacts/ – незмінні докази, scripts/ – контрольовані засоби запуску та генератори рисунків і таблиць. Джерелом істини є локальні артефакти, а не служба відстеження експериментів.

Три публічні репозиторії зберігають шляхи відтворення за попередніми методами; їхні ролі наведено в таблиці Ж.1.

Таблиця Ж.1 – Публічні репозиторії попередніх методів і даних.

Компонент	Публічне джерело	Роль у відтворенні
Процедурні дані обертання у 2D/3D	simple-shape-dataset-toolbox [171]	генератори, метадані та створення наборів даних із командного рядка
Реверсивне часове моделювання	TempVerseFormer [172]	код моделі, конфігурації навчання/оцінювання/тестування пам'яті, контрольні точки та посилання на експерименти
Візуальне моделювання на рівні байтів	visionBLT [173]	реалізація V-BLT та інтерфейс конфігурації виконуваних експериментів

Доступність репозиторію та історична ідентичність фіксуються окремо. Новий запуск є відтворюваним, якщо зафіксовано коміт, середовище, маніфест даних, конфігурацію, ініціалізації та хеші контрольних точок. Цей запуск не обов'язково має бути описаний як байтово ідентичний опублікованому запуску, точний історичний маніфест якого не був заархівований. Таке розмежування захищає опублікований маніфест, водночас надаючи конкретний шлях для незалежного виконання.

Інтеграційне розширення належить до поточного дослідницького стану, а не до замороженого релізу 0.3.0. Його компоненти й перевірки наведено в таблиці Ж.2.

Таблиця Ж.2 – Програмні компоненти інтеграційного розширення та їх перевірки.

Програмний компонент	Файл	Перевірка
пакування фіксованих грубих і детальних ділянок предиктора зі сталими ділянками	hvp_rev/fixed_region_revformer.py	tests/test_fixed_region_revformer.py
адаптація упакованого стану предиктора зі сталими ділянками для SimVP	hvp_rev/packed_simvp.py	tests/test_packed_simvp.py
реверсивне відтворення часових переходів предиктора зі сталими ділянками	hvp_rev/reversible_rollout.py	tests/test_reversible_rollout.py
навчання та профілювання предиктора зі сталими ділянками	scripts/train_fixed_region_adapter.py, scripts/run_fixed_region_revformer.py, scripts/profile_fixed_region_memory.py	короткі перевірки та повний CPU-набір попередньої робочої гілки

Програмний компонент	Файл	Перевірка
фізична піраміда, пакувальник, розподільник, координати, реверсивне ядро й декодер моделі з адаптивним пакуванням	OpenSTL-integrated/openstl/models/hvp_integrated_model.py	OpenSTL-integrated/tests/test_models/test_hvp_integrated.py
контракти даних і конфігурації моделі з адаптивним пакуванням	OpenSTL-integrated/configs/mmnist/HVPIntegrated.py, OpenSTL-integrated/configs/taxibj/HVPIntegrated.py	OpenSTL-integrated/tests/test_hvp_data_contracts.py
контролер і виконавець інтегрованої кампанії	hierarchical-video-prediction-integration/scripts/v2/run_integrated_openstl_campaign.py, hierarchical-video-prediction-integration/scripts/v2/train_integrated_openstl.py	hierarchical-video-prediction-integration/tests/test_integrated_openstl_worker.py, hierarchical-video-prediction-integration/tests/test_integrated_campaign_controller.py

Зовнішній профіль пам’яті предиктора зі сталими ділянками подано окремо в таблиці Ж.3, оскільки горизонти моделей не всюди збігаються. Він надає масштаб витрат. Перші два рядки мають спільні компоненти й початковий стан, однак після першого кроку застосовують різну зовнішню динаміку, тому навіть їх дозволено тлумачити лише як інженерне, а не причинне порівняння.

Таблиця Ж.3 – Описове порівняння пікової додаткової пам’яті предиктора зі сталими ділянками з моделями OpenSTL. Усі значення виміряно локально з розміром мініпакета 2 на одному GPU без градієнтних контрольних точок. Реверсивний і BPTT-режими відрізняються зовнішньою динамікою після першого кроку, тому відношення їхніх піків не ізолює причинний ефект реверсивності.

Модель	Оброблений або прогнозований горизонт	Пам’ять, МБ	Статус
Інтегрована, реверсивна	20 прогнозованих кадрів	904,77	попередня другопорядкова динаміка
Та сама модель, BPTT	20 прогнозованих кадрів	1 416,53	інша зовнішня динаміка; не причинний контроль
OpenSTL E3D-LSTM	20 кадрів послідовності	2 821,32	описовий зовнішній базис
OpenSTL ConvLSTM	20 кадрів послідовності	**198,65**	описовий зовнішній базис
OpenSTL SimVP-IncepU	10 прогнозованих кадрів	453,06	інший горизонт
OpenSTL SimVP-gSTA	10 прогнозованих кадрів	616,40	інший горизонт

У релізі 0.3.0 було 83 успішні CPU-тести. Після додавання модулів предиктора зі сталими ділянками відповідна робоча гілка проходила 99 тестів; це число не змінює історичного запису релізу. Остаточний OpenSTL-інтерфейс окремо пройшов 20 CPU-тестів моделі й контрактів даних, а його контролер — 5 CPU-тестів відновлення та виконання. Ці перевірки встановлюють програмну коректність і паритет форм, але не замінюють майбутні вимірювання CUDA-пам’яті та якості прогнозу.

Додаток И – Походження та дозволи щодо рисунків

Машиночитані записи про ілюстрації розподілені між реєстром вилучення та генерації розділу 1, реєстром вилучення та генерації розділів 2–4, реєстром наявних ілюстрацій із репозиторію та реєстром нових інтеграційних рисунків. Кожна повторно використана опублікована ілюстрація додатково містить запис про джерельну статтю, оригінальний номер ілюстрації та сторінку, метод вилучення, хеш SHA-256, розміри в пікселях, статус модифікації, атрибуцію підпису та статус дозволу. Вилучена панель джерела зберігає опублікований вигляд. Розташування, навколишні пробіли та підпис дисертації можуть змінюватися; написи, зміст та доказове значення – ні.

Рисунки 3.20, 3.21, 3.22 і 4.15, а також нижню частину рисунка 4.1 створено автором для пояснення інтеграційних інтерфейсів й калібрування A4. Рисунки 3.20–3.22 відтворюють специфікації інтерфейсів та архітектури з адаптивним пакуванням, рисунок 4.15 побудовано з integrated_reversible_openstl_memory.json, а графік калібрування — з артефактів A4-COR. Вони мають біле тло й не змінюють жодної опублікованої ілюстрації TempVerseFormer.

Додаток И – Покриття експериментальних питань

Реєстр пов’язує методику з місцем результату. Повні комбінації умов та їхній статус збережено у docs/reviews/hierarchy_integration_2026-09-06/experiment_evidence_inventory.json. «Очікується» означає відсутність перевіреного вимірювання; умовні досліди не є обіцянкою запуску. Одне

навчання може обслуговувати кілька ролей, тому кількість комірок не дорівнює кількості незалежних моделей.

Таблиця И.1 – Реєстр покриття експериментальних питань. Основні таблиці компактні; цей реєстр визначає повні виміри для заповнення й не додає навчальних запусків.

Питання	Методика / результат	Таблиця	Статус
FRT	3.6.3 / 4.8.1	4.6	перевірено
ALC	3.6.3 / 4.8.1	4.7	перевірено
CEX	3.6.4 / 4.8.2	4.8	перевірено
STS	3.6.4 / 4.8.2	4.9	перевірено
LVL	3.6.5 / 4.8.3	4.10	перевірено
OVR	3.6.5 / 4.8.3	4.11	перевірено
CONF	3.6.6 / 4.8.4	4.12	перевірено
MECH	3.6.6 / 4.8.4	4.14	перевірено
VAL300	3.6.6 / 4.8.4	4.13	перевірено
ROLL64	3.6.6 / 4.8.4	4.15	умовний дослід
PARITY	3.7.7 / 4.9.4	4.18	перевірено
RESOURCE	3.7.7 / 4.9.4	4.19	повна модель: перевірено; операції ядра: очікується
SCREEN	3.7.7 / 4.9.5	4.20	перевірено
QUALITY	3.7.7 / 4.9.5	4.21	перевірено
COMP	3.7.7 / 4.9.5	4.22	умовний дослід

Ресурсний реєстр охоплює обидві задачі, три способи пакування, три режими ядра, FP32 і точність навчання, застосування й навчальний крок, повну модель та операції ядра. Кожний запис передбачає allocated/reserved baseline і peak у байтах, додатковий пік, типи тензорів, унікальні сховища, saved tensors, параметри/градієнти/стан оптимізатора та час повторів. Непідтримувана точність позначається незастосовною з причиною, а не нульовою витратою.

Криві на рисунку И.1 доповнюють підсумкові оцінки таблиці 4.21: вони показують перебіг оптимізації та зміну похибки в межах прямого прогнозу. Кожна лінія відповідає окремій ініціалізації, без усереднення між навчаннями.

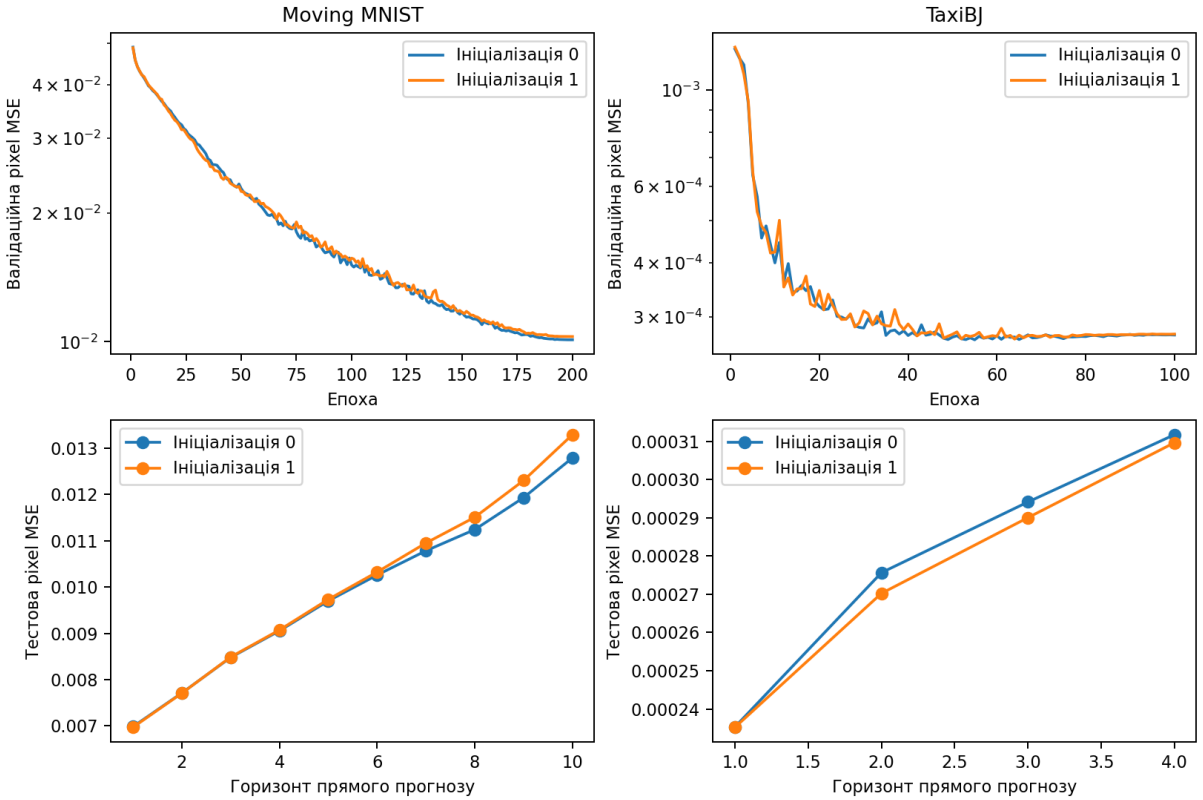


Рисунок И.1 – Валідаційні траєкторії та похибка за горизонтом. Угорі — валідаційна піксельна MSE за епохами, логарифмічна вісь ординат; унизу — тестова піксельна MSE за горизонтом прямого прогнозу для вибраних контрольних точок. Moving MNIST та TaxiBJ мають окремі шкали; зображення не є зіставленням складності задач.